

基于 HJ-1 影像和环境变量的叶绿素 *a* 浓度反演 ——以深圳海域为例

吴健生^{1,2}, 王 伟¹

(1. 北京大学 深圳研究生院 城市规划与设计学院 城市人居环境科学与技术重点实验室, 深圳 518055;
2. 北京大学 城市与环境学院 资源与环境地理系 地表过程与模拟教育部重点实验室, 北京 100871)

摘 要: 叶绿素 *a* 的浓度能够表征海域富营养化状况, 是反映海洋环境状态的一个重要指标。本研究以深圳海域为研究区, 基于环境一号卫星遥感影像和实测叶绿素 *a* 浓度数据, 将陆源入海排污口的核密度、距港口航道的距离和距海水增殖养殖区的距离作为环境变量, 在 Matlab 平台中分别构建了基于环境一号卫星四个波段反射率为输入参数的误差逆向传播神经网络模型, 及在此基础上引入了环境变量的误差逆向传播神经网络模型, 以检验环境变量的引入能否提高叶绿素 *a* 浓度的反演精度, 并对其输入参数进行敏感性分析。结果表明: (1) 环境变量的引入能较大地提高误差逆向传播神经网络模型的反演精度, 且引入环境变量的误差逆向传播神经网络模型的训练均方误差和验证均方误差分别为 4.71 $\mu\text{g/L}$ 和 3.50 $\mu\text{g/L}$, 均优于原始误差逆向传播模型的 10.98 $\mu\text{g/L}$ 和 12.61 $\mu\text{g/L}$; (2) 引入环境变量的误差逆向传播模型的框架如下: 输入层为 7 个变量, 分别为蓝光波段反射率、绿光波段反射率、红光波段反射率和近红外波段反射率、陆源入海排污口的核密度、距港口航道的距离和距海水增殖养殖区的距离; 隐含层节点数为 5 个; 输出层为叶绿素 *a* 的浓度; (3) 叶绿素 *a* 的浓度对陆源入海排污口的核密度的变化最敏感, 其次分别是近红外波段反射率、红光波段反射率、距港口航道距离、蓝光波段反射率、绿光波段反射率和距海水增殖养殖区的距离。

关键词: 叶绿素 *a*; 环境变量; HJ-1 数据; BP 神经网络模型; 敏感性分析

中图分类号: X87

文献标识码: A

文章编号: 1007-6336(2018)03-0424-08

DOI:10.13634/j.cnki.mes.2018.03.017

Retrieval of chlorophyll *a* concentration based on HJ-1 data and environmental variables: a case study of marine areas in Shenzhen

WU Jian-sheng^{1,2}, WANG Wei¹

(1. Key Laboratory of Urban Habitatant Environment Science and Technology, School of Urban Planning and Design, Shenzhen Graduate School, Peking University, Shenzhen 518055, China; 2. Laboratory of Earth Surface Processes of Ministry of Education, College of Urban and Environmental Sciences, Peking University, Beijing 100871, China)

Abstract: The concentration of chlorophyll *a* (Chl *a*) is an important indicator of eutrophication in coastal marine environments. This research retrieved the Chl *a* concentration of marine areas in Shenzhen using environmental variables such as the kernel density of land-based pollution outfall, distance to the harbor approach, and the distance to marine aquaculture zones. The environmental in situ data was then combined with HJ-1 multispectral data to derive two back-propagation (BP) neural-network models using Matlab. The BP neural-network models of this study were used to test whether the introduction of environmental variables could improve the accuracy of Chl *a* concentration estimates ob-

收稿日期: 2016-12-19, 修订日期: 2017-05-10

基金项目: 国家自然科学基金项目(41330747)

作者简介: 吴健生(1965-), 男, 湖南新化人, 博士生导师, 研究方向为遥感、景观生态与土地利用, E-mail: wujsh@pku.edu.cn

tained with BP neural networks. In addition, the sensitivity of input parameters was analyzed. Results showed that: (1) The introduction of environmental variables could greatly improve the retrieval accuracy of a BP neural-network. The retrievable accuracy of the BP neural-network model modified with environmental variables was better than that of the original BP neural-network model. The *MSEs* (mean squared errors) of training and verification of the BP neural-network model with environmental variables were 4.71 $\mu\text{g/L}$ and 3.50 $\mu\text{g/L}$, respectively. The original BP neural-network model had *MSEs* of training and verification of 10.98 $\mu\text{g/L}$ and 12.61 $\mu\text{g/L}$, respectively. (2) The approach of using a BP neural-network model with environmental variables was investigated further. The input layer had seven variables including blue reflectance, green reflectance, red reflectance, near-infrared reflectance, the kernel density of land-based pollution outfall, distance to the harbor approach, and the distance to marine aquaculture zones. The hidden layer had five nodes. The output layer was the Chl *a* concentration. (3) The Chl *a* concentration was most sensitive to the kernel density of land-based pollution outfall, followed sequentially by the near-infrared reflectance, red reflectance, distance to the harbor approach, blue reflectance, green reflectance, and the distance to marine aquaculture zones.

Key words: chlorophyll *a*; environmental variables; HJ-1 data; BP neural-network model; sensitivity analysis

随着经济的高速发展,深圳海域环境质量普遍下降,已成为我国典型的赤潮高发区。浮游植物色素指标——叶绿素 *a* 的浓度可以表征藻类现存量^[1],能够反映富营养化对人类生活的影响,常作为海洋生态系统富营养化研究中不可或缺的指标^[2]。因此,对其进行反演有利于了解研究区叶绿素 *a* 的浓度变化,有利于实时动态监测研究海域的营养化状况,为海洋环境保护政策制定提供一定理论基础。

多数研究基于 Landsat 和中分辨率成像光谱仪 (moderate-resolution imaging spectroradiometer, 下文简称: MODIS) 遥感数据来反演叶绿素 *a* 的浓度^[3-4],但 Landsat 的时间分辨率较为粗糙,难以监测短时间内叶绿素 *a* 浓度的变化,加之深圳天气多变,获取到理想的与现场实测数据同步的遥感数据较为困难; MODIS 的空间分辨率较低,难以应用于小范围海域的研究。而环境一号 (HJ-1) 卫星同时具备较高的时间分辨率 (2 d 的重访周期) 和较高的空间分辨率 (30 m 分辨率),能够弥补上述两种遥感数据的不足。因此,采用 HJ-1 卫星遥感数据在深圳海域开展叶绿素 *a* 反演的研究,能在一定程度上降低因数据局限性而产生的反演误差。

误差逆向传播 (back-propagation, 下文简称: BP) 神经网络方法在预测近海叶绿素 *a* 浓度的领域中已经得到相对广泛和成熟的运用^[5]。大多数学者采用不同波段反射率^[6]或水温、营养盐和透明度等微观层面上的理化因子^[7-9]作为 BP 神经网络的输入层参数,但少有研究考虑宏观层面

上的环境变量。由于陆源污染通过生活污水和工业污水排放等方式对海水水质产生影响^[10];港口建设和维护作业中产生的废弃物也会直接或间接影响海水水质^[11];水产养殖业中的大量残饵成为“肥水”,产生有机污染,进而危害海洋环境^[12]。因此,本研究拟以深圳海域为研究区,利用 HJ-1 卫星实测数据,将陆源入海排污口的核密度、距港口航道的距离和距海水增养殖区的距离作为环境变量,通过对比有、无环境变量的 BP 神经网络模型的反演结果,探究环境变量的引入能否提高 BP 神经网络模型反演深圳海域叶绿素 *a* 浓度的精度,并对模型的输入参数 (蓝光波段反射率、绿光波段反射率、红光波段反射率、近红外波段反射率、陆源入海排污口的核密度、距港口航道的距离和距海水增养殖区的距离) 进行敏感性分析。

1 材料与方法

1.1 研究区概况

深圳市位于珠江三角洲的东南沿海,陆域面积 2020 km^2 ,海域面积 1145 km^2 ^[13]。深圳海域渔业资源丰富,滨海旅游业和港口资源发达,海洋产业发展前景广阔^[14]。整个海域分为东西两部分,东部海域包括大亚湾和大鹏湾;西部海域包括深圳湾和珠江口。参照《2015 年深圳市近岸海域环境状况》中的深圳海域范围^[15],利用 Arc GIS 10.2 中的影像配准和矢量化工具得到本文的研究范围,同时叠加叶绿素 *a* 浓度测量点的空间分布,得到图 1。

1.2 数据及其预处理

本研究采用 2009 ~ 2012 年的现场实测数据




图 1 研究区及其测量点分布

Fig. 1 Study area and the distribution of measuring points 及其对应的 HJ-1 卫星遥感数据(表 1)。其中,遥感数据来自中国资源卫星应用中心(<http://www.cresda.com/CN/>),采用 HJ-1 卫星 CCD(charge-coupled device)数据,包含蓝光波段、绿光波段、

红光波段和近红外波段,空间分辨率为 30 m;叶绿素 a 浓度的现场实测数据来自深圳市规划国土委,采用美国 YSI 公司生产的 YSI6600-V2 型多参数水质监测仪现场测量获取叶绿素 a 浓度(该监测仪测量叶绿素 a 浓度的传感器属于光学传感器,测量范围为 0 ~ 400 $\mu\text{g/L}$)。叶绿素 a 浓度数据的实测时段均为 9:30 ~ 16:30,同时,为减小外界偶然因素带来的误差,每个测量点连续监测 1 min,每间隔 20 s 读取一次数据,取 3 次叶绿素 a 浓度值的平均值作为该点的实测叶绿素 a 浓度值。从表 1 可以看出 HJ-1 卫星遥感数据的采集时间段约为 10:30 ~ 11:30,但由于现场测量点位较多而人力物力又有限,使得现场测量时间段较长,为 9:30 ~ 16:30。

表 1 过境卫星时间以及现场测量时间

Tab. 1 Satellite and in-situ data measuring information

日期	卫星过境时间	地面测量时间	日期	卫星过境时间	地面测量时间
2009-04-20	11:04	9:30 ~ 16:30	2011-08-31	10:48	9:30 ~ 16:30
2009-06-17	10:58	9:30 ~ 16:30	2012-06-05	10:41	9:30 ~ 16:30
2009-07-21	11:22	9:30 ~ 16:30	2012-08-08	10:42	9:30 ~ 16:30
2010-08-10	11:06	9:30 ~ 16:30	2012-10-09	10:39	9:30 ~ 16:30
2010-10-18	11:19	9:30 ~ 16:30	2012-10-15	10:45	9:30 ~ 16:30
2010-11-02	11:03	9:30 ~ 16:30	2012-10-22	10:31	9:30 ~ 16:30
2011-04-27	10:53	9:30 ~ 16:30	2012-10-24	10:37	9:30 ~ 16:30
2011-08-29	10:48	9:30 ~ 16:30			

首先,利用 ENVI 5.1 软件对 HJ-1 卫星遥感数据进行几何校正、辐射定标、大气校正、镶嵌和裁剪等处理;然后,通过 Arc GIS 10.2 软件,基于测量点位得到本研究的叶绿素 a 浓度值(值域为:0.3 $\mu\text{g/L}$ ~ 22.4 $\mu\text{g/L}$),并提取相应的 HJ-1 卫星遥感数据(蓝光波段反射率、绿光波段反射率、红光波段反射率和近红外波段反射率),对其进行归一化处理,最终得到 86 个可用的样本,随机将其分为两组,一组为原始训练样本(60 个),另一组为原始验证样本(26 个);接着,根据相关文献^[16-17]以及广东省海洋与渔业局等其他相关单位的统计公报^[18],结合 Google Earth,利用 Arc-GIS 10.2 中的影像配准和矢量化工具得到陆源入海排污口、港口航道和海水增殖殖区的分布情况(如图 2、图 3 和图 4 所示),进而通过 Arc GIS 10.2

中的空间分析工具得到陆源入海排污口的核密度、距港口航道的距离和距海水增殖殖区的距离这 3 个环境变量(图 5、图 6 和图 7 所示),并提取与测量点位对应的 3 个环境变量值,对其进行归一化处理;接着,将归一化后的 3 个环境变量值附加至原始训练和验证样本中,得到两组新的训练样本和验证样本(下文简称为:新训练样本,新验证样本);最后,基于以上 4 组样本,分别构建有、无环境变量的 BP 神经网络模型来反演深圳海域的叶绿素 a 浓度,并对比二者的反演精度。

1.3 BP 神经网络模型

BP 神经网络属于多层前馈神经网络,可视为一个从输入到输出的高度非线性映射,由输入层、输出层和一个或者多个隐含层组成,每一层都有若干个神经元,层与层间的神经元通过连接权重

及阈值相连,每层神经元的状态只影响下一层的神经元状态,同层的神经元之间没有联系^[19]。BP神经网络的学习训练过程由正向传播和反向传播组成,在正向传播过程中,信息依次按照输入层、隐含层和输出层的顺序进行传播,如果在输出层中误差值大于设定阈值,就将误差值反向传播回各层,并修改各层的权重和阈值^[20]。如此循环反

复,最终得到期望的输出。其中,隐含层节点个数的选取是构建 BP 神经网络的一个关键步骤,若选取不当,模型有可能出现“过度拟合”或者“过度泛化”问题。然而,理论上目前还没有一种科学和普遍的隐含层节点数确定方法,故本研究根据部分学者给出的相应经验公式来确定隐含层节点数^[21]。



图 2 陆源污染排污口的分布情况

Fig. 2 The distribution of land-based pollution outfall



图 3 港口航道的分布情况

Fig. 3 The distribution of the harbor approach




图 4 海水增殖养殖区的分布情况

Fig. 4 The distribution of marine aquaculture zones




图 5 陆源入海排污口的核密度

Fig. 5 The kernel density of land-based pollution outfall




图 6 距港口航道的距离

Fig. 6 Distance to the harbor approach




图 7 距海水增殖养殖区的距离

Fig. 7 The distance to marine aquaculture zones

1.4 反演叶绿素 a 的 BP 神经网络模型

本研究通过 Matlab R2012a 软件构建两种 BP 神经网络模型,用来反演深圳海域叶绿素 a 的浓度。首先,两种模型的不同之处在于:一种将环境卫星的 4 个波段反射率:蓝光波段反射率(B1)、绿光波段反射率(B2)、红光波段反射率(B3)和近红外波段反射率(B4)作为输入层;另一种在前者的基础上,引入陆源入海排污口的核密度(X1)、距港口航道的距离(X2)和距海水增殖区的距离(X3)等 3 个环境变量共同作为输入层;其次,根据经验公式^[9,21]确定两种模型的隐含层节点数的范围,分别为 2~13 和 3~15;再次,利用相应的样本组分别对两种模型进行调试,并根据均方误差(mean squared error,下文简称: MSE)选出最优隐含层节点数;最后,对二者进行训练和验证,同时对比两种模型反演结果的准确性。

1.5 模型敏感性分析

模型敏感性分析是用于分析模型如何响应输入数据的变化。本研究对引入环境变量的 BP 模型进行敏感性分析,即将新验证样本的输入参数值分别调低或调高 10% 和 20%,并通过引入环境变量的 BP 模型分别得到模型的输出结果(参数值调整后的叶绿素 a 浓度预测值),进而得到叶绿素 a 浓度变化率绝对值的百分比($(|$ 参数值调整后的叶绿素 a 浓度预测值-调整前的叶绿素 a 浓度预测值 $|$ / 调整前的叶绿素 a 浓度预测值) $\times$

100%)。百分比越大,表示该输入参数对模型结果的影响越大。

2 结果与讨论

2.1 确定最优隐含层节点数

由于 BP 神经网络存在一定的随机性,每次训练得到的模型均不相同。为降低随机因素的影响,并得到相对最优的隐含层节点数,本研究分别利用相应的样本组对两种 BP 模型进行 1000 次重复训练与验证,最终得到两种模型的平均均方误差和 MSE 的极差,如表 2 和表 3 所示。

根据原始 BP 模型的均方误差(表 2),当隐含层节点数为 8 个时,原始 BP 模型的训练结果的平均 MSE 最小,为 4.98 $\mu\text{g/L}$, MSE 的极差为 106.32 $\mu\text{g/L}$;验证结果的平均 MSE 为 8.64 $\mu\text{g/L}$, MSE 的极差为 126.35 $\mu\text{g/L}$,故原模型的最优隐含层节点数为 8。根据引入环境变量的 BP 模型均方误差(表 3),当隐含层节点数为 5 个时,引入环境变量的 BP 模型的训练结果的平均 MSE 最小,为 4.83 $\mu\text{g/L}$, MSE 的极差为 24.15 $\mu\text{g/L}$;验证结果的平均 MSE 为 6.79 $\mu\text{g/L}$, MSE 的极差为 68.47 $\mu\text{g/L}$,故引入环境变量的 BP 模型的最优隐含层节点数为 5。对比二者的最优隐含层节点数可以发现,在重复运算 1000 次后,相对于原始模型,引入环境变量的 BP 模型的平均 MSE 更小, MSE 的离散程度更小。

表 2 原始 BP 模型均方误差(单位: $\mu\text{g/L}$)

Tab. 2 The MSE of the original BP model(Unit: $\mu\text{g/L}$)

隐含层节点数	训练		验证	
	平均 MSE	MSE 的极差	平均 MSE	MSE 的极差
2	7.15	339.96	9.19	789.84
3	5.70	42.31	10.78	2551.94
4	5.46	31.23	7.26	149.16
5	5.26	98.00	7.40	94.32
6	5.38	137.73	8.20	350.59
7	5.25	146.33	8.14	162.71
8	4.98	106.32	8.64	126.35
9	5.06	102.94	8.38	95.25
10	5.02	44.41	8.65	140.30
11	5.27	73.26	8.77	85.50
12	5.13	98.71	9.01	176.70
13	5.43	228.12	9.75	344.64

表3 引入环境变量的 BP 模型均方误差(单位: $\mu\text{g/L}$)
Tab.3 The *MSE* of the BP model with environmental variables(Unit: $\mu\text{g/L}$)

隐含层节点数	训练		验证	
	平均 <i>MSE</i>	<i>MSE</i> 的极差	平均 <i>MSE</i>	<i>MSE</i> 的极差
3	5.36	87.17	6.70	90.31
4	5.16	68.87	6.59	61.17
5	4.83	24.15	6.79	68.47
6	5.44	215.73	8.08	875.43
7	5.15	94.02	7.57	132.66
8	5.58	73.79	7.83	89.07
9	5.42	160.46	8.50	132.13
10	5.48	70.37	8.28	72.08
11	5.71	61.83	8.89	103.16
12	6.29	116.96	9.99	96.71
13	6.04	97.01	9.66	109.34
14	6.69	72.60	11.05	100.52
15	7.26	73.75	11.70	194.39

2.2 模型的对比

在得到两种模型的最优隐含层节点个数后,利用对应样本组分别对二者进行训练和验证,结果如表4和图8所示。从表4中可以看到无论是训练的 *MSE* 还是验证的 *MSE*,引入环境变量的 BP 模型均小于原始 BP 模型;同时,从图8可以看出引入环境变量的 BP 模型的估计值与观测值一元回归的 R^2 为 0.59253,要明显高于原模型,且其 *RMSE* 为 1.594 要低于原模型的 2.3974。由此可见,在反演深圳海域叶绿素 *a* 的浓度时,引入环境变量能够较大地提高 BP 模型的反演精度。表5为引入环境变量的 BP 模型的最终权重和阈值。

表4 两种模型的均方误差(单位: $\mu\text{g/L}$)

Tab.4 The *MSE* of two BP models (Unit: $\mu\text{g/L}$)

模型	训练的 <i>MSE</i>	验证的 <i>MSE</i>
原始 BP 模型	10.98	12.61
引入环境变量的 BP 模型	4.71	3.50

2.3 模型敏感性分析

为了探究输入参数对模型的影响程度,本研究利用新验证样本对训练好的引入环境变量的 BP 模型进行输入参数敏感性分析(图9)。结果表明叶绿素 *a* 的浓度对 X1 的变化最敏感,其次是 B4;而对 X3 的变化最不敏感。输入参数对模型的影响程度排序为: 陆源入海排污口的核密度 (X1) > B4 > B3 > 距港口航道的距离 (X2) > B1 > B2 > 距海水增殖养殖区的距离 (X3)。




图8 两种模型的验证结果
Fig.8 Verification of the two models

表 5 引入环境变量的 BP 模型的权值和阈值

Tab.5 Weights and threshold of the BP model with environmental variables

权值/阈值	隐含层节点 1	隐含层节点 2	隐含层节点 3	隐含层节点 4	隐含层节点 5
输入 1 权值	1.0482	1.1442	0.1507	-0.4320	0.0386
输入 2 权值	-0.2479	0.1795	0.6980	1.4109	-2.9194
输入 3 权值	-0.3592	0.4970	-0.4670	-1.0867	0.0541
输入 4 权值	-1.2683	0.5606	0.5135	-0.9434	1.4213
输入 5 权值	-0.4526	-0.3399	-0.2409	-0.0329	-0.2009
输入 6 权值	0.8747	-0.3491	0.9331	-0.0483	-2.3373
输入 7 权值	-0.4796	1.8011	1.3473	-1.2334	-0.0186
隐含层节点阈值	-2.1586	0.0538	-0.2725	-1.0837	2.1542
输出节点权值	0.4302	-0.9942	0.4405	-0.4656	0.7362
输出节点阈值	-1.1271				




图 9 输入参数的敏感性分析

Fig.9 Sensitivity analysis of input parameter

2.4 讨论分析

对 BP 模型进行训练,需要充足的样本数量。部分研究利用水质、气象等变量^[2]作为 BP 神经网络模型的输入来反演叶绿素 *a* 的浓度,也有研究利用波段反射率等变量^[3]作为 BP 神经网络模型的输入来反演叶绿素 *a* 的浓度。前者的样本数据一般相对充足,后者囿于实测-遥感数据的可获取性,通常样本数据比较少^[4],BP 神经网络模型可能出现“过拟合”现象。本研究的实测-遥感数据样本相对较多(86 个),不仅能增加 BP 神经网络模型的反演精度,而且能够降低模型“过拟合”的风险。

另外,多数学者选用水质、水温等微观变量作为 BP 模型的输入参数,很少考虑选用环境变量等宏观因素作为输入变量。而表征区域本底特征的环境变量与人类活动密切相关,本研究将其作为 BP 神经网络模型的部分输入参数来探究环境变量对叶绿素 *a* 浓度的影响程度,在一定程度上

有利于提高 BP 神经网络模型的反演精度,有利于从宏观层面了解人类活动对研究海域富营养化的影响情况,为制定相应海洋环境保护政策提供一定的基础依据。

引入陆源入海排污口的核密度、距港口航道的距离和距海水增殖养殖区的距离等环境变量作为输入参数能够提高 BP 神经网络模型的反演精度。进一步地,在输入参数的敏感性分析中叶绿素 *a* 的浓度对陆源入海排污口的核密度的变化最敏感,主要原因是部分近海污染来源于深圳及其周边地区如广州、东莞和中山等众多河流的污染排放,因此基于河流数量的陆源入海排污口的核密度越大,人类活动产生的有机污染和无机污染等就越多,为海水中藻类的迅速生长提供了充足养分,从而增加了叶绿素 *a* 的浓度;叶绿素 *a* 的浓度对近红外波段反射率(B4)和红光波段反射率(B3)的变化次敏感,是因为叶绿素 *a* 在近红外波段和红光波段具有特定的光谱特征^[13],其含量能够由近红外波段反射率和红光波段反射率来表征;叶绿素 *a* 的浓度对距港口航道距离的变化较为敏感,这与深圳市盐田港、蛇口港和赤湾港等众多港口频繁的港口作业活动有关。例如:深圳盐田港是目前中国大陆远洋集装箱班轮密度最高的集装箱码头之一,也是目前世界上单港集装箱吞吐量最高的码头。因此,距离港口航道越近,人流、物流流量越大,港口建设和维护作业中的污染物以及船舶的油污污染物也就越多,进而海水富营养化的风险增大,直接表现为叶绿素 *a* 浓度的升高。

此外,本研究也存在一定不足:首先,由于遥感影像、环境等条件的限制,样本点的分布范围比较集中,可能会对深圳海域叶绿素 *a* 的反演精度

造成一定影响;其次,由于测量点位较多而人力物力又有限,本研究的现场实测数据与卫星遥感数据难以完全同步,会对模型的反演结果造成一定影响;再次,模型隐含层节点数的选取比较关键,本研究利用重复 1000 次的方法,在一定程度上能降低模型最优隐含层节点数选取的误差,但如何使用更为科学和有效的办法来降低选取的误差值得进一步研究;最后,在敏感性分析中,叶绿素 a 的浓度对陆源入海排污口的核密度这一环境变量较为敏感,而本研究的陆源入海排污口的核密度主要是根据入海河流的数量来确定的,并假设不同河流的排污量相同,未考虑不同河流排污量的差异性,因此进一步研究中应确定不同河流的权重,从而降低模型的反演误差。

3 结 论

(1) 环境变量的引入能较大地提高 BP 神经网络模型反演精度,且引入环境变量的 BP 神经网络模型的训练 MSE 和验证 MSE 分别为 $4.71 \mu\text{g/L}$ 和 $3.50 \mu\text{g/L}$,均优于原始 BP 模型的 $10.98 \mu\text{g/L}$ 和 $12.61 \mu\text{g/L}$ 。

(2) 引入环境变量的 BP 神经网络模型框架如下:输入层为 7 个变量,分别为蓝光波段反射率 ($B1$)、绿光波段反射率 ($B2$)、红光波段反射率 ($B3$) 和近红外波段反射率 ($B4$)、陆源入海排污口的核密度 ($X1$)、距港口航道的距离 ($X2$) 和距海水增殖区的距离 ($X3$);隐含层节点数为 5 个;输出层为叶绿素 a 的浓度。

(3) 根据引入环境变量的 BP 神经网络模型的参数敏感性分析,叶绿素 a 的浓度对陆源入海排污口的核密度 ($X1$) 的变化最敏感,其后依次为近红外波段反射率 ($B4$)、红光波段反射率 ($B3$)、距港口航道距离 ($X2$)、蓝光波段反射率 ($B1$)、绿光波段反射率 ($B2$) 和距海水增殖区的距离 ($X3$)。

参考文献:

- [1] 陈永根,刘伟龙,韩红娟,等. 太湖水体叶绿素 a 含量与氮磷浓度的关系 [J]. 生态学杂志,2007(12):2062-2068.
- [2] MORADI M, KABIRI K. Spatio-temporal variability of SST and Chlorophyll- a from MODIS data in the Persian Gulf [J]. Marine Pollution Bulletin,2015,98(1/2):14-25.
- [3] CIANCIA E, LOUREIRO C M, MENDONÇA A, et al. On the potential of an RST-based analysis of the MODIS-derived chl- a product over Condor seamount and surrounding areas (Azores, NE Atlantic) [J]. Ocean Dynamics, 2016,66(9):1165-1180.

- [4] MURUGAN P, SIVAKUMAR R, PANDIYAN R, et al. Comparison of in-Situ Hyperspectral and Landsat ETM+ Data for Chlorophyll- a Mapping in Case-II Water (Krishnarajapuram Lake, Bangalore) [J]. Journal of the Indian Society of Remote Sensing, 2016,44(6):949-957.
- [5] SONG K S, WANG Z M, BLACKWELL J, et al. Water quality monitoring using LandsatThematic Mapper data with empirical algorithms in Chagan Lake, China [J]. Journal of Applied Remote Sensing,2011,5(1):053506-053506-16.
- [6] 王琦,孟伟,马云峰,等. 利用 BP 神经网络预测大伙房水库叶绿素 a 质量浓度 [J]. 东北大学学报:自然科学版,2013,34(12):1792-1795,1800.
- [7] 周露洪,谷孝鸿,曾庆飞,等. 利用 BP 神经网络短期预测太湖不同湖区叶绿素 a 浓度 [J]. 水生态学杂志,2012,33(4):1-6.
- [8] SIVRI N. Applying artificial neural networks for the estimation of chlorophyll- a concentrations along the istanbul coast [J]. Polish Journal of Environmental Studies,2014,23(4):1281-1287.
- [9] RAJAEI T, BOROUMAND A. Forecasting of chlorophyll- a concentrations in South San Francisco Bay using five different models [J]. Applied Ocean Research,2015,53:208-217.
- [10] 张际标,姚兼辉,杨波,等. 雷州湾陆源入海污染负荷及其对海水水质的影响 [J]. 海洋开发与管理,2015,32(6):107-113.
- [11] 李亚军,杨忠振. 港口生态环境影响及生态补偿关系分析研究 [J]. 环境科学与管理,2016,41(2):134-137.
- [12] 管延龄. 秦皇岛海域陆源污染调查及其控制对策研究 [D]. 咸阳:西北农林科技大学,2015.
- [13] 赵冬至. 中国典型海域赤潮灾害发生规律 [M]. 北京:海洋出版社,2010.
- [14] 谭上进,朱小山,周进,等. 深圳近岸海域环境状况近 10a 变化趋势 [J]. 海洋环境科学,2014(1):154-160.
- [15] 深圳市规划和国土资源委员会. 2015 年深圳市近岸海域环境状况 [R]. 深圳:深圳市规划和国土资源委员会,2016.
- [16] 刘念,鹏泰,赵振业. 深圳陆源入海排污口现状及污染防治对策研究 [J]. 环境科学与管理,2015,40(1):91-93.
- [17] 曾辉,高启辉,陈雪,等. 深圳市 1988—2007 年间湿地景观动态变化及成因分析 [J]. 生态学报,2010,30(10):2706-2714.
- [18] 广东省海洋与渔业局. 2014 年广东省海洋环境状况公报 [R]. 广州:广东省海洋与渔业厅,2015.
- [19] 杨敏,林杰,顾哲衍,等. 基于 Landsat 8 OLI 多光谱影像数据和 BP 神经网络的叶面积指数反演 [J]. 中国水土保持科学,2015,13(4):86-93.
- [20] 贾坤,李强子,田亦陈,等. 遥感影像分类方法研究进展 [J]. 光谱学与光谱分析,2011,31(10):2618-2623.
- [21] 张立明. 人工神经网络的模型及其应用 [M]. 上海:复旦大学出版社,1993.
- [22] LIU Y, XI D, LI Z. Determination of the optimal training principle and input variables in artificial neural network model for the biweekly chlorophyll- a prediction: a case study of the Yuqiao Reservoir, China [J]. PLoS One,2015,10(3):e119082.
- [23] 朱子先,臧淑英. 基于遗传神经网络的克钦湖叶绿素反演研究 [J]. 地球科学进展,2012,27(2):202-208.
- [24] 赵冬至,曲元,张丰收,等. 用 TM 图象估算海表面叶绿素浓度的神经网络模型 [J]. 海洋环境科学,2001,20(1):16-21.