

基于机器学习的FY3D/MERSI-II传感器大气校正研究

宋顺翌¹, 丘仲锋^{2,3*}, 詹雅婷^{1,4,5}, 段超凡^{6**}, 武燕²¹南京信息工程大学海洋科学学院, 江苏 南京 210044;²南京信息工程大学电子与信息工程学院, 江苏 南京 210044;³三亚海洋实验室, 海南 三亚 572025;⁴江苏省地质调查研究院, 江苏 南京 210018;⁵江苏省自然资源厅卫星遥感应用重点实验室, 江苏 南京 210018;⁶国防科技大学信息通信学院, 湖北 武汉 430015

摘要 FY3D搭载的MERSI-II传感器设置了丰富的水色遥感波段,然而同步匹配数据集少等因素导致当前大气校正算法不完善,限制了其在水色遥感领域的应用。针对上述问题,构建了基于多层感知机(MLP)模型的大气校正算法,以MODIS大气校正后的遥感反射率作为参考,实现MERSI-II从DN值到离水反射率的信息提取。通过引入时间、空间、角度以及背景场特征的分箱加权,并经过系统参数优选实验,训练得出最优模型,即以平均绝对误差(MAE)为损失函数并对波段、时间、角度和背景场实施分箱加权,模型在各测试集均表现出较高的预测精度:大部分波段的决定系数(R^2)在0.85以上,MAE低于0.002,均方根误差(RMSE)为0.001~0.002;模型估算的MERSI-II大气校正结果与MODIS结果高度一致,反映了渤海区域离水遥感反射率“近岸高、外海低”的空间分布和“夏季最低、冬季最高、春秋过渡”的季节变化特征。本研究为FY3D MERSI-II传感器发展了与MODIS精度相当的机器学习大气校正模型,经更多现场同步观测资料验证和优化后,可进一步扩展应用到其他海域。

关键词 海洋光学; FY3D; MERSI-II; 多层感知机; 大气校正

中图分类号 O436

文献标志码 A

DOI: 10.3788/AOS251704

1 引言

大气校正是水色遥感水质参数反演的重要环节,传统大气校正方式主要基于暗像元假设,通过将近红外波段海水反射率近似为0,获得近红外波段的气溶胶影响,根据气溶胶模型得到可见光波段的气溶胶影响,从而估算出可见光波段的遥感反射率^[1]。对于暗像元假设不再成立的浑浊水体,学者将暗像元假设从近红外扩展到波长更长的波段,从而实现大气校正。此外,紫外大气校正方法也被广泛应用,尤其是在较浑浊海域,该方法可获得比基于暗像元假设更好的大气校正结果^[2]。

上述大气校正算法在水色遥感中得到了广泛应用,但在实际复杂环境中容易受到影响,特别在浑浊水体或强吸收性气溶胶等区域,会出现校正错误或失败的现象。

近年来,随着人工智能的发展,机器学习或深度学习已被广泛应用于大气校正,包括多层感知机

(MLP)、自适应神经网络(IPAC)、人工神经网络(ANN)等。Schroeder等^[3]利用多重MLP神经网络反演气溶胶参数,再结合叶绿素模拟数据实现大气校正;He等^[4]利用IPAC模型结合多光谱卫星观测,基于向量辐射传输模型(VRTS)和查找表(LUT)实现偏振反射率和气溶胶属性反演等;Medina-Lopez^[5]利用ANN构建卫星光谱信号与盐度的关系,通过Sen2Cor处理Sentinel-2资料,实现大气校正。

与传统的物理模型和查找表方法相比,机器学习能够充分挖掘遥感影像与实测大气参数之间复杂的非线性关系,在多种传感器、不同环境条件下都能保持较高的精度和泛化能力,并在处理大量数据和复杂场景(如近岸混合水体、太阳眩光等)时表现出一定的优势。

FY3D气象卫星搭载的MERSI-II传感器具有与常用水色遥感传感器(如SeaWiFS、MODIS等)类似的波段设置,也可用于水色定量遥感。目前风云卫星的大气校正主要借鉴MODIS、SeaWiFS等主流传感器大气

收稿日期: 2025-09-03; 修回日期: 2025-11-11; 录用日期: 2025-11-17; 网络首发日期: 2025-11-28

基金项目: 国家自然科学基金(41976165)、江苏省地质调查研究院项目(JSTCC2400210021)、国家重点研发计划(2024YFC3109000)、国家卫星气象中心项目(FY-3(03)-AS-11.10-ZT, FY-3(03)-AS-11.12-ZT)

通信作者: *zhongfeng.qiu@nuist.edu.cn; **duanchaofan18@nudt.edu.cn

校正的标准算法,即由 Gordon 和 Clark^[1]提出的暗像元假设辐射传输理论物理模型方法。

Pei 等^[6]将 MODIS 的暗像元法运用在 MERSI-II 传感器上,针对空间分辨率差异及波段设置进行改进,包括多波段拟合替代传统沉积物掩模、优化云检测与像元聚合方法并基于 MERSI-II 波段重建气溶胶查找表,实现了暗像元大气校正,取得较高的大气校正精度,但在渤海等浑浊水体存在气溶胶光学厚度(AOD)系统性高估和高悬浮泥沙难以剔除等问题,导致反演准确性下降以及部分像元大气校正失败。

除暗像元算法之外,Fan 等^[7]提出了 OC-SMART 算法,该算法采用大气-海洋耦合辐射传输模型和多层神经网络,不依赖于近红外波段的暗像元假设,提升 FY3D/MERSI-II 在复杂水体的大气校正精度。

Zhang 等^[8]提出 SIRAW 同步反演算法,以大气-海洋耦合辐射传输模型为物理基础,采用三组生物光学模型表征水体光学特性,并通过神经网络加速辐射传输计算,采用最优估计联合反演气溶胶与水体参数,从而实现大气校正^[8]。SIRAW 算法在渤海的反演结果与 VIIRS 产品高度一致,443 nm 波段的相对误差为 28%,555 nm 的均方根误差(RMSE, E_{RMSE})低至 0.002;针对 MERSI-II 蓝光波段定标衰减,SIRAW 引入新定标方法,使蓝光波段的 RMSE 由原定标的 0.011 降为 0.003,提升了水色反演精度。

尽管学者针对 FY3D/MERSI-II 开展了一些大气校正算法研究,但中国近海多变的水色背景下,大气校正结果的区域适应性有待验证^[6];大气散射、气溶胶类型等多种因素对海洋遥感信号的影响较大,当悬浮泥沙、有色溶解有机物(CDOM)等影响增大时,传统算法往往失效,导致 AOD 和 水体反射率反演误差显著增加^[9];此外,OC-SMART、SIRAW 等算法在蓝光波段的性能还有待提升,大气校正应用仍面临许多挑战,目前仍无法公开获取官方发布的 MERSI-II 传感器海洋大气校正产品。

针对上述问题及前人工作的研究思路,为提升 FY3D/MERSI-II 在复杂水体的大气校正精度,本文以 MODIS 大气校正结果为参照,构建 MLP 模型,对 FY3D/MERSI-II 数据进行大气校正,预期获得与 MODIS 大气校正产品精度相当的离水遥感反射率。

2 数据与方法

2.1 研究区域

本研究区域为渤海,位于中国大陆东部北端,三面环陆,是中国最大且近封闭的内海(117°33'E~122°08'E, 37°07'N~40°56'N),总面积为 7.7 万平方千米,平均深度为 18 m^[10](图 1)。渤海的大部分区域属于二类水体,光学特性复杂多变,不仅受浮游植物的影响,还受到悬浮颗粒物和 CDOM 的显著影响^[10]。



图 1 研究区域遥感影像图(过境时间为 2024 年 3 月 12 日 5:45 (UTC), RGB 图像由 FY3D 的波段 1~3(中心波长分别为 470 nm(蓝光)、550 nm(绿光)、650 nm(红光))合成,红框标注为研究区域)

Fig. 1 Remote sensing image of the study area (overpass occurred at 05:45 UTC on March 12, 2024. The RGB image was composed using bands 1 to 3 of FY3D, with central wavelengths of 470 nm (blue), 550 nm (green), and 650 nm (red), respectively, and the study area is indicated by the red rectangle)

2.2 数据

2.2.1 数据介绍

本研究使用的 FY3D/MERSI-II 的 L1 级数据,来自风云卫星遥感数据服务网 NSMC (<https://satellite.nsmc.org.cn/DataPortal/cn/home/index.html>)。选取的数据时间为 2024 年,覆盖渤海区域(117°E~123°E, 37°E~41°E),包括空间分辨率为 1000 m 的 5 个可见光波段数据(中心波长分别为 412 nm、443 nm、490 nm、555 nm 和 670 nm,下文以 5 波段简述,不再提及中心波长)、地理定位(经纬度、太阳/仪器天顶角、太阳/仪器方位角)和观测时间等信息。

FY3D 是一颗近极地太阳同步轨道卫星,每天覆盖全球 1~2 次,卫星过境时间为真太阳时 14:00。FY3D 上搭载的 MERSI-II 传感器具有 25 个通道,包括 16 个可见光-近红外通道、3 个短波红外通道和 6 个中长波红外通道;其中 6 个通道地面分辨率为 250 m(可见光-近红外通道 1~6),其余通道地面分辨率为 1000 m。

本研究选用 Aqua/MODIS 的遥感反射率 R_{rs} 产品(来自 NASA 相关网站(<https://oceancolor.gsfc.nasa.gov>)),作为 FY3D/MERSI-II 大气校正的参考值。选用资料为 MODIS-Aqua 卫星 2024 年渤海区域的 L2OC 产品,即大气校正后的可见光波段 R_{rs} 数据,空间分辨率为 1000 m,中心波长分别为 412、443、488、555、667 nm。

Aqua 是一颗太阳同步轨道卫星,过境时间为真太阳时 13:30,其上搭载的 MODIS 传感器具有 36 个波段,包括 21 个可见光-近红外波段和 15 个中红外与热红外波段,其中 2 个波段的地面分辨率为 250 m(可见光-近红外波段 1~2),5 个波段的地面分辨率为 500 m(可

见光-近红外波段3~7),其余29个波段的地面分辨率为1000 m。

由于过境时间相近,且FY3D卫星与Aqua卫星均具备高频次的全球覆盖能力,因此,MERSI-II与MODIS的观测数据在全球范围内具有长时间的重叠,可以获取时空同步的匹配数据集。

2.2.2 匹配数据集

匹配数据集的构建,采用了严格的时空一致性约束数据匹配标准:卫星过境时间相差不超过 $\pm 20\text{ min}$,像元空间距离不超过 1 km ,且均在渤海区域($117^{\circ}\text{E}\sim 123^{\circ}\text{E}$, $37^{\circ}\text{N}\sim 41^{\circ}\text{N}$)。匹配数据集包括MERSI-II传感器的5波段DN值、经纬度、太阳及传感器的天顶角与方位角、观测时间等辅助数据,MODIS传感器的5波段 R_{rs} 数据、经纬度、太阳及传感器的天顶角与方位角、观测时间等辅助数据。匹配数据集包含130多万万个像元点,80%的数据被随机选取为模型训练集,剩余20%作为验证集。

此外,本研究还收集了2023年和2025年的匹配数据构建模型的独立测试集。

2.2.3 数据预处理

为保证数据的有效性,开展模型训练前对数据进行预处理。

通过对 MODIS 数据进行质量筛选控制,剔除包含 ATMFAIL(大气校正失败)、LAND(陆地)、

HIGLINT(强烈太阳镜面反射)、CLDICE(云和/或冰)、HILT(某波段总辐射超限)、LOWLW(555 nm 水体离开辐射太低)、NAVWARN(导航可疑)等异常标志的像素;随后对筛选后的数据进行标准化处理,将各波段的 R_s 归一化到 $[0, 1]$ 范围,去除 NaN 值,输出渤海区域的有效像元。

通过对MERSI-II数据进行像元级质量控制,并对每条扫描帧和各通道观测位进行筛查,剔除在定标(bit26)、定位(bit33)、污染(bit35、36)、时间码(bit37)等方面存在异常,以及5波段(bit7~11)任意通道质量异常的像元,并结合海陆掩码去除所有陆地像元,最终输出渤海区域的有效像元。

2.3 机器学习方法

2.3.1 模型原理

本研究采用全连接前馈神经网络(FNN)模型(图2)。FNN由输入层、隐藏层和输出层组成,层间节点全连接,能够通过多层非线性映射自动学习输入特征与目标输出之间的复杂关系^[11];FNN利用误差反向传播算法优化网络权重和偏置参数,从而对输入与输出之间的非线性关系进行有效建模;隐藏层包含一个或多个带有激活函数(如ReLU、Sigmoid或Tanh等)的神经元,用于提升模型的非线性拟合能力。本研究的大气校正算法程序以Python编写,采用Pytorch和sklearn模块进行FNN调试。




图2 FNN模型原理图

Fig. 2 Principle diagram of FNN model

2.3.2 模型基本参数设置

模型的结构参数包括输入特征、输出特征、隐藏层数目、每层神经元数目以及激活函数类型,模型的训练参数包括损失函数、优化器和正则化方法,这些结构参数与训练参数的合理设置共同决定了模型的输入输出表达能力、训练稳定性和泛化性能。

在输入特征参数方面,本研究选取MERSI-II的5波段DN值、太阳及传感器的天顶角与方位角作为基础

输入;输出特征参数为MODIS的5波段 R_n 数据。模型采用Adam优化器,学习率设为0.0005,损失函数采用均方误差(MSE, E_{MSE}),同时,为防止过拟合,设置L2正则化权重衰减系数为0.01。

初始模型设置为一个含有 3 层隐藏层(第一层 48 个神经元、第二层 32 个神经元、第三层 24 个神经元)的 MLP 神经网络,在隐藏层之间使用 LeakyReLU 函数,输出层采用线性激活函数。

2.3.3 模型的参数优选实验

本研究在初始模型基础上主要针对特征构建、防止过拟合、损失函数和权重设置的优化等开展了上百组模型优选实验(图3)。

特征构建方面,本研究在初始模型基础上,考虑数

据的时空异质性与观测条件的多样性,通过引入FY3D卫星的经纬度与时间,以及太阳和传感器的方位角计算出相对方位角,并进行特征增强处理;此外,本研究还引入研究区域背景场特征,通过2024年MODIS各波段L2 R_{rs} 数据得出年平均场作为背景场。

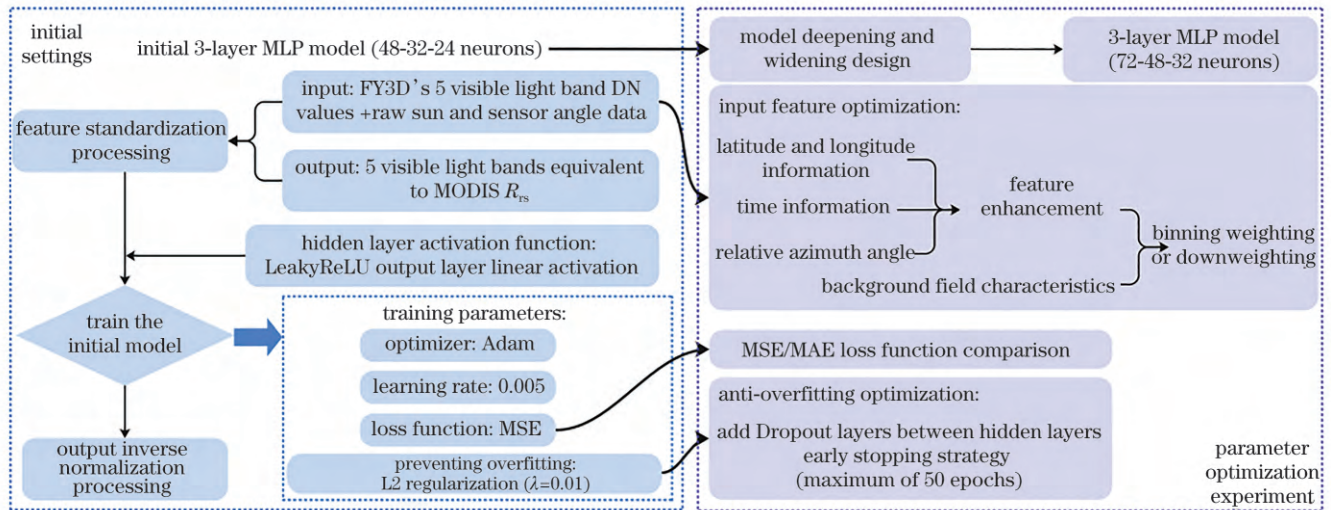


图3 模型参数优选实验框图

Fig. 3 Flowchart of model parameter optimization experiment

防止过拟合方面,本研究在初始模型采用L2正则化(系数为0.01)的基础上,在每个隐藏层激活函数之后引入Dropout层,采用早停(early stopping)策略,训练过程中若验证集损失在50轮内不再提升则提前终止训练;并对不同输入特征的多种分箱加权或降权组合进行实验,以减小样本分布不均衡带来的影响。

损失函数方面,本研究开展了MSE和平均绝对误差(MAE, M_{MAE})两种对比实验,系统分析损失函数与

权重策略协同对模型训练收敛速度、稳定性、精度及泛化能力的影响。同时,通过增加输入特征数量,对神经网络结构进行了加深加宽实验,对比不同结构下各组权重组合的训练与测试性能。

在模型优选过程中,通过设计多组损失函数与权重协同策略,对单一特征(包括时间、空间、观测角度和区域背景场等)及不同特征加权或降权组合下模型的预测性能进行实验分析,筛选出5组表现较好的损失函数与权重调整组合(表1)。

表1 模型优选组合

Table 1 Optimal combinations of models

Combination	Loss function	Weight adjustment
Combination 1	MAE	Band weighting+temporal weighting+20% angular down-weighting
Combination 2	MAE	Band weighting+background field weighting+temporal weighting+angular weighting
Combination 3	MSE	Band weighting+temporal weighting+20% angular down-weighting
Combination 4	MSE	Band weighting+background field weighting+20% temporal down-weighting+angular weighting
Combination 5	MSE	Band weighting+20% background field down-weighting+temporal weighting+20% angular down-weighting

2.4 评价指标

为了评估模型训练、验证和测试的性能表现,本研究运用多种评价指标,包括MAE、相对平均绝对误差(RMAE, E_{RMAE})、MSE、RMSE和决定系数(R^2):

$$M_{MAE} = \frac{1}{N} \sum_{i=1}^N |Y_i - X_i| \quad (1)$$

$$E_{RMAE} = \frac{1}{N} \sum_{i=1}^N \frac{|Y_i - X_i|}{X_i} \quad (2)$$

$$E_{MSE} = \frac{1}{N} \sum_{i=1}^N (Y_i - X_i)^2 \quad (3)$$

$$E_{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (Y_i - X_i)^2} \quad (4)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (Y_i - X_i)^2}{\sum_{i=1}^N (X_i - \bar{X})^2} \quad (5)$$

式中: Y_i 表示第 i 个样本的预测值; X_i 表示第 i 样本的真实值; $\bar{X}$ 表示真实值的均值; N 表示样本数量。

3 结 果

3.1 最优模型的实验与构建

为了系统评估模型的性能,本研究依次构建并对比了多种输入特征和训练策略下的 MLP 模型,经过上百组权重调整协同损失函数的消融与组合实

验,本研究得出性能较好的 5 种组合,验证指标如表 2 所示。作为参照,表 2 同时还展示了初始模型的情况。

初始模型整体训练的 R^2 达 0.8475,在 5 个波段上均体现出一定的拟合能力。以 $R_{rs}(412)$ 为例,验证集 R^2 为 0.7815, MAE 为 0.0012 sr^{-1} , RMSE 为 0.0017 sr^{-1} ,其余波段验证集 R^2 最大为 0.9111 ($R_{rs}(555)$),最小为 0.8013 ($R_{rs}(667)$), MAE 和 RMSE 的数值处于 $0.0012 \sim 0.0025 \text{ sr}^{-1}$ 之间。

5 组组合均表现出较高的模型验证精度。平均 R^2 均在 0.958 以上,各波段 R^2 也均超过 0.93,同时 MAE 和 RMSE 等误差值均较低。

表 2 初始模型及 5 组优选实验组合的结果统计

Table 2 Statistical results of initial model and five optimized experimental combinations

Combination	Product	R^2	MAE / sr^{-1}	RMAE	MSE / sr^{-2}	RMSE / sr^{-1}
Initial model	$R_{rs}(412)$	0.7815	0.0012	0.2146	3.00×10^{-6}	0.0017
	$R_{rs}(443)$	0.8582	0.0012	0.1660	2.67×10^{-6}	0.0016
	$R_{rs}(488)$	0.8858	0.0013	0.1458	3.25×10^{-6}	0.0018
	$R_{rs}(555)$	0.9111	0.0015	0.1387	4.35×10^{-6}	0.0021
	$R_{rs}(667)$	0.8013	0.0016	0.3008	6.49×10^{-6}	0.0025
Combination 1 experiment	$R_{rs}(412)$	0.9390	0.0006	0.1017	0.86×10^{-6}	0.0009
	$R_{rs}(443)$	0.9550	0.0006	0.0820	0.86×10^{-6}	0.0009
	$R_{rs}(488)$	0.9643	0.0006	0.0682	1.03×10^{-6}	0.0010
	$R_{rs}(555)$	0.9735	0.0007	0.0618	1.32×10^{-6}	0.0011
	$R_{rs}(667)$	0.9638	0.0006	0.1082	1.22×10^{-6}	0.0011
Combination 2 experiment	$R_{rs}(412)$	0.9390	0.0006	0.1006	0.84×10^{-6}	0.0009
	$R_{rs}(443)$	0.9550	0.0006	0.0813	0.85×10^{-6}	0.0009
	$R_{rs}(488)$	0.9644	0.0006	0.0675	1.01×10^{-6}	0.0010
	$R_{rs}(555)$	0.9738	0.0007	0.0608	1.28×10^{-6}	0.0011
	$R_{rs}(667)$	0.9634	0.0006	0.1086	1.20×10^{-6}	0.0011
Combination 3 experiment	$R_{rs}(412)$	0.9410	0.0006	0.1038	0.81×10^{-6}	0.0009
	$R_{rs}(443)$	0.9566	0.0006	0.0837	0.82×10^{-6}	0.0009
	$R_{rs}(488)$	0.9650	0.0006	0.0704	1.00×10^{-6}	0.0010
	$R_{rs}(555)$	0.9744	0.0007	0.0636	1.25×10^{-6}	0.0011
	$R_{rs}(667)$	0.9650	0.0006	0.1111	1.14×10^{-6}	0.0011
Combination 4 experiment	$R_{rs}(412)$	0.9431	0.0006	0.1008	0.78×10^{-6}	0.0009
	$R_{rs}(443)$	0.9573	0.0006	0.0829	0.80×10^{-6}	0.0009
	$R_{rs}(488)$	0.9653	0.0006	0.0703	0.99×10^{-6}	0.0010
	$R_{rs}(555)$	0.9746	0.0007	0.0639	1.24×10^{-6}	0.0011
	$R_{rs}(667)$	0.9658	0.0006	0.1113	1.12×10^{-6}	0.0011
Combination 5 experiment	$R_{rs}(412)$	0.9621	0.0006	0.0999	0.77×10^{-6}	0.0009
	$R_{rs}(443)$	0.9584	0.0006	0.0813	0.78×10^{-6}	0.0009
	$R_{rs}(488)$	0.9663	0.0006	0.0685	0.96×10^{-6}	0.0010
	$R_{rs}(555)$	0.9753	0.0007	0.0617	1.20×10^{-6}	0.0011
	$R_{rs}(667)$	0.9664	0.0006	0.1097	1.10×10^{-6}	0.0010

为进一步优选出泛化能力稳定和预测精度较高的最优模型,本研究引入不同独立测试集对 5 组组合进行对比。取 2025 年 3 月 22 日、2023 年 9 月 22 日两个过境时间在 20 min 内的匹配影像,研究区域分别包括 84775 和 33363 个像元;此外,为进一步测试模型泛化能力,本文还选取了 2023 年 2 月 4 日的测试数据集作为时间差异测试集,两者过境时间相差 70 min,像元数为 39540 个。

本研究以 R^2 为例,讨论不同组合的对比情况

(表 3)。通过对比可以看出,各组合模型性能在不同测试集存在一定差异,组合二展现出最好的均衡性和预测性能,针对 2025 年 3 月 22 日测试集,组合二 5 波段的 R^2 分别达到 0.6853、0.8577、0.9105、0.9525 和 0.9002,整体优于其他 4 种组合;针对时间差异测试集,组合二各波段也取得较高的 R^2 ;组合二在 2023 年 9 月 22 日测试集的性能也很稳定,443 nm 和 488 nm 波段预测 R^2 分别为 0.8607 和 0.8552。

表 3 5 种组合在不同测试集的性能对比

Table 3 Performance comparison of five combinations on different test sets

Test set	Product	Predicted R^2				
		Combination 1	Combination 2	Combination 3	Combination 4	Combination 5
September 22, 2023, test set	$R_{rs}(412)$	0.8117	0.7647	0.8145	0.8317	0.8075
	$R_{rs}(443)$	0.8414	0.8607	0.8529	0.8746	0.8656
	$R_{rs}(488)$	0.8564	0.8552	0.8496	0.8682	0.8838
	$R_{rs}(555)$	0.9121	0.8654	0.8724	0.8880	0.9218
	$R_{rs}(667)$	0.7387	0.7158	0.7190	0.7383	0.7843
March 22, 2025, test set	$R_{rs}(412)$	0.1811	0.6853	0.7072	0.0951	0.1786
	$R_{rs}(443)$	0.5782	0.8577	0.8481	0.5811	0.5484
	$R_{rs}(488)$	0.7268	0.9105	0.8798	0.7685	0.7079
	$R_{rs}(555)$	0.8501	0.9525	0.9170	0.8911	0.8401
	$R_{rs}(667)$	0.8579	0.9002	0.8614	0.9034	0.8084
Temporal difference test set	$R_{rs}(412)$	0.4080	0.5476	0.5091	0.3936	0.5788
	$R_{rs}(443)$	0.6345	0.7052	0.6355	0.6138	0.7517
	$R_{rs}(488)$	0.7678	0.8457	0.7228	0.7533	0.8600
	$R_{rs}(555)$	0.7980	0.9037	0.7828	0.8371	0.9194
	$R_{rs}(667)$	0.2689	0.3429	0.3628	0.4683	0.5635

由于组合二在不同场景和波段下都能保持较高且稳定的预测精度,泛化能力最好,因此本研究确定组合二为最优方案模型,对应网络结构包含三层隐藏层:第一层为 72 个神经元,第二层为 48 个神经元,第三层为 32 个神经元。

图 4 展示了最优模型的训练和验证散点图对比。经过 K 折交叉验证后模型整体训练结果在 0.9587~0.9591 之间, $R_{rs}(412)$ 的 R^2 为 0.9390,其余波段与 $R_{rs}(412)$ 类似,均超过 0.95,最高 R^2 达 0.9738 ($R_{rs}(555)$);MAE、RMSE 和 RMAE 等误差指标较初始模型进一步降低,且各波段间差异缩小。

3.2 最优模型性能验证

为进一步说明最优模型的性能,本研究采用 3 组独立数据进行测试,数据获取时间分别为 2025 年 3 月 22 日、2023 年 9 月 22 日及 2023 年 2 月 4 日。其中,2023 年 2 月 4 日作为时间差异测试集,两者空间匹配(像元空间

距离不超过 1 km,且均在渤海区域),而时间不匹配(过境时间相差 70 min)。

3.2.1 2025 年 3 月 22 日测试集验证结果

表 4 列出 2025 年 3 月 22 日测试集的模型结果统计,图 5 给出空间分布和对比,多数散点沿 1:1 线分布,一致性很好;除 412 nm 波段外 R^2 均达到 0.85 以上,尤其是 488 nm、555 nm、667 nm 三个波段平均 R^2 超过 0.91,并且 MAE、RMSE 低,说明模型对后三个波段的预测能力较强。

3.2.2 2023 年 9 月 22 日测试集验证结果

表 5 列出 2023 年 9 月 22 日测试集的模型结果统计,图 6 给出测试集测试结果的空间分布和对比,多数散点沿 1:1 线分布,能较好地重现区域大尺度的空间格局;除 412 nm、667 nm 波段外 R^2 均在 0.85 以上,且模型的整体误差较小。而模型在极值区域的预测值存在一定离散性,且在 412 nm 和 667 nm 波段存在一定偏差。




图 4 最优模型训练和验证散点图。(a) 412 nm 波段;(b) 443 nm 波段;(c) 488 nm 波段;(d) 555 nm 波段;(e) 667 nm 波段

Fig. 4 Training and validation scatter plots of optimal model. (a) 412 nm band; (b) 443 nm band; (c) 488 nm band; (d) 555 nm band; (e) 667 nm band

表 4 2025 年 3 月 22 日测试集结果统计

Table 4 Statistical results on test set on March 22, 2025

Product	R^2	MAE / sr^{-1}	RMAE	MSE / sr^{-2}	RMSE / sr^{-1}
$R_s(412)$	0.6853	0.0010	0.3035	1.63×10^{-6}	0.0013
$R_s(443)$	0.8577	0.0008	0.1647	1.13×10^{-6}	0.0011
$R_s(488)$	0.9105	0.0008	0.1038	1.06×10^{-6}	0.0010
$R_s(555)$	0.9525	0.0007	0.0714	8.32×10^{-7}	0.0009
$R_s(667)$	0.9002	0.0006	0.1587	8.01×10^{-7}	0.0009

3.2.3 2023 年 2 月 4 日时间差异测试集验证结果

表 6 列出时间差异测试集的模型结果统计,图 7 给出时间差异测试集测试结果的空间分布和对比,模型预测结果在大体趋势上与真值分布保持一致,但在 412 nm 和 667 nm 波段部分区域的差异明显增大;488 nm、555 nm 波段的预测 R^2 在 0.84 以上,模型对这两个波段具有较强的泛化能力;而 412 nm、667 nm 波段的拟合效果较差,且这两个波段的 MAE、RMAE 和 RMSE 高于其他波段,整体出现明显的系统性高估。

相较于 2025 年 3 月 22 日和 2023 年 9 月 22 日,时间差异测试集整体的 R^2 下降,尤其在 412 nm 和 667 nm 波段表现更为敏感;然而,尽管测试数据存在一定的时空不匹配,模型仍表现出良好的泛化能力,体现出模型对不同条件下数据的较强的适应性。

针对以上三个测试集的模型性能分析的结果表明,本研究构建的最优模型具有较强的估算能力,与 MODIS 遥感产品具有较高的相关性和较小的差异,能够有效获取渤海区域离水遥感反射率信息。

3.3 离水遥感反射率的季节变化特征

本研究选取 2022—2024 年渤海区域的 FY3D 数据,经过有效像元筛选构建得到 3 a 内多时相的数据集(每年约 2×10^7 个有效像元),利用模型得到离水遥感反射率(R_s),对结果进行季节分组:3、4、5 月为春季,6、7、8 月为夏季,9、10、11 月为秋季,12、1、2 月为冬季。对每年各季结果进行平均,得到年均季节分布;再对各年的年均值进行 3 a 平均,最终获得研究区域在 2022—2024 年的平均季节分布特征(图 8)。

如图 8 可见,研究区域 5 个波段的季节变化均表现




图5 2025年3月22日测试集测试结果。(a)(e)(i)(m)(q) 412 nm、443 nm、488 nm、555 nm、667 nm波段模型预测空间分布图；(b)(f)(j)(n)(r) 412 nm、443 nm、488 nm、555 nm、667 nm波段MODIS真值空间分布图；(c)(g)(k)(o)(s) 412 nm、443 nm、488 nm、555 nm、667 nm波段预测值与真值的差值图；(d)(h)(l)(p)(t) 412 nm、443 nm、488 nm、555 nm、667 nm波段散点密度图

Fig. 5 Test results of March 22, 2025 on test set. (a)(e)(i)(m)(q) Spatial distributions of model predictions for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (b)(f)(j)(n)(r) spatial distributions of MODIS true values for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (c)(g)(k)(o)(s) difference maps of prediction value and true value for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (d)(h)(l)(p)(t) scatter density plots for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands

表5 2023年9月22日测试集的结果统计

Table 5 Statistical results of September 22, 2023 on test set

Product	R^2	MAE / sr^{-1}	RMAE	MSE / sr^{-2}	RMSE / sr^{-1}
$R_{rs}(412)$	0.7647	0.0011	0.2581	1.97×10^{-6}	0.0014
$R_{rs}(443)$	0.8607	0.0009	0.1690	1.75×10^{-6}	0.0013
$R_{rs}(488)$	0.8552	0.0013	0.2021	3.09×10^{-6}	0.0018
$R_{rs}(555)$	0.8654	0.0019	0.2419	5.25×10^{-6}	0.0023
$R_{rs}(667)$	0.7158	0.0012	0.4234	3.33×10^{-6}	0.0018




图6 2023年9月22日测试集测试结果。(a)(e)(i)(m)(q) 412 nm、443 nm、488 nm、555 nm、667 nm波段模型预测空间分布图；(b)(f)(j)(n)(r) 412 nm、443 nm、488 nm、555 nm、667 nm波段MODIS真值空间分布图；(c)(g)(k)(o)(s) 412 nm、443 nm、488 nm、555 nm、667 nm波段预测值与真值的差值图；(d)(h)(l)(p)(t) 412 nm、443 nm、488 nm、555 nm、667 nm波段散点密度图

Fig. 6 Test results of September 22, 2023 on test set. (a)(e)(i)(m)(q) Spatial distributions of model predictions for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (b)(f)(j)(n)(r) spatial distributions of MODIS true values for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (c)(g)(k)(o)(s) difference maps of prediction value and true value for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (d)(h)(l)(p)(t) scatter density plots for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands

表6 时间差异测试集的结果统计

Table 6 Statistical results of the temporal difference test set

Product	R^2	MAE / sr^{-1}	RMAE	MSE / sr^{-2}	RMSE / sr^{-1}
$R_s(412)$	0.5476	0.0020	0.2341	6.41×10^{-6}	0.0025
$R_s(443)$	0.7052	0.0019	0.1971	5.20×10^{-6}	0.0023
$R_s(488)$	0.8457	0.0016	0.1264	3.68×10^{-6}	0.0019
$R_s(555)$	0.9037	0.0015	0.1028	3.30×10^{-6}	0.0018
$R_s(667)$	0.3429	0.0032	0.3896	1.75×10^{-5}	0.0042




图7 时间差异测试集的测试结果。(a)(e)(i)(m)(q) 412 nm、443 nm、488 nm、555 nm、667 nm 波段模型预测空间分布图；(b)(f)(j)(n)(r) 412 nm、443 nm、488 nm、555 nm、667 nm 波段 MODIS 真值空间分布图；(c)(g)(k)(o)(s) 412 nm、443 nm、488 nm、555 nm、667 nm 波段预测-真值差值对比图；(d)(h)(l)(p)(t) 412 nm、443 nm、488 nm、555 nm、667 nm 波段散点密度图

Fig. 7 Test results of temporal difference test set. (a)(e)(i)(m)(q) Spatial distributions of model predictions for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (b)(f)(j)(n)(r) spatial distributions of MODIS true values for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (c)(g)(k)(o)(s) difference maps of prediction value and true value for the 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (d)(h)(l)(p)(t) scatter density plots for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands

出“夏季最低、冬季最高、春秋为过渡”的模式。随着波长增加,季节变化幅度逐渐变大。所有波段均显示近岸及河口高、外海低的空间分布特征,且长波段对陆源输入与悬浮物变化的响应更为敏感。各波段表现出较为一致的整体季节性变化规律,但在空间异质性和季节响应强度上存在一定差异。

以 412 nm 波段为例(如图 8 中第一行), R_{rs} 在时间上呈现明显的“夏季最低、冬季最高、春秋过渡”模式,在空间上各季 R_{rs} 都表现为近岸及河口区域高、外海区域低的特征:春季近岸及河口区域出现明显高值带且范

围更为集中,夏季降至全年最低,秋季近岸及部分外海区域显著提升,而冬季为全年最高,高值区覆盖近岸及河口,并向外海大范围扩展; R_{rs} 的空间分布上,渤海南部区域高于中部及北部,尤其是在辽东湾、渤海湾西南部和黄河口等区域,数值明显高于外海,外海区域则以较低值为主。

443 nm、488 nm、555 nm 波段(图 8 中第 2 至第 4 行) R_{rs} 的季节变化趋势与 412 nm 波段基本一致,均表现为“夏季最低、冬季最高、春秋过渡”模式;但 R_{rs} 在空间分布上存在一定差异:443 nm 波段的春秋两季近




图8 模型预测各波段季节变化的空间分布图。(a)(e)(i)(m)(q) 412 nm、443 nm、488 nm、555 nm、667 nm 波段,春季;(b)(f)(j)(n)(r) 412 nm、443 nm、488 nm、555 nm、667 nm 波段,夏季;(c)(g)(k)(o)(s) 412 nm、443 nm、488 nm、555 nm、667 nm 波段,秋季;(d)(h)(l)(p)(t) 412 nm、443 nm、488 nm、555 nm、667 nm 波段,冬季

Fig. 8 Spatial distributions of seasonal variations in model predictions for each band. (a)(e)(i)(m)(q) At 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands in spring; (b)(f)(j)(n)(r) at 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands in summer; (c)(g)(k)(o)(s) at 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands in autumn; (d)(h)(l)(p)(t) at 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands in winter

岸及河口高值带明显,冬季高值区范围显著扩大,空间梯度较 412 nm 波段更加清晰;488 nm 波段整体 R_{rs} 值略高于 443 nm,秋冬季近岸高值带更宽广,外海区域全年较为稳定,近岸高值区分布更突出;555 nm 波段近岸高值区更加明显且范围更广,春、秋和冬季高值带在渤海湾、辽东湾、黄河口等沿岸分布,夏季 R_{rs} 分布更均匀,

冬季高值区进一步向外扩展;667 nm (图 8 中第 5 行)波段的 R_{rs} 与 412 nm 波段呈现相同的季节变化模式,但季节波动与空间分布展现出更显著的差异。与前 4 个波段相比,667 nm 波段 R_{rs} 各季节波动幅度增大。空间分布上,667 nm 波段 R_{rs} 的整体水平略低于其他波段,但空间分布梯度变化更大,其中秋冬季

节高值区随季节扩展的幅度最大。此外,在外海区域也能观察到 R_{rs} 明显升高,近岸-外海梯度减小,表现出该波段对悬浮颗粒物和底质扰动的高度敏感性。

同时,为验证结果的可靠性,本研究对比了同时期的 MODIS 结果,如图 9 所示。

模型估算结果与 MODIS 大气校正数据具有高度一致性,多数波段和季节数据均有一致的变化趋势,散

点大部分集中于 1:1 线附近。与 MODIS 大气校正结果相比,模型估算值在高反射率区间存在一定的低估现象,在部分波段(特别是 667 nm 长波段)和极端高值区域较离散,主要表现为:秋冬季节近岸高值区散点低于 1:1 线,从而导致高值的空间范围和强度低估;在蓝绿波段(412、443、488、555 nm),模型结果与 MODIS 数据的季节变化趋势较一致,散点分布较为紧密,但仍存在部分散点偏离 1:1 线的情况。




图 9 模型预测得到的各波段季节变化散点密度图。(a)(e)(i)(m)(q) 412 nm、443 nm、488 nm、555 nm、667 nm 波段,春季;(b)(f)(j)(n)(r) 412 nm、443 nm、488 nm、555 nm、667 nm 波段,夏季;(c)(g)(k)(o)(s) 412 nm、443 nm、488 nm、555 nm、667 nm 波段,秋季;(d)(h)(l)(p)(t) 412 nm、443 nm、488 nm、555 nm、667 nm 波段,冬季

Fig. 9 Scatter density plots of seasonal variations in model predictions for each band. (a)(e)(i)(m)(q) At 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands in spring; (b)(f)(j)(n)(r) at 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands in summer; (c)(g)(k)(o)(s) at 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands in autumn; (d)(h)(l)(p)(t) at 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands in winter

4 讨 论

4.1 DN 值与大气层顶反射率建模差异

DN 值是将接收到的辐射能量经过模数转换后得到的数字化表示,它属于原始遥感影像的灰度级数据^[12]。大气层顶反射率是对 DN 值进行辐射定标后并进行归一化的物理量,它表示大气和地物共同作用下单位入射辐射能量被反射到传感器的比例,具有明确的物理意义与时空可比性^[12]。

DN 值不仅反映地表实际反射特性,还受到传感器响应特性、地表类型、大气条件等多种因素的共同作用^[13],因此 DN 值的大小并不能真实反映某一位置或场景的真实反射率水平,采用 DN 值建模对结构设计和泛化能力提出较高的要求。

相较而言,大气层顶反射率消除了传感器增益、偏置等仪器特性的影响^[13]。基于大气层顶反射率进行建模,可以有效降低外部扰动的不确定性,从而更有利于在多时空、多传感器场景下的应用。同时,模型的建模结构复杂度降低,且对样本分布的要求也降低。然而,大气层顶反射率依赖于前期高质量的定标与数据处理,如果出现定标信息缺失、传感器状态异常或老化等情况,则会引入较大的误差^[13]。

本研究以 MERSI-II 的 DN 值作为模型的输入,模型需要同时学习多种复杂且非线性的外部扰动,从而实现从 MERSI-II 的 DN 值到等效 MODIS 值的有效映射。这种建模流程的挑战之处在于 DN 值并不能等效为实际的反射特征,输入及输出数据之间的对应关系复杂,模型的干扰因素较多,模型的稳定性、适用性及泛化能力等面临较大挑战;该流程的好处在于比较简便,并且可以绕过前期的辐射定标,避免定标系数不准确、定标环境变化等带来的系统误差,从而减小人为定标产生的误差的影响。

4.2 模型适用性

本研究基于 FY3D/MERSI-II 与 Aqua/MODIS 高质量时空匹配数据集,构建并优化了多输入 MLP 神经网络大气校正模型,实现了对渤海区域离水遥感反射率的高精度反演。模型在渤海区域 5 波段均表现出优异的训练与验证效果;该模型具有高精度,在多种时空条件下能准确反演渤海区域离水遥感反射率的空间分布及季节变化趋势。

模型在渤海区域不同时间和观测条件下展现出良好的适用能力。对于严格时间匹配的 2025 年 3 月 22 日和 2023 年 9 月 22 日测试集,443 nm、488 nm 和 555 nm 等主要波段的预测结果与 MODIS 真值分布高度一致,能准确反映离水遥感反射率的空间分布和季节变化趋势;在 MERSI-II 与 MODIS 观测时间有差异的测试集上,模型在主波段依然保持较好的泛化能力和较小的误差。模型在一定程度上能突破卫星观测时间限制,稳定地模拟离水遥感反射率的

空间动态变化趋势;但在 412 nm 和 667 nm 波段,模型预测的系统性偏差较大,主要表现为高值区高估、低值区“堆积”的现象^[14];同时时间不严格匹配使模型的预测精度和相关性进一步下降。因此,模型虽然具备较强的时空适应性,但模型泛化能力未来仍需改善。

由于 MERSI-II 与 MODIS 在仪器响应特性和观测几何上存在差异,匹配像元对时可能在几何条件上不完全一致,可能引入一定的不确定性。本研究在进行模型优化训练时,考虑到匹配点对之间在不同仪器天顶角和方位角信息上的差异,分别加入天顶角和方位角进行模型训练。结果表明方位角影响较大,天顶角影响较小,因此在模型训练时,将基于太阳和传感器方位角计算出的相对方位角作为模型的输入参数。

为进一步评估模型在其他区域的适用性,本研究将模型应用于 2025 年 2 月 13 日中国黄海区域(119°E~127°E, 31°N~37°N)的 MERSI-II 数据,经过严格时空匹配得到 22 万余个有效像元进行独立测试(图 10)。

如图 10 所示,模型较好地重现黄海区域离水遥感反射率的空间分布格局。在 555 nm 和 667 nm 波段 R^2 分别为 0.6827 和 0.5640, MAE 均低于 0.003,表现出模型的预测结果与 MODIS 数据具有较高的一致性,数据误差较小;然而,在 412 nm、443 nm 等短波段,模型的相关性与精度下降(R^2 分别为 0.2577、0.3057),主要表现为近岸高浑浊区域和部分高值存在一定偏差,但模型估算结果的空间分布趋势仍与 MODIS 大体一致。

尽管本研究所构建的 MLP 神经网络大气校正模型能较好地重现区域离水遥感反射率的空间分布,但仍存在一定局限性。针对 MODIS 无法获得可靠的大气校正结果的像元,如高浑浊水体或强吸收性气溶胶区域等,本模型同样难以实现准确反演。由于缺乏这些区域的有效参考数据,模型无法针对性地学习相应区域的特征,尽管模型具有一定的泛化能力,但这些区域的特征分布仍可能存在估算偏差。因此,针对实际应用场景的像元质量判别以及模型在高浑浊水体或强吸收性气溶胶等区域的适用性仍需要持续深入探索。

本研究的意义在于通过构建机器学习模型,获取与 MODIS 大气校正精度相当的离水遥感反射率资料,为下一步水色要素反演提供支持。为进一步验证模型的准确性,推广模型的应用,需要加强模型反演结果与现场观测数据的同步对比,全面评估模型在不同水体环境下的适用性与预测精度;此外,还应开展与其他卫星传感器(如 VIIRS、OLCI 等)产品的系统对比,考察模型在不同传感器下的通用性。




图 10 黄海区域测试集测试结果。(a)(e)(i)(m)(q) 412 nm、443 nm、488 nm、555 nm、667 nm 波段模型预测空间分布图；(b)(f)(j)(n)(r) 412 nm、443 nm、488 nm、555 nm、667 nm 波段 MODIS 真值空间分布图；(c)(g)(k)(o)(s) 412 nm、443 nm、488 nm、555 nm、667 nm 波段预测值与真值的差值图；(d)(h)(l)(p)(t) 412 nm、443 nm、488 nm、555 nm、667 nm 波段的散点密度图

Fig. 10 Test results of the Yellow Sea region test set. (a)(e)(i)(m)(q) Spatial distributions of model predictions for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (b)(f)(j)(n)(r) spatial distributions of MODIS true values for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (c)(g)(k)(o)(s) difference maps of predicted value and true value for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands; (d)(h)(l)(p)(t) scatter density plots for 412 nm, 443 nm, 488 nm, 555 nm, and 667 nm bands

5 结 论

本文开展了针对 FY3D/MERSI-II 数据在渤海区域的大气校正研究,通过构建包含三层隐藏层结构的 MLP 模型,以 Aqua/MODIS 大气校正后的遥感反射率为参考基准,结合 MERSI-II 的 5 个可见光波段 DN 值及多种辅助特征,实现了 MERSI-II 等效 MODIS 离水遥感反射率的反演。与前人依赖物理辐射传输模型或查找表的传统做法相比,本研究直

接采用 MODIS 大气校正产品作为参考输出,不依赖于复杂的传感器定标过程,可规避定标误差对蓝光等敏感波段反演的影响。此外,本研究同时引入了区域背景场等物理约束和参数优化策略,有效提升了在浑浊区域的适应性,改善了算法的反演性能。

通过上百组参数优选实验,本研究获得了预测稳定且泛化能力优良的最优模型,其整体训练 R^2 达 0.9591;通过引入多个独立测试集对模型进行系统评估,发现模型在渤海区域具有良好的季节泛化能力,反

演结果准确反映了研究区域“夏季最低、冬季最高、春秋过渡”的季节变化模式和“近岸高、外海低”的空间分布格局。在 2025 年 3 月 22 日测试集中, 488、555 nm 等主要波段的 R^2 分别为 0.9105 和 0.9525, RMSE 为 0.0010 和 0.0009; 在 2023 年 9 月 22 日测试集中, 模型在 443 nm 和 555 nm 波段的 R^2 分别为 0.8607 和 0.8654。这些结果优于 OC-SMART 与 SIRAW 在渤海区域的同类指标。

综上所述, 本研究模型在不同时空测试集和多年数据集中均能准确呈现渤海区域“近岸高、外海低”的空间分布格局以及“夏季最低、冬季最高、春秋过渡”的季节变化特征; 不同时间及不同区域的对比验证结果表明, 模型具有一定的泛化和迁移能力; 未来需要进一步加强现场同步观测验证, 优化模型精度和适用性。

参 考 文 献

- [1] Gordon H R, Clark D K. Clear water radiances for atmospheric correction of coastal zone color scanner imagery[J]. *Applied Optics*, 1981, 20(24): 4175-4180.
- [2] He X Q, Bai Y, Pan D L, et al. Atmospheric correction of satellite ocean color imagery using the ultraviolet wavelength for highly turbid waters[J]. *Optics Express*, 2012, 20(18): 20754-20770.
- [3] Schroeder T, Fischer J, Schaale M, et al. Artificial-neural-network-based atmospheric correction algorithm: application to MERIS data[J]. *Proceedings of SPIE*, 2003, 4892: 124-132.
- [4] He X Q, Pan T F, Bai Y, et al. Intelligent atmospheric correction algorithm for polarization ocean color satellite measurements over the open ocean[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 4201322.
- [5] Medina-Lopez E. Machine learning and the end of atmospheric corrections: a comparison between high-resolution sea surface salinity in coastal areas from top and bottom of atmosphere sentinel-2 imagery[J]. *Remote Sensing*, 2020, 12(18): 2924.
- [6] Pei X, Yang L K, Ji W Q, et al. Applying the dark target aerosol algorithm to MERSI-II: retrieval and validation of aerosol optical depth over the ocean[J]. *Advances in Atmospheric Sciences*, 2024, 41(12): 2446-2463.
- [7] Fan Y Z, Li S Q, Han X Z, et al. Machine learning algorithms for retrievals of aerosol and ocean color products from FY-3D MERSI-II instrument[J]. *Journal of Quantitative Spectroscopy and Radiative Transfer*, 2020, 250: 107042.
- [8] Zhang X H, Shi C, Si Y D, et al. Remote sensing of aerosols and water-leaving radiance from Chinese FY-3/MERSI based on a simultaneous method[J]. *Remote Sensing*, 2023, 15(24): 5650.
- [9] Yang Z D, Zhang P, Gu S Y, et al. Capability of Fengyun-3D satellite in earth system observation[J]. *Journal of Meteorological Research*, 2019, 33(6): 1113-1130.
- [10] Song J, Duan L. The Bohai sea[M]//Sheppard C. World seas: an environmental evaluation. 3rd ed. London: Academic Press, 2019: 377-394.
- [11] Kruse R, Mostaghim S, Borgelt C, et al. Multi-layer perceptrons: a methodological introduction[M]//Computational intelligence. Cham: Springer International Publishing, 2022: 53-124.
- [12] Justice C O, Townshend J R G, Holben B N, et al. Analysis of the phenology of global vegetation using meteorological satellite data[J]. *International Journal of Remote Sensing*, 1985, 6(8): 1271-1318.
- [13] Kim W, He T, Wang D, et al. Assessment of long-term sensor radiometric degradation using time series analysis[J]. *IEEE transactions on geoscience and remote sensing*, 2013, 52(5): 2960-2976.
- [14] Doxaran D, Froidefond J M, Lavender S, et al. Spectral signature of highly turbid waters Application with SPOT data to quantify suspended particulate matter concentrations[J]. *Remote Sensing of Environment*, 2002, 81(1): 149-161.

Machine Learning-Based Atmospheric Correction Study for FY3D/MERSI-II Sensor

Song Shunying¹, Qiu Zhongfeng^{2,3*}, Zhan Yating^{1,4,5}, Duan Chaofan^{6**}, Wu Yan²

¹*School of Marine Sciences, Nanjing University of Information Science and Technology, Nanjing 210044, Jiangsu, China;*

²*School of Electronics & Information Engineering, Nanjing University of Information Science & Technology, Nanjing 210044, Jiangsu, China;*

³*Sanya Ocean Laboratory, Sanya 572025, Hainan, China;*

⁴*Jiangsu Geological Survey, Nanjing 210018, Jiangsu, China;*

⁵*Key Laboratory of Satellite Remote Sensing Application, Jiangsu Provincial Department of Natural Resources, Nanjing 210018, Jiangsu, China;*

⁶*College of Information and Communications, National University of Defense Technology, Wuhan 430015, Hubei, China*

Abstract

Objective The medium resolution spectral imager-II (MERSI-II) onboard the Fengyun-3D (FY3D) satellite provides abundant ocean color spectral bands and serves as an essential data source for China's independent marine environment monitoring. However, due to the lack of sufficient synchronous *in-situ* observations and the complex atmospheric influences over optically diverse waters, an official atmospheric correction product for FY3D/MERSI-II has not yet been released, which constrains its application in ocean color remote sensing. Traditional physics-based atmospheric correction algorithms, such as those relying on the dark-pixel assumption within radiative transfer models, often fail in highly turbid coastal regions such as the Bohai Sea, resulting in substantial uncertainties in the retrieval of water-leaving reflectance.

To address these limitations, this study develops an atmospheric correction model for FY3D/MERSI-II based on a machine-learning framework using a multi-layer perceptron (MLP). The proposed model establishes an end-to-end nonlinear mapping from the original digital number (DN) values to the equivalent MODIS water-leaving reflectance. The objective is to improve the accuracy, stability, and applicability of atmospheric correction for FY3D/MERSI-II data in optically complex and highly turbid coastal environments.

Methods The study area of this research is the Bohai Sea, which is characterized by complex optical properties and strong turbidity gradients. Temporally and spatially matched datasets from FY3D/MERSI-II and Aqua/MODIS acquired in 2024 were utilized to construct high-quality training and validation samples. Approximately 1.3 million valid pixel pairs were obtained under strict matching constraints (temporal difference of ≤ 20 min and spatial distance of ≤ 1 km), with 80% used for training and 20% for validation. Additionally, MERSI-II data from 2023 and 2025 were selected as independent test sets. The model inputs include DN values from five visible MERSI-II bands, solar and sensor zenith and azimuth angles, geolocation, and observation time, while the outputs correspond to the MODIS atmospherically corrected reflectance for the same five bands.

This study enhanced model performance and robustness by introducing a multi-dimensional feature-weighting scheme that integrated temporal, spatial, angular, and regional background-field binning. Moreover, early stopping and dropout techniques were employed to effectively mitigate overfitting. More than one hundred parameter optimization experiments were conducted, evaluating various network architectures, loss functions, and weighting combinations. The optimal configuration employs mean absolute error (MAE) as the loss function and incorporates spectral, temporal, angular, and background-field weighting (Scheme II). The final network architecture comprises three hidden layers with 72, 48, and 32 neurons, respectively.

Results and Discussions The optimized MLP model exhibits robust performance, achieving R^2 of 0.9591, with correlation coefficients exceeding 0.93 for all spectral bands and RMSE ranging from 0.0009 to 0.0011. For the independent test acquired on March 22, 2025, the model demonstrated the best performance, with R^2 values of 0.9105 and 0.9525 for the 488 nm and 555 nm bands, respectively, and MAE values below 0.0010. The September 22, 2023 test produced similarly consistent and reliable predictions, indicating that the model maintains stability across different temporal and environmental conditions. The temporal-difference test further confirmed the model's strong generalization ability, except for minor deviations in the 412 nm and 667 nm bands.

Using the trained MLP model, multi-temporal FY3D/MERSI-II data from 2022 to 2024 were processed to derive water-leaving reflectance over the Bohai Sea. The results reveal pronounced spatiotemporal patterns: seasonally characterized by "lowest in

summer, highest in winter, and transitional in spring and autumn”, and spatially by a gradient of “high nearshore and low offshore”, showing strong consistency with the MODIS atmospherically corrected products. Compared with existing algorithms such as OC-SMART and SIRAW, the proposed model achieved higher correlation and accuracy across the main visible bands, particularly in the longer wavelength region (667 nm), where it exhibited superior stability and reduced bias. Furthermore, the model was successfully applied to the Yellow Sea dataset, maintaining high consistency with MODIS-derived results. This cross-regional validation confirms the model’s strong generalization capability and adaptability to different optical environments.

Conclusions This study presents an atmospheric correction methodology for FY3D/MERSI-II based on an MLP neural network that achieves an end-to-end transformation from raw DN values to MODIS-equivalent water-leaving reflectance. The proposed method effectively overcomes the limitations of traditional physics-based approaches, such as the reliance on dark-pixel assumptions and complex radiative calibration processes, which are often invalid in highly turbid waters. By integrating multi-dimensional feature weighting and regional background constraints, the model achieves accuracy comparable to MODIS products in the Bohai Sea, successfully reproducing the spatial pattern of “high nearshore, low offshore” and the seasonal pattern of “highest in winter, lowest in summer, and transitional in spring and autumn”.

The machine learning-based atmospheric correction method developed in this study demonstrates strong feasibility in highly turbid waters and significantly outperforms the OC-SMART and SIRAW algorithms in comparable metrics. Future work will focus on integrating synchronous *in-situ* measurements, multi-sensor data validation, and hybrid physical-learning models to further enhance the physical interpretability, temporal adaptability, and global applicability of the proposed method.

Key words ocean optics; FY3D; MERSI-II; multi-layer perceptron; atmospheric correction