

DOI: 10.13671/j.hjkxxb.2024.0231

莫锦英, 田义超, 王家乐, 等. 2024. 基于机器学习的养殖池-红树林-海洋复合生态系统氨氮遥感反演[J]. 环境科学学报, 44(11): 415-429

MO Jinying, TIAN Yichao, WANG Jiale, *et al.* 2024. Remote sensing inversion of ammonia nitrogen in aquaculture pond mangrove marine composite ecosystem based on machine learning[J]. Acta Scientiae Circumstantiae, 44(11): 415-429

基于机器学习的养殖池-红树林-海洋复合生态系统氨氮遥感反演

莫锦英^{1,2}, 田义超^{1,2,3,4,5,*}, 王家乐¹, 杜金泽⁶, 张强¹, 张亚丽¹, 陶进¹, 林俊良¹

1. 北部湾大学资源与环境学院, 钦州 535011
2. 广西大学资源环境与材料学院, 南宁 530004
3. 广西北部湾海洋环境变化与灾害研究重点实验室, 钦州 535011
4. 北部湾海洋发展中心, 钦州 535011
5. 北部湾海洋地理信息资源开发利用重点实验室, 钦州 535011
6. 北部湾大学海洋学院, 钦州 535011

摘要: 氨氮($\text{NH}_3\text{-N}$)是监测养殖污染和衡量水质优劣的主要指标之一, 对水产养殖和近海生态环境产生重要影响, 因此定量评估 $\text{NH}_3\text{-N}$ 浓度有助于维护水产养殖业的健康发展和近海环境的监管保护. 本研究基于 Sentinel-2 卫星提取的单波段 B5~B8a、波段组合 B1/B8 和 B1-B5、水体指数和植被指数, 采用极端梯度提升(XGBR)、轻量级梯度提升机(LGBM)、随机森林(RF)和 K 最近邻(KNNR)4 种机器学习模型, 基于决定系数(R^2)和均方根误差(RMSE)对不同模型的性能进行评价, 并选取性能最优的模型, 对茅尾海及其沿岸养殖池 $\text{NH}_3\text{-N}$ 的浓度分布特征进行研究. 结果表明: ①XGBR 模型性能最优, 训练集 R^2 达到 0.9340, RMSE 为 $0.0446 \text{ mg}\cdot\text{L}^{-1}$; 测试集 R^2 达到 0.7522, RMSE 为 $0.0249 \text{ mg}\cdot\text{L}^{-1}$. 此外, 单波段和波段组合对 $\text{NH}_3\text{-N}$ 浓度变化较为敏感, 在 XGBR 模型中的贡献度最高. ②茅尾海 2023 年 11 月 $\text{NH}_3\text{-N}$ 浓度($0.058 \text{ mg}\cdot\text{L}^{-1}$)高于 2023 年 12 月($0.055 \text{ mg}\cdot\text{L}^{-1}$), 呈现近岸高于远岸, 河口区域出现较高浓度的空间分布特征; 养殖池 2023 年 11 月 $\text{NH}_3\text{-N}$ 浓度($0.107 \text{ mg}\cdot\text{L}^{-1}$)高于 2023 年 12 月($0.072 \text{ mg}\cdot\text{L}^{-1}$), 钦江沿岸高于茅岭江沿岸. ③养殖池 $\text{NH}_3\text{-N}$ 浓度高于茅尾海. 养殖水体中 $\text{NH}_3\text{-N}$ 通过康熙岭片区和尖山片区红树林后的降低效果要高于沙井片区. 本研究说明了 Sentinel-2 数据结合 XGBR 模型在茅尾海及其沿岸养殖池 $\text{NH}_3\text{-N}$ 浓度反演中表现出良好的性能, 为海洋环境管理和海洋资源规划提供了科学依据和技术支持.

关键词: $\text{NH}_3\text{-N}$; 机器学习算法; Sentinel-2; 养殖池; 红树林; 茅尾海

文章编号: 0253-2468(2024)11-0415-15 中图分类号: X87, X832 文献标识码: A

Remote sensing inversion of ammonia nitrogen in aquaculture pond mangrove marine composite ecosystem based on machine learning

MO Jinying^{1,2}, TIAN Yichao^{1,2,3,4,5,*}, WANG Jiale¹, DU Jinze⁶, ZHANG Qiang¹, ZHANG Yali¹, TAO Jin¹, LIN Junliang¹

1. School of Resources and Environment, Beibu Gulf University, Qinzhou 535011
2. School of Resources, Environment and Materials, Guangxi University, Nanning 530004
3. Guangxi Key Laboratory of Marine Environmental Change and Disaster in Beibu Gulf, Qinzhou 535011
4. Gulf Ocean Development Research Center, Beibu Gulf University, Qinzhou 535011
5. Key Laboratory of Marine Geographic Information Resources Development and Utilization in the Beibu Gulf, Beibu Gulf University, Qinzhou 535011
6. School of Marine Sciences, Beibu Gulf University, Qinzhou 535011

Abstract: Ammonia nitrogen ($\text{NH}_3\text{-N}$) is a critical indicator for monitoring aquaculture pollution and measuring water quality, which has a significant impact on aquaculture and the nearshore ecological environment. Consequently, the quantitative evaluation of $\text{NH}_3\text{-N}$ concentrations is essential for

收稿日期: 2024-04-02 修回日期: 2024-05-17 录用日期: 2024-05-20

基金项目: 国家自然科学基金项目(No. 42261024); 广西林业厅项目(No. 桂林科研[2022]第4号); 北部湾大学海洋科学一流学科项目(No. DRB003); 广西高校人文社会科学重点研究基地项目(No. BHZKY2202); 广西高校人文社科重大项目(No. JDZD202214); 广西创新驱动发展专项项目(No. AA18118038); 广西科技基地和人才项目(No. 2019AC20088)

作者简介: 莫锦英(1999—), 女, E-mail: 2082348270@qq.com; * 责任作者, E-mail: tianyichao1314@hotmail.com

maintaining the healthy development of aquaculture industry and regulatory protection of nearshore environment. This study utilized single band B5~B8a, band combination B1/B8 and B1-B5, water index and vegetation index extracted from Sentinel-2 satellite. Four machine learning algorithms were employed: extreme gradient boosting regression (XGBR), light generalized boosted regression (LGBM), random forest (RF), and k-nearest neighbor regression (KNNR). The performance of each model was evaluated with the coefficient of determination (R^2) and root mean square error (RMSE), and the optimal performance was selected to analyse the concentration distribution characteristics of $\text{NH}_3\text{-N}$ in Maowei Sea and its coastal aquaculture ponds. The findings indicated that ① the XGBR algorithm exhibited superior performance, with a training set of $R^2=0.9340$ and $\text{RMSE}=0.0446 \text{ mg}\cdot\text{L}^{-1}$; test set $R^2=0.7522$ and $\text{RMSE}=0.0249 \text{ mg}\cdot\text{L}^{-1}$. In addition, single band and band combination were most sensitive to $\text{NH}_3\text{-N}$ concentration and made the highest contribution in the XGBR model. ② The $\text{NH}_3\text{-N}$ concentration in Maowei Sea was $0.058 \text{ mg}\cdot\text{L}^{-1}$ in November 2023, which was higher than that of $0.055 \text{ mg}\cdot\text{L}^{-1}$ in December 2023, showing a spatial distribution pattern of higher concentration near the shore compared to the far shore, and a higher concentration in the estuarine area. The $\text{NH}_3\text{-N}$ concentration in the aquaculture pond was $0.107 \text{ mg}\cdot\text{L}^{-1}$ in November 2023 which was higher than that of $0.072 \text{ mg}\cdot\text{L}^{-1}$ in December 2023, and the $\text{NH}_3\text{-N}$ concentration in aquaculture ponds is higher along the Qin River than along the Maoling River. ③ The $\text{NH}_3\text{-N}$ concentration in the aquaculture pond was higher than that in Maowei Sea. The reduction effect of $\text{NH}_3\text{-N}$ in aquaculture water after passing through mangroves in Kangxiling and Jianshan areas was higher than that in Shajing areas. The combination of Sentinel-2 data and XGBR model has shown good performance in retrieving $\text{NH}_3\text{-N}$ concentration in Maowei Sea and its coastal aquaculture ponds, providing scientific basis and technical support for marine environmental management and marine resource planning.

Keywords: $\text{NH}_3\text{-N}$; machine learning algorithm; Sentinel-2; aquaculture pond; Mangrove; Maowei Sea

1 引言(Introduction)

氨氮(Ammonia nitrogen, $\text{NH}_3\text{-N}$)作为水体中的重要营养物质,是评价水质优劣和监测养殖污染变化的重要指标之一(Wang *et al.*, 2020).据联合国粮农组织(FAO)发布的《2022年世界渔业和水产养殖状况》(The State of World Fisheries and Aquaculture 2022)报告统计,全球水产养殖的总产量达到2.14亿t,其中,中国占全球产量的60%以上.有研究表明,水产养殖造成了海洋富营养化为 $140\times 10^4 \text{ t N}$ 当量,是海洋富营养化的主要原因之一(Ahmed *et al.*, 2019).在水产养殖过程中,高密度的养殖模式和过度饲料投喂的现象易导致 $\text{NH}_3\text{-N}$ 在养殖水体中的浓度急速上升(Li *et al.*, 2017; Breitburg *et al.*, 2018; Han *et al.*, 2020).而由于养殖尾水未经处理直接排入近海,导致水体中 $\text{NH}_3\text{-N}$ 浓度上升,增加了水体水质下降、富营养化和生物多样性降低等环境风险(Li *et al.*, 2014; Neofitou *et al.*, 2019).此外, $\text{NH}_3\text{-N}$ 浓度的增加也会导致水中毒性的上升,从而导致大面积水生动物中毒进而影响其生长,造成大量经济损失(张卫强等, 2012; 马晓娜等, 2021).目前关于 $\text{NH}_3\text{-N}$ 监测的研究较少,影响了对水产养殖和近海污染的监控和管理.因此,如何及时、准确的掌握 $\text{NH}_3\text{-N}$ 浓度的时空动态变化和影响因素的信息,对水产养殖业的健康发展和近海环境的监管保护具有重要意义.

传统的 $\text{NH}_3\text{-N}$ 监测方法是以现场监测为主,将水样带回实验室进行化学分析(Li *et al.*, 2020).但这类方法需要人工采样和大量繁琐的实验分析才能获得准确的水质参数,且时效性差、不连续、范围小,难以满足大范围且动态、快速的 $\text{NH}_3\text{-N}$ 浓度变化要求(Gholizandeh *et al.*, 2016).因此,此类方法更多用于对其他监测技术的验证与补充(王皓等, 2012).遥感监测技术具有时效性强、监测范围和监测成本低等优点,在内陆湖泊和近岸海域水质动态监测中具有不可替代的优越性(Huang *et al.*, 2015),在 $\text{NH}_3\text{-N}$ 浓度监测方面具有巨大的应用潜力.国内外的众多学者利用遥感监测技术对 $\text{NH}_3\text{-N}$ 进行了研究.Shlah 等(2021)、Sudduth 等(2015)和龚绍琦等(2008)使用实测光谱数据与 $\text{NH}_3\text{-N}$ 建立联系,为遥感定量研究水体中的氮奠定了基础.虽然地面实测光谱技术具有波段多、光谱范围窄、数据量大等特点(Bansod *et al.*, 2018),能够有效替代 $\text{NH}_3\text{-N}$ 传统实验分析,但获得的遥感数据为点源信息,需要与其它技术结合分析.无人机航空遥感具有高分辨率、高频采集以及实时观测等优点,在 $\text{NH}_3\text{-N}$ 监测上得到了应用.Yao 等(2024)、庞吉玉等(2023)和孙骄阳等(2019)基于无人机多光谱影像和实测水质数据构建了 $\text{NH}_3\text{-N}$ 反演模型.但受飞行高度和机载传感器等限制,无人机航空遥感技术只能在小尺度区域应用.此外由于无人机操控难度大,影像处理复杂,所以实际应用较少.而卫星航天遥感技术在快速获取大范围地表信息上具有不可比拟的优势,同时可免费获取其影像资料,在 $\text{NH}_3\text{-N}$ 监测上应用更广.在水质遥感监测上常用的遥感影像有 Landsat-8(Cao *et al.*, 2022)、Sentinel-2(Cao *et al.*, 2023)和 GF-2(Yu *et al.*, 2022)等.而与其他遥感数据源相比, Sentinel-2 能够同时满足高时间分辨率和高空间分辨率的要求,在 $\text{NH}_3\text{-N}$ 浓度遥感反演上具有应用前景.Tian 等(2022)、Dong 等(2020)和王歆晖等

(2020)均利用 Sentinel-2 影像建立了 $\text{NH}_3\text{-N}$ 反演模型,获得了高质量的反演产品,这也进一步说明了 Sentinel-2 在 $\text{NH}_3\text{-N}$ 监测上的可行性.但前者的研究多集中在内陆湖泊和河流等区域,对于养殖水质以及近海海域的应用效果还需要进一步验证.

目前应用在水质遥感反演的方法主要包括分析模型(Chawla *et al.*, 2020)、半分析模型(Yang *et al.*, 2022)、经验模型(Ouma *et al.*, 2018)和机器学习模型(Saha *et al.*, 2024)4类.分析模型是通过模拟光在大气和水体中的传播过程,建立反射光谱与水质参数之间的关系,但由于数据获取难度大、准确性要求高和偏向理论分析的特点,导致其实用性较差(Le *et al.*, 2009; Palmer *et al.*, 2015).半分析模型是将某些辐射传输与生物光学模型中难以获取的参数替换为经验方法获取的一种方法,但建模比较繁琐,迁移性也因某些光学参数为经验值的替代而无法保证准确性(Werdell *et al.*, 2018; 刑帅等, 2022).此外,由于 $\text{NH}_3\text{-N}$ 属于非光学活性物质,与悬浮颗粒物、叶绿素 a 和溶解有机质(CDOM)等光学活性参数相比,其浓度变化不易通过光谱特征直接捕捉(Zhang *et al.*, 2022; 高佳欣等, 2023),使得分析模型和半分析模型在 $\text{NH}_3\text{-N}$ 反演上受到限制.因此,许多研究使用经验模型进行 $\text{NH}_3\text{-N}$ 浓度遥感估算.Zhu 等(2023)和吴欢欢等(2021)均基于回归分析建立了 $\text{NH}_3\text{-N}$ 反演模型,但其验证精度均低于 0.6,模型性能不佳.由于内陆和沿海水体具有复杂特性, $\text{NH}_3\text{-N}$ 与遥感反射率之间往往不是简单的线性关系,因此经验模型在 $\text{NH}_3\text{-N}$ 反演上可能效果不是最优.水体中复杂的光谱特征导致水质遥感监测在本质上是一个非线性的反演过程.而机器学习具有较强的适用性、组织性和容错性,通过持续不断的学习、校正和误差反馈提升遥感反演模型的精度和泛化能力(Guo *et al.*, 2021; Li *et al.*, 2021; 黄振辉等, 2024),为 $\text{NH}_3\text{-N}$ 反演提供了新的方向.Zhao 等(2022)、Chen 等(2021)和庞吉玉等(2023)学者基于随机 XGBR、RF 和 KNNR 等机器学习算法对 $\text{NH}_3\text{-N}$ 进行预测评估,发现其反演效果较好.这些研究成果证明了机器学习算法在 $\text{NH}_3\text{-N}$ 反演上的应用潜力.此外,Huang 等(2023)和刘梅等(2022)将机器学习模型拓展于沿海养殖水体和池塘养殖水体,并取得一定成效,说明了机器学习模型可能适用于养殖水体 $\text{NH}_3\text{-N}$ 浓度反演.但目前利用机器学习预测 $\text{NH}_3\text{-N}$ 浓度的研究较少,多数仍集中在内陆河流与湖泊,对于近海水体和养殖水体的研究还需要进一步进行.不同机器学习算法在本研究区的适用性如何? 其反演效果如何? 这方面的研究还需要进一步探索.

茅尾海位于北部湾北部,属钦州湾内湾.该区域渔业养殖区资源丰富,是中国最大的牡蛎养殖区和育苗区,牡蛎养殖筏约占海湾面积的 20%(Yang *et al.*, 2019; Xu *et al.*, 2020).同时该区域是养殖池塘分布较为集中的区域,养殖池塘主要分布在茅尾海北部沿岸(彭小燕等, 2022; 吴舒燕等, 2024).与此同时,该区域的红树林是中国最大、最典型的红树林生态系统群落,集中分布于茅尾海北部的钦江、茅岭江河口地区以及康熙岭、海虾楼、坚心围等滨海区域(蒙良莉等, 2020; 黄星等, 2022).红树林在水质净化上发挥着关键作用,对维持生态系统稳定起一定帮助(Wadnerkar *et al.*, 2019).该区域是一个集养殖、红树林保护区、旅游及港口于一体的亚热带半封闭海湾.由于长年开展养殖活动,该区域整体水质较差,富营养化问题时有发生,其中氮是主要污染物(Xie *et al.*, 2024).该海域海水养殖过程中 $\text{NH}_3\text{-N}$ 的增加和养殖池排放的养殖尾水中的高浓度的 $\text{NH}_3\text{-N}$ 排放对该海域水质产生影响尚不明确,红树林能否有效的控制养殖尾水中高浓度的 $\text{NH}_3\text{-N}$ 排入该区域尚未有明确的研究.此外,目前针对该区域的 $\text{NH}_3\text{-N}$ 的研究较少,尚未有将虾塘、红树林和茅尾海作为一个整体探究 $\text{NH}_3\text{-N}$ 浓度变化的研究.基于此,本文通过 Sentinel-2 影像与实测 $\text{NH}_3\text{-N}$ 数据,利用单波段及其组合变量、水体指数和植被指数结合 XGBR、LGBM、RF 和 KNNR 4 种机器学习算法构建 $\text{NH}_3\text{-N}$ 水质反演模型.本文主要有 3 个研究目标:①探究不同机器学习方法在 $\text{NH}_3\text{-N}$ 反演上的适用性以及不同特征变量对于构建模型的影响;②了解 $\text{NH}_3\text{-N}$ 在养殖池和茅尾海的分布特征;③探究红树林对于 $\text{NH}_3\text{-N}$ 的水质净化作用.

2 材料与方法(Materials and methods)

2.1 研究区域

本研究区位于南海北部湾北部的茅尾海及其北部沿岸区域($108^{\circ}28'\sim 108^{\circ}37'\text{E}$, $21^{\circ}48'\sim 21^{\circ}55'\text{N}$)(图 1a、1b),总面积约 135 km^2 (Chen *et al.*, 2018).该区域位于亚热带地区,具有典型的亚热带季风气候特征,年平均气温约 22°C ,年平均降雨量约 1600 mm ,太阳辐射强(田义超等, 2019).该区域主要受茅岭江、大榄江和

钦江3条入海径流影响(图1c),在河流与海水交汇作用下使得入海口形成泥沙质平滩和潮沟岛屿景观.优越的自然地理因素为红树林生长提供条件,使得该地区的红树林成为我国面积最大和最典型的红树林分布区.此外独特的生态环境和自然资源使该地区养殖业发达,渔业资源丰富.该地区周边岸基养殖以传统池塘养殖为主,养殖面积达5万余亩.养殖种类以南美白对虾为主,其他种类如蟹类、鱼类的比例相对较少.养殖尾水排水时间段在夏秋两季,主要集中在养殖后期、收获期和清塘期,大部分未经有效处理直接外排(彭小燕等, 2022).




图1 中国广西壮族自治区位置(a)、北部湾茅尾海研究区位置(b)及研究区采样点位(c)(基于国家测绘地理信息局标准地图服务网站下载的审图号为GS(2019)1822号的标准地图制作)

Fig. 1 Location of Guangxi (a), the study area in Maowei Sea, Beibu Gulf (b) and sampling points in the study area (c)

2.2 数据来源

2.2.1 实测数据采集与检测 本研究分别于2023年11月4—5日和2024年1月1—2日对茅尾海和养殖池进行水样采集(图1c),两次野外采样获得的样本数分别为71个和69个.在采样出发前先布设好采样点的位置,然后按照实际环境情况选取合适的地点采样,并用GPS记录好采样经纬度坐标.按照水质采样技术指导要求,在水面以下0.5 m处设置采样点,每个采样点采集5 L水样.采集水样后,带回实验室用于 $\text{NH}_3\text{-N}$ 浓度的测定.根据标准GB 17378.4-2007规定,使用靛酚蓝分光光度法对 $\text{NH}_3\text{-N}$ 进行检测.在弱碱性条件下, $\text{NH}_3\text{-N}$ 与苯酚和次氯酸盐在亚硝酰铁氰化钠的催化下生成靛酚蓝,测定波长640 nm处的吸光值,从而获取水样中的 $\text{NH}_3\text{-N}$ 浓度.

2.2.2 遥感数据获取和预处理 Sentinel-2是由欧洲空间局发射的两颗多光谱卫星组成,其中Sentinel-2A于2015年6月发射,Sentinel-2B于2017年3月发射.Sentinel-2搭载的多光谱仪器(MSI)采集了从可见光和近红外到短波红外(SWIR) (443~2190 nm)的13个光谱波段,可提供空间分辨率10、20和60 m的影像数据(表1).1颗卫星的重返周期是10 d,两颗互补,重访周期为5 d.由于Sentinel-2具有高空间分辨率和丰富的光谱信息,能够反映水质变化,有利于水质反演.特别是它是为数不多的在红边范围内(700~800 nm)具有3个波段的光学数据集之一,对叶绿素a(Chl-a)浓度、浮游植物分布等水生态信息灵敏,能够反映水体在不同环境条件下的富营养化水平(Baillarin *et al.*, 2012).与MODIS、Landsat-8和SeaWiFS等多光谱卫星相比,Sentinel-2在沿海环境监测上更具优势,更有利于 $\text{NH}_3\text{-N}$ 浓度反演.本研究从哥白尼开放获取中心(<https://dataspace.copernicus.eu/browser/>)下载经过几何校正、辐射校正以及大气校正等预处理过后的L2A级产品.由于云量和访问时间的影响,野外采样时间难与影像同步,以往的研究设定地面实测数据和遥感影像的匹配数据集的时间窗为 ± 7 d(Li *et al.*, 2021; 刘轩等, 2021; Yuan *et al.*, 2022).本研究获取与 $\text{NH}_3\text{-N}$ 采样时间接近的两幅

且云量低于10%的影像,即2023年11月1日和2023年12月26日。本研究使用SNAP软件将Sentinel-2的除Band10卷云波段外的所有波段的分辨率调整为10 m,经波段合成及裁剪处理后获得本研究区的影像数据。归一化水体指数(NDWI)能够最大化地将水体与背景地物区分开来(McFeeters, 1996)。本研究根据Sentinel-2影像光谱特征,将NDWI提取的水体结果对比分析后对分割阈值进行不断调整,以达到最优分割效果。本研究最终确定NDWI提取水体的阈值为0.1,此时基本能将茅尾海水体与地物区分并将茅尾海海域内部的养殖筏剔除。此外,养殖池与红树林区域使用目视解译法确定。

2.3 方法

2.3.1 技术路线图 在Sentinel-2数据与实测数据的基础上,本研究通过提取Sentinel-2遥感影像的单波段变量、波段组合、水体指数和植被指数,构建能够反演 $\text{NH}_3\text{-N}$ 的特征变量数据集,然后通过比较XGBR、LGBM、RF、KNNR 4种机器学习算法的预测精度,得出最优反演模型来估算研究区 $\text{NH}_3\text{-N}$ 浓度。具体技术路线如图2所示。




图2 $\text{NH}_3\text{-N}$ 浓度估算的技术路线

Fig. 2 Research technical route for estimation of $\text{NH}_3\text{-N}$

2.3.2 特征变量提取 Pearson 相关系数可以衡量变量之间的相关程度,其绝对值越接近 1,这两个变量之间的相关性越大, $|r|>0.2$ 表示具有相关性(马丰魁等, 2020;Cao *et al.*, 2023; Song *et al.*, 2024).本研究使用 SPSS 软件对实测 $\text{NH}_3\text{-N}$ 数据和 Sentinel-2 影像的单波段变量、波段比值、波段差值以及归一化指数等波段组合变量进行 Pearson 相关性分析,发现单波段 B5、B6、B7、B8 以及 B8a 和波段组合 B1/B8 以及 B1-B5 与 $\text{NH}_3\text{-N}$ 具有相关性,且在 0.01 水平上相关性显著(表 2),可以作为机器学习算法的输入变量.水体的光谱特征虽然受到水中各种物质对光辐射的吸收和散射性质影响,但 $\text{NH}_3\text{-N}$ 作为光学非活性物质,其浓度变化不易被光谱特征直接捕捉, $\text{NH}_3\text{-N}$ 与反射率之间可能存在复杂的非线性关系,Pearson 相关性分析难以充分捕捉这些相关性.有研究表明,遥感指数具有比单一波段更加敏感的信息,采用遥感指数的方法能够提高水质参数与光谱之间的敏感程度(Li *et al.*, 2020; Gao *et al.*, 2020).由于 $\text{NH}_3\text{-N}$ 是导致富营养化现象出现的主要因素,与叶绿素 a(Chl-a)具有明显的相关性(韩淑贤等, 2023; 王嗣彤等, 2024).因此本研究在 Sentinel-2 的波段变量的基础上添加了与 Chl-a 反演常用的水体指数和植被指数,以达到提高反演精度的目的.即本次研究选用了 7 个波段变量、6 个水体指数变量和 5 个植被指数变量,具体变量信息如表 2~3 所示.

表 1 Sentinel-2 波段信息			
Table 1 Sentinel-2 spectral variables list.			
波段名称	空间分辨率/m	中心波长/ μm	波长范围/ μm
气溶胶波段 (B1)	60	0.443	0.433~0.453
蓝波段 (B2)	10	0.490	0.458~0.523
绿波段 (B3)	10	0.560	0.543~0.578
红波段 (B4)	10	0.665	0.650~0.680
红边波段 (B5)	20	0.705	0.698~0.713
红边波段 (B6)	20	0.740	0.733~0.748
红边波段 (B7)	20	0.783	0.773~0.793
近红外波段 (B8)	10	0.842	0.785~0.900
近红外波段 (B8a)	20	0.865	0.855~0.875
水蒸气波段 (B9)	60	0.945	0.935~0.955
卷云波段 (B10)	60	1.375	1.360~1.390
短波红外波段 (B11)	20	1.610	1.565~1.655
短波红外波段 (B12)	20	2.190	2.100~2.280

表 2 $\text{NH}_3\text{-N}$ Pearson 相关性结果							
Table 2 Pearson correlation analysis result of $\text{NH}_3\text{-N}$							
敏感波段	B5	B6	B7	B8	B8a	B1/B8	B1-B8
Pearson 相关系数 r	0.271**	0.285**	0.250**	0.271**	0.252**	-0.318**	-0.323**

注:**表示相关关系在 0.01 水平上显著,*表示相关关系在 0.05 水平上显著.

表 3 本研究使用的指数变量			
Table 3 The indexes used in this study			
特征变量类型	变量名称	公式	参考文献
水体指数	归一化水体指数 (NDWI)	$(B3-B8)/(B3+B8)$	McFeeters, 1996
	改进的归一化水体指数 (MNDWI)	$(B3-B11)/(B3+B11)$	Xu, 2006
	增强型水体指数 (EWI)	$(B3-B8-B11)/(B3+B8+B11)$	刘宇等, 2019
	修订型归一化水体指数 (RNDWI)	$(B11-B4)/(B11+B4)$	罗崇亮, 2015
	新型水体指数 (NWI)	$(B1-(B8+B11+B12))/(B1+B8+B11+B12)$	姚焕玫等, 2022
	New 型水体指数 (NEW)	$(B1-B12)/(B1+B12)$	姚焕玫等, 2022
	归一化植被指数 (NDVI)	$(B8-B4)/(B8+B4)$	朱冰川等, 2020
植被指数	蓝色归一化植被指数 (Blue NDVI)	$(B8-B2)/(B8+B2)$	Zhang <i>et al.</i> , 2022
	绿蓝归一化植被指数 (Green-Blue NDVI)	$(B8-B3+B2)/(B8+B3+B2)$	Guo <i>et al.</i> , 2022
	红蓝归一化植被指数 (Red-Blue NDVI)	$(B8-B2+B4)/(B8+B2+B4)$	Guo <i>et al.</i> , 2022
	叶绿素植被指数 (CVI)	$B8*B4/B3$	Hunt <i>et al.</i> , 2011

2.3.3 机器学习算法 本研究选用 XGBR、LGBM、RF 和 KNNR 构建 $\text{NH}_3\text{-N}$ 反演模型,最终选择最适用的模型对 $\text{NH}_3\text{-N}$ 进行浓度估计.

(1) 极端梯度提升(XGBR).极端梯度提升(extreme gradient boosting regression, XGBR)是一类以分类回归树为基础的集成学习方法,于 2016 年由 Chen 等(2016)提出.其采用多颗 CART 树进行预测,泛化性能好,

适合解决复杂的非线性回归问题.建模流程大致为首先构建单颗树来对训练集进行预测,迭代过程中增加树来拟合上次预测的残差,最终通过多棵树模型集成来提高预测模型的准确性.该算法在目标函数中添加正则化项,可有效防止过拟合,从而减少计算量,在最短时间内得到最优解.

(2) 轻量级梯度提升机(LGBM).轻量级梯度提升机(light generalized boosted regression, LGBM)由微软提供的一种算法(周挺等, 2019),实现GBDT算法的轻量级框架,解决了GBDT在处理大样本和高维度中遇到的问题,可应对多重共线性特征,提高模型的鲁棒性.其采用直方图算法(Histogram),核心是将连续的浮点特征离散成 k 个离散值,并构造宽度为 k 的Histogram.然后遍历训练数据,统计每个离散值在直方图中的累计统计量.在进行特征选择时,根据直方图的离散值,遍历寻找最优的分割点(Mahsa *et al.*, 2023).此外, LGBM使用leaf-wise叶子生长策略,从当前所有叶子中找出分裂增益最大的叶子进行分裂,从而保证算法的高效率和防止模型的过度拟合现象的发生(何红艳等, 2022).

(3) 随机森林(RF).随机森林(random forest, RF)是一种组合了多个决策树的集成技术,最早由Breiman提出(Breiman, 2001).其模型的基本思想是通过套袋抽样技术从数据集中提取多个样本,然后为每个套袋样本建立决策树模型,并将其整合成一个综合分类器.该综合分类器通过对各个决策树模型的投票,计算出最终的分类预测结果.由于RF的随机性,通常比单个树具有更好的泛化性能,这有助于减少模型的方差,不易造成过拟合现象.

(4) K 最近邻(KNNR). K 最近邻(k-nearest neighbor regression, KNNR)模型是一种非参数模型,根据距离度量找出训练集中与其最靠近的 k 个训练样本.其建模预测流程是首先确定距离计算方法,从而确定 k 值大小,再从训练集中找到 k 个与测试样本距离最接近的样本,最后使用 k 个近邻的均值作为测试样本的预测值(Fatemeh *et al.*, 2020).由于KNNR算法的精度受近邻个数 K 的取值影响,可能会出现过拟合或者预测错误的现象(唐茂淞等, 2023).

2.3.4 模型实现与评估 本研究将140个样本数据中的80%的样本(112个)作为训练集,20%的样本(28个)作为测试集,构建 $\text{NH}_3\text{-N}$ 的反演模型.首先根据不同反演模型设置参数初始值,然后采用网络搜索法进行超参数优化确定各模型最优参数.本文将18个变量(7个波段变量、6个水体指数变量和5个植被指数变量)共同输入4个机器学习模型中进行训练,根据决定系数(R^2)和均方根误差(RMSE)选择最适合 $\text{NH}_3\text{-N}$ 浓度反演的模型.其中, R^2 和RMSE如式(1)和式(2)所示.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (1)$$

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (2)$$

式中, y_i 为第 i 个采样点的 $\text{NH}_3\text{-N}$ 浓度的真实值, $\bar{y}$ 为采样点的 $\text{NH}_3\text{-N}$ 浓度的平均值, $\hat{y}_i$ 为第 i 个采样点的 $\text{NH}_3\text{-N}$ 的预测值.

3 结果(Results)

3.1 机器学习模型性能评估与特征变量分析

图3和表4分别为4种机器学习模型对 $\text{NH}_3\text{-N}$ 反演的精度评估结果.通过对比 R^2 和RMSE可知,XGBR模拟效果最好,拟合程度最高($R^2=0.7522$, $\text{RMSE}=0.0249 \text{ mg}\cdot\text{L}^{-1}$).其次,LGBM虽然训练集的反演精度较好($R^2=0.8420$, $\text{RMSE}=0.0689 \text{ mg}\cdot\text{L}^{-1}$),但测试集表现极差($R^2=0.2136$, $\text{RMSE}=0.0443 \text{ mg}\cdot\text{L}^{-1}$).RF和KNNR反演效果很不理想,其训练集和测试集 R^2 均低于0.5,不适用于 $\text{NH}_3\text{-N}$ 模型反演.

表4 不同机器学习算法精确度评估结果

Table 4 Accuracy comparison results of different models.

机器学习 模型	训练集(80%)		测试集(20%)	
	R^2	RMSE/ ($\text{mg}\cdot\text{L}^{-1}$)	R^2	RMSE/ ($\text{mg}\cdot\text{L}^{-1}$)
XGBR	0.9340	0.0446	0.7522	0.0249
LGBM	0.8420	0.0689	0.2136	0.0443
RF	0.4816	0.1248	0.1703	0.0455
KNNR	0.1205	0.1626	0.3553	0.0401




图3 4种机器学习模型预测的 $\text{NH}_3\text{-N}$ 浓度值与实测值的散点图

Fig. 3 Performances of the four different models for $\text{NH}_3\text{-N}$ estimation on the training set and test set

XGBR能够进行特征变量筛选,输出变量特征的重要性排序结果,可以用于 $\text{NH}_3\text{-N}$ 特征变量重要性分析.本研究将所有变量导入XGBR模型中,根据重要性的强弱将特征从大到小进行排序,结果见图4.在 $\text{NH}_3\text{-N}$ 浓度反演模型中,贡献度排名前2的变量为波段变量B5和B1-B5;其次是植被指数Green-Blue NDVI和CVI,水体指数中NWI、EWI和NEW排进前十.这一结果说明波段变量在 $\text{NH}_3\text{-N}$ 反演模型中的贡献度较大.

3.2 $\text{NH}_3\text{-N}$ 的分布特征分析

本研究基于XGBR算法绘制了 $\text{NH}_3\text{-N}$ 的空间分布图.由图5可以看出,养殖池中的 $\text{NH}_3\text{-N}$ 浓度高于茅尾海,2023年11月 $\text{NH}_3\text{-N}$ 浓度整体高于12月.2023年11月养殖池 $\text{NH}_3\text{-N}$ 浓度均值为 $0.107\text{ mg}\cdot\text{L}^{-1}$,茅尾海中的 $\text{NH}_3\text{-N}$ 浓度均值为 $0.058\text{ mg}\cdot\text{L}^{-1}$,养殖池中的 $\text{NH}_3\text{-N}$ 浓度约是茅尾海的1.84倍.此外,由图5a可以看出,钦江沿岸养殖池浓度略高于茅岭沿岸;而在茅尾海海域, $\text{NH}_3\text{-N}$ 浓度大体呈现由北向南递减的趋势,在蚝排附近水体、钦江、大榄江和茅岭江河口浓度较高.2023年12月养殖池 $\text{NH}_3\text{-N}$ 浓度均值为 $0.072\text{ mg}\cdot\text{L}^{-1}$,茅尾海为 $0.055\text{ mg}\cdot\text{L}^{-1}$,养殖池中的 $\text{NH}_3\text{-N}$ 浓度约是茅尾海的1.36倍.由图5b可以看出,钦江沿岸养殖池 $\text{NH}_3\text{-N}$ 浓度大于茅岭沿岸,与2023年11月份的结果一致;而茅尾海海域中的 $\text{NH}_3\text{-N}$ 浓度近岸高于远岸,在河口、金鼓江以及鹿耳环江浓度较高.

3.3 $\text{NH}_3\text{-N}$ 浓度降低效果探讨

为探究养殖池经过红树林片区排入茅尾海内各红树林片区之间的降低效果及其差异,本研究利用XGBR模型通过Sentinel-2影像绘制2023年11月和12月 $\text{NH}_3\text{-N}$ 浓度分布图,根据结果求 $\text{NH}_3\text{-N}$ 浓度平均值,如图6a所示.本研究在康熙岭片区、尖山片区和沙井片区这3个典型红树林片区设置500 m缓冲区,根据距离红树林500 m范围内养殖池和茅尾海 $\text{NH}_3\text{-N}$ 浓度均值变化,计算养殖池至茅尾海降低百分比,具体如图6所示.由图6可以看出,康熙岭片区养殖池养殖废水经过红树林排入茅尾海的降低效果最高,为32.14%;其次是尖山片区,为17.92%;沙井片区的降低效果最低,为14.89%.




图4 XGBR模型中所有特征变量的重要性排序

Fig. 4 Ranking of the importance of all characteristic variables in the XGBR model




图5 研究区 $\text{NH}_3\text{-N}$ 浓度空间分布格局

Fig.5 Spatial distribution of $\text{NH}_3\text{-N}$ concentration in the study area

4 讨论(Discussion)

4.1 机器学习算法的选择

目前,越来越多的机器学习算法被运用在 $\text{NH}_3\text{-N}$ 浓度反演上.本研究利用 Sentinel-2 数据,选用4个不同的机器学习算法模型对茅尾海及其沿岸养殖池的 $\text{NH}_3\text{-N}$ 浓度进行估算,发现XGBR模型的精度最高,其中训练集 R^2 达到0.7522, RMSE为0.0249 $\text{mg}\cdot\text{L}^{-1}$.为进一步探究XGBR模型在本研究区的适用性和可拓展性,本研究对比分析了近年来其他 $\text{NH}_3\text{-N}$ 反演模型的精度(表5).根据表5,本文利用 Sentinel-2 数据和实测 $\text{NH}_3\text{-N}$ 数




图6 不同区域养殖池至茅尾海NH₃-N降低百分比

Fig.6 Percentage reduction of NH₃-N from aquaculture pond to Maowei Sea in different regions

据建立的XGBR模型在沿海水体和养殖池塘水体的反演上具有优越性.XGBR模型相较于其他机器学习有更好的拟合效果,Chen等(2023)在城市河流NH₃-N浓度估算时对比XGBR、RF和KNNR模型时也发现XGBR模型性能更优,这一结果说明了XGBR模型较稳定,对于不同水体的适用性更强.XGBR算法是基于传统的GBDT算法的提升,同时引入了正则项,有效限制了模型的过拟合,使其拥有更快的数据训练速度和更准确的预测精度,性能更强(Chen *et al.*, 2016).虽然本研究没有与回归分析模型进行对比,但KNNR是一种基于距离度量的非参数算法,与回归分析相似(Altman, 1992).通过图3和表3可以看出,KNNR算法的性能极差,无法用于NH₃-N估算.而庞吉玉等(2023)构建NH₃-N反演模型时对比4种回归模型与XGBR模型性能时也发现了XGBR优于回归模型,说明XGBR算法在NH₃-N含量估算上有一定的应用潜力.NH₃-N的遥感监测本身是一个复杂的非线性过程,XGBR模型具有较强的自适应,有着解决复杂非线性问题的能力,更适合遥感影像和NH₃-N关系的模拟.本研究的研究结果证明XGBR在沿海和养殖水体NH₃-N反演模型上具有优越性,为NH₃-N浓度估算中提供了新的研究方向.

表5 NH₃-N的反演模型精度对比
Table 5 Comparison of accuracy of NH₃-N inversion models

模型类型	数据源	水体类型	反演模型	精度R ²	参考文献
机器学习模型	Sentinel-2	沿海和养殖池	XGBR	0.7522	本研究
	Sentinel-2	沿海和养殖池	LGBM	0.2136	本研究
	Sentinel-2	沿海和养殖池	RF	0.1703	本研究
	Sentinel-2	沿海和养殖池	KNNR	0.3553	本研究
	UAV	沿海和养殖池	PLSR	0.5600	Zhang <i>et al.</i> , 2023
	UAV	城市河流	DNN	0.6320	Chen <i>et al.</i> , 2021
	UAV	城市河流	ABR	0.5340	Chen <i>et al.</i> , 2021
	Landsat-8	内陆湖泊	RF	0.7084	Song <i>et al.</i> , 2024
经验模型	Sentinel-2	地表水	$C_{NH_3-N} = 0.0585 \times e^{-0.8332 \times B4/(B5 - B12)}$	0.7390	Cao <i>et al.</i> , 2023

4.2 特征变量的选择

本研究对所有的特征变量重要性进行排序,排序结果如图4所示.由图4可以发现单波段变量特征中的B5和B1-B5对NH₃-N浓度最为敏感.B5波长范围为698~713 nm,这个波长范围内由于浮游植物吸收系数达到最小,从而出现反射峰,是判断水体中Chl-a浓度的重要依据(Zhao *et al.*, 2022; 孟黎等, 2024).研究表明,NH₃-N浓度变化影响浮游植物生物量,即NH₃-N浓度为藻类提供氮源,促进藻类生长;而随着浮游植物的增

加, $\text{NH}_3\text{-N}$ 的消耗量也随之增加(冯驰等, 2015; 孙菲等, 2017; 时瑶等, 2023). 所以 $\text{NH}_3\text{-N}$ 与 Chl-a 密切相关, 能够通过影响浮游植物生长进而影响 Chl-a 浓度变化. 本研究中 B5 在 $\text{NH}_3\text{-N}$ 反演模型中贡献最大, 可能是由于 B5 与 Chl-a 之间存在联系导致. 崔文君(2018)通过 Chl-a 构建 BP 神经网络模型估算 $\text{NH}_3\text{-N}$ 浓度, 也间接说明了 B5 可能对 $\text{NH}_3\text{-N}$ 模型的构建有帮助. 本研究中的植被指数 Green-Blue NDVI 和 CVI 对 $\text{NH}_3\text{-N}$ 浓度也较为重要, 植被指数与 Chl-a 相关, 能够衡量水体浮游植物生物量(Kim *et al.*, 2021), 因此添加植被指数有利于提高 $\text{NH}_3\text{-N}$ 反演模型精度. 此外, 水体指数 NWI 也在模型中发挥一定作用, 吴欢欢等(2021)的研究也证明了 NWI 有助于 $\text{NH}_3\text{-N}$ 反演模型构建. 本研究大体上与这些结论一致.

4.3 $\text{NH}_3\text{-N}$ 分布特征分析

众多研究表明, $\text{NH}_3\text{-N}$ 的分布特征主要受人为因素的影响(He, 2023). 本研究基于最优的 XGBR 模型得到了茅尾海 $\text{NH}_3\text{-N}$ 空间变化特征(图 5), 发现 $\text{NH}_3\text{-N}$ 近岸浓度高于远岸, 并在河口区域出现较高浓度, 主要受到径流输入、沿岸排污口排放和水产养殖等影响导致 $\text{NH}_3\text{-N}$ 在空间上存在异质性(党二莎等, 2019; 洪雄业等, 2022). 而 11 月 $\text{NH}_3\text{-N}$ 浓度高于 12 月, 可能是由于 11 月大量浮游生物死亡, 有机体氨化作用导致 $\text{NH}_3\text{-N}$ 浓度较高(侯昱廷等, 2019). 此外, 11 月温度较 12 月高, 更有利于 $\text{NH}_3\text{-N}$ 和 $\text{NO}_3\text{-N}$ 的转化(庄亚润等, 2020). Shi 等(2024)在探究灌河河口 $\text{NH}_3\text{-N}$ 时空分布特征时发现 11 月 $\text{NH}_3\text{-N}$ 浓度高于 12 月, 与本文研究大体一致. 根据图 5 可知, 钦江沿岸养殖池的 $\text{NH}_3\text{-N}$ 略高于茅岭沿岸. 养殖水体中 $\text{NH}_3\text{-N}$ 主要来源于投喂饲料的残渣以及养殖生物的排泄物, 不同地区其饲料种类、投喂量以及养殖方式的不同均可能造成 $\text{NH}_3\text{-N}$ 浓度差异(仇建标等, 2019). 此外, 养殖池养殖尾水排水时间段在夏秋两季, 大部分未经有效处理直接外排(彭小燕等, 2022), 从而导致 2023 年 11 月 $\text{NH}_3\text{-N}$ 整体浓度高于 12 月.

由图 5 和图 6 可知, 养殖池 $\text{NH}_3\text{-N}$ 浓度要高于茅尾海. 研究表明水产养殖池塘中 $\text{NH}_3\text{-N}$ 含量明显要高于近海水体特别是非养殖水体(刘志根, 2019; 孙喆等, 2020), 与本研究结论一致. 由图 6 可以看出, 虽然养殖池中的 $\text{NH}_3\text{-N}$ 含量较高, 但其经过红树林排入茅尾海后含量较低. 红树林对 $\text{NH}_3\text{-N}$ 具有一定的净化作用使得 $\text{NH}_3\text{-N}$ 并没有对茅尾海水体造成很大影响. Wadnerkar 等(2019)、Reef 等(2010)和邹航等(2014)研究也表明红树林对 $\text{NH}_3\text{-N}$ 具有吸附能力, 能够通过硝化作用降低 $\text{NH}_3\text{-N}$ 浓度. 此外, 康熙岭片区和尖山片区养殖池至茅尾海的降低效果要高于沙井片区, 可能原因是康熙岭片区和尖山片区的红树林群落主要由无瓣海桑和桐花树组成, 沙井片区的红树林群落主要为桐花树(Huang *et al.*, 2022). 研究表明, 不同红树林群落对 $\text{NH}_3\text{-N}$ 的吸附效果不同(虞丹君等, 2018; 刘永等, 2022), 本研究区 3 个片区红树林群落的差异可能是导致降低效果不同的主要原因. 但康熙岭片区和尖山片区的降低效果也有差别, 说明在该区域中不同种类的红树林群落的分布格局也会对降低效果有影响.

但值得注意的是, 养殖池养殖水体经过红树林到茅尾海的 $\text{NH}_3\text{-N}$ 降低效果并不明显, 低于虞丹君等(2018)和齐丹等(2018)的研究. 这一现象的出现可能是入海口 $\text{NH}_3\text{-N}$ 浓度较高(聂瑞等, 2016; 鲁婉婷等, 2023), 而红树林生长于河口滩涂附近, 高浓度 $\text{NH}_3\text{-N}$ 随径流扩散到红树林 500 m 缓冲区附近, 对结果产生影响. 其次, 养殖池养殖水体排入茅尾海多从河流河道排入, 且茅尾海海域属于不规则全日潮, 湾内水体与海水交换较充分, 海水混合稀释可能是 $\text{NH}_3\text{-N}$ 浓度降低的原因之一(王奎等, 2007). Xiao 等(2023)和赵春宇等(2020)研究也表明, 海水混合稀释和红树林共同影响着污染物浓度变化. 目前, 我们无法确定 $\text{NH}_3\text{-N}$ 各来源的比重, 也无法量化各因素在 $\text{NH}_3\text{-N}$ 浓度降低中的贡献度. 因此, 在未来研究中需要通过氮同位素示踪技术确定 $\text{NH}_3\text{-N}$ 来源和对河口与非河口地区养殖池养殖水体 $\text{NH}_3\text{-N}$ 经过红树林到海水之间的降低效果进行对比, 来进一步完善研究成果.

4.4 模型的不确定性以及未来研究方向

本研究利用 XGBR 模型对研究区 $\text{NH}_3\text{-N}$ 浓度进行反演, 得到模型精度 $R^2=0.7522$, $\text{RMSE}=0.0249 \text{ mg}\cdot\text{L}^{-1}$, 说明 XGBR 模型仍然具有较好的鲁棒性, 能够应用在茅尾海及其养殖池的养殖水体的研究中. 从拟合效果(图 3 和表 3)可以看到, 模型的训练精度要高测试精度 18.1889%, 说明其存在一定的局限性. 此外, 该模型存在高浓度 $\text{NH}_3\text{-N}$ 低估的现象, 说明 XGBR 模型对于不同浓度的 $\text{NH}_3\text{-N}$ 反演的适用性不同. 养殖池水体与茅尾海水体的光学特性不同, 可能是导致 XGBR 算法高浓度低估的主要原因. 养殖池水体为富营养化水体, 由于

藻类和悬浮颗粒物浓度较高,反射光谱曲线波峰、波谷变化显著;而茅尾海水体较养殖池水体相对清洁,其整体反射率较低(李云梅等, 2022; 刘梅等, 2022)。两者光学特征不同,导致两者水体中 $\text{NH}_3\text{-N}$ 与遥感反射率之间的相关性有所差异,从而对 XGBR 模型反演效果造成影响。此外本研究所采用的 XGBR 模型预测精度低于 Dong 等(2020)和庞吉玉等(2023)的模型,说明不同数据源和输入变量对于 XGBR 模型的精度有影响,因此未来可以考虑将更高空间分辨率的影像数据应用在这个模型中。

模型参数的确定和特征变量的选择均对 $\text{NH}_3\text{-N}$ 反演模型的精度有一定的影响,这可能会使得预测结果存在不确定性;其次,本研究使用的茅尾海实测 $\text{NH}_3\text{-N}$ 浓度较低,养殖塘的实测 $\text{NH}_3\text{-N}$ 较高,两者的差异性也可能会影响模型的预测结果;最后卫星自身传感器误差以及遥感图像在进行处理的过程中存在的误差也可能对模型的拟合结果产生一定的影响。因此,在未来的研究中可以从以下几个方面改进:①对 XGBR 模型中的 `estimators`、`learning_rate` 和 `max_depth` 等参数进一步调节和优化;②采用优选变量的方式,减少冗余变量以提高 $\text{NH}_3\text{-N}$ 估算的精度;③增加 $\text{NH}_3\text{-N}$ 样本数量,减少因不同水体的差异而造成的预测误差。

5 结论(Conclusions)

1)对比 4 种机器学习算法,XGBR 相较于 RF、LGBM、KNNR 有更好的预测效果,其训练集 R^2 达到 0.7522, RMSE 为 $0.0249 \text{ mg}\cdot\text{L}^{-1}$,适用本研究区 $\text{NH}_3\text{-N}$ 浓度反演研究。此外,单波段和波段组合在 XGBR 模型中的贡献度最高,其次为植被指数和水体指数。

2)研究区茅尾海和养殖池 $\text{NH}_3\text{-N}$ 浓度均是 2023 年 11 月高于 12 月。茅尾海 $\text{NH}_3\text{-N}$ 大体呈现近岸浓度高于远岸,在河口区域出现较高浓度的分布特征;养殖池 $\text{NH}_3\text{-N}$ 浓度则是钦江沿岸要高于茅岭江沿岸。

3)养殖池 $\text{NH}_3\text{-N}$ 浓度高于茅尾海。养殖池 $\text{NH}_3\text{-N}$ 经过红树林排入茅尾海后的降低效果康熙岭片区和尖山片区要高于沙井片区。

参考文献(References):

- Ahmed N, Thompson S. 2019. The blue dimensions of aquaculture: A global synthesis [J]. *Science of the Total Environment*, 652: 851-861
- Baillarin S J, Meygret A, Dechoz C, *et al.* 2012. Sentinel-2 level 1 products and image processing performances [J]. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 39: 197-202
- Bansod B, Singh R, Thakur R. 2018. Analysis of water quality parameters by hyperspectral imaging in Ganges River [J]. *Spatial Information Research*, 26: 203-211
- Bramante J, Sin T. 2021. Optimization of a semi-analytical algorithm for multi-temporal water quality monitoring in inland waters with wide natural variability [J]. *Remote Sensing*, 7:16623-16646
- Breiman L. 2001. Random forests [J]. *Machine Learning*, 45:5-32
- Breitbart D, Levin A L, Oschlies A, *et al.* 2018. Declining oxygen in the global ocean and coastal waters [J]. *Science*, 359 (6371)
- Cao Q, Yu G, Sun S, *et al.* 2021. Monitoring water quality of the Haihe River based on ground-based Hyperspectral remote sensing [J]. *Water*, 14(1): 22
- Cao X, Zhang J, Meng H, *et al.* 2023. Remote sensing inversion of water quality parameters in the Yellow River Delta [J]. *Ecological Indicators*, 155: 110914
- Chawla I, Karthikeyan L, Mishra K A. 2020. A review of remote sensing applications for water security: Quantity, quality, and extremes [J]. *Journal of Hydrology*, 585: 124826
- Chen B, Mu X, Chen P, *et al.* 2021. Machine learning-based inversion of water quality parameters in typical reach of the urban river by UAV multispectral data [J]. *Ecological Indicators*, 133:108434
- Chen P, Wang B, Wu Y, *et al.* 2023. Urban river water quality monitoring based on self-optimizing machine learning method using multi-source remote sensing data [J]. *Ecological Indicators*, 146: 109750
- Chen T, Guestrin C. 2016. Xgboost: A scalable tree boosting system [C]. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA, 13-17 August. 785-794
- Chen X, Lao Y, Wang J, *et al.* 2018. Submarine groundwater-borne nutrients in a tropical bay (Maowei Sea, China) and their impacts on the oyster aquaculture [J]. *Geochem, Geophy, Geosy*, 19: 932-951
- 崔文君. 2018. 广东省近岸海水养殖水质参数定量反演与评估研究[D]. 广州: 广州大学
- 党二莎, 唐俊逸, 周连宁, 等. 2019. 珠江口近岸海域水质状况评价及富营养化分析 [J]. *大连海洋大学学报*, 34 (4): 580-587
- Dong G, Hu Z, Liu X, *et al.* 2020. Spatio-temporal variation of total nitrogen and ammonia nitrogen in the water source of the Middle Route of the

- South-To-North Water Diversion Project [J]. *Water*, 12 (9): 2615
- Fateme A, Alireza A, Mohammad F, *et al.* 2020. Salt dome related soil salinity in southern Iran: Prediction and mapping with averaging machine learning models [J]. *Land Degradation & Development*, 32 (3): 1540-1554
- 冯驰, 金琦, 王艳楠, 等. 2015. 基于GOCI影像和水体光学分类的内陆湖泊叶绿素a浓度遥感估算[J]. *环境科学*, 36 (5): 1557-1564
- 高佳欣, 林昱坤, 涂耀仁, 等. 2023. 遥感反演技术应用于监测地表水体水质参数的现状与展望 [J]. *遥感信息*, 38 (6): 1-14
- Gao L, Wang X F, Johnson B A, *et al.* 2020. Remote sensing algorithms for estimation of fractional vegetation cover using pure vegetation index values: A review [J]. *SPRS Journal of Photogrammetry and Remote Sensing*, 159:364-377
- Gholizadeh M H, Melesse M, Reddi L. 2016. A comprehensive review on water quality parameters estimation using remote sensing techniques [J]. *Sensors*, 16(8): 1298
- 龚绍琦, 黄家柱, 李云梅, 等. 2008. 水体氮磷高光谱遥感实验研究初探 [J]. *光谱学与光谱分析*, 2008(4): 839-842
- Guo H, Huang J J, Chen B, *et al.* 2021. A machine learning-based strategy for estimating non-optically active water quality parameters using Sentinel-2 imagery [J]. *International Journal of Remote Sensing*, 42 (5): 1841-1866
- 郭庆华, 胡天宇, 刘瑾, 等. 2021. 轻小型无人机遥感及其行业应用进展[J]. *地理科学进展*, 40(9): 1550-1569
- Guo H, Tian S, Jeanne H J, *et al.* 2022. Performance of deep learning in mapping water quality of Lake Simcoe with long-term Landsat archive [J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 183: 451-469
- Han A, Kao S, Lin W, *et al.* 2020. Nutrient budget and biogeochemical dynamics in Sansha Bay, China: A coastal bay affected by intensive mariculture [J]. *Journal of Geophysical Research: Biogeosciences*, 126: e2020JG006220
- 韩淑贤, 刘叶, 赵妹晴, 等. 2023. 基于城市湖泊叶绿素分布特征及影响因子实验设计 [J]. *山东化工*, 52 (15): 238-241
- 何红艳, 黄国言, 张炳, 等. 2022. 基于极限树特征递归消除和LightGBM的异常检测模型 [J]. *信息安全*, 22 (1): 64-71
- He M. 2023. Spatiotemporal distribution and controlling factors on ammonium in waters in the central Yangtze River Basin, China [J]. *Journal of Contaminant Hydrology*, 58:104239
- 洪雄业. 2022. 厦门湾营养盐长期动态变化与陆源污染关系分析 [J]. *应用海洋学学报*, 41 (2): 249-258
- 侯昱廷, 高爱国, 林建杰, 等. 2019. 闽江下游及河口溶解无机氮的季节分布及组成 [J]. *浙江海洋大学学报(自然科学版)*, 38 (2): 134-141
- Huang C, Shi K, Yang H, *et al.* 2015. Satellite observation of hourly dynamic characteristics of algae with Geostationary Ocean Color Imager (GOCI) data in Lake Taihu [J]. *Remote Sensing of Environment*, 159(12): 278-287
- Huang J, Wang D, Pan S, *et al.* 2023. A new high-resolution remote sensing monitoring method for nutrients in coastal waters [J]. *IEEE Transactions on Geoscience and Remote Sensing*, 61: 4206315
- 黄星, 袁菁菁, 王薛平, 等. 2022. 红树林变化的驱动力: 基于茅尾海30年观测的分析[J]. *海洋学研究*, 40 (3): 132-141
- Huang Z, Tian Y, Zhang Q, *et al.* 2022. Estimating mangrove above-ground biomass at Maowei Sea, Beibu Gulf of China using machine learning algorithm with Sentinel-1 and Sentinel-2 data [J]. *Geocarto International*, 37 (27): 15778-15805
- 黄振辉, 杨小红, 王力哲, 等. 2024. 小样本下大冶湖非光学活性水质参数反演与时空变化分析[J]. *长江流域资源与环境*, 33 (1): 102-113
- Hunt E R, Daughtry C S T, Eitel J U H, *et al.* 2011. Remote sensing leaf chlorophyll content using a visible band index [J]. *Agronomy Journal*, 103 (4): 1090-1099
- Kim E, Nam S, Koo J, *et al.* 2021. Hybrid approach of unmanned aerial vehicle and unmanned surface vehicle for assessment of Chlorophyll-a imagery using spectral indices in Stream, South Korea [J]. *Water*, 13 (14): 1930
- Le C, Li Y, Zha Y, *et al.* 2009. Validation of a quasi-analytical algorithm for highly turbid eu-trophic water of Meiliang Bay in Taihu Lake, China [J]. *IEEE Trans. Geoscience and Remote Sensing*, 47: 2492-2500
- Li D, Xu X, Li Z, *et al.* 2020. Detection methods of ammonia nitrogen in water: A review [J]. *Trends in Analytical Chemistry*, 127: 115890
- Li H, Li X, Li Q, *et al.* 2017. Environmental response to long-term mariculture activities in the Weihai coastal area, China [J]. *Science of the Total Environment*, 601-602: 22-31
- Li H, Tang H, Shi X, *et al.* 2014. Increased nutrient loads from the Changjiang (Yangtze) River have led to increased Harmful Algal Blooms [J]. *Harmful Algae*, 39: 92-101
- Li L, Gu M, Gong C, *et al.* 2023. An advanced remote sensing retrieval method for urban non-optically active water quality parameters: An example from Shanghai [J]. *The Science of the Total Environment*, 880: 163389
- Li S, Song K, Wang S, *et al.* 2021. Quantification of chlorophyll-a in typical lakes across China using Sentinel-2 MSI imagery with machine learning algorithm [J]. *Science of the Total Environment*, 778: 146271
- Li X, Huang M, Li J. 2020. Remote sensing inversion of lake water quality parameters based on ensemble modelling [J]. *E3S Web of Conferences*, 143 (12): 2007
- 李云梅, 赵焕, 毕顺, 等. 2022. 基于水体光学分类的二类水体水环境参数遥感监测进展 [J]. *遥感学报*, 26 (1): 19-31
- 刘梅, 马启良, 原居林, 等. 2022. 基于无人机高光谱遥感技术对内陆养殖池塘水质监测的研究 [J]. *海洋与湖沼*, 53 (1): 195-205
- 鲁婉婷, 徐攻博, 王昱, 等. 2023. 基于北京二号卫星影像与同步实测数据的椒江入海口水质遥感反演[J]. *杭州师范大学学报(自然科学版)*,

22 (2): 218-224

- 刘轩, 赵同谦, 蔡太义, 等. 2021. 丹江口水库总氮、氨氮遥感反演及时空变化研究 [J]. 农业资源与环境学报, 38 (5): 829-838
- 刘永, 张诗涵, 肖雅元, 等. 2022. 红树林人工湿地的脱氮除磷效果研究 [J]. 农业环境科学学报, 41 (8): 1788-1799
- 刘宇, 李旭龙. 2019. 基于水体指数的镜泊湖叶绿素 a 质量浓度反演研究 [J]. 湖南农业大学学报(自然科学版), 45 (2): 172-178
- 刘志根. 2019. 粤东柘林湾海水养殖污染高光谱遥感监测与定量评估[D]. 广州: 广州大学
- 罗崇亮. 2015. 基于水体指数的艾比湖湖水面积提取对比研究 [J]. 科技创新导报, 12 (24): 34-35
- 马丰魁, 姜群鸥, 徐黎丹, 等. 2020. 基于 BP 神经网络算法的密云水库水质参数反演研究 [J]. 生态环境学报, 29 (3): 569-579
- 马晓娜, 李碧莹, 吴乐乐, 等. 2021. 养殖水无机氮盐测定方法比较分析研究 [J]. 海洋湖沼通报, 43 (6): 117-123
- Mahsa H, Abbas M, Reza G. 2023. A novel scheme for mapping of MVT-Type Pb-Zn Prospectivity: LightGBM, a highly efficient gradient boosting decision tree machine learning algorithm [J]. Natural Resources Research, 32 (6): 2417-2438
- McFeeters S K. 1996. The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features[J]. International journal of remote sensing, 1996, 17(7): 1425-1432
- 孟黎, 孟静. 2024. 基于集成学习的内陆水体叶绿素 a 浓度反演[J]. 海河水利, (2): 17-21
- 蒙良莉, 凌子燕, 蒋卫国, 等. 2020. 基于 Sentinel 遥感数据的红树林信息提取研究——以广西茅尾海为例 [J]. 地理与地理信息科学, 36 (4): 41-47
- Moses J W, Gitelson A A, Berdnikov S, *et al.* 2009. Estimation of chlorophyll- a concentration in case II waters using MODIS and MERIS data——successes and challenges [J]. Environmental Research Letters, 4 (4): 045005
- Neofitou N, Papadimitriou K, Domenikiotis C, *et al.* 2019. GIS in environmental monitoring and assessment of fish farming impacts on nutrients of Pagasitikos Gulf, Eastern Mediterranean[J]. Aquaculture, 501: 62-75
- 裴瑞, 王芬, 周涛, 等. 2016. 海口湾陆源入海口污染状况及主要污染物分布特征 [J]. 环境污染与防治, 38 (9): 12-18
- Ouma Y O, Waga J, Okech M, *et al.* 2018. Estimation of reservoir bio-optical water quality parameters using smartphone sensor apps and Landsat ETM+: Review and comparative experimental results [J]. Journal of Sensors, 2018(1): 3490757
- Palmer S C J, Kutser T, Hunter P D. 2015. Remote sensing of inland waters: Challenges, progress and future directions [J]. Remote Sensing of Environment, 157: 1-8
- 庞吉玉, 张安兵, 王贺封, 等. 2023. 基于无人机多光谱影像和 XGBoost 模型的城市河流水质参数反演 [J]. 中国农村水利水电, (3): 111-119
- 彭小燕, 郭梅修, 庞敏倩, 等. 2022. 广西钦州湾茅尾海海水养殖污染影响及防治对策 [J]. 环境保护与循环经济, 42 (11): 57-60
- 齐丹, 公维洁, 谭媛, 等. 2018. 潜流型人工湿地系统对海洋富营养化水体的净化效果 [J]. 海南热带海洋学院学报, 25 (5): 28-33
- 仇建标, 陈琛, 彭欣, 等. 2019. 红树林人工湿地-养殖耦合系统构建与净化效果 [J]. 浙江农业科学, 60 (11): 2073-2077
- Reef R, Feller I C, Lovelock C E. 2010. Nutrition of mangroves [J]. Tree Physiology, 30: 1148-1160
- Salah E, Hekmat I, Hend H, *et al.* 2021. Assessment of water quality in Lake Qaroun using ground-based remote sensing data and artificial neural networks [J]. Water, 13 (21): 3094-3094
- Saha A, Pal C S. 2024. Application of machine learning and emerging remote sensing techniques in hydrology: A state-of-the-art review and current research trends [J]. Journal of Hydrology, 632: 130907
- Shi X, Qiu Z, Hu Y, *et al.* 2024. Monitoring the water quality distribution characteristics in the Huaihe River Basin based on the Sentinel-2 satellite [J]. Water, 16(6):860
- 时瑶, 张雷, 秦延文, 等. 2023. 四川邛海水体氮、磷浓度时空分布特征及其生态环境响应研究 [J]. 地学前缘, 30 (2): 495-505
- Sudduth K A, Jang G S, Lerch R N, *et al.* 2015. Long-term agroecosystem research in the central Mississippi River basin: hyperspectral remote sensing of reservoir water quality [J]. Journal of Environmental Quality, 44(1): 71-83
- 孙菲, 袁鹏, 程建光, 等. 2017. 宜兴市殷村港叶绿素 a 与影响因子的多元分析 [J]. 环境工程, 235 (9): 53-57
- 孙驷阳. 2019. 基于多源遥感与机器学习的密云水库水质参数反演研究[D]. 北京: 北京林业大学
- 孙喆, 罗菊花, 杨井志成, 等. 2020. 越南东部近岸区域水产养殖塘分布及其对近海水体中叶绿素 a 质量浓度的影响 [J]. 湿地科学, 18 (2): 207-218
- 唐茂淞, 张楠, 李国辉, 等. 2023. 基于机器学习算法的棉田土壤钾、钠离子量预测 [J]. 灌溉排水学报, 42 (9): 32-39
- Tian S, Guo H, Xu W, *et al.* 2022. Remote sensing retrieval of inland water quality parameters using Sentinel-2 and multiple machine learning algorithms [J]. Environmental science and pollution research international, 30 (7): 18617-18630
- 田义超, 黄远林, 张强, 等. 2019. 北部湾典型海岛生态系统服务价值空间异质性对比研究[J]. 海洋科学, 43(2): 60-68
- Wadnerkar D P, Santos R I, Looman A, *et al.* 2019. Significant nitrate attenuation in a mangrove-fringed estuary during a flood-chase experiment [J]. Environmental Pollution, 253: 1000-1008
- 王皓, 赵冬至, 王林, 等. 2012. 水质遥感研究进展 [J]. 海洋环境科学, 31 (2): 285-288
- 王奎, 金明明, 陈建芳, 等. 2007. 三门湾海域 4、7 月营养盐分布及其稀释效应[J]. 海洋学研究, (1): 10-22
- 王嗣彤, 程全国, 雷坤, 等. 2024. 温州市鳌江水系叶绿素 a 和氮、磷的分布特征与富营养化研究[J]. 环境污染与防治, 46 (2): 291-296

- Wang W, Jia Y, Yu W, *et al.* 2020. On-line ammonia nitrogen measurement using generalized additive model and stochastic configuration networks [J]. *Measurement*, 170: 108743
- 王歆晖, 田华, 季铁梅, 等. 2020. 哨兵2卫星综合水质指标的河流水质遥感监测方法 [J]. *上海航天(中英文)*, 37 (5): 92-97+104
- 王嗣彤, 程全国, 雷坤, 等. 2024. 温州市鳌江水系叶绿素 a 和氮、磷的分布特征与富营养化研究[J]. *环境污染与防治*, 46(2): 291-296
- Werdell J P, McKinna I L, Boss E, *et al.* 2018. An overview of approaches and challenges for retrieving marine inherent optical properties from ocean color remote sensing [J]. *Progress in Oceanography*, 160: 186-212
- 吴欢欢, 国巧真, 臧金龙, 等. 2021. 基于 Landsat8 与实测数据的水质参数反演研究[J]. *遥感技术与应用*, 36(4):898-907
- 吴舒雁, 朱庆林, 翟焕锋. 2024. 基于 In VEST 模型的广西茅尾海土地利用变化与碳储量评估 [J]. *水土保持通报*, 44(1)
- Xiao K, Zhang P, Santos I R, *et al.* 2023. Tidal pumping controls dissolved organic matter properties and outwelling from mangrove groundwater to coastal water [J]. *Water Resources Research*, 59 (3): e2022WR033913
- Xie L, Yang B, Xu J, *et al.* 2024. Effects of intensive oyster farming on nitrogen speciation in surface sediments from a typical subtropical mariculture bay [J]. *The Science of the Total Environment*, 916: 170092
- 邢帅, 刘宸博, 王丹药, 等. 2022. 半分析算法在固有光学特性反演中的性能研究[J]. *海洋测绘*, 42 (3): 66-71+82
- Xu C, Yang B, Dan S F, *et al.* 2020. Spatiotemporal variations of biogenic elements and sources of sedimentary organic matter in the largest oyster mariculture bay (Maowei Sea), Southwest China [J]. *Science of the Total Environment*, 730: 139056
- Xu H, 2006. Modification of normalised difference water index (NDWI) to enhance open water features in remotely sensed imagery [J]. *International Journal of Remote Sensing*, 27: 3025-3033
- Yang B, Lan R Z, Lu D L, *et al.* 2019. Phosphorus biogeochemical cycling in intertidal surface sediments from the Maowei Sea in the northern Beibu Gulf [J]. *Regional Studies in Marine Science*, 28: 100624
- Yang H, Kong J, Hu H, *et al.* 2022. A review of remote sensing for water quality retrieval: progress and challenges [J]. *Remote Sensing*, 14 (8): 1770
- 姚焕玫, 廖鹏任, 韦毅明, 等. 2022. 基于水体特征指数的广西北部湾近岸海域叶绿素 a 浓度反演 [J]. *桂林理工大学学报*, 42 (2): 469-476
- Yao K, Chen Y, Li Y, *et al.* 2024. Water quality prediction of small-micro water body based on the intelligent-algorithm-optimized support vector machine regression method and unmanned aerial vehicles multispectral data [J]. *Sustainability*, 16(2): 559
- 虞丹君, 罗海忠, 徐志进, 等. 2018. 不同红树处理海水养殖尾水效果初探 [J]. *科学技术与工程*, 18 (7): 271-274
- Yu Z, Huang Q, Peng X, *et al.* 2022. Comparative study on recognition models of black-odorous water in Hangzhou based on GF-2 Satellite Data [J]. *Sensors (Basel, Switzerland)*, 22 (12): 4593-4593
- Yuan X, Wang S, Fan F, *et al.* 2022. Spatiotemporal dynamics and anthropologically dominated drivers of chlorophyll-a, TN and TP concentrations in the Pearl River Estuary based on retrieval algorithm and random forest regression [J]. *Environmental research*, 215 (P3): 114380
- Zhang H, Xue B, Wang G, *et al.* 2022. Deep learning-based water quality retrieval in an impounded Lake using Landsat 8 imagery: an application in Dongping Lake [J]. *Remote Sensing*, 14 (18): 4505
- 张卫强, 朱英. 2012. 养殖水体中氨氮的危害及其检测方法研究进展 [J]. *环境卫生学杂志*, 2(6): 324-327
- Zhang Y, Jin S, Wang N, *et al.* 2022. Total phosphorus and nitrogen dynamics and influencing factors in Dongting Lake using Landsat data [J]. *Remote Sensing*, 14 (22): 5648
- 赵春宇, 张凌, 江志坚, 等. 2020. 大亚湾滨海湿地沉积物间隙水无机氮分布特征及其沉积物-水界面交换通量 [J]. *海洋环境科学*, 39 (3): 359-366
- Zhao Y, Yu T, Hu B, *et al.* 2022. Retrieval of water quality parameters based on near-surface remote sensing and machine learning algorithm [J]. *Remote Sensing*, 14 (21): 5305
- 邹航, 王立立, 柳蓉. 2014. 珠江河口湿地沉积物吸附氨氮及影响因素研究 [J]. *环境污染与防治*, 36(3): 46-51
- 周挺, 杨军, 周强明, 等. 2019. 基于改进 LightGBM 的电力系统暂态稳定评估方法 [J]. *电网技术*, 43 (6): 1931-1940
- 朱冰川, 尤凯, 石凌哲, 等. 2020. 基于 GOCI 数据的太湖叶绿素 a 浓度反演和蓝藻水华遥感监测 [J]. *环境污染与防治*, 42 (8): 1021-1025+1032
- Zhu X, Wen Y, Li X, *et al.* 2023. Remote sensing inversion of typical water quality parameters of a complex river network: A case study of Qidong's Rivers [J]. *Sustainability*, 15 (8): 6948
- 庄亚润, 孙真, 周凯, 等. 2020. 中国西北地区次生盐碱水无机氮转化与环境因子的相关关系 [J]. *中国水产科学*, 27 (12): 1438-1447