

莫锦英, 田义超, 王家乐, 等. 基于机器学习的茅尾海及近岸养殖池水体 COD 遥感反演[J]. 海洋学报, 2025, 47(5): 128–140, doi:10.12284/hyxb2025046

Mo Jinying, Tian Yichao, Wang Jiale, et al. Remote sensing inversion of COD in Maowei Sea and nearshore aquaculture ponds based on machine learning[J]. Haiyang Xuebao, 2025, 47(5): 128–140, doi:10.12284/hyxb2025046

基于机器学习的茅尾海及近岸养殖池 水体 COD 遥感反演

莫锦英^{1,2}, 田义超^{1,2,3,4,5*}, 王家乐², 杜金泽⁶, 张强², 张亚丽², 陶进², 林俊良²

(1. 广西大学资源环境与材料学院, 广西 南宁 530004; 2. 北部湾大学资源与环境学院, 广西 钦州 535011; 3. 广西北部湾海洋环境变化与灾害研究重点实验室, 广西 钦州 535011; 4. 北部湾大学北部湾海洋发展中心, 广西 钦州 535011; 5. 北部湾大学海洋地理信息资源开发利用重点实验室, 广西 钦州 535011; 6. 北部湾大学海洋学院, 广西 钦州 535011)

摘要: 化学需氧量 (chemical oxygen demand, COD) 是衡量水体有机污染程度的重要参数, 利用遥感反演快速获取 COD 浓度时空分布状况, 对水产养殖污染治理和近海生态环境保护具有重要意义。本研究利用 Sentinel-2 提取的单波段、归一化植被指数 (normalized difference vegetation index, NDVI) 和归一化水体指数 (normalized difference water index, NDWI), 基于决定系数 (R^2) 和均方根误差 (RMSE) 对类别提升回归树 (catboost regression, CBR)、梯度提升回归树 (gradient boost regression, GBR)、 K 最近邻 (K -nearest neighbor regression, KNNR)、轻量级梯度提升机 (light gradient boosting machine, LGBM)、随机森林 (random forest, RF) 和极端梯度提升 (extreme gradient boosting regression, XGBR) 6 种模型性能进行评估, 分析茅尾海及其北部沿岸养殖池 COD 浓度时空分布特征。结果表明: (1) XGBR 模型拟合效果最好, 其测试集 R^2 达到 0.943 2, RMSE 为 1.403 3 mg/L。 (2) B8a、B2 以及 NDVI 在 XGBR 反演模型中的贡献度较高。 (3) 2019–2023 年期间, 养殖池水体中 COD 年平均浓度分别在 16.23~17.39 mg/L 之间, 空间分布格局较为均匀; 茅尾海 COD 年平均浓度在 2.30~2.88 mg/L 之间, 基本呈现由内湾向外湾递减、近岸高于远岸的分布格局。本研究验证了 XGBR 模型在同时应用于养殖水体及其沿岸海域这两类特定水体环境的 COD 反演时, 展现出了极高的适用性。相关成果可为在多种复杂水质条件下进行 COD 反演提供了宝贵的思路借鉴, 而且为沿海区域的水产养殖活动及环境管理工作提供了有力的技术支持与理论基础。

关键词: COD; 机器学习算法; Sentinel-2; 养殖池; 茅尾海

中图分类号: X87; X832

文献标志码: A

文章编号: 0253-4193(2025)05-0128-13

1 引言

水体有机污染是一个重大的全球性环境问题, 需

要我们进行评估与监测。COD 是反映水体有机污染的重要参数, 有助于我们衡量水体有机污染程度^[1]。近 20 a 来, 我国在水产养殖生产领域发挥着重要作

收稿日期: 2024-07-14; 修订日期: 2025-02-07。

基金项目: 国家自然科学基金 (No. 42261024); 广西八桂青年拔尖人才项目 (广西八桂青年学者); 广西林业厅项目 (桂林科研 [2022] 第 4 号); 北部湾大学海洋科学一流学科项目 (No. DRB003); 广西高校人文社会科学重点研究基地项目 (No. BHZKY2202); 广西高校人文社科重大项目 (No. JDZD202214); 广西创新驱动发展专项项目“海岸双频激光 LiDAR 探测仪产品开发与应用示范” (No. AA18118038); 广西科技基地和人才项目“广西钦州湾红树林岛群生态系统健康评价及应用示范” (No. 2019AC20088)。

作者简介: 莫锦英 (1999—), 女, 广西壮族自治区梧州市人, 研究方向为海洋遥感与生态系统修复。E-mail: 2082348270@qq.com

*** 通信作者:** 田义超, 教授, 广西八桂青年学者, 主要从事喀斯特与海岸带生态水文过程方面的研究。E-mail: tianyichao1314@hotmail.com

用,是世界上公认的水产养殖大国^[2]。随着养殖规模的扩大,养殖污染问题逐渐引起人们关注。根据2020年《第二次全国污染源普查公报》,水产养殖业产生的COD排放量为66.60万吨,较《第一次全国污染源普查公报》有所上升^[3]。近岸海域是水产养殖的主要场所之一,高密度、高投入、高产出的养殖模式易导致COD浓度超标排放,从而超出近海水环境生态的环境承载力和自净能力,导致周边水质恶劣^[4]。因此,如何高效地掌握COD浓度的时空变化特征,为推进水产养殖污染治理和近海海洋生态环境管理具有重要意义。

传统的COD监测工作主要是由工作人员在监测水域的某些固定监测点收集水样,然后在实验室通过化学方法获得水样COD浓度^[5]。但这种方法**仅能获取特定点位的COD浓度信息,无法获取整个区域的整体信息**。同时,这种COD监测方法**受到时间、空间和人力等其他不确定因素的限制,无法对水质进行长期动态监测**^[6]。近年来,随着遥感技术蓬勃发展,遥感数据为开展COD遥感反演奠定了基础。国内外学者对COD进行浓度反演使用的遥感数据源主要分为非卫星遥感数据源、高光谱数据和多光谱数据三大类。非卫星遥感数据包括航空遥感数据和地面实测光谱数据。Zheng等^[7]、Zhang等^[8]和董月群等^[9]基于无人机光谱数据构建了COD反演模型,但无人机数据源成本较高,受飞行高度和机载传感器等限制,对大尺度区域的综合观测能力较弱。Hou等^[10]、陈瑶等^[11]和赵旭阳等^[12]利用实测光谱仪测量的反射光谱与COD建立联系,探讨了COD反演的可行性。虽然实测光谱仪可以灵活地进行水面反射率的探测,受大气的影响较少,但其成本较高且应用区域较小。高光谱数据分辨率较高,在COD遥感反演上显示出良好的应用潜力。Yang等^[13]、盛辉等^[14]和鲁婉婷等^[15]分别验证了ZY1-02D、珠海1号和北京二号高光谱图像在绘制COD这类非光学活性参数方面的潜力,但高分辨率卫星无法同时满足高空间分辨率和高时间分辨率的要求,在实际应用中相对较少。用于COD浓度反演的多光谱数据有MODIS^[16]、Landsat-8^[17]和Sentinel-2^[18]等。考虑到空间、时间和光谱分辨率,Sentinel-2具有空间分辨率可达10 m,重访周期5 d,光谱范围涵盖可见光、近红外和短波红外的优势,在COD反演上具有广泛的应用前景。Cao等^[19]、Peng等^[20]和王姣等^[21]利用Sentinel-2影像数据构建COD反演模型,反演精度高,其 R^2 均达到0.8以上。这说明Sentinel-2在COD反演上有着巨大应用潜力,但是

在本研究区的应用效果如何,还需要进一步验证。

应用在水质遥感反演的方法有分析方法、半经验方法、经验方法和机器学习算法4大类。由于COD属于非光学活性物质,对光的辐射的吸收和散射作用较弱,其浓度大小对光谱特征的影响较小^[22-23],使得分析方法和半分析方法在COD反演的应用上受到限制。因此,早期的COD反演的研究大多基于经验模型。Cao等^[24]、黄振辉等^[25]和郭荣幸等^[18]通过光谱数据与实测数据建立了COD的经验模型,但其反演精度不是很理想。COD的光谱特征与浓度信息难以用简单的线性关系进行描述,传统的经验模型难以取得较好的反演结果。随着计算机和遥感技术的不断发展,机器学习算法凭借其优秀的非线性拟合能力在COD反演上取得了不错的效果。早期较为传统的机器学习算法,如随机森林(random forest, RF)^[21]、K最近邻(K-nearest neighbor regression, KNNR)^[26]以及支持向量机(support vector regression, SVR)^[14]等,已成功应用于COD反演领域。这些研究成果表明了传统机器学习算法在COD浓度反演方面的应用潜力,然而它们的反演精度仍有待提高。近年来,得益于计算机技术的飞速发展,集成学习算法这类新型机器学习算法,如类别提升回归树(catboost regression, CBR)、梯度提升回归树(gradient boost regression, GBR)、轻量级梯度提升机(light gradient boosting machine, LGBM)和极端梯度提升(extreme gradient boosting regression, XGBR)等,凭借其独特的将弱学习器转化为强学习器以提升模型预测精度的能力,也被引入到COD浓度的反演中。如Zhao等^[27]通过对比包括集成学习在内的14种机器学习算法,发现集成学习算法在COD预测方面展现出更高的鲁棒性;王春玲等^[28]则在宝带河水域对集成学习算法与RF及线性回归算法的精度进行了对比,结果表明集成学习在COD反演上表现出较好的性能。与上述研究相比,机器学习模型尤其是集成学习算法在反演精度上优于了传统的经验模型。但上述利用机器学习反演COD的研究基本集中于内陆湖泊和城市河流。另外,尽管Zhang等^[29]、邹志伟等^[30]以及胡义强等^[31]在养殖水体或者沿海水域中已经采用了传统的经验模型对COD进行建模分析,并取得一定成效;同时,Zhao等^[27]也已尝试在大型鱼塘利用机器学习算法建立模型,但这些研究大多局限于特定的水体类型。特别是,针对养殖水体及其沿岸海域这两类特殊水体,我们尚需验证是否能同时运用机器学习算法进行COD的反演。因此,关于传统机器学习算法与集成机器学习算法在这类独特水

环境中的适用性和性能优劣,仍有待进一步验证与深入探究。

茅尾海位于北部湾北部,因其独特的地理位置和优良的自然条件,成为我国近江牡蛎养殖的核心区之一^[32-33]。该区域渔业资源丰富,养殖方式包括池塘养殖、滩涂养殖、海上浮筏吊养和网箱养殖。池塘养殖主要位于茅尾海北部沿岸地区,养殖方式传统粗放,养殖种类以南美白对虾为主,易导致养殖尾水未达标排放造成水体污染。同时该地区沿岸滩涂及其附近地区生长大片红树林,种类有桐花树、秋茄和无瓣海桑等,是我国面积最大和最典型的红树林保护区^[34]。由于常年开展养殖活动,该地区整体水质较差,COD是影响水质状况的主要因素之一^[35]。此外,该区域位于平陆运河施工区域,也有可能由于COD浓度升高。现有相关研究大多采用COD实测数据与遥感数据作为输入机器学习模型的因变量和特征变量,然而实际过程中由于COD实测数据与遥感波段之间的相关性不高,仍然存在着模型反演模型精度不高的问题。此外,机器学习模型多应用在单一的水体类型中,难以满足多种复杂水质条件下的COD反演。而目前针对该地区COD浓度的研究也集中在海域和河口地区,尚未与岸边养殖池建立联系,同时尚未有合适的监测方法能够大范围应用在该区域COD浓度监测。为了克服上述不足,本研究基于Sentinel-2提取的单波段、归一化植被指数(normalized difference vegetation index, NDVI)和归一化水体指数(normalized difference water index, NDWI)数据和实测COD数据构建模型,从而解决由于实测数据与特征变量之间相关性不高导致模型精度不高的问题。最后利用CBR、GBR、KNNR、LGBM、RF和XGBR 6种机器学习模型构建COD反演模型,进而为实现复杂水体条件下的COD反演寻找并提供一种可行的实现途径。本研究主要有3个目标:(1)探究不同机器学习算法在COD模型构建上的适用性;(2)分析不同特征变量对COD反演模型精度的影响;(3)了解COD在养殖池和茅尾海的时空分布特征。

2 材料与方法

2.1 研究区域

以茅尾海及其北部沿岸地区(21°48'~21°55'N, 108°28'~108°37'E)为研究区。该区域属于典型的亚热带季风气候,具有明显的干、湿季节变化特征:5-9月的降雨量占全年70%以上,10月至翌年4月降雨较少^[36]。茅岭江、大榄江和钦江为茅尾海海域3条

主要入海河流,优越的自然地理环境为红树林提供适宜生长的资源。同时,该地区也是水产养殖较为集中的区域。其北部沿岸池塘养殖方式较为传统,养殖种类较为单一。养殖水体中COD浓度远高于茅尾海,而养殖池塘则主要通过沿岸设置的排水口与茅尾海相连通。然而,由于池塘养殖技术相对落后且管理水平不足,导致大部分尾水未经有效处理便直接排放至茅尾海,对该海域水质产生影响。研究区具体位置如图1所示。

2.2 数据来源与处理

本研究于2023年11月4-5日和2024年1月1-2日在茅尾海海域及其北部沿岸养殖塘布设采样点(图1),共采集水样140份。水样的采集过程严格按照《海洋监测规范》执行,在水面以下0.5 m处采集5 L海水后将样品密封保存送往实验室进行水质检测。根据标准GB 17 378.4—2007,使用碱性高锰酸钾法测定COD浓度。

Sentinel-2数据从欧洲航空局哥白尼数据中心获取(<https://dataspace.copernicus.eu/browser/>)。其影像包括13个波段,分辨率范围为10~60 m,主要指标如表1所示。本研究选用经过辐射定标和大气校正的Sentinel-2 L2A级数据产品,其中B10为包含高空卷云信息的波段,所以不使用该波段。由于云量和访问时间的影响,本研究设定地面实测数据和遥感影像的匹配数据集的时间窗为 ± 7 d^[37-39]。本文获取两幅与采样时间最为接近、云量小于10%的2023年11月1日和2023年12月26日的影像用于模型构建。我们使用SNAP软件将L2A产品各个波段重采样为10 m,并经过波段合成和裁剪后获得本研究区的影像。此外,NDWI可以有效地将水体与背景地物区分开来^[40]。在本研究中,我们基于Sentinel-2卫星数据,运用NDWI来提取茅尾海海域的边界。为达到最优的分割效果,我们通过不断调整分割阈值,最终确定了NDWI提取水体的最佳阈值为0.1。与此同时,我们采用目视解译法提取沿岸养殖池和红树林边界。

2.3 方法

2.3.1 技术路线

本研究在Sentinel-2数据和实测COD数据基础上,通过比较6种机器学习算法,反演了茅尾海及其沿岸养殖池COD浓度,了解COD的时空分布特征。技术路线如图2所示,具体如下:(1)在实地进行采样后,将水样带回实验室通过碱性高锰酸钾法获取实测COD数据。(2)对Sentinel-2数据进行预处理后提取单波段、NDVI和NDWI作为变量,通过




图 1 研究区采样点位及其养殖池与茅尾海之间的水体交换口
Fig. 1 Study area of sample points and water exchange outlet between aquaculture pond and Maowei Sea

表 1 Sentinel-2 波段信息
Table 1 Sentinel-2 spectral band information

波段名称	空间分辨率/m	中心波长/ μm	波长范围/ μm	意义
B1	60	0.443	0.433~0.453	监测近岸水体或大气气溶胶
B2	10	0.490	0.458~0.523	可见光波段
B3	10	0.560	0.543~0.578	可见光波段
B4	10	0.665	0.650~0.680	可见光波段
B5	20	0.705	0.698~0.713	红边波段
B6	20	0.740	0.733~0.748	红边波段
B7	20	0.783	0.773~0.793	红边波段
B8	10	0.842	0.785~0.900	近红外波段(宽)
B8a	20	0.865	0.855~0.875	近红外波段(窄)
B9	60	0.945	0.935~0.955	水蒸汽波段
B10	60	1.375	1.360~1.390	卷云波段
B11	20	1.610	1.565~1.655	短波红外波段
B12	20	2.190	2.100~2.280	短波红外波段




图 2 基于机器学习的茅尾海及近岸养殖池水体
COD 遥感反演技术流程

Fig. 2 Research technical route of COD remote sensing inversion for Maowei Sea and nearshore aquaculture ponds based on machine learning

Pearson 相关性分析筛选敏感变量构建特征变量数据集。(3)将数据随机分为 80% 的训练集和 20% 的测试集。采用 R^2 和 RMSE 对 CBR、GBR、KNNR、LGBM、RF 和 XGBR 6 种机器学习模型进行精度评估,选择最优模型。(4)利用最优模型绘制 COD 浓度时空分布图。

2.3.2 特征变量选择

在 COD 反演模型构建中, 获取与 COD 关系密切的敏感波段, 将其作为模型的输入因子有助于我们提高模型的预测精度。本研究利用 Pearson 相关性分析来探究与 COD 浓度相关的敏感波段。Pearson 相关系数是一种线性相关系数, 通过 Pearson 相关分析可以得出不同波段与 COD 浓度的相关性强弱, 可进一步剔除没有相关性的、可能干扰反演的波段。因此, 首先使用 Pearson 相关性分析对除 B10 外的 Sentinel-2

各个波段进行相关性分析, 从中选出与 COD 具有相关性的波段。此外, 有研究表明, 遥感指数可能提供更加敏感的信息, 将遥感指数作为模型的输入因子参与模型构建能够提高模型精度^[41-42]。基于此, 本研究选择了最为常用的 NDVI^[43] 和 NDWI^[40], 并进行 Pearson 相关性分析。经过 Pearson 相关性分析后, 本研究最终确定了 10 个单波段指数和 2 个遥感指数作为输入变量, 共同参与模型的构建, 其相关性结果如表 2 所示。

表 2 COD Pearson 相关性结果
Table 2 Pearson correlation analysis result of COD

变量	B2	B3	B5	B6	B7	B8	B8a	B9	B11	B12	NDWI	NDVI
Pearson相关性	-0.315**	-0.335**	0.479**	0.776**	0.774**	0.732**	0.773**	0.795**	0.752**	0.752**	-0.861**	0.809**

注: **表示相关关系在 0.01 水平上显著。

2.3.3 机器学习算法

(1) 类别提升回归树

类别提升回归树 (catboost regression, CBR) 是由俄罗斯 Yandex 学者于 2017 年提出的一种改进的新型梯度提升决策树算法。该算法在梯度提升学习的基础上进行了改进, 在进行类别特征处理的同时可以将信息损失降到最低。由于该算法可以在实现不同结构数据特征的合并的情况下消除数据中的噪声以及彼此之间的复杂依赖关系, 而被广大学者欢迎^[44]。

(2) 梯度提升回归树

梯度提升回归树 (gradient boost regression, GBR) 是一类以决策树为基本学习器的集成算法。其基本思路是使用 CART 回归树作为弱分类器, 并通过提升机制进行迭代训练; 迭代过程中, GBR 根据弱学习器的误差调整训练样本权重, 采用梯度下降法在每次迭代中向损失函数的负梯度移动, 使损失函数下降以达到局部最优解或全局最优解^[45]。

(3) K 最近邻

K 最近邻 (K-nearest neighbor regression, KNNR) 基于距离度量的一种非参数算法。其主要原理是根据距离计算方法确定 K 值, 然后从训练样本中选择 K 个与测试样本距离最接近的样本, 以 K 个样本均值作为预测值^[46]。KNNR 的算法固有特性使其对 K 值敏感, 容易出现误差导致预测结果不理想^[47]。

(4) 轻量级梯度提升机

轻量级梯度提升树 (light gradient boosting machine, LGBM) 是一种基于梯度增强决策树 (GBDT) 算

法的改进模型。它结合了随机森林和梯度学习算法的优点, 采用直方图算法来寻找最优的分割点^[48]。同时, LGBM 使用 leaf-wise 叶子生长策略来提高预测模型的准确性并减少计算时间。

(5) 随机森林

随机森林 (random forest, RF) 是一类以决策树作为基学习器的集成算法。它基于装袋法思想进行随机采样, 生成不同的子集用于构建回归树^[49]。该算法通过计算特征变量的重要性去除弱相关特征, 能够以较少的强相关特征变量集作为输入也获得较高的预测精度^[50]。此外 RF 具有随机性, 不需要过多考虑多元共线的问题, 具有较高的准确性和泛化能力。

(6) 极端梯度提升

极端梯度提升 (extreme gradient boosting regression, XGBR) 是由 Chen and Guestrin^[51] 提出的一种基于梯度提升回归树的决策树模型。它将基于原因的决策树方法 (CBDT) 和基于梯度提升的机器方法 (GBM) 有效的结合在一起, 并通过使用二阶泰勒展开有效地最小化函数。同时, XGBR 使用正规化项来提高模型的泛化能力并防止过拟合。

2.3.4 模型构建与评估

本研究将 80% 的样本数据 (112 个) 作为训练集, 其余 20% (28 个) 作为测试集, 用于 COD 反演模型的构建。我们将利用 Pearson 相关性分析后与 COD 相关性较高的 12 个特征变量 (表 2) 作为输入因子输入 6 个机器学习模型中进行训练, 根据决定系数 (R^2) 和均方根误差 (RMSE) 选择最优的 COD 浓度反演的模型。其中, R^2 和 RMSE 如式 (1) 和式 (2) 所示。

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (1)$$

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}, \quad (2)$$

式中: y_i 为第 i 个采样点的 COD 浓度的实测值, $\bar{y}$ 是采样点的 COD 浓度的平均值, $\hat{y}_i$ 是第 i 个采样点的 COD 的预测值。

3 结果

3.1 机器学习模型性能评估

图 3 和表 3 表示了使用 6 种机器学习算法模型对 COD 反演的精度评估结果。根据 R^2 和 RMSE 可知,

XGBR 在 6 种机器学习模型中的拟合效果最好, 训练阶段 R^2 均达到 0.963 9, RMSE 达到 1.375 0 mg/L; 测试阶段 R^2 均达到 0.943 2, RMSE 达到 1.403 3 mg/L。其次, GBR 和 LGBM 也表现了优异的拟合效果, 其 R^2 均不低于 0.918 0, 且 RMSE 均不大于 1.578 6 mg/L。此外, 尽管 CBR 和 RF 的 R^2 值显示出其反演效果尚可, 但结合 RMSE 的数值来看, 它们的反演模型性能相较于 XGBR、GBR 以及 LGBM 模型稍显逊色。而 KNNR 虽然训练集的 R^2 均达到 0.816 0, 但其 RMSE 过高, 这可能意味着在低浓度 COD 的反演中, 该模型可能会产生较大的误差。

3.2 特征变量分析

根据表 3 和图 3 结果选择 XGBR 模型作为本研




图 3 6 种机器学习模型预测的 COD 浓度值与实测值的散点图

Fig. 3 Performances of the six different models for COD estimation on the training set (blue) and test set (red)

表 3 不同机器学习算法精确度评估结果
Table 3 Accuracy comparison results of different models

机器学习模型	训练集(80%)		测试集(20%)	
	R^2	RMSE/(mg·L ⁻¹)	R^2	RMSE/(mg·L ⁻¹)
CBR	0.919 4	2.054 5	0.938 7	1.457 8
GBR	0.958 1	1.481 8	0.918 0	1.554 5
KNNR	0.816 0	3.104 5	0.878 6	2.052 0
LGBM	0.989 2	0.750 5	0.928 2	1.578 6
RF	0.875 2	2.556 7	0.926 7	1.594 1
XGBR	0.963 9	1.375 0	0.943 2	1.403 3

究的 COD 反演模型进行下一步的研究。XGBR 能够将输入的特征变量进行重要性排序,可以用于进行 COD 的特征变量分析。本研究将所有的输入变量导入 XGBR 模型中,对它们在 COD 浓度反演上的重要性进行排序。根据重要性的强弱,将特征从大到小进行排序,其贡献程度用 F score 表示,结果如图 4 所示。在 COD 浓度反演模型中,贡献度排名第一的为 B8a,其次是 B2。NDVI 位列第三,而 NDWI 则排在第四位。这一结果表明,在构建机器学习模型进行反演时,除了利用遥感影像的单波段变量外,纳入植被指数以及水体指数等遥感指数作为特征变量,能够有利于提升模型的反演精度。




图 4 XGBR 模型中所有特征变量的重要性排序
Fig. 4 Ranking of the importance of all characteristic variables in the XGBR model

3.3 COD 的时空分布特征

COD 浓度时空动态变化迅速,单个年份的浓度空间分布无法全面揭示 COD 浓度的时空分布特征,需要结合多个年份进行分析。基于此,本文利用 XGBR 模型通过 2019–2023 年的 Sentinel-2 影像绘制 COD 浓度分布图,并按照年份求 COD 浓度平均值(图 5)。由图 5 可知,养殖池中的 COD 浓度远高于茅尾海。

2019–2023 年期间,养殖池中 COD 的空间分布较为均匀,同时其 COD 年平均浓度变化不大,位于 16.23~17.39 mg/L 之间波动。相比之下,茅尾海海域 COD 年平均浓度则在 2.30~2.88 mg/L 之间,大体上呈现上升的趋势,该浓度范围满足《海水水质标准》(GB 3097–1997)中的第二类水质标准。从空间分布来看,COD 整体上呈现北高南低、近岸高于远岸的空间分布特征。此外,在养殖蚝排附近水体可能存在局部高值区域,这些区域的 COD 浓度可能相对较高。

4 讨论

4.1 机器学习算法选择与变量分析

机器学习算法已被证明比传统统计回归方法在 COD 浓度估算方面具有优势^[28]。这些算法不需要数据服从一定的分布规律,同时能够克服多重共线性问题。然而,不同机器学习算法和不同输入变量对 COD 模型的预测能力不同。本研究选用了 6 种机器学习模型对茅尾海及其沿岸养殖池进行 COD 浓度估算。结果表明(图 3 和表 3),XGBR 模型的反演能力最强,在测试阶段 R^2 为 0.943 2, RMSE 为 1.403 3 mg/L。这一结果表明,对于养殖水体和沿海海域这两类水质差异显著的水体,XGBR 模型表现出较强的适用性和良好的通用性,无论在低浓度还是高浓度区域均取得了良好的表现。XGBR 模型结合了梯度提升算法与正则化技术的优势,通过集成多个决策树来增强预测的精确性,尤其擅长处理复杂且非线性的关系^[51]。此外,我们发现 CBR、GBR、LGBM 和 RF 模型的拟合效果较好。XGBR、GBR、CBR、LGBM 和 RF 是较为典型的以决策树为基础的集成算法,可以灵活处理各种数据,预测精度较高。这可能是由于这类算法结合了多个基础学习器,并集成为一个具有高鲁棒性的强学习器,因此可以获得比单个学习器更好的预测结果^[52]。同时,本研究中 KNNR 模型的预测精度低于其他模型,KNNR 模型是一类基于距离度量的单一模型,也说明了这一结论。综上所述,集成学习模型在 COD 反演领域具有广阔的应用前景,其中 XGBR 模型表现尤为突出。本研究不仅为茅尾海及其沿岸养殖池的 COD 浓度估算提供了新的方向,还为如何同时反演差异性较大的水体的 COD 浓度提供了一种新的解决思路。

本研究对输入变量的重要性进行排序,结果如图 4 所示。我们可以发现 B8a、B2 以及 NDVI 对 COD 反演发挥着重要的贡献,这可能是由于 COD 与有机物以及叶绿素 a 之间存在内在联系。COD 浓度取决




图5 2019–2023年研究区COD浓度分布

Fig. 5 Distribution of COD concentration from 2019 to 2023

于水体可溶性有机物总量,这些有机物含有大量氢基团(如C-H),这些基团在近红外区的倍频与合频会发生光谱吸收现象^[53]。因此,随着COD浓度的变化,水体在近红外区的反射率一般也会呈现出相应的变化。所以B8a可能更为敏感地反映了COD浓度的变化,在模型构建中发挥最大贡献。B2虽然与COD浓度的相关性较低,但在模型构建中发挥着较大的作用,这可能由于叶绿素 a 在B2处存在一个吸收带,而水体本身在B2波段的吸收作用就很强导致^[21]。虽然COD的升高或降低并非是直接导致叶绿素 a 浓度变化的原因,但在人类活动的影响下,COD浓度较高的水体往往伴随着较高的营养盐和有机物含量,这为浮游植物的生长和繁殖提供了有利条件,进而增加了叶绿素 a 的浓度。这一过程表明,COD浓度与叶绿素 a 浓度之间存在着密切的关联,可以说COD是叶绿素 a 的被动因子,即COD浓度的变化往往伴随着叶绿素 a 浓度的相应变化。目前,已有相关研究证实了COD与叶绿素 a 具有相关性^[54–56]。此外,NDVI对模型的贡献度较高,NDVI与水体中的叶绿素 a 浓度

密切相关,可以衡量水体浮游植物生物量和富营养化水平^[57]。这一结果进一步验证了COD与叶绿素 a 之间相关性的结论。因此,在建立反演模型时,增加与叶绿素 a 有关的光谱波段和植被指数参数可以提高模型的反演性能。同时,我们发现水体指数也在模型中发挥一定作用。多数研究将水体指数用于叶绿素 a 反演模型构建^[58–59],而COD与叶绿素 a 具有相关性,表明水体指数可能有助于COD浓度反演。如王小平等^[60]在艾比湖流域验证了水体指数在COD反演上的应用潜力,与本文研究成果一致。虽然可以利用不同波段进行组合运算,但波段的简单组合不仅具有随机性还缺乏科学严谨性,而通过添加植被指数和水体指数弥补了这一缺陷,为COD反演模型中特征变量选取提供新的思路。

4.2 COD时空分布特征分析

研究表明,茅尾海海域COD浓度变化主要与人类活动有关^[61]。COD呈现从河口向外湾递减的分布格局。茅尾海水动力过程较为复杂,潮流呈往复流性质,受茅岭江和钦江较强径流的推动作用,COD随茅

岭江和钦江进入湾内河口区并向外湾扩散^[62]。养殖池 COD 浓度分布较为均一,局部出现高值或者低值。茅尾海沿岸池塘养殖多以散养为主, COD 的这一分布格局可能与养殖种类、养殖方式和养殖密度有关^[29, 63]。在本研究中,茅尾海北部沿岸养殖池中的 COD 浓度显著高于茅尾海海域。这一现象可能是随着养殖周期的推进,投喂的饵料与养殖过程中使用的药剂不断累积,导致养殖水体中的 COD 浓度逐步上升。同时,养殖水体自身的净化能力不足,难以有效降解水中的 COD,从而使其浓度维持在较高水平。相比之下,当养殖尾水排入茅尾海海域时, COD 受到红树林的净化效应、水体的自然稀释作用以及 COD 自身的降解过程等多重因素的影响,其浓度得以有效降低,维持在相对较低的水平。这一发现与 Zhang 等^[29]的研究结果较为一致。

4.3 模型不确定性分析以及未来研究方向

在对比多种机器学习模型的过程中,我们发现基于树的集成学习算法展现出了卓越的性能,其中 XGBR 模型尤为突出。这一发现表明,即使在样本量较少且水质差异显著的情况下, XGBR 模型依然能够为 COD 反演提供出色的效果,并展现出极强的稳定性。因此, XGBR 模型在 COD 模型的反演方面上展现出了广阔的应用前景。未来我们可以尝试将其推广并应用于其他水体或海域。然而,通过观察图 3,我们可以发现,除了 XGBR 和 LGBM 模型外, CBR、GBR 和 RF 均存在一定的问题。具体来说,这些模型在预测 COD 浓度低值范围(0~6 mg/L)时表现不佳,具体表现为:在 0~3 mg/L 的范围内存在低值高估的现象,而在 3~6 mg/L 的水体中则出现了高值低估的情况。这一现象表明了不同浓度的 COD 会对模型性能产生显著影响。水体光学特性受水体组分影响,养殖池和茅尾海由于水体组成和浓度具有较大差异。像养殖池这类水体属于富营养化水体,具有明显的波峰、波谷,而茅尾海这类相对清洁的水体在绿波段附近形成波峰后迅速降低^[64-65]。两者不同的光学特性可能对反演模型性能造成影响,这说明对于水质差异性较大的水体,这类模型可能不太适用。此外,本研究使用的采样点位数据较少,同时茅尾海水体中与养殖池水体中的样本量存在一定差距,导致训练模型时难以平衡两者差距,从而产生误差。同时本研究区设置的时间窗为 7 d,采样时间与影像获取时间无法保

证高度一致,从而影响 COD 浓度估算的准确性。尽管目前已经取得了初步成果,但本研究存在一定局限性,需要在未来的研究中克服和改进:(1)进一步完善野外采样方案,增加并平衡茅尾海以及沿岸养殖池的 COD 样本量,减少由于水体差异性较大导致的模型不稳定性;(2)增加野外采样过程中进行实测原位光谱数据的采集这一部分工作内容,避免采样时间与影像获取时间不一致导致的不确定性;(3)未来研究时将自动机器学习以及深度学习纳入模型进行 COD 建模,进一步提高模型的学习能力和泛化能力。

5 结论

本研究基于 Sentinel-2 遥感数据和实测 COD 数据,比较 CBR、GBR、KNNR、LGBM、RF 和 XGBR 6 种不同的机器学习算法对茅尾海及其沿岸养殖塘的 COD 浓度评估结果,分析两者 COD 浓度的时空分布特征。主要结论如下:

(1)基于树的集成模型在 COD 反演上取得良好的拟合效果,其中, XGBR 模型拟合效果最好,模型性能最优,其测试集阶段的 R^2 达到 0.943 2, RMSE 为 1.403 3 mg/L,适用于本研究区 COD 浓度反演。

(2)B8a 在 XGBR 反演模型中的贡献度最高,其次是 B2,排名第三的是 NDVI,通过增加与叶绿素 a 有关的光谱波段和植被指数参数可以提高模型的反演性能。

(3)养殖池水体中 COD 在 2019–2023 年期间年平均浓度变化不大,位于 16.23~17.39 mg/L 之间波动,空间分布格局较为均匀,整体维持在一个较高的水平。茅尾海海域 COD 年平均浓度则在 2.30~2.88 mg/L 之间,大体上呈现上升的趋势,呈现由内湾向外湾递减、近岸高于远岸的空间分布特征。

总体上,在构建 COD 反演模型的过程中,引入与 COD 高度相关的水体指数及植被指数,能够显著提升模型的预测精度。同时,针对养殖水体及其沿岸海域这两类具有特殊性的水体环境,采用 XGBR 模型进行 COD 的反演展现出了广泛的适用性,无论在低浓度还是高浓度区域均取得了良好的表现。本研究成果不仅为多种复杂水质条件下的 COD 反演提供了有益的思路参考,还为沿海地区的水产养殖活动及环境管理工作提供了坚实的技术支撑与理论依据。

参考文献:

- [1] 马达开,尹涓.水环境中有机污染综合指标监测方法及其进展[J].实验与分析,2023,1(1):6–10.

- Ma Dakai, Yin Wei. Monitoring methods and progress of organic pollutants in water environment[J]. Labor Praxis, 2023, 1(1): 6–10.
- [2] Naylor R L, Hardy R W, Buschmann A H, et al. A 20-year retrospective review of global aquaculture[J]. *Nature*, 2021, 591(7851): 551–563.
- [3] 第二次全国污染源普查公报[J]. 环境保护, 2020, 48(18): 8–10.
The second national pollution source census bulletin[J]. Environmental Protection, 2020, 48(18): 8–10.
- [4] 陈一波, 宋国宝, 赵文星, 等. 中国海水养殖污染负荷估算[J]. 海洋环境科学, 2016, 35(1): 1–6, 12.
Chen Yibo, Song Guobao, Zhao Wenxing, et al. Estimating pollutant loadings from mariculture in China[J]. Marine Environmental Science, 2016, 35(1): 1–6, 12.
- [5] 邱嘉玲, 刘庆玉, 贺莉. 化学需氧量检测标准与检测方法进展[J]. 化学研究与应用, 2023, 35(12): 2809–2819.
Qiu Jialing, Liu Qingyu, He Li. Chemical oxygen demand test standard and test method[J]. Chemical Research and Application, 2023, 35(12): 2809–2819.
- [6] 范日高, 王武, 郑芝芳, 等. 近红外光谱的水体污染指标 COD 定量预测模型[J]. 福州大学学报 (自然科学版), 2024, 52(2): 228–235.
Fan Rigao, Wang Wu, Zheng Zhifang, et al. Quantitative prediction model of COD water pollution index based on near-infrared spectroscopy[J]. Journal of Fuzhou University (Natural Science Edition), 2024, 52(2): 228–235.
- [7] Zheng Zijia, Jiang Yizhu, Zhang Qiutong, et al. A feature selection method based on relief feature ranking with recursive feature elimination for the inversion of urban river water quality parameters using multispectral imagery from an unmanned aerial vehicle[J]. *Water*, 2024, 16(7): 1029.
- [8] Zhang Yishan, Kong Xin, Deng Licui, et al. Monitor water quality through retrieving water quality parameters from hyperspectral images using graph convolution network with superposition of multi-point effect: a case study in Maozhou River[J]. *Journal of Environmental Management*, 2023, 342: 118283.
- [9] 董月群, 冒建华, 梁丹, 等. 城市河道无人机高光谱水质监测与应用[J]. 环境科学与技术, 2021, 44(S1): 289–296.
Dong Yuequn, Mao Jianhua, Liang Dan, et al. Water quality monitoring and application in urban river based on hyperspectral of unmanned aerial vehicle[J]. Environmental Science & Technology, 2021, 44(S1): 289–296.
- [10] Hou Yikai, Zhang Anbing, Lv Rulan, et al. A study on water quality parameters estimation for urban rivers based on ground hyperspectral remote sensing technology[J]. *Environmental Science and Pollution Research*, 2022, 29(42): 63640–63654.
- [11] 陈瑶, 黄长平, 张立福, 等. 水体 COD 光谱特性分析及遥感反演模型构建[J]. 光谱学与光谱分析, 2020, 40(3): 824–830.
Chen Yao, Huang Changping, Zhang Lifu, et al. Spectral characteristics analysis and remote sensing retrieval of COD concentration[J]. Spectroscopy and Spectral Analysis, 2020, 40(3): 824–830.
- [12] 赵旭阳, 刘征, 贺军亮, 等. 黄壁庄水库水质参数遥感反演研究[J]. 地理与地理信息科学, 2007, 23(6): 46–49.
Zhao Xuyang, Liu Zheng, He Junliang, et al. Hyperspectral characteristics and retrieval of water quality parameters for Huangbizhuang Reservoir[J]. Geography and Geo-Information Science, 2007, 23(6): 46–49.
- [13] Yang Zhe, Gong Cailan, Ji Tiemei, et al. Water quality retrieval from ZY1-02D hyperspectral imagery in urban water bodies and comparison with sentinel-2[J]. *Remote Sensing*, 2022, 14(19): 5029.
- [14] 盛辉, 池海旭, 许明明, 等. 改进 SVR 的内陆水体 COD 高光谱遥感反演[J]. 光谱学与光谱分析, 2021, 41(11): 3565–3571.
Sheng Hui, Chi Haixu, Xu Mingming, et al. Inland water chemical oxygen demand estimation based on improved SVR for hyperspectral data[J]. Spectroscopy and Spectral Analysis, 2021, 41(11): 3565–3571.
- [15] 鲁婉婷, 徐攻博, 王昱, 等. 基于北京二号卫星影像与同步实测数据的椒江入海口水质遥感反演[J]. 杭州师范大学学报 (自然科学版), 2023, 22(2): 218–224.
Lu Wanting, Xu Gongbo, Wang Yu, et al. Remote sensing retrieval of water quality at Jiaojiang Estuary based on Beijing No. 2 satellite image and synchronously measured data[J]. Journal of Hangzhou Normal University (Natural Science Edition), 2023, 22(2): 218–224.
- [16] 王丽艳, 史小红, 孙标, 等. 基于 MODIS 数据遥感反演呼伦湖水体 COD 浓度的研究[J]. 环境工程, 2014, 32(12): 103–108.
Wang Liyan, Shi Xiaohong, Sun Biao, et al. Determination of COD concentration of water in Hulun Lake based on MODIS data[J]. Environmental Engineering, 2014, 32(12): 103–108.
- [17] 解启蒙, 林茂森, 杨国范, 等. 清河水库水体高锰酸盐指数遥感反演模型研究[J]. 中国农村水利水电, 2017(10): 57–61.
Xie Qimeng, Lin Maosen, Yang Guofan, et al. Study on remote sensing inversion model of permanganate index in Qinghe Reservoir[J]. China Rural Water and Hydropower, 2017(10): 57–61.
- [18] 郭荣幸, 王超梁, 陈济民, 等. 基于 Sentinel-2 多光谱遥感影像的小浪底水质反演[J]. 人民黄河, 2024, 46(1): 93–96, 102.
Guo Rongxing, Wang Chaoliang, Chen Jimin, et al. Remote sensing inversion of water quality of Xiaolangdi Reservoir based on Sentinel-2 multi-spectral images[J]. *Yellow River*, 2024, 46(1): 93–96, 102.
- [19] Cao Xin, Zhang Jing, Meng Haobin, et al. Remote sensing inversion of water quality parameters in the Yellow River Delta[J]. *Ecological Indicators*, 2023, 155: 110914.
- [20] Peng Changchun, Xie Zhijun, Jin Xing. Using ensemble learning for remote sensing inversion of water quality parameters in Poyang Lake[J]. *Sustainability*, 2024, 16(8): 3355.
- [21] 王姣, 李威, 赵卫权, 等. 基于哨兵-2 数据的喀斯特高原深水湖库 COD_{Mn} 遥感反演[J]. 遥感技术与应用, 2024, 39(1): 98–109.
Wang Jiao, Li Wei, Zhao Weiquan, et al. Retrieving COD_{Mn} concentration in Karst Plateau Deep Lake reservoir using Sentinel-2 data[J].

- Remote Sensing Technology and Application, 2024, 39(1): 98–109.
- [22] 高佳欣, 林昱坤, 涂耀仁, 等. 遥感反演技术应用于监测地表水体水质参数的现状与展望[J]. 遥感信息, 2023, 38(6): 1–14.
Gao Jiaxin, Lin Yukun, Tu Yaoren, et al. Current status and prospects of remote sensing inversion technology applied to monitoring water quality parameters of surface water[J]. Remote Sensing Information, 2023, 38(6): 1–14.
- [23] Yang Haibo, Kong Jialin, Hu Huihui, et al. A review of remote sensing for water quality retrieval: progress and challenges[J]. *Remote Sensing*, 2022, 14(8): 1770.
- [24] Cao Jiaju, Wen Xingping, Luo Dayou, et al. Study on water quality inversion model of Dianchi Lake based on Landsat 8 data[J]. *Journal of Spectroscopy*, 2022, 2022: 3341713.
- [25] 黄振辉, 杨小红, 王力哲, 等. 小样本下大冶湖非光学活性水质参数反演与时空变化分析[J]. 长江流域资源与环境, 2024, 33(1): 102–113.
Huang Zhenhui, Yang Xiaohong, Wang Lizhe, et al. Inversion and spatiotemporal variation of non-optically active water quality parameters in Daye Lake with small samples[J]. *Resources and Environment in the Yangtze Basin*, 2024, 33(1): 102–113.
- [26] Gholizadeh M, Saeedi R, Bagheri A, et al. Machine learning-based prediction of effluent total suspended solids in a wastewater treatment plant using different feature selection approaches: a comparative study[J]. *Environmental Research*, 2024, 246: 118146.
- [27] Zhao Yubo, Yu Tao, Hu Bingliang, et al. Retrieval of water quality parameters based on near-surface remote sensing and machine learning algorithm[J]. *Remote Sensing*, 2022, 14(21): 5305.
- [28] 王春玲, 史锴源, 明星, 等. 基于机器学习的水体化学需氧量高光谱反演模型对比研究[J]. 光谱学与光谱分析, 2022, 42(8): 2353–2358.
Wang Chunling, Shi Kaiyuan, Ming Xing, et al. A comparative study of the COD hyperspectral inversion models in water based on the machine learning[J]. *Spectroscopy and Spectral Analysis*, 2022, 42(8): 2353–2358.
- [29] Zhang Yumeng, Jing Wenlong, Deng Yingbin, et al. Water quality parameters retrieval of coastal mariculture ponds based on UAV multispectral remote sensing[J]. *Frontiers in Environmental Science*, 2023, 11: 1079397.
- [30] 邹志科, 余蕾, 张煜, 等. 基于 Sentinel2-L1C 的江汉平原水产养殖区水质参数反演[J]. 长江科学院院报, 2023, 40(9): 181–187, 194.
Zou Zhike, Yu Lei, Zhang Yu, et al. Inversion of water quality parameters in Jiangnan Plain based on Sentinel2-L1C image[J]. *Journal of Changjiang River Scientific Research Institute*, 2023, 40(9): 181–187, 194.
- [31] 胡义强, 杨骥, 荆文龙, 等. 茅尾海入海河口池塘养殖污染状况遥感调查[J]. 测绘通报, 2022(7): 12–17, 53.
Hu Yiqiang, Yang Ji, Jing Wenlong, et al. Remote sensing investigation on water pollution of pond aquaculture in estuary of Maowei Sea[J]. *Bulletin of Surveying and Mapping*, 2022(7): 12–17, 53.
- [32] Xu Cheng, Yang Bin, Dan S F, et al. Spatiotemporal variations of biogenic elements and sources of sedimentary organic matter in the largest oyster mariculture bay (Maowei Sea), Southwest China[J]. *Science of the Total Environment*, 2020, 730: 139056.
- [33] Yang Bin, Lan Rizhong, Lu Dongliang, et al. Phosphorus biogeochemical cycling in intertidal surface sediments from the Maowei Sea in the northern Beibu Gulf[J]. *Regional Studies in Marine Science*, 2019, 28: 100624.
- [34] 黄友菊, 田义超, 张强, 等. 资源一号 02D 高光谱数据红树林地上生物量反演[J]. 光谱学与光谱分析, 2023, 43(12): 3906–3915.
Huang Youju, Tian Yichao, Zhang Qiang, et al. Estimation of aboveground biomass of mangroves in Maowei Sea of Beibu Gulf based on ZY-1-02D satellite hyperspectral data[J]. *Spectroscopy and Spectral Analysis*, 2023, 43(12): 3906–3915.
- [35] 高金荣, 赵则春. 钦州茅尾海海域化学需氧量的分布特征及与富营养化的关系[J]. 海洋湖沼通报, 2021, 43(3): 145–150.
Gao Jinrong, Zhao Zechun. Distribution of COD and its relationship with Eutrophication in Maowei Bay of Qinzhou[J]. *Transactions of Oceanology and Limnology*, 2021, 43(3): 145–150.
- [36] Lu Dangleiang, Zhang Dong, Zhu Wenjuan, et al. Sources and long-term variation characteristics of dissolved nutrients in Maowei Sea, Beibu Gulf, China[J]. *Journal of Hydrology*, 2022, 615: 128576.
- [37] Li Sijia, Song Kaishan, Wang Shuai, et al. Quantification of chlorophyll-a in typical lakes across China using Sentinel-2 MSI imagery with machine learning algorithm[J]. *Science of the Total Environment*, 2021, 778: 146271.
- [38] 刘轩, 赵同谦, 蔡太义, 等. 丹江口水库总氮、氨氮遥感反演及时空变化研究[J]. 农业资源与环境学报, 2021, 38(5): 829–838.
Liu Xuan, Zhao Tongqian, Cai Taiyi, et al. Spatiotemporal monitoring of total nitrogen and ammonia nitrogen in Danjiangkou reservoir[J]. *Journal of Agricultural Resources and Environment*, 2021, 38(5): 829–838.
- [39] Yuan Xingyu, Wang Shengrui, Fan Fuqiang, et al. Spatiotemporal dynamics and anthropologically dominated drivers of chlorophyll-a, TN and TP concentrations in the Pearl River Estuary based on retrieval algorithm and random forest regression[J]. *Environmental Research*, 2022, 215: 114380.
- [40] McFeeters S K. The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features[J]. *International Journal of Remote Sensing*, 1996, 17(7): 1425–1432.
- [41] Li Xiaojuan, Huang Mutao, Li Jianbao. Remote sensing inversion of lake water quality parameters based on ensemble modelling[C]//Proceedings of 2nd International Symposium on Architecture Research Frontiers and Ecological Environment (ARFEE 2019). EDP Sciences, 2020: 02007.
- [42] Gao Lin, Wang Xiaofei, Johnson B A, et al. Remote sensing algorithms for estimation of fractional vegetation cover using pure vegetation index values: a review[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2020, 159: 364–377.

- [43] 朱冰川, 尤凯, 石浚哲, 等. 基于 GOCI 数据的太湖叶绿素 a 浓度反演和蓝藻水华遥感监测[J]. 环境污染与防治, 2020, 42(8): 1021–1025, 1032.
Zhu Bingchuan, You Kai, Shi Junzhe, et al. Retrieval of chlorophyll-a and remote sensing monitoring of cyanobacteria blooms in Taihu Lake based on GOCI data[J]. Environmental Pollution & Control, 2020, 42(8): 1021–1025, 1032.
- [44] Prokhorenkova L, Gusev G, Vorobev A, et al. CatBoost: unbiased boosting with categorical features[C]//Proceedings of the 32nd International Conference on neural information processing systems. Montréal: Curran Associates Inc., 2018.
- [45] Friedman J H. Greedy function approximation: a gradient boosting machine[J]. *Annals of Statistics*, 2001, 29(5): 1189–1232.
- [46] Abedi F, Amirian - Chakan A, Faraji M, et al. Salt dome related soil salinity in southern Iran: prediction and mapping with averaging machine learning models[J]. Land Degradation & Development, 2021, 32(3): 1540–1554.
- [47] 唐茂淞, 张楠, 李国辉, 等. 基于机器学习算法的棉田土壤钾、钠离子量预测[J]. 灌溉排水学报, 2023, 42(9): 32–39.
Tang Maosong, Zhang Nan, Li Guohui, et al. Predicting soil K⁺ and Na⁺ contents in cotton field using machine learning algorithm[J]. Journal of Irrigation and Drainage, 2023, 42(9): 32–39.
- [48] Hajhosseini M, Maghsoudi A, Ghezelbash R. A novel scheme for mapping of MVT-type Pb–Zn prospectivity: LightGBM, a highly efficient gradient boosting decision tree machine learning algorithm[J]. *Natural Resources Research*, 2023, 32(6): 2417–2438.
- [49] 程婉清, 袁定波, 熊鹏, 等. 基于多种机器学习算法的水质指数预测模型构建与评估[J]. 环境科学学报, 2023, 43(11): 144–152.
Cheng Wanqing, Yuan Dingbo, Xiong Peng, et al. Construction and evaluation of city water quality index prediction model based on multiple machine learning algorithms[J]. Acta Scientiae Circumstantiae, 2023, 43(11): 144–152.
- [50] Genuer R, Poggi J M, Tuleau-Malot C. Variable selection using random forests[J]. *Pattern Recognition Letters*, 2010, 31(14): 2225–2236.
- [51] Chen Tianqi, Guestrin C. Xgboost: a scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco: Association for Computing Machinery, 2016: 785–794.
- [52] 贾涛, 韩萌, 王少峰, 等. 数据流决策树分类方法综述[J]. 南京师大学报 (自然科学版), 2019, 42(4): 49–60.
Jia Tao, Han Meng, Wang Shaofeng, et al. Survey of decision tree classification methods over data streams[J]. Journal of Nanjing Normal University (Natural Science Edition), 2019, 42(4): 49–60.
- [53] 粟晖, 姚志湘, 黎国梁, 等. 生化废水 COD 的近红外光谱法测定[J]. 光谱实验室, 2011, 28(6): 3040–3043.
Su Hui, Yao Zhixiang, Li Guoliang, et al. Determination of COD in biological and chemical wastewater by near infrared spectrometry[J]. *Chinese Journal of Spectroscopy Laboratory*, 2011, 28(6): 3040–3043.
- [54] 唐海滨, 郑志伟, 胡莲, 等. 2008–2020 年三峡库区小江叶绿素 a 的时空演变特征及驱动因子[J]. 湖泊科学, 2023, 35(5): 1529–1537.
Tang Haibin, Zheng Zhiwei, Hu Lian, et al. Spatiotemporal characteristics and driver analysis of chlorophyll-a in Xiaojiang River of the Three Gorges Reservoir from 2008 to 2020[J]. *Journal of Lake Sciences*, 2023, 35(5): 1529–1537.
- [55] 罗桂林, 田林峰. 基于 WQI 法的宁夏湖泊藻类爆发过程水环境质量变化及溯源探究[J]. 环境化学, 2021, 40(7): 2073–2082.
Luo Guilin, Tian Linfeng. Study on water environmental quality change and source tracing of algae bloom in lakes of Ningxia based on WQI method[J]. *Environmental Chemistry*, 2021, 40(7): 2073–2082.
- [56] 高磊, 姚海燕, 曹婧, 等. 滦河口邻近海域夏季海水叶绿素 a 时空分布特征及其影响因素[J]. 海洋湖沼通报, 2017(5): 109–113.
Gao Lei, Yao Haiyan, Cao Jing, et al. Temporal and spatial distribution of chlorophyll-a and its influencing factors in the Luanhe adjacent waters in summer[J]. Transactions of Oceanology and Limnology, 2017(5): 109–113.
- [57] Kim E J, Nam S H, Koo J W, et al. Hybrid approach of unmanned aerial vehicle and unmanned surface vehicle for assessment of chlorophyll-a imagery using spectral indices in stream, South Korea[J]. *Water*, 2021, 13(14): 1930.
- [58] 姚焕玫, 廖鹏任, 韦毅明, 等. 基于水体特征指数的广西北部湾近岸海域叶绿素 a 浓度反演[J]. 桂林理工大学学报, 2022, 42(2): 469–476.
Yao Huanmei, Liao Pengren, Wei Yiming, et al. Inversion of chlorophyll-a concentration in coastal waters of Beibu Gulf, Guangxi based on water feature index[J]. *Journal of Guilin University of Technology*, 2022, 42(2): 469–476.
- [59] 刘宇, 李旭龙. 基于水体指数的镜泊湖叶绿素 a 质量浓度反演研究[J]. 湖南农业大学学报 (自然科学版), 2019, 45(2): 172–178.
Liu Yu, Li Xulong. The inversion study of chlorophyll a concentration in Jingpo Lake based on water body index[J]. Journal of Hunan Agricultural University (Natural Sciences), 2019, 45(2): 172–178.
- [60] 王小平, 张飞, Ghulam A, 等. 艾比湖流域地表水水质指标与水体指数关系研究[J]. 环境科学学报, 2017, 37(3): 900–909.
Wang Xiaoping, Zhang Fei, Ghulam A, et al. The relationship between the surface water quality indices and hydrology of Ebinur Lake watershed[J]. Acta Scientiae Circumstantiae, 2017, 37(3): 900–909.
- [61] 杨斌, 钟秋平, 鲁栋梁, 等. 钦州湾海域 COD 时空分布及对富营养化贡献分析[J]. 海洋科学, 2014, 38(3): 20–25.
Yang Bin, Zhong Qiuping, Lu Dongliang, et al. Temporal and spatial distributions of COD and its contribution to the eutrophication in the Qinzhou Bay[J]. Marine Sciences, 2014, 38(3): 20–25.
- [62] 高劲松, 陈波, 陆海生, 等. 钦州湾潮流场及污染物输运特征的数值研究[J]. 广西科学, 2014, 21(4): 345–350.
Gao Jingsong, Chen Bo, Lu Haisheng, et al. Numerical study on the characteristics of tidal current field and pollutant transport in Qinzhou Bay[J]. *Guangxi Sciences*, 2014, 21(4): 345–350.
- [63] 马贵范, 郭文学, 王玲玲, 等. 养殖密度和换水量及频率对凡纳滨对虾生长的影响[J]. 渔业现代化, 2018, 45(4): 21–26, 48.
Ma Guifan, Guo Wenxue, Wang Lingling, et al. Effects of culturing density and water exchange rate and frequency on growth of Litopen-

- aeus vannamei[J]. *Fishery Modernization*, 2018, 45(4): 21–26,48.
- [64] 李云梅, 赵焕, 毕顺, 等. 基于水体光学分类的二类水体水环境参数遥感监测进展[J]. *遥感学报*, 2022, 26(1): 19–31.
Li Yunmei, Zhao Huan, Bi Shun, et al. Research progress of remote sensing monitoring of case II water environmental parameters based on water optical classification[J]. *National Remote Sensing Bulletin*, 2022, 26(1): 19–31.
- [65] 刘忠华, 李云梅, 吕恒, 等. 基于生物光学模型的巢湖后向散射概率估算[J]. *环境科学*, 2011, 32(2): 464–471.
Liu Zhonghua, Li Yunmei, Lü Heng, et al. Estimating of backscattering rate in Lake Chaohu based on bio-optical model[J]. *Environmental Science*, 2011, 32(2): 464–471.

Remote sensing inversion of COD in Maowei Sea and nearshore aquaculture ponds based on machine learning

Mo Jinying^{1,2}, Tian Yichao^{1,2,3,4,5}, Wang Jiale², Du Jinze⁶, Zhang Qiang²,
Zhang Yali², Tao Jin², Lin Junliang²

(1. School of Resources, Environment and Materials, Guangxi University, Nanning 530004, China; 2. School of Resources and Environment, Beibu Gulf University, Qinzhou 535011, China; 3. Guangxi Key Laboratory of Marine Environmental Change and Disaster in Beibu Gulf, Qinzhou 535011, China; 4. Gulf Ocean Development Research Center, Beibu Gulf University, Qinzhou 535011, China; 5. Key Laboratory of Marine Geographic Information Resources Development and Utilization in the Beibu Gulf, Beibu Gulf University, Qinzhou 535011, China; 6. School of Marine Sciences, Beibu Gulf University, Qinzhou 535011, China)

Abstract: Chemical oxygen demand (COD) is an critical parameter for measuring the degree of organic pollution in water bodies. Using remote sensing inversion to quickly obtain the spatiotemporal distribution of COD concentration is essential for aquaculture pollution control and nearshore ecological environment protection. This study used Sentinel-2 extracted single band, vegetation index (NDVI), and water index (NDWI) to evaluate the performance of six models, including catboost regression (CBR), gradient boost regression (GBR), *K*-nearest neighbor regression (KNNR), light generalized boosted regression (LGBM), random forest (RF), and extreme gradient boosting regression (XGBR). The performance of each model was evaluated with the coefficient of determination (R^2) and root mean square error (RMSE). The spatiotemporal distribution characteristics of COD concentration Maowei Sea and its coastal aquaculture ponds were analyzed. The results showed that: (1) The XGBR model had the best predictive performance, with a test set R^2 of 0.943 2 and an RMSE of 1.403 3 mg/L. (2) B8a, B2, and NDVI contributed significantly to the XGBR inversion model. (3) During the period of 2019–2023, the annual average concentration of COD in the aquaculture pond water ranged from 16.23 to 17.39 mg/L, with a relatively uniform spatial distribution pattern; The annual average concentration of COD in Maowei Sea ranged from 2.30 mg/L to 2.88 mg/L, showing a distribution pattern of decreasing from the inner bay to the outer bay and higher near the shore than far shore. This study has validated the remarkable universal applicability of the XGBR model when applied simultaneously to COD inversion in two specific aquatic environments: aquaculture waters and their coastal seas. The relevant findings not only provide valuable insights for COD inversion under various complex water quality conditions but also offer robust technical support and a solid theoretical foundation for aquaculture activities and environmental management in coastal areas.

Key words: COD; machine learning algorithm; Sentinel-2; aquaculture pond; Maowei Sea