

人民长江

Yangtze River

ISSN 1001-4179, CN 42-1202/TV

《人民长江》网络首发论文

题目：基于集成学习方法的鄱阳湖水质反演模型研究
作者：刘浩，唐海云，曹列凯，张尚弘
收稿日期：2025-05-14
网络首发日期：2026-01-22
引用格式：刘浩，唐海云，曹列凯，张尚弘. 基于集成学习方法的鄱阳湖水质反演模型研究[J/OL]. 人民长江. <https://link.cnki.net/urlid/42.1202.TV.20260121.1754.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于集成学习方法的鄱阳湖水质反演模型研究

刘浩，唐海云，曹列凯，张尚弘*

(华北电力大学水利与水电工程学院，北京 102206)

摘要：针对传统统计模型与单一机器学习算法在水质遥感反演中的精度瓶颈问题，本研究提出基于多源遥感影像的集成学习优化方法。研究采用多元线性回归与3种机器学习模型（K近邻、支持向量回归和多层感知机）以及3种集成策略（Bagging、Boosting和Stacking）进行对比，分别实现鄱阳湖水温、溶解氧和pH值的反演。研究结果表明：基于Ridge回归的Stacking策略在水温反演中表现最优， R^2 值达0.829，较单模型中表现最佳的KNN提升了8.2%；Bagging中的随机森林模型在pH值反演中效果最佳， R^2 值达0.868，较单模型中表现最佳的KNN模型提升12.9%，在溶解氧反演中表现突出，RF模型 R^2 值为0.868，较单模型中表现最佳的KNN提升11.7%。通过对影像的波段特征组合优化，验证了少波段数据在集成学习框架中的有效性。反演结果表明，集成学习方法相较于单模型方法显著提升了卫星数据在水质反演方面的能力，为湖泊环境监测提供了一种高效的解决方案。

关键词：水质反演；集成学习；多源影像；机器学习模型；鄱阳湖

中图分类号：X87

文献标识码：A

Research on Poyang Lake Water Quality Inversion Model Based on Ensemble Learning Method

LIU Hao, TANG Haiyun, CAO Liekai, ZHANG Shanghong*

School of Water Resources and Hydropower Engineering, North China Electric Power University, Beijing 102206, China

Abstract: Aiming at the accuracy limitations of traditional statistical models and single machine learning algorithms in water quality remote sensing inversion, this study proposes an ensemble learning optimization method based on multi-source remote sensing imagery. The research employs multiple linear regression and three machine learning models (K-Nearest Neighbors, Support Vector Regression, and Multilayer Perceptron), along with three ensemble strategies (Bagging, Boosting, and Stacking), to invert water temperature, dissolved oxygen, and pH values in Poyang Lake. The results show that the Stacking strategy based on ridge regression performs best in water temperature inversion, and the R^2 value is 0.829, which is 8.2% higher than the k nearest neighbor which performs best in the single model; the Random Forest model within the Bagging ensemble demonstrates the best performance in pH remote sensing inversion, with an R^2 value of 0.868, representing a 12.9% improvement over the optimal single model (KNN); The Random Forest model also excels in dissolved oxygen inversion, achieving an equally high R^2 value of 0.868, which is 11.7% higher than the best single model (KNN). By optimizing the combination of spectral band features in the imagery, the study successfully

收稿日期：2025-05-14；接受日期：2025-09-15

基金项目：国家重点研发计划课题（2022YFC32020004）；国家自然科学基金（52379065）

作者简介：刘浩，男，研究生，硕士研究生，主要从事流域可视化，水域遥感反演研究。E-mail: liuhao13235@163.com

通信作者：张尚弘，男，教授，博士，主要从事数字孪生流域、防洪减灾研究。E-mail: zhangsh928@126.com

validates the effectiveness of using limited spectral bands within the ensemble learning framework. The results demonstrate that ensemble learning methods significantly enhance the capability of satellite data in water quality inversion compared to single-model approaches, providing an efficient solution for lake environmental monitoring.

Key words: water quality inversion; ensemble learning; multi-source imagery; machine learning models; Poyang Lake

0 引言

水温、溶解氧及 pH 值是基本的水质理化参数，也是反映水体环境质量状况和生态系统活力的环境指标^[1]。水温通过影响水体中的溶解氧含量和微生物活动来影响水生生物的生长代谢和增殖^[2]；水体中的溶解氧是反映水体自净能力的水质指标，可用以表征水体富营养化水平^[3]；pH 通过影响水体化学平衡影响水中污染物迁移转化与微生物群落结构^[4]。传统水质监测方法依赖于固定站点采样，观测范围较小、时效性较差，无法较好的反映湖泊水质的空间变异性及动态变化特点^[5]，当湖泊面临突发污染事件或者季节性水文波动时，无法做到快速响应与多点监测。而遥感技术^[6]由于具有范围大、频次高、成本低等特点，可应用于湖泊水质动态监测。

溶解氧及 pH 值作为弱光学活性参数，是当前遥感反演领域的重点及难点，尽管弱光学活性参数对水体波段信息的直接影响较弱，但其变化会通过影响浊度、藻类活性等参数，间接改变光谱特征，这为构建 pH、溶解氧等弱光学活性参数与波段值关联的回归模型提供了可能^[7-10]。例如，拓明香^[11]基于 Sentinel-2 影像反演 pH 值时发现，B4/(B3+B5)波段组合与 pH 的相关性最强，相关系数大于 0.6，属于强相关；彭令^[12]等则通过高光谱影像数据，实现了水体 pH 的反演，精度接近 80%；王羿^[13]采用少波段组合策略，成功反演区域土壤 pH，模型决定系数 (R^2) 达到 0.856。溶解氧的反演中，杜程^[14]发现高原盐湖环境中 679nm 和 696nm 两波段组合下的溶解氧相关性最高，达到了 0.75，钟炜萍^[15]则在太湖水质反演中使用 GF-1 影像对溶解氧反演，发现基于传统线性回归模型的反演 R^2 也能达到 0.5 以上。这些研究为弱光学活性参数的遥感反演提供了重要参考。

水质参数遥感反演方法主要包括经验统计模

型^[16]、生物光学模型^[17]及机器学习模型^[18]。余丰宁等^[19]利用经验模型成功进行了太湖水体中叶绿素参数的反演，经验模型基于遥感反射率与水质参数的统计关系构建，但受限于特定区域的适用性。崔剑^[20]等通过传统回归模型实现了青藏高原多尔索洞错水深反演与水量变化估算；而唐军武和田国良^[21]基于水色光谱分析利用生物光学模型对水体主要成分成功反演，生物光学模型通过解析水体固有光学特性实现机理化反演，但需复杂的参数输入与现场测量数据支持。

近年机器学习方法凭借出色的非线性拟合能力在水质反演中广泛应用，温开祥等^[22]基于支持向量回归 (SVR) 进行内陆水体水深的反演，李玉翠等^[23]基于 K 近邻 (KNN)、随机森林 (RF) 等算法联合构建了水质参数定量反演模型，但单一模型受过拟合或局部最优问题局限，泛化能力有待增强^[24]。而集成学习在反演水质参数时可以通过集成多个基学习器，提升反演模型的稳定性和泛化性能，在水质反演中具有较大潜力。

另外，除了模型选取外，遥感数据源的选择也是影响水质参数反演的重要影响因素。目前国内虽然在水质反演研究领域已取得了较大进展，但研究主要基于国外卫星的高光谱数据，这种过度依赖国外卫星数据的局面，也使得我国在水质反演研究上存在一定的被动性和局限性。

国产的高分一号 WFV 影像^[25]空间分辨率为 16m，只有 4 天的重访周期，数据获取成本低并且连续时间长，在水质反演中的应用潜力尚未充分开发，特别是基于少波段组合与多源数据融合的水质参数反演研究还不够充分^[26]，此外由于高分一号 WFV 影像缺少热红外波段，对水温反演造成了一定的困难，故水温反演补充采用 Landsat 遥感影像。

本文构建了基于高分一号 WFV 遥感影像、

Landsat8/9 OLI/TIRS 遥感影像与集成学习的鄱阳湖水水质参数反演框架,开展了大范围鄱阳湖水体温度、溶解氧及 pH 值的动态监测。通过分析高分一号 WFV 数据,探索了其在水质遥感参数反演中的应用潜力,验证了少波段组合对水体遥感参数的表征潜力;通过 Bagging、Boosting 和 Stacking 等策略建立多模型集成框架,集成互补的基学习器以提升反演精度和反演模型的稳定性。该研究成果可以为国产卫星遥感反演模型选取提供借鉴,为鄱阳湖水环境保护与湖泊生态管理提供技术支撑。

1 研究区域与数据

1.1 研究区概况

鄱阳湖(28°22'~29°45'N, 115°47'~116°45'E)位于江西省北部,是长江中下游典型通江湖泊,其湖口河段与长江干流形成季节性的水文连通^[18-19],在维持区域水生态物质能量循环方面发挥着关键作用,鄱阳湖的水温、溶解氧、pH 等参数的时空演变对区域水生态安全有着重要指示意义。

湖区受流域农业开发、城市化进程的影响,呈现复合型的水质特征:水温受太阳辐射影响,呈日周期性垂直分层,溶解氧受生物代谢过程影响,呈现出动态性变化,pH 值受陆源输入与藻类活动耦合作用,产生周期性波动^[27-29]。这些参数的耦合变化改变了污染物的生物地球化学行为,同时也影响底栖生物群落及迁徙水禽的栖息环境,亟待高效高精度监测体系对各水质参数的空间异质性进行解析。

本研究选取鄱阳湖区 13 个水质自动监测站点开展遥感影像水质反演研究,如图 1 所示。这些站点布设于湖区主航道、入湖河口及生态保护区等典型水域,包括位于湖区中部开阔水域的都昌站(116°11'E, 29°14'N)、临近赣江入湖口的吴城赣江站(116°00'E, 29°11'N)以及地处鄱阳湖南部信江入湖口浅水湿地的康山站(116°25'E, 28°53'N)等,站点分布涵盖了不同水文条件下的水质特征,监测数据来源于国家地表水水质自动监测实时数据发布系统,可为评估不同遥感反演模型提供可靠的地面验证数据。




图 1 鄱阳湖区位及监测站点分布

Fig.1 Location of Poyang Lake and distribution of monitoring stations

1.2 遥感与地面数据

本文遥感数据为高分一号(GF-1)卫星宽视场成像仪(WFV)数据和 Landsat8/9 OLI/TIRS 数据,其多光谱波段参数见表 1。GF1-WFV 空间分辨率 16 m,重访周期 4 天,同时具有高时间分辨率及中等空间分辨率特点,可作为大范围湖泊水质动

态监测的重要传感器。而 Landsat 9 OLI/TIRS 数据则具备更广泛的波段覆盖范围(包括可见光、近红外、短波红外以及热红外波段)。特别是 TIRS 波段,为水温反演提供了关键的热红外信息,这是 GF-1 WFV 数据所不具备的。

GF-1 遥感影像数据来自中国资源卫星应用中心陆地观测卫星数据服务平台,选取 2022 年

12 月-2023 年 12 月云覆盖量小于 10%的影像 71 景，每景影像覆盖鄱阳湖的部分区域，然后将其整合成 23 景完整的湖区影像。Landsat8/9 OLI/TIRS 遥感影像来源于地理空间数据云平台处理过的 L2 级数据,选取 2022 年 1 月-2023 年 5

月的鄱阳湖区域影像，通过裁剪最终得到覆盖鄱阳湖部分区域的影像 21 幅。水质数据来自于国家水质自动综合监管平台,选取湖区 13 个站点的水温(°C)、溶解氧(mg/L)和 pH 值的监测数据，时间分辨率为 1h。

表 1 遥感影像传感器参数
Table 1 Remote sensing sensor parameters

遥感卫星	波段	光谱范围(μm)	空间分辨率(m)	重访周期(天)	主要用途
高分一号	B1	0.45~0.52	16	4	水体悬浮物、叶绿素检测
	B2	0.52~0.59	16	4	植被识别、浑浊度反演
	B3	0.63~0.69	16	4	水体吸收特征提取
	B4	0.77~0.89	16	4	水体悬浮物、富营养化监测
Landsat8/9 OLI/TIRS	B1	0.43~0.45	30	16	海岸和气溶胶研究
	B2	0.45~0.51	30	16	植被监测
	B3	0.53~0.59	30	16	植被健康监测和悬浮物反演
	B4	0.64~0.67	30	16	植被生物量评估
	B5	0.85~0.88	30	16	监测水分含量
	B6	1.57~1.65	30	16	监测植被健康
	B7	2.11~2.29	30	16	监测植被和土壤湿度
	B10	10.6~11.19	100	16	地表温度监测

2 研究方法

为了研究集成学习方法在鄱阳湖水水质参数反演中的应用，本文构建了三种基于 Bagging、Boosting 和 Stacking 策略的集成学习模型^[30-31]，并分别建立了传统统计模型（多元线性回归）和单一机器学习模型（支持向量机、K 近邻等）与

之进行性能上的比较分析，使用评价指标决定系数（ R^2 ）和均方根误差（RMSE）对各反演模型在水温、溶解氧和 pH 值反演中的性能进行评价。技术路线如图 2 所示。




图 2 技术路线图

Figure 2 Technology roadmap

2.1 数据预处理与时空匹配

下载的 Landsat 数据为 L2 级的数据，B10 波段也通过数据重采样统一分辨率为 30m，无需再经处理。而 GF 影像数据为 GF1-WFV 原始数据，为获得高精度的遥感反演模型，应对原始数据进行图像预处理。采用三阶段处理流程：以遥感影像预处理消除大气和地形影响、以严格的时空匹配机制建立起遥感与地面数据间的匹配关系、以异常值筛选获得高质量数据。

(1) 遥感影像预处理

遥感影像预处理在 ENVI 软件中进行：①辐射定标将 DN 值转换为表观反射率；②使用 FLAASH 模块结合 MODTRAN 辐射传输模型进行大气校正；③基于 SRTM DEM 数据进行正射校正，控制空间定位误差在一个像元内。

(2) 时空匹配

为确保遥感数据与地面观测的同步性，使用严格的数据时空匹配机制来匹配遥感影像数据与水质监测数据。在空间匹配方面，鉴于水体空间连续性特征，相邻水体像元相关性较强。以各水质监测站点的地理坐标为中心，截取大小为 2×2 像元的窗口。一方面，有效表征站点周边水体的整体特征；另一方面，可将单个像元的随机噪声影响降低。然后在预处理后的遥感影像中用该窗口内所有像元的平均反射值作为对应监测站点的特征值。

时序匹配上，优先选择与卫星过境时间在同一时间窗口的 15 分钟内的水质数据，这样能最大程度满足遥感数据与地面监测数据的时间一致性要求。若该时间窗口内没有数据，则使用卫星过

境时间前后 2h 时间窗口内数据进行匹配。这样既能尽可能满足数据时间一致性原则的同时，又能兼顾样本数据的数量要求。

(3) 异常值剔除

为了保证数据质量，对数据采用两重异常值的筛选方式。一是应用水质参数的物理特点设定参数的阈值(水温区间 $(-5-40)^{\circ}\text{C}$ ，溶解氧 $(0, 20)\text{mg/L}$ ，pH 值区间 $(4, 10)$)，剔除数据中明显超出自然界水环境的数值。二是运用四分位距(IQR)法^[32]对数据进行统计学检验，以进一步识别筛选异常值。

按照上述时空匹配方法和异常值剔除方式，得到拟构建模型的样本数据：水温 64 组、pH 值 67 组、溶解氧 67 组，有效样本数据共计 198 组数据对，均通过时空一致性和数据质量控制，可作为后续构建特征和训练模型的有效数据集。

2.2 波段组合特征构建

特征工程构建作为模型构建的关键步骤^[33]，直接关系到水质参数的反演精度。基于 GF-1 WFV 卫星 4 个波段和 Landsat8/9 OLI/TIRS 的 8 个波段的反射率数据，构建一套特征组合方法，包括差波段反射率 $(B_i - B_j)$ 、比波段反射率 (B_i / B_j) 、归一化指数 $(B_i - B_j) / (B_i + B_j)$ 以及改进型比值特征 $((1/B_i \pm 1/B_j) \times B_k)$ ，设计这些特征组合充分考虑了各水质参数的光谱响应机制：波段差值特征可以强调和区分特定波段范围内的光谱响应特征^[34]；波段比值可以一定程度上减弱大气和水面状况的干扰^[34-35]；归一化指数则可对特征区分度进

一步增强,减轻环境因素干扰的影响^[36]。

特征筛选采用基于相关性分析的方法,计算所有候选特征与水温、pH 值、溶解氧等水质参数间的皮尔逊相关系数,并进行显著性检验($P<0.05$)^[37]。基于检验结果,为每个水质参数选择相关性最强的四个波段组合构建最终的特征数据集。该特征构建与筛选策略不仅保证了特征对水质参数的表征能力,而且能通过控制特征冗余降低模型过拟合风险,为后续水质参数反演模型的构建提供数据基础。

2.3 基准单模型构建

为探索水质参数与光谱特征间的关系,首先建立多元线性回归模型作为基准参照,该模型通过最小二乘准则建立水质参数与波段特征间的线性映射关系。该模型虽简单易解释,但受限于水质-光谱关系的复杂性,难以准确刻画水质参数与光谱特征间的复杂非线性映射关系^[38]。

为此,采用 3 种非线性机器学习模型:支持向量机回归(SVR)能解决非线性模型的问题,映射到高维空间的数据可以通过径向基核函数展开,适合捕捉水质参数与遥感反射率之间的非线性关系;因水质参数空间分布的连续特性,对惩罚因子 C 及 epsilon 进行网格搜索实现参数优化,从而减小 SVR 模型的过拟合现象、保证泛化性能^[39]。K 近邻回归(KNN)基于样本间近邻关系做近邻估计,这与水体光学特性的空间自相关性契合,故对邻居数目及距离的权重进行优化^[40],使得 KNN 更适合水质数据建模。多层感知机(MLP)基于多层人工神经网络结构,通过调整隐藏层结构、归一化、早停机制,能在模型复杂度和泛化能力间寻求最优平衡点^[41]。

2.4 面向水质参数反演的集成学习框架构建

由于单一模型在水质反演问题上普遍存在不足:如 MLR 无法处理非线性关系、KNN 对数据噪声较为敏感、SVR 参数优化困难等问题,构建了基于 Bagging、Boosting、Stacking 策略的集成学习方法^[30],这些方法中不同学习器组合增强了水质参数反演的稳定性和精度。

Bagging 是基于 Bootstrap 采样的并行集成学习方法,其核心思想是通过随机重采样来构建多个具有差异性的训练子集,然后训练多个相互独

立的基学习器,最终通过集成这些学习器来提高模型的泛化能力^[42]。这一机制特别适合处理水质监测中样本不平衡问题(如枯水期与丰水期在样本数量上的差异)。其中,Original Bagging 生成 m 个子集,每个子集独立训练一个决策树,反演时再平均各学习器的输出结果。RF 在其基础上随机选取特征,在决策树的每个节点分裂时从 n 个特征中随机选取 $n/3$ 个特征构建候选特征子集^[34]。这种双重随机性策略提高了基学习器的多样性,降低了过拟合发生的概率^[43],且帮助模型识别出水质参数反演最敏感的波段组合。

Boosting 的核心思想是通过加权迭代训练多个回归器,每个回归器都针对性地修正前一轮中的预测偏差,逐步提高模型整体的预测准确性^[44]。在水质参数反演中,自适应提升算法(AdaBoost)能动态调控水质样本的权重,使模型重点关注预测误差较大的水质数据,以此来提高模型对不同特性的水质参数的适应性^[45]。GBDT 则利用负梯度信息指导模型训练,将负梯度设置为训练优化目标,并采用深度优先生长、预剪枝等方法来控制树的规模,使得模型能更好的捕捉水质参数与波段组合间的联系^[46]。在此基础上,XGBoost 通过引入二阶导数和正则化项来调控训练过程,平衡模型的预测精度和复杂度,提升模型预测的稳定性^[47]。

Stacking 是常见的多层集成学习策略,其核心思想是通过堆叠多层模型结构充分整合各个类别学习器所擅长的特性,获得比单个学习器更强的学习和预测能力^[48]。在具体操作层面,第 1 层的三个异质基学习器分别是 KNN、MLR 和 SVR,第 2 层的 3 个元学习器分别是 Ridge 回归、MLP 和 RF,该方案设计充分考虑到不同特征的水质参数,如 KNN 擅长处理空间连续性的参数如水温,SVR 擅长处理非线性关系突出的参数如溶解氧,MLR 则为线性关系提供基础支撑,而 Ridge 则通过 L2 正则处理一定程度上防止模型过拟合,MLP 则采用反向传播算法不断优化神经网络权重,RF 则提供非线性特征组合能力。为了避免信息泄露,所有的方法均采用 K 折交叉验证进行数据集生成。以上方案多层堆叠融合不同模型能够自适应捕捉水质参数与遥感特征间的复杂关系,为高精度水质反演奠定了坚实的基础。

2.5 模型评价指标

选用决定系数(R^2)及均方根误差(RMSE)作为水质参数反演模型评价指标。其中, 决定系数反映模型对因变量变化解释的程度,其计算公式为:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$
 (1)

式中, y_i 为实测值, $\hat{y}_i$ 为预测值, $\bar{y}$ 实测值均值, n 为样本数量。 R^2 值范围为[0, 1], 值越接近 1, 表明模型的拟合效果越好。

均方根误差用于量化预测值与实测值之间的偏差程度, 其计算公式为:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$
 (2)

RMSE 的量纲与因变量一致, 其值越小, 表明模型的预测精度越高。通过综合考虑这两个互补性指标, 可对模型的整体性能进行客观评价, 为最优模型的筛选提供定量依据。

3 确定模型输入特征

表 2 相关性分析表明, pH 值与 B2/(B1-B4)和 B3/(B1-B4)的相关系数达到 0.742, 溶解氧与 (1/B3-B2)*B4 组合的相关系数为 0.759。水温与 B10 波段的相关性为 0.817, 表明二者之间存在高关联性, 进一步探索水温的波段组合策略, 结果显示水温与 B3+B10 组合相关性最高, 达到 0.824。此外所有波段组合均具有高度统计显著性 ($P<0.001$), 表明影像数据在水质监测中具有良好应用潜力。

表 2 波段组合与水质参数的相关系数

Table 2 Correlation coefficient between band combination and water quality parameters

水质参数	波段组合	相关性	p 值
pH (无量纲)	B2/(B1-B4)	0.742	6.67e-13
	B3/(B1-B4)	0.728	2.90e-12
	B2/(B1+B4)	0.711	1.44e-11
	B2/(B3+B4)	0.709	1.80e-11
溶解氧 (mg/L)	(1/B2-1/B3)*B4	-0.759	9.39e-14
	B2/(B1+B3)	0.720	6.70e-12
	(1/B2-1/B3)*B1	-0.701	3.90e-11
	B2/B3	0.688	1.24e-10
水温 (°C)	B3+B10	0.824	6.43e-17
	B2-B10	-0.805	1.15e-15
	B1-B10	-0.807	8.72e-16
	B4+B10	0.784	1.79e-14

pH 和溶解氧均采用相关性前四的波段组合作为输入特征。而水温模型在训练过程中, 特征输入在 B3+B10 的基础上添加 B4+B10、B2-B10、B1-B10 波段组合训练出的模型出现 R^2 依次下降现象, 这可能是由于新添加的特征 (B4+B10、B2-B10、B1-B10) 与已选特征 (如 B3+B10) 高度相关, 模型无法有效利用新增特征的信息, 甚至引入的新特征成为了噪声, 阻碍了模型收敛。

故在后续的水温模型训练中, 仅采用相关性分析中相关性最高的波段组合 B3+B10 作为特征输入。

4 结果分析

4.1 模型性能对比

为定量比较不同模型水质参数反演性能, 将不同模型预测结果在验证集进行了比较, 结果如表 3。

表 3 不同反演模型在水温、溶解氧和 pH 值预测中的性能对比

Table 3 Comparison of the performance of different inversion models in water temperature, dissolved oxygen and pH prediction

模型		方法	pH		溶解氧		水温	
			R^2	RMSE	R^2	RMSE	R^2	RMSE
传统方法	MLR	MLR	0.345	0.446	-0.116	1.613	0.685	2.79
	SVR	SVR	0.384	0.433	0.651	0.902	0.702	2.712
机器学习	KNN	KNN	0.777	0.261	0.752	0.761	0.766	2.403
	MLP	MLP	0.630	0.336	0.697	0.863	0.749	2.489
集成学习	Bagging	Original Bagging	0.824	0.231	0.837	0.617	0.685	2.787

模型	方法	pH		溶解氧		水温	
		R^2	RMSE	R^2	RMSE	R^2	RMSE
Boosting	RF	0.868	0.200	0.849	0.594	0.757	2.447
	AdaBoost	0.135	0.513	0.591	0.977	0.634	3.007
	GBDT	0.657	0.323	0.759	0.749	0.681	2.807
	XGBoost	0.467	0.403	0.825	0.639	0.773	2.369
Stacking	KNN+MLR+SVR+Ridge	0.537	0.369	0.700	0.792	0.829	2.053
	KNN+MLR+SVR+MLP	0.601	0.342	0.694	0.801	0.750	2.486
	KNN+MLR+SVR+RF	0.584	0.350	0.643	0.864	0.783	2.316

从单模型来看，机器学习算法相较于传统的 MLR 方法展现出更强的非线性拟合性能，在三种水质参数的反演中均能超越传统的 MLR 方法。集成学习在反演中通过结合多个模型的优势，进一步提高了水质参数反演的精度，各集成方法在 3 种水质参数反演中的精度都有了一定提升。Bagging 策略下 RF 方法在 pH 和溶解氧的反演中表现最佳， R^2 分别达到了 0.868 和 0.849，Boosting 策略下的 XGBoost 在溶解氧和水温参数的反演过程中 R^2 也能稳定达到 0.75 以上，而基于 Stacking 策略下的 KNN+MLR+SVR+Ridge 模型，通过两层的异质学习器组合增强模型的稳定性和可靠性，在水温的反演中达到了最高的 R^2 ，水温反演效果是所有模型中最好的。

4.1.1 单模型反演结果

如图 3 所示，pH 值反演采用传统的 MLR 和 SVR 模型效果较差， R^2 分别为 0.345 和 0.384，说明 pH 值和光谱特征之间的复杂关系超出了线性模型能表征的范围；溶解氧反演中，MLR 模型表现不佳， R^2 为-0.116，表明模型完全无法捕捉溶解氧与波段组合间的内在联系，其它各模型表现较为接近， R^2 在 0.65-0.75 之间，KNN 模型在这些方法中略胜一筹($R^2=0.752$ ， $RMSE=0.761$)；此外基于局部相似性的 KNN 模型也在水温反演中获得了单模型最优结果($R^2=0.766$ ， $RMSE=2.403$)，其次是 MLP($R^2=0.749$ ， $RMSE=2.489$)。各单模型在不同水质参数反演中表现的差异性和互补性，为下一步构建高性能的集成学习策略奠定基础。




图 3 单模型遥感反演散点图

Fig.3 Scatter plot of single-model remote sensing inversion

4.1.2 集成学习模型反演结果

集成学习实现多个基学习器优点的集纳，针对 3 个水质参数反演均实现了显著的模型性能提升。相比单一模型，Bagging 策略下的 RF 模型在 pH 值反演中的 R^2 值达到 0.868，解释力提升了约 11.7%；在溶解氧反演中的 R^2 值达到 0.849，提高了 12.9%。

Stacking 策略下的 KNN+MLR+SVR+Ridge 在水温反演中的 R^2 值达到 0.829，提高了 8.2%。由此可见，集成学习实现了利用多模型集成提高了反演预测的准确性。

在三种水质参数的反演中，Bagging 策略下

的 RF 方法均展现出比 Original Bagging 方法更优的性能，这可能是因为 RF 方法引入特征随机选择机制，进一步增强了基学习器（决策树）的多样性，而且 RF 中的决策树通常生长得更深，能够学习到更复杂的决策边界，从而更好地拟合水质参数与遥感特征之间的非线性关系。

此外注意到在 pH 和溶解氧的反演中，Bagging 策略下的两种模型性能均强于其它集成模型，可见 Bagging 策略通过随机采样和集成模型提高了模型预测的稳定性，适用于反演 pH 值和溶解氧这类线性特征不强的参数。




图 4 Bagging 策略遥感反演散点图

Fig.4 Scatter plot of remote sensing inversion of Bagging strategy

pH 反演中基于梯度提升框架的三种集成学习算法性能表现均较差，这可能是因为 pH 值与水体光谱特征的关系具有强非线性和复杂交互性，梯度提升模型对此类特征捕捉能力较弱。而在溶解氧参数反演任务中，三种集成学习算法的性能表现展现出显著的差异，XGBoost 算法凭借正则化优化与目标函数改进等措施使决定系数 (R^2) 达到 0.825，均方根误差 (RMSE) 控制在 0.639 的较低水平，相较于传统 AdaBoost 算法和

梯度提升决策树 (GBDT)，其预测准确率分别实现了 39.6%和 10.4%的显著提升。

在水温参数反演任务中，模型性能结果表明，XGBoost、AdaBoost 和 GBDT 在该任务上的 R^2 值均稳定分布在 0.6-0.76 区间，展现出中等精度的预测能力。值得注意的是，XGBoost 模型在溶解氧和水温的反演任务中展现出较好的适应性，在水温预测中能保持 R^2 大于 0.75 的可靠精度，远超其它两种提升树模型。




图 5 Boosting 策略遥感反演散点图

Fig.5 Scatter plot of remote sensing inversion of boosting strategy

如图 6 所示，在 Stacking 集成策略中，元学习器的设计对模型泛化性能具有决定性影响，该策略通过异构基学习器的优势互补，在三种水质参数的反演任务中均展现出非常高的预测稳定性。

在水温反演中的结果表明，KNN+MLR+SVR+Ridge 集成模型通过多模型预测波动的对冲效应，将决定系数 (R^2) 提升至 0.829，相较单模型领域表现最优的 KNN 算法提升 8.2%，较其它集成策略中 R^2 排名第一的 XGBoost 模型高出 7.2%，验证了 Stacking 架构在

复杂水质参数反演中的独特优势。

Stacking 策略的集成模型受组成的基学习器的性能影响较大。三种基础模型中包含了主要依赖线性回归拟合的 MLR，以及能够处理非线性关系的 KNN 和 SVR。在 pH 预测中发现个别单模型的性能较好，但其它模型性能太差的情况下，集成学习模型的性能往往仅能处于性能强和性能弱的模型之间。原因在于当基础模型中存在对非线性关系捕捉能力差异较大的模型时，集成模型难以充分发挥各模型的优势，反而会因为差的模型的干扰而产生性能下降。




图 6 Stacking 策略遥感反演散点图

Fig.6 Scatter plot of remote sensing inversion of the stacking strategy

4.1.3 模型反演表现

为验证模型在实际使用时的表现，测试集选择 2021 年 9 月-2021 年 11 月 GF-1 影像和 Landsat 影像以及国家水质自动综合监管平台监测数据。选取在验证集中表现最好的单模型和集成模型，检验其在测试集中的表现，具体结果如下：

如图 7 所示，在测试集的 pH 反演中，单模型策略的 KNN 模型决定系数 (R^2) 仅为 0.540，其均方根误差 (RMSE) 为 0.304，而验证集中表现最优的随机森林 (RF) 模型在测试集的决定系数 (R^2) 为 0.724，其均方根误差 (RMSE) 也低至 0.236，较单模型有很大提升，且预测值与实测值呈现出基本一致的变化趋势（相关系数 $r=0.872>0.7$ ，显著性水平 $P=0.0000012<0.005$ ），能够满足水质 pH 监测的基本应用需求。




图 7 测试集 pH 反演对比图

Fig.7 Comparison of pH inversion in the test set

如图 8 所示，在测试集的溶解氧 (DO) 反演任务中，集成学习模型较单模型同样展现出了显

著优势。其中，随机森林（RF）模型虽然决定系数（ R^2 ）仅为 0.562、均方根误差（RMSE）为 0.801 mg/L，但其预测值与实测值趋势高度吻合（相关系数 $r=0.757>0.7$ ，显著性水平 $P=0.00018<0.005$ ），可有效辅助水质动态监测。相较之下，单模型策略中的 KNN 模型表现显著劣化，其 R^2 低至 -0.284， $RMSE=1.373$ mg/L 说明 KNN 模型未能有效捕捉数据规律，印证了集成学习模型在溶解氧预测任务中具备更强的泛化能力。




图 8 测试集溶解氧反演对比图

Fig.8 Comparison of dissolved oxygen inversion in the test set

如图 9 所示，在测试集的水温反演中，两种模型的决定系数（ R^2 ）均达到 0.65 以上。具体来看，KNN 模型表现最佳（ $R^2=0.692$ ， $RMSE=3.95^{\circ}\text{C}$ ），与实测值的相关系数 $r=0.839$ （ >0.7 ），显著性水平 $P=0.0012$ （ <0.005 ），能够较好的拟合真实水温的变化趋势，而在验证集中表现最佳的 KNN+MLR+SVR+Ridge 模型在测试集中则稍落后于前者（ $R^2=0.654$ ， $RMSE=4.18^{\circ}\text{C}$ ）。与实测值的相关系数 $r=0.814$ （ >0.7 ），显著性水平 $P=0.0023$ （ <0.005 ），同样可以较好的拟合真实水温。




图 9 测试集水温反演对比图

Fig.9. Comparison of the inversion of the water temperature of the test set

4.2 鄱阳湖水质参数反演

利用卫星过境时间为 2023 年 10 月 17 日 12 时的高分一号 WFV 影像数据对鄱阳湖水体 pH 和溶解氧进行反演分析，采用 2023 年 4 月 16 日 10 时的 Landsat9 影像对鄱阳湖水温进行反演分析。先通过鄱阳湖水体掩膜提取研究区内鄱阳湖水体像元，然后综合考虑模型在验证集和测试集中的表现，采用性能最佳的集成学习模型对鄱阳湖全湖水水质参数进行反演。其中，基于 Bagging 策略下的 RF 模型对鄱阳湖全湖 pH 反演和全湖溶解氧反演，基于 Ridge 回归的 Stacking 模型对鄱阳湖全湖水温反演。

2023 年 10 月 17 日 12 时的 pH 值分布如图 10 所示，鄱阳湖 pH 值具有空间特异性，湖区范围内 pH 值在 6.8~8.3 之间。信江支流等区域受农业面源氮磷污染和有机质厌氧分解影响，pH 值较低(6.8~7.2)，但其他主河道区域受弱碱性水化学的主导，pH 值较高；在饶河支流入湖口及湖湾地带，因受水体底质成分（含钙、镁、硅酸盐）及陆源碱性物质输入的影响，部分区域 pH 值可达 8.3。该差异主要受鄱阳湖枯水期水位下降产生的分离水域以及人类为因素（如采砂造成的底质扰动）以及水体生物地球化学过程（如水体沉积磷释放）的影响所致。




图 10 鄱阳湖水体 pH 值反演空间分布图

Fig.10 Spatial distribution of pH inversion in Poyang Lake

Lake

鄱阳湖的水体溶解氧的空间分布如图 11 所示,水体溶解氧浓度在空间上存在一定的差异性,溶解氧浓度最高值(10.109 mg/L)发生在主河道地区,可能是因为河道及支流之间由于水体扰动增加了大气复氧的效果,同时,支流汇入形成的水体扰动有效促进了溶解氧的垂向混合与水平输移。而从主河道向湖湾区域呈现溶解氧浓度递减趋势,可能是因为湖湾区域的河床坡度缓、水动力较弱导致有机物累积和厌氧分解使得溶解氧浓度表现较低(6.409 mg/L)。




图 11 鄱阳湖水体溶解氧反演空间分布图

Fig.11 Spatial distribution of dissolved oxygen inversion in Poyang Lake

2023 年 4 月 16 日 10 时的鄱阳湖水体温度空间分布如图 12 所示。根据遥感反演结果,研究区水温范围为 12.16-20.88 °C,具有明显的空间区域性差异。其原因可能是主河道及其支流内水深较大、热容量较高,所以其水温相对稳定,水温基本集中在中等水平(约 15-17 °C)。而浅水湖湾区域由于深度较浅,受太阳辐射加热影响更为显著,水温较高,高值区可达 20.88 °C。




图 12 鄱阳湖水体水温反演空间分布图

Fig.12 Spatial distribution of water temperature inversion in Poyang Lake

5 讨论

本研究基于高分一号 WFV 影像和 Landsat8/9 OLI/TIRS 数据,结合集成学习方法对鄱阳湖水质参数进行反演研究,得到的反演模型对于单张影像的单水质参数反演时间控制在了 10min 内,可以实现快速的长序列影像反演,为探究水质演变背后的自然和人为因素提供数据支撑,对于研究鄱阳湖区域水质历史变迁和实现实时水质监测具有重要意义。其中水温反演可揭示水体热环境时空变化,识别候鸟栖息地、鱼类产卵场等生态敏感区的温度阈值,实现生态保护;溶解氧反演可实时监测藻类暴发、有机污染等导致的缺氧事件,完成水环境质量评定;而 pH 反演能快速定位工业废水、农业面源等污染源并指导污染治理;三种参数联合分析还能结合河湖相关评价标准划分水质等级,识别不良水体并划定

优先治理区域，为鄱阳湖生态保护和 water 环境评价提供助力。

在适用性方面，现有模型是基于鄱阳湖水质数据训练得到的，由于不同湖泊的水体特性存在差异，直接将其应用于其他湖泊可能会存在一定偏差。具体而言，在将模型推广至其他区域时，要充分考虑到目标水体与鄱阳湖水体的光学性质差异，如部分湖泊水体混浊、含沙量大，悬浮颗粒物会影响光传播与吸收，改变光谱特征，需针对其水体光学性质优化调整反演算法，如重选波段组合、调整模型参数等，以提升模型适用性与反演精度。

6 结论

本研究构建了基于多种机器学习算法的三种水质参数反演模型，并对它们的性能开展了对比分析，最终得出如下结论：

(1) 集成学习方法突破了单一模型的精度瓶颈，通过不同的模型组合减低了过拟合的风险，通过不同模型之间的互补性提高了对水质参数不同特征的表达能力。在验证集中，Bagging 策略的 RF 模型相较于采用单模型，pH 值反演的 R^2 值提高了 11.7%，溶解氧反演的 R^2 值提升了 12.9%。其在测试集中也仍领先于单模型，但如果反演参数与波段具有较强的线性相关性，如水温反演，则传统机器学习模型仍有可能在部分样本的预测中占据优势。

(2) 集成学习的不同策略在水质参数反演中存在差异。在 Stacking 策略中基于 Ridge 回归的 KNN+MLR+SVR+Ridge 组合得益于正则化项对模型复杂度的约束，其水温反演效果最好，在验证集中 R^2 达 0.829，测试集中 R^2 也能大于 0.65；而 Bagging 策略中 RF 方法依靠随机抽取特征以及样本的方式，在 pH 值和溶解氧的反演中，无论是验证集还是测试集中性能都超越其它模型。

参考文献：

[1] ASMA'U MAHE N S, SANI M M. Perspective Chapter: Physicochemical Parameters and Water Quality [J]. Sustaining Water Quality-From Local Challenges to Global Solutions: From Local Challenges to Global Solutions, 2025: 85.

[2] CREIGHTON A. Modeling the Water Temperature Profile of Lakes: A Physics Informed Neural Network (PINN) Approach [J]. Journal of Student Research, 2023, 12(4): 5213.

[3] ZULKIFLI S N, ABDUL RAHIM H, LAU W J. Detection of contaminants in water supply: A review on state-of-the-art monitoring technologies and their applications[J]. Sensors and Actuators B: Chemical, 2018, 255(3): 2657-2689.

[4] WU B, REN Q, XIA L, et al. pH-dependent microbial niches succession and antibiotic resistance genes distribution in an oxygen-based membrane biofilm reactor treating greywater [J]. Environmental Research, 2023, 216: 114725.

[5] 高娟, 华珞, 滑丽萍, 等. 地表水水质监测现状分析与对策 [J]. 首都师范大学学报 (自然科学版), 2006, 75-80.

GAO J, HUA L, HUA L P. Analysis of Surface Water Quality Monitoring Condition and Its Countermeasures [J]. Journal of Capital Normal University (Natural Science Edition), 2006, 75-80.

[6] 陈飞. 无人机遥感技术在水利工程测量中的应用探究 [J]. 科技资讯, 2024, 22: 179-181.

CHEN F. Exploration of the Application of Unmanned Aerial Vehicle Remote Sensing Technology in Water Conservancy Engineering Surveying [J]. SCIENCE & TECHNOLOGY INFORMATION, 2024, 22: 179-181.

[7] 兑紫璇, 王卿, 王敏, 等. 基于多源遥感及气象数据的河流非光学活性水质参数反演模型研究 [J]. 遥感技术与应用, 2024, 39(1): 120-133.

DUI Zixuan, WANG Qing, WANG Min, et al. Research on the retrieval model of non-optically active water quality parameters of rivers based on multi-source remote sensing and meteorological data [J]. Remote Sensing Technology and Application, 2024, 39 (1): 120-133.

[8] 唐中林, 朱忠福, 李小辉, 等. 九寨沟世界自然遗产地湖泊水质参数的高光谱定量反演模型 [J]. 应用与环境生物学报, 2021, 27(5): 1256-1263.

Tang ZL, Zhu ZF, Li XH, et al. Zhuomanta, Plenković-Moraj A, Sun G. Hyperspectral quantitative inversion model for water quality parameters of lakes at the Jiuzhaigou World Natural Heritage Site [J]. Chin J Appl Environ Biol, 2021, 27 (5): 1256-1263

[9] 张宏建, 周健, 皇甫款. 基于 OLI 数据的信阳市境内淮河流域水质遥感反演 [J]. 人民长江, 2021, 52(12): 47-53.

ZHANG H J, ZHOU J, HUANGFU K. Analysis on water quality monitoring indicators by remote sensing based on OLI data: case of Huaihe River Basin in Xinyang City, [J]. Yangtze River, 2021, 52(12): 47-53.

[10] 赵爽, 柳锦宝, 耿蔚, 等. 基于 PIE-Engine Studio 的西藏典型湖泊总悬浮物反演 [J]. 人民长江, 2024, 55(9): 85-92.

Zhao S, Liu J B, Geng W, et al. Inversion of total suspended matter in typical lakes in Tibet based on PIE - Engine Studio [J]. Yangtze River, 2024, 55(9): 85-92.

- [11] 拓明香. 基于光谱法的太湖水质遥感反演及时空变化特征评价[D]. 陕西:西北农林科技大学,2024.
- Ta M X. Remote Sensing Inversion and Spatiotemporal Variation Evaluation of Water Quality in Taihu Lake Based on Spectral Method[D]. Shaanxi: Northwest A&F University, 2024.
- [12] 彭令,梅军军,王娜,等. 工矿业城市区域水质参数高光谱定量反演[J]. 光谱学与光谱分析,2019,39(9):2922-2928.
- Peng L, Mei J J, Wang N, et al. Quantitative Inversion of Water Quality Parameters in Industrial and Mining Cities from Hyperspectral Remote Sensing[J]. Spectroscopy and Spectral Analysis, 2019, 39(9): 2922-2928.
- [13] 王羿,丁鸣鸣,何菁,等. 基于不同建模方法的土壤 pH 值无人机遥感影像反演[J]. 江苏农业科学,2022,50(14):224-231.
- Wang Y, Ding M M, He J, et al. Inversion of Soil pH Value from UAV Remote Sensing Images Based on Different Modeling Methods[J]. Jiangsu Agricultural Sciences, 2022, 50(14): 224-231.
- [14] 杜程,李得林,李根军,等. 基于高原盐湖光谱特性下的溶解氧反演应用与探讨[J]. 自然资源遥感,2021,33(3):246-252.
- Du C, Li D L, Li G J, et al. Application and explration of Dissolved Oxygen Inversion of Plateau Salt Lakes based on Spectral Characteristics [J]. Remote Sensing for Natural Resources, 2021, 33(3): 246-252.
- [15] 钟炜萍,姚焕玖,陈华权等. 基于自动监测和 Sentinel-2 影像的钦州湾溶解氧反演模型研究[J]. 广西科学院学报,2020,36(4):392-398.
- ZHONG W P,YAO H M,CHEN H Q.Research on Dissolved Oxygen Inversion Model of Qinzhou Bay Based on Automatic Monitoring Data and Sentinel-2 Data [J].Journal of Guangxi Academy of Sciences,2020,36(4):392-398
- [16] 林晓丹, 陈方亮, 强志民,等. 供水管网水质模型的研究进展: 经验统计模型 [J]. 中国给水排水, 2021, 37: 1-7.
- Lin X D, Chen F L, Qiang Z M, et al. Research Progress of Water Quality Models of Drinking Wate Distribution Systems: Empirical Statistical Model[J]. China Water & Wastewater, 2021, 37: 1-7.
- [17] 谢婷婷, 陈芸芝, 卢文芳. 基于三波段生物光学模型反演闽江下游叶绿素 a [J]. 激光与光电子学进展, 2020, 57: 248-255.
- Xie T T, Chen Y Z, Lu W F. Retrieval of Chlorophyll-a in Lower Reaches of the Minjiang River Via Three-Band Bio-Optical Model[J]. Progress in Laser and Optoelectronics, 2020, 57: 248-255.
- [18] 吴欢欢, 国巧真, 臧金龙, 等. 基于 Landsat 8 与实测数据的水质参数反演研究 [J]. 遥感技术与应用, 2021, 36: 898-907.
- Wu H H, Guo Q Z, Zang J L, et al. Study on Water Quality Parameter Inversion based on Landsat 8 and Measured Data[J]. Remote Sensing Technology and Application, 2021, 36: 898-907
- [19] 余丰宁, 蔡启铭, 陈宇炜, 等. 水体叶绿素含量的遥感定量模型[J]. 湖泊科学, 1996, 201-207.
- She F N, Cai Q M, Chen Y W, et al. QUANTITATIVE ANALYSIS ON CHLOROPHYLL-A CONCENTRATION IN TAIHU LAKE USING THEMATIC MAPPER DATA[J]. Journal of Lake Sciences, 1996, 8(3): 201-207.
- [20] 崔剑,乔宝晋,郭恒亮,等. 青藏高原多尔索洞错水深反演与水量变化估算[J]. 人民长江,2024,55(4):142-149.
- Cui J, Qiao B J, Guo H L, et al. Water depth inversion and water storage changes estimation of Duoersuodong Co in Tibetan Plateau[J]. Yangtze River, 2024, 55(4): 142-149.
- [21] 唐军武, 田国良. 水色光谱分析与多成分反演算法 [J]. 遥感学报, 1997, 252-256.
- Tang J W, Tian G L. Spectral Analysis of Water Color and Multi-Component Inversion Algorithm[J]. Journal of Remote Sensing, 1997, 2(1): 252-256.
- [22] 温开祥, 李勇, 王华, 等. 基于遥感和机器学习的内陆水体水深反演技术 [J]. 热带地理, 2020, 40: 314-322.
- Wen K X, Li Y, Wang H, et al. Estimating Inland Water Depth Based on Remote Sensing and Machine Learning Technique[J]. Tropical Geography, 2020, 40(3): 314-322.
- [23] 李玉翠, 周正, 彭漪, 等. 基于机器学习的东湖富营养化研究[J]. 人民长江, 2018, 49: 12-17.
- Li Y C, Zhou Z, Peng Y, et al. Assessment of eutrophication status in East Lake based on machine learning methods[J]. Yangtze River, 2018, 49(Sup2): 12-17.
- [24] Zhang S. The Study of Model Generalization Ability for Spam Classification Based on Machine Learning Models[C]//2024 9th International Symposium on Computer and Information Processing Technology (ISCIPIT). Xi'an, China: IEEE, 2024: 43-46.
- [25] 戴鑫, 周卫, 王倩, 等. 基于高分一号影像的洞庭湖遥感水深反演研究 [J]. 水利水电快报, 2024, 45: 25-29.
- Dai X, Zhou W, Wang Q, et al. Study on remote sensing bathymetric inversion of Dongting Lake based on GF-1 images[J]. Express Water Resources Information, 2024, 45: 25-29.
- [26] 朱利,李云梅,赵少华,等. 基于 GF-1 号卫星 WFV 数据的太湖水质遥感监测[J]. 国土资源遥感,2015(1):113-120.
- Zhu L, Li Y M, Zhao S H, et al. Remote sensing monitoring of Taihu Lake water quality by using GF- 1 satellite WFV data[J]. Remote Sensing for Land and Resources, 2015(1): 113-120.
- [27] 胡茂林,吴志强,刘引兰. 鄱阳湖湖口水位特性及其对水环境的影响[J]. 水生态学杂志,2010,03(1):1-6.
- HU Maolin, WU Zhiqiang, LIU Yinlan. Characteristics of water level at Hukou in Poyang Lake and its impacts on the aquatic environment [J].

Journal of Hydroecology, 2010, 3(1): 1-6.

[28] 曾冰茹, 李云良, 谭志强. 鄱阳湖流域水文连通性的影响因素和环境效应 [J]. 长江流域资源与环境, 2022, 31: 2718-2728.

Zeng B R, Li Y L, Tan Z Q. Influential Factors and Environmental Effects of Hydrological Connectivity in the Poyang Lake Catchment[J]. Resources and Environment in the Yangtze Basin, 2022, 31(10): 2718-2728.

[29] 杨潇, 马吉顺, 张欢, 等. 鄱阳湖不同水文期浮游生物群落结构特征和影响因素及水质评价 [J]. 水生生物学报, 2021, 45: 1093-1103.
Yang X, Ma J S, Zhang H, et al. COMMUNITY STRUCTURE AND THE WATER QUALITY DURING DIFFERENT HYDROLOGICAL PERIODS IN POYANG LAKE[J]. Acta Hydrobiologica Sinica, 2021, 45(4): 1093-1103.

[30] 徐继伟, 杨云. 集成学习方法:研究综述 [J]. 云南大学学报 (自然科学版), 2018, 40: 1082-1092.

Xu J W, Yang Y. A survey of ensemble learning approaches[J]. Journal of Yunnan University (Natural Sciences Edition), 2018, 40(6): 1082-1092.

[31] 罗常伟, 王双双, 尹峻松, 等. 集成学习研究现状及展望 [J]. 指挥与控制学报, 2023, 9: 1-8.

Luo C W, Wang S S, Yin J S, et al. Research Status and Prospect of Ensemble Learning[J]. Journal of Command and Control, 2023, 9(3): 1-8.

[32] DALLAH D, SULIEMAN H. Outlier Detection Using the Range Distribution[C]//2022 International Conference on Recent Developments in Mathematics (ICRDM). Dubai, UAE: Springer, 2024: 687 – 697.

[33] Khurana U, Samulowitz H, Turaga D. Feature engineering for predictive modeling using reinforcement learning[C]//Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence (AAAI-18). New Orleans, Louisiana, USA: AAAI, 2018:3407 - 3414 .

[34] 赵松, 侯毅凯, 张安兵, 等. 基于无人机多光谱影像的溇阳河水质遥感反演[J]. 测绘与空间地理信息, 2022, 45(3):81-85.

ZHAO Song, HOU Yikai, ZHANG Anbing, et al. Remote sensing inversion of water quality in the Fuyang River based on UAV multispectral images [J]. Geomatics & Spatial Information Technology, 2022, 45(3): 81-85.

[35] 光洁, 韦玉春, 黄家柱, 等. 分季节的太湖悬浮物遥感估测模型研究[J]. 湖泊科学, 2007, 19(3):241-249.

GUANG Jie, WEI Yuchun, HUANG Jiazhu, et al. Study on season-specific remote sensing estimation models for suspended solids in Taihu Lake [J]. Journal of Lake Sciences, 2007, 19(3): 241-249.

[36] 杨振, 卢小平, 武永斌, 等. 无人机高光谱遥感的水质参数反演与模型构建[J]. 测绘科学, 2020, 45(9):60-64.

Yang Z, Lu X P, Wu Y B, et al. Retrieval and model construction of

water quality parameters for UAV hyperspectral remote sensing[J]. Science of Surveying and Mapping, 2020, 45(9): 60-64.

[37] 黄国金, 刘成林, 乐兴华. 鄱阳湖叶绿素 a 浓度遥感反演[J]. 山西建筑, 2010, 36(34):357-359.

HUANG Guojin, LIU Chenglin, LE Xinghua. On remote sensing retrieval of chlorophyll-a concentration in Poyang Lake [J]. Shanxi Architecture, 2010, 36(34): 357-359.

[38] CHU H-J, JAE LANI L M, VAN NGUYEN M, et al. Spectral and spatial kernel water quality mapping [J]. Environ Monit Assess, 2020, 192(5): 299.

[39] 张玉超, 钱新, 钱瑜, 等. 支持向量机在太湖叶绿素 a 非线性反演中的应用 [J]. 中国环境科学, 2009, 29: 78-83.

Zhang Y C, Qian X, Qian Y, et al. Application of SVM on Chl-a concentration retrievals in Taihu Lake[J]. China Environmental Science, 2009, 29(4): 78-83.

[40] 吴建生, 陈恩红. 基于 k 近邻非参数回归的神经网络集成降水预测模型 [J]. 计算机应用与软件, 2010, 27: 114-118.

Wu J S, Chen E H. NEURAL NETWORK ENSEMBLE MODEL FOR RAINFALL FORECAST BASED ON K-NEAREST NEIGHBOUR NONPARAMETRIC REGRESSION[J]. Computer Applications and Software, 2010, 27(5): 114-118.

[41] 韦岗, 贺前华, 欧阳景正. 关于多层感知器的函数逼近能力 [J]. 信息与控制, 1996, 2-5.

Wei G, He Q H, Ouyang J Z. On the Function Approximation Capability of Multilayer Perceptron[J]. Information and Control, 1996, 25(2): 2-5.

[42] LENG C, CHENG J, YUAN T, BAI X, LU H Q. Learning binary codes with bagging PCA[C]//Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2014, September 15 – 19, 2014 Proceedings, Part II. Nancy, France: Springer, 2014: 177 – 192.

[43] 雍凯. 随机森林的特征选择和模型优化算法研究[D]. 黑龙江: 哈尔滨工业大学, 2008.

YONG Kai. Research on Feature Selection and Model Optimization Algorithms for Random Forests [D]. Heilongjiang: Harbin Institute of Technology, 2008.

[44] 于玲, 吴铁军. 集成学习:Boosting 算法综述 [J]. 模式识别与人工智能, 2004, 17: 52-59.

Yu L, Wu T J. ASSEMBLE LEARNING: A SURVEY OF BOOSTING ALGORITHMS[J]. Pattern Recognition and Artificial Intelligence, 2004, 17(2): 52-59.

[45] 曹莹, 苗启广, 刘家辰, 等. AdaBoost 算法研究进展与展望 [J]. 自动化学报, 2013, 39: 745-758.

Cao Y, Miao Q G, Liu J C, et al. Advance and Prospects of AdaBoost

Algorithm[J]. Acta Automatica Sinica, 2013, 39(6): 745-758.

[46] 毕云帆, 撒奥洋, 张智晟, 等. 基于模糊 Bagging-GBDT 的短期负荷预测模型研究 [J]. 电力系统及其自动化学报, 2019, 31: 51-56.

Bi Y F, Han A Y, Zhang Z S, et al. Study on Short-term Load Forecasting Model Based on Fuzzy Bagging-GBDT[J]. Journal of Power System and Automation, 2019, 31(5): 51-56.

[47] 李浩, 朱焱. 基于梯度分布调节策略的 Xgboost 算法优化[J]. 计算机应用, 2020, 40(6): 1633-1637.

Li H, Zhu Y. Xgboost algorithm optimization based on gradient distribution harmonized strategy[J]. Computer Applications, 2020, 40(6): 1633-1637.

[48] FU Y, LIANG X, YANG X, et al. Stacking model framework reveals clinical biochemical data and dietary behavior features associated with type 2 diabetes: A retrospective cohort study [J]. APL Bioengineering, 2024, 8(4): 046111.

