

海洋水色遥感机器学习模型应用现状及定标与真实性检验 AI 模型展望*

陈 鹏^{1,3} 厉运周^{1,2} 赵志刚¹ 张思琪^{1,3}
张镇华^{1,3} 王军成^{1,2} 潘德炉^{1,3}

(1. 齐鲁工业大学(山东省科学院) 山东青岛 266061; 2. 崂山实验室 山东青岛 266237;
3. 自然资源部第二海洋研究所 浙江杭州 310012)

摘要 海洋水色遥感技术是观测海洋水色状况的高效工具,数十年来持续提供了全球海洋光学特性、水色和生物地球化学参数的重要数据。随着人工智能的快速发展,基于机器学习模型的水色遥感研究逐渐成为科研领域的新热点。本文回顾了海洋水色遥感中机器学习模型的现状与挑战,并评估了这些模型在大气校正、水色反演、碳循环及数据重构中的应用效果。本文重点综述了机器学习在海洋水色遥感应用中的进展。鉴于卫星传感器长期在轨运行中,可能遭受元器件老化等问题,本文强调了对遥感器进行持续定标和真实性检验的必要性。这些检验工作是确保卫星遥感数据质量的基础,对于卫星遥感应用至关重要。因此,本文还展望了未来在水色遥感定标与真实性检验中,人工智能大模型的发展前景。

关键词 水色遥感; 大模型; 机器学习; 辐射定标; 真实性检验; 大气校正

中图分类号 P731 **doi:** 10.11693/hyhz20240800178

在大数据时代背景下,大规模模型的训练和部署已经成为全球研究者关注的焦点。深度学习技术的快速发展,推动了以 GPT (Generative Pre-trained Transformer)、BERT (Bidirectional Encoder Representations from Transformers) (Yenduri *et al.*, 2024)、XLNet (Yang *et al.*, 2019)、T5 (Text-to-Text Transfer Transformer) (Raffel *et al.*, 2020) 为代表的大型语言模型的快速涌现。目前 ChatGPT 已经发展至 4.0 版。除 ChatGPT 外,国内产品如“文心一言”“讯飞星火”“天工 3.5”“百度 Ernie Bot”“华为盘古”“腾讯天机”“清华 GLM”等也在大语言模型领域处于领先地位。中国正积极推动人工智能在各个行业的广泛应用。

我国已经建成了完善的海洋水色卫星观测体系,发射多颗海洋水色卫星[HY-1A/B(结束任务)、

HY-1C/D/E(在轨运行)、HY-1F(即将发射)],并规划发展高轨静止水色卫星。海洋水色遥感技术通过遥感手段捕捉海洋表层的水色信息,并据此推断出海洋中的溶解物质、悬浮物质和生物量等关键参数。这些参数对于深入理解海洋生态系统状况、监测海洋环境变化以及有效管理海洋资源极为重要。在过去数十年,遥感技术凭借其卓越的空间分辨能力,为全球海洋信息的获取提供了新的视角,极大地推动了海洋学研究的革新。这项技术赋予了科学家们深入洞察海洋环境复杂动态变化的能力。然而,海量且多样化的遥感图像数据给数据分析和处理带来了前所未有的挑战。在这种背景下,机器学习尤其是深度学习技术,已经成为应对这些挑战的关键工具,它们帮助我们挖掘并释放人工智能的全部潜力。随着遥感技术和数据处理能力的

*国家自然科学基金,42322606 号,42276180 号,61991453 号;山东省重点研发计划,2023ZLYS01 号;国家重点研发计划项目,2022YFB3901703 号,2022YFB3902603 号,2022YFC3104200 号;南方海洋科学与工程广东实验室引进人才重点专项,GML2021GD0809 号。陈 鹏,硕士生导师,研究员, E-mail: chenp@sio.org.cn

收稿日期: 2024-08-12, 收修改稿日期: 2024-10-08

发展,海洋水色遥感研究正在经历一场从传统统计方法向深度学习和大数据技术转变的革命。机器学习方法正被广泛应用于海洋时空数据流中模式和知识的提取(Reichstein *et al.*, 2019)。

在海洋遥感数据处理方面,深度学习模型相较于传统方法展现出了明显的优势,这些优势主要体现在以下几个方面:(1) **自动特征提取**。深度学习模型,尤其是卷积神经网络(convolutional neural network, CNN),具有强大的特征提取能力。这使得模型能够直接从原始遥感影像中自动识别并提取关键特征,无需人工干预,极大地简化了模型开发流程,并提高了处理海量遥感数据的效率和准确性(Li *et al.*, 2020b)。(2) **大数据处理能力**。随着遥感技术的发展,海洋遥感的数据量日益庞大。深度学习模型,尤其是利用图形处理器(graphics processing unit, GPU)并行加速计算的模型(Linghu *et al.*, 2018),能够有效处理和分析这些庞大的数据集,充分挖掘海洋遥感数据的潜力。(3) **高准确度和泛化能力**。在水质参数反演(Zhang *et al.*, 2023e)、海洋浮游植物分类(Li *et al.*, 2023)等海洋水色遥感任务中,深度学习模型表现出了高度的准确性。适当地训练和调整,这些模型能够捕捉复杂的数据模式,对未知数据做出精确预测。(4) **多源数据融合**。深度学习模型能够有效地整合不同来源(如多波段、多时空分辨率)的海洋遥感数据,增强模型的预测能力。这对于综合利用多源遥感资源,全面地反映和分析海洋环境具有重要价值(Wang *et al.*, 2023)。(5) **跨任务学习能力**。通过迁移学习和多任务学习等技术,训练好的深度学习模型可以在不同但相关的海洋遥感任务间共享知识,提高学习效率和模型性能(Wang *et al.*, 2024)。这为同时处理多种海洋遥感任务提供了可能。

本文旨在梳理海洋水色遥感研究中机器学习模型的应用现状和挑战,分析不同算法在大气校正、水色反演及环境监测中的应用效果,并探讨这些模型所面临的挑战。此外,本文还展望了人工智能大模型在水色遥感定标与真实性检验等方面的未来发展。

1 海洋水色遥感机器学习模型应用现状

人工智能的发展使得机器学习技术得以融入数据驱动的建模系统,从而减少海洋学研究对人类专家的依赖。机器学习算法已被证明是分析海洋和气候数据的强大工具,能够以高精度和高效率进行数据分析。机器学习在海洋科学和地球科学中有着广泛的应用。

机器学习的一般工作流程如图 1 所示:大量采样数据由科学仪器收集,然后被分为训练集和测试集。这些数据随后用于训练机器学习算法,通过不断优化参数,构建高精度模型。然后在预测阶段,将训练好的模型用于推断新数据的结果。海洋是广阔、动态且复杂的,海洋数据结构愈发复杂和庞大。传统的数据分析方法不仅耗时且成本高昂,在某些情况下,常规方法甚至无法进行有效分析。相比之下,机器学习技术展现出其显著的稳健性、速度和精度优势。




图 1 机器学习工作流程

Fig.1 The workflow of simple machine learning

机器学习通常可分为监督学习、无监督学习和强化学习。其中,监督学习是一种使用标记数据的机器学习算法,它尝试模拟输入和相应输出之间的关系,然后基于学习到的知识来预测新的输出。无监督学习使用未分类或未标记的数据来训练模型,通过识别相似性、模式和差异对未排序的数据进行分组,而无需外部指导。无监督学习可用于聚类、降维和异常检测等任务。强化学习主要关注如何在环境中采取行动以最大化某种累积奖励。强化学习中的智能体通过与环境的交互来学习最佳的行为策略。海洋水色遥感领域常见的机器学习算法如表 1 所示。

深度学习(deep learning, DL)是机器学习(machine learning, ML)的一个子集,它使用人工神经网络(artificial neural network, ANN)来模拟人类大脑的处理方式。这些网络通过大量节点相互连接,通过权重传递信息,处理复杂的数据。深度学习模型在海洋遥感领域的应用得益于其强大的数据处理能力,包括分布式计算、数据预处理、批处理、自动特征提取、迁移学习以及多任务学习。这些技术使得模型能够有效地处理和分析大规模的海洋遥感数据,提高海洋环境和资源研究的效率和准确性。此外,深度学习模型通过自动提取特征和多任务学习,简化了特征工程,提高了模型的泛化能力。迁移学习允许模型利用预训练的基

表 1 海洋水色遥感常见的机器学习算法及其定义

Tab.1 Definitions of machine learning algorithms commonly used in ocean color remote sensing

类型	算法	描述	应用
监督学习	决策树(decision tree, DT)	基于输入变量的连续决策标准的层次结构(“树”),用于标记数据实例。流行的实现包括分类和回归树算法。	易于理解和解释,对于非线性关系建模能力强,但对于大规模数据容易过拟合。
	随机森林(random forest, RF)	一种集成方法,结合了多个决策树的预测,其中每棵树都是在数据的自举重采样上训练的。	水体漫衰减系数反演(Corcoran <i>et al.</i> , 2021)等,泛化能力强,对噪声数据鲁棒,但模型训练和预测速度相对较慢。
	梯度提升树,提升回归树(gradient boosted trees, boosted regression trees, BRTs)	一种集成方法,结合了决策树,每棵树都在前一个残差上工作。梯度提升通常是一种将多个“弱”学习器结合起来的智能方式。	大气校正(He <i>et al.</i> , 2024; Song <i>et al.</i> , 2023)等,具有强大的预测能力和处理复杂数据集的能力,但对参数和异常值敏感且需要更多的计算资源。
	线性判别分析(linear discriminant analysis, LDA)	对每个类别的输入拟合多元高斯分布,其中每个分布都有自己的均值,但共享协方差矩阵。新数据实例被分配到条件概率最高的分布。	简单高效,适用于小样本数据,但各类别数据的协方差相等的假设,这在实际应用中往往不成立,限制了其分类性能。
	支持向量机(support vector machine, SVM)	一种算法,试图在输入变量的大变换空间中找到一个最优的分离线性边界。	叶绿素反演(Blix <i>et al.</i> , 2018)等,在高维空间表现良好,适用于小样本数据,但对于大规模数据计算量大。
	朴素贝叶斯(naive Bayesian, NB)	一种分类器,结合了贝叶斯定理和“朴素”假设,即所有变量彼此独立;一种贝叶斯网络。	计算简单、易于实现,但特征条件独立的假设过于理想化,可能不适用于特征高度相关的数据集。
	贝叶斯网络(Bayesian network)	一个有向无环图,其中每个顶点(节点)都有一个概率分布或条件分布,条件是其父值。	能够表示变量间的条件依赖关系,但需要大量的数据来估计概率模型。
	人工神经网络(artificial neural network, ANN)	一种算法,结合了节点层或“神经元”。每个神经元接收前一层神经元输出的加权线性组合作为输入。第一层的节点代表输入变量。权重使用训练数据递增更新,从最后一层开始。一旦设置权重,就通过层喂养新数据进行预测。	具有出色的非线性拟合能力和处理复杂模式识别任务的效率,但局限性是模型的解释性差,训练过程中容易过拟合,并且对参数和架构的选择非常敏感。
	卷积神经网络(convolutional neural network, CNN)	深度学习中的一种方法。卷积神经网络以数组作为输入,并在其上执行卷积和缩减(池化),以提取特征,然后将其输入到人工神经网络。	具有强大的图像特征提取能力,但对于非图像数据不适用。
	区域卷积神经网络(region-based convolutional neural network, R-CNN)	R-CNN 是一种深度学习架构,旨在识别、定位(边框)和分类图像中的多个对象。Mask R-CNN 是一个变体,能够识别、分割并分类图像中的单个像素到多个对象。	适用于图像分割定位和识别。
非监督学习	深度信念网络(deep belief network, DBN)	一种深度学习形式,其中生成图形模型由多层潜在变量组成。层彼此连接,但层内的节点不连接。	能够自动提取特征,适合复杂数据,但训练时间长,需要大量的计算资源。
	长短期记忆(long short-term memory, LSTM)	一种循环神经网络的类型,属于深度学习。这些类型的网络用于预测数据序列。LSTM 在网络内提供反馈连接,而许多深度学习架构只提供前馈连接。	适合处理时间序列数据,但对于非序列数据不适用。
	k -最近邻(k -nearest neighbors)	新数据点根据其 k 个最近邻的平均值/多数标签进行标记。 k 的值必须事先设定。	简单直观,但随着数据规模的增加,预测效率会显著下降。
	k -均值(k -means)	将数据实例聚类到 k 个组中,其中最小化组内方差。	简单高效且易于实现,但对初始中心点敏感,可能陷入局部最优。
	自组织映射(self-organizing map, SOM)	一种无监督人工神经网络,其中网格中的节点被优化以匹配相似数据点的组。	$p\text{CO}_2$ 重构(Landschützer <i>et al.</i> , 2013)等,能够保持数据的拓扑结构,有效降维和可视化,但计算成本高,且对于大规模数据集的适应性较差。

础,快速适应新的数据集,如 Zhu 等(2019)利用迁移学习对浮游植物种类组成进行了高光谱遥感监测。在该研究中,一个在大型数据集上预训练的深度卷积神经网络被迁移到一个新的任务,即使在数据量较小的情况下,也能准确地识别和分类不同的浮游植物种类。而多任务学习则让模型能够同时处理多个相关任务,共享信息,提高学习效率。随着计算资源的增加和深度学习技术的不断进步,这些模型在海洋水色遥感领域的应用前景广阔,有助于深入理解海洋生态系统和环境变化。

1.1 大气校正

大气校正(atmospheric correction, AC)是许多海洋水色算法中的第一步,也是非常重要的一步。理想情况下,它应该删除大气(包括空气分子和气溶胶)的辐射贡献和卫星测量辐射的表面反射产生离水辐射(L_w),可用于导出海洋水色产品,例如叶绿素 a (chl a)浓度。卫星传感器测量的大气层顶(top-of-atmosphere, TOA)辐射中,大气成分(包括气体和气溶胶)的贡献通常占主导地位,平均可达 90%。在沿海或近岸水域,由于气溶胶浓度和反射率的变化,大气对 TOA 辐射的贡献可能会更高,尤其是在蓝色波段,这一现象更为显著。相反,在沉积物含量高的极浑浊水域,如某些河口区域,大气对红色和近红外波段的 TOA 辐射贡献相对较小。因此,准确的大气校正算法对于海洋水色数据处理至关重要(Fan *et al.*, 2017)。其中,基于卫星遥感的海洋大气参数观测是能够最大程度节约观测的时间和成本,具有良好的前景。但同时基于遥感数据的海洋大气参数观测也存在实际困难,从大气参数的变化机制来看,复杂多样的环境因素影响这些参数的测量。在最初的研究中,通常使用统计插值、线性回归、非线性回归和多元回归等多种数据插值方法实现对海洋大气参数的重构,使用的常见数据包括来自卫星数据的气温、气压、湿度、风速和气溶胶光学厚度(aerosol optical depth, AOD)等。

然而,由于不同海区大气参数的影响因素复杂,这些模型通常缺乏在全球不同海域的普适性。以前的研究主要集中在开阔海洋环境的大气校正算法上,而很少有研究关注于内陆水体以及沿海高浑浊度水体相关的独特特征和挑战。近年来,机器学习相关的算法已经广泛应用于一些海洋特殊天气的预报(Liu *et al.*, 2023; Ouyang *et al.*, 2023; Zhao *et al.*, 2023a; Zhou *et al.*, 2023a)。同样,机器学习的快速发展也为捕捉全球海洋大气环境参数之间的非线性关系提供了新的途径,适用于综合考虑不同区域、多种影响因素复杂共同

作用的机器学习算法被大量应用于大气校正的研究中(Schroeder *et al.*, 2022; Shen *et al.*, 2022; Cuartero *et al.*, 2023; Men *et al.*, 2023; Zhao *et al.*, 2023b; Zhou *et al.*, 2023c; Allam *et al.*, 2024)。He 等(2024)首次提出一种智能偏振交流(intelligent polarization atmospheric correction, IPAC)算法,使用矢量辐射传输模拟(vector radiative transfer simulation, VRTS)模型模拟了开阔海洋上的 TOA 矢量表现反射率。与标准大气校正算法相比,IPAC 算法显著提高了反演海洋水色产品的准确率(He *et al.*, 2024)。

此外,神经网络(neural network, NN)也是大气校正过程中一个非常重要的算法,Wang 等(2022)在其研究中介绍了一种基于美国国家航空航天局(National Aeronautics and Space Administration, NASA)海洋、地球、大气数据分析系统(sea, earth, atmosphere data analysis system, SeaDAS)的神经网络近红外大气校正算法(neural network near-infrared atmospheric correction algorithm, ACANIR-NN)。该算法可以在清澈和浑浊的海水中无缝实现大气校正,即使对于没有短波红外的传感器也是如此(Wang *et al.*, 2022)。Sun 等(2021)提出了一种基于时间依赖的神经网络,用于在不同高程角下利用多扫描高光谱数据进行自动大气校正和目标检测。提出的网络能够在季节和昼夜变化的环境下估计大气球体特性,并处理缺失数据的影响(Sun *et al.*, 2021)。Li 等(2020a)通过 GOCI 观测的早晨和晚上瑞利校正辐射与 GOCI 反演的高质量中午遥感反射率(R_{rs})之间的大量匹配,训练出新的 NN 算法,在从早到晚的开阔海域中产生了昼夜稳定的 R_{rs} ,解决了在高太阳天顶角下 GOCI 反演数据异常的问题(Li *et al.*, 2020a)。

同时,一些基于机器学习的大气校正反演算法也在逐渐更新迭代。Brockmann 等(2016)在已有的适用于哨兵 2 号卫星的 C2 (Case 2)算法上,进一步优化开发出了 C2RCC (Case 2 Regional CoastColour),适用于所有过去和现在的海洋水色传感器(Brockmann *et al.*, 2016)。Rusia 等(2021)通过机器学习,在原有的算法中将插值建模为回归问题来进行优化,大大缩短了数据处理时间,提高了有效性。此外,有学者提出了大气-海洋耦合辐射传输仿真驱动的机器学习算法(Fan *et al.*, 2021),其卫星资料处理结果如图 2 所示,可以看到,与 NASA 标准产品相比(图 2a),机器学习 NN 建模的结果在近岸浑浊水体中效果更好(图 2b)。传统基于物理方法的查找表线性插值方法,复杂烦琐,而




图2 深度学习卫星资料处理结果

Fig.2 Results of satellite data processing based on deep learning

机器学习的非线性拟合,更适合复杂环境,尤其是近岸浑浊区域和吸收性气溶胶的处理。

1.2 水色参数反演

利用深度学习模型,如 CNN 和循环神经网络(recurrent neural network, RNN),直接从遥感影像数据中反演海洋水色参数,例如叶绿素 a 浓度和有色溶解有机物(colored dissolved organic matter, CDOM)等。这些模型可以自动提取特征,提高反演精度和效率。

利用卫星遥感监测叶绿素 a 浓度已经做了很多工作,针对不同的水域和季节,使用不同的传感器,已经开发了许多两波段比算法(band ratio, BR)、三波段算法(three-band algorithms, TBA)、四波段算法(four-band algorithms, FBA)、基线减法算法(baseline subtraction algorithms, BS)、嵌套波段比算法(nested band ratio algorithms, NBR)、准解析算法(quasi-analytical algorithms, QAA)及基于 QAA 的算法等(Dekker, 1993; Gons *et al*, 2002; Lee *et al*, 2002; Dall'Olmo *et al*, 2005; Gower *et al*, 2005; Simis *et al*, 2005; Le *et al*, 2009; Xue *et al*, 2019; Liu *et al*, 2020)。光学水类型(optical water type, OWT)分类策略也是光学复杂水的有效工具,并已用于从广泛分散的原位数据中检索 chl a 浓度(Bi *et al*, 2019; Neil *et al*, 2019; Liu *et al*, 2021)。

海岸带海洋叶绿素 a 浓度的准确预测是动态水质监测的必要条件,富营养化是一个关键因素。Niu 等(2023)的研究强调了高斯过程回归(Gaussian process

regression, GPR)模型估算 chl a 的有效性,以及在模拟 chl a 浓度时考虑颗粒有机碳(particulate organic carbon, POC)的重要性。Cui 等(2022)建立了一个基于极端梯度增强 XGBoost 算法和智能参数优化策略的 chl a 丰度预测模型,模型能够较好揭示环境因子与海洋中 chl a 浓度之间的潜在关系。Blix 等(2018)提出了一种自动模型选择算法 AMSA 旨在通过使用 4 种 ML 特征排序方法和 3 种 ML 回归模型来估计全球和光学复杂水域的海洋 chl a 。Kolluru 等(2022)基于大多数海洋水色传感器中存在的 4 种海洋水色带提出了一种基于多层感知器神经网络(multi-layer perceptron neural network, MLPNN)的弹性反向传播方法来推导 chl a 的新方法。赵海阳等(2022)利用机器学习方法对中国东部海域的浮游植物类群进行了遥感反演研究。该研究通过分析长时间序列的遥感数据,结合机器学习算法,成功地反演了浮游植物类群的分布和变化,为海洋生态研究提供了重要的数据支持。Zhang 等(2023d)利用海洋大数据驱动的集合学习方法,对 1997~2020 年全球海洋浮游植物群落组成进行了估计。这项研究通过集成多个机器学习模型,提高了反演的准确性和可靠性,为我们理解全球海洋生态系统的变化提供了宝贵的信息。Zhang 等(2023f)则将深度学习用于星载激光雷达,从而反演出极地海域叶绿素浓度(如图 3a)。其中,激光雷达和中分辨率成像光谱仪(moderate resolution imaging spectroradiometer, MODIS)在重叠区域具有相似的分布,基于深度学习

的星载激光雷达水体参数反演模型,可以拓展海洋遥感的探测区域。与传统反演方法对比如表 2 所示,与

常规方法相比,基于深度学习的激光雷达水体参数反演具有更高的精度。




图 3 深度学习星载激光雷达水体参数反演结果(单位: mg/m^3)

Fig.3 Deep learning results for spaceborne lidar water body parameter inversion

注: a:激光雷达 CALIOP 冬季北极海域叶绿素反演结果;b:被动遥感 MODIS 冬季北极海域叶绿素反演结果;
其中深蓝色表示海冰覆盖区域(Zhang *et al*, 2023f)

表 2 激光雷达深度学习反演模型(CALIOP_DNN)和传统反演方法(CALIOP_PHY)与
实测结果(Argo)对比(Zhang *et al*, 2023e)

Tab.2 Comparison of lidar deep learning inversion model (CALIOP_DNN) and traditional inversion method
(CALIOP_PHY) with measured results (Argo)

数据类型	匹配结果	R^2	$\text{RMSD}/\text{m}^{-1}$	$\text{Bias}/\text{m}^{-1}$	MAD/m^{-1}	MAPD
所有数据	Argo vs. CALIOP_PHY	0.59	0.000 9	0.001 1	0.001 2	123.5%
	Argo vs. MODIS	0.69	0.000 8	0.000 3	0.000 7	57.8%
	Argo vs. CALIOP_DNN	0.62	0.000 8	0.000 4	0.000 8	62.3%
日间数据	Argo vs. CALIOP_PHY	0.67	0.000 8	0.001 2	0.001 2	121.3%
	Argo vs. CALIOP_DNN	0.68	0.000 8	0.000 5	0.000 7	63.2%
夜间数据	Argo vs. CALIOP_PHY	0.56	0.001 0	0.000 9	0.001 2	125.8%
	Argo vs. CALIOP_DNN	0.61	0.000 8	0.000 2	0.000 7	56.5%

注: R^2 : 决定系数; RMSD: root mean square difference, 均方根偏差; Bias: 偏差; MAD: mean absolute difference, 平均绝对偏差; MAPD: mean absolute percentage difference, 平均绝对百分比偏差

固有光学特性(inherent optical properties, IOPs)是水体的特性,只取决于水中的成分,而与周围的光照条件无关(Mobley, 1994)。这些特性是海洋光学研究的基础,对于理解海洋生态系统、生物地球化学循环以及海洋遥感等领域具有重要意义。许多相关算法都使用了广义叠加约束模型(Generalized Stacked Constraints Model, GSCM) (Zheng *et al*, 2015)。与其他传统回归

模型相比,神经网络(NN)具有灵活性强、计算速度快、可靠性高、输出一致等优点,并能很好地处理非线性问题。在海洋水色方面,NNs 已被用于推导各种水质参数、总体 IOPs (Zhang *et al*, 2023e)、子分量 IOPs (Ioannou *et al*, 2013)、大气参数(Schiller *et al*, 1999)、漫射-衰减系数(Jamet *et al*, 2012)。除此之外,He 等(2024)提出了一种智能极化大气校正(IPAC)算法,可

以有效地处理多角度、多光谱和偏振卫星观测,从而推导出公海水域的极化水离开反射率、气溶胶特性(粗模和细模)和水体固有光学特性(He *et al.*, 2024)。Kolluru 等(2021)的研究比较了 17 个 ML 模型,分为 6 种不同的方法和两种现有的吸收分配模型对原位数据集的 IOPs 进行评估,涵盖了广泛的光学特性。Zhang 等(2023e)则基于深度学习,重新构建了星载激光雷达水体颗粒后向散射反演模型。与传统方法相比(图 3b),深度学习方法与实测值更为接近,提高了反演的准确性。

海水中的浮游植物、非藻颗粒物以及 CDOM 等光学活性成分的浓度对于调控光线在水体中的传播具有显著影响(Kirk, 1983)。Alam 等(2024)开发了优化的集成机器学习模型,用于预测浮游植物吸收系数,在 5 个海洋水色卫星传感器的常用的波段上表现出更高的精度,利用贝叶斯优化和特征重要性分析等技术显著提高了预测的准确性和可解释性。Liu 等(2022a)开发了一种机器学习方法来重建 2003~2019 年黄海和渤海表层溶解无机氮(dissolved inorganic nitrogen, DIN)、溶解无机磷(dissolved inorganic phosphorus, DIP)和溶解硅酸盐(dissolved silicate, DSi)的月浓度,对监测陆架海营养物质浓度的时空变化和了解海洋初级生产力和生态问题具有重要意义。

1.3 碳循环

海洋在碳循环中的贡献可以通过海水的二氧化碳分压(p_{CO_2})来估算,高时空异质性的海水 p_{CO_2} 是量化海-气二氧化碳(CO_2)最重要的基本参数之一。因此,通过走航、浮标和卫星遥感等观测手段重构海水 p_{CO_2} 数据集,对正确认识海洋碳库的动态变化至关重要(Sadaippan *et al.*, 2023)。其中,基于卫星遥感的海水 p_{CO_2} 观测是能够最大程度节约观测的时间和成本,具有良好的前景。但同时基于遥感数据的海水 p_{CO_2} 观测也存在实际困难,从海水 p_{CO_2} 的变化机制来看,复杂多样的环境因素影响海水 p_{CO_2} 。在最初的研究中,通常使用统计插值、线性回归、非线性回归和多元回归等多种数据插值方实现对海水 p_{CO_2} 的重构,使用的常见数据包括来自卫星数据的海面温度(sea surface temperature, SST)、海面盐度(sea surface salinity, SSS)、叶绿素 *a* 浓度、漫衰减系数(K_d)、风和混合层深度(mixed layer depth, MLD)等(Stephens *et al.*, 1995; Sarma, 2003; Ono *et al.*, 2004; Jamet *et al.*, 2007; Rödenbeck *et al.*, 2014, 2015; Zhang *et al.*, 2023b)。

然而,由于不同海区海水 p_{CO_2} 的影响因素复杂,

这些模型通常缺乏在全球不同海域的普适性。机器学习的快速发展也为捕捉全球海洋生态环境参数与海水 p_{CO_2} 之间非线性关系提供了新的途径,适用于综合考虑不同区域间,多种影响因素复杂共同作用的机器学习算法被大量应用于重建全球海水 p_{CO_2} 的研究中(Lefèvre *et al.*, 2005; Friedrich *et al.*, 2009; Telszewski *et al.*, 2009; Landschützer *et al.*, 2013; Nakaoka *et al.*, 2013; Zeng *et al.*, 2014; Laruelle *et al.*, 2017; Denvil-Sommer *et al.*, 2019; Chau *et al.*, 2022)。Landschützer 等(2013)首次提出使用基于自组织映射的两步神经网络,通过聚类对大西洋海水 p_{CO_2} 进行分类,并分区域分季节以 1° 的空间分辨率重建了大西洋月平均海水 p_{CO_2} 。这一遥感反演算法被广泛应用,并实现了对全球开阔大洋(Landschützer *et al.*, 2014)、全球边缘海(Laruelle *et al.*, 2017)、北极(Nakaoka *et al.*, 2013)、东北太平洋(Hales *et al.*, 2012)等不同地区海水 p_{CO_2} 的反演。此外,前馈神经网络(feedforward neural network, FFNN)也是海水 p_{CO_2} 重建过程中一个非常重要的算法,Jo 等(2012)使用 FFNN 创建了一个具有大量海洋参数的数据集推动对于全球碳收支的估算。Zeng 等基于 FFNN 重建了热带大西洋(Zeng *et al.*, 2017)和全球(Zeng *et al.*, 2015)月平均分布数据集。Denvil-Sommer 等提出前馈神经网络实现对开阔大洋(Denvil-Sommer *et al.*, 2019)与边缘海(Chau *et al.*, 2022)海水 p_{CO_2} 的反演。Zhang 等基于星载激光雷达数据进一步扩展了 FFNN 在北极(Zhang *et al.*, 2022)和全球昼/夜碳循环中的应用(Zhang *et al.*, 2023c),填补了传统数据集在极地冬季的缺失(图 4),首次刻画了全球海水 p_{CO_2} 的夜间分布。

同时,在一些特殊边缘海,许多其他的机器学习算法也被广泛应用,Chung 等(2018)采用随机森林反演算法技术,通过优化模型性能,开发了基于 4 个潜在预测变量(pH、浊度、风速、叶绿素浓度)的简约模型,大大提高了对韩国地表水系统中 p_{CO_2} 的预测能力;Chen 等(2019)的研究指出基于随机森林的集成回归(random forest regression ensemble, RFRE)模型是重构墨西哥湾 p_{CO_2} 的最佳方法,基于 RFRE 重建的海水 p_{CO_2} 空间分辨率约为 1 km,均方根差异低,在沿海、河流和开放水域都具有令人满意的性能;Zhang 等(2023a)发现在白令海等具有复杂区域特征的边缘海,高斯过程回归模型能够有效处理不同水体间差异,有效处理过渡区域,完成对海水 p_{CO_2} 的较好反演。




图4 北极气候态二氧化碳分压(p_{CO_2})分布(Zhang *et al.*, 2022)

Fig.4 Climatological distribution of p_{CO_2} in the Arctic region (Zhang *et al.*, 2022)

1.4 数据重构

在海洋水色遥感中,由于云层遮挡、传感器故障或空间分辨率限制,常会出现数据缺失或质量下降的问题。而数据重构利用可用数据填补信息缺失,提高数据集的完整性和精度,是海洋水色遥感的一项关键技术。结合多种遥感数据源和地面观测数据,利用多源数据融合技术和大模型处理能力,构建综合性的海洋环境监测模型。通过这些模型,可以更全面和准确地反映海洋环境的变化趋势和状态。

1.4.1 空间重构 在空间重构方面,传统方法如克里金插值和最佳插值方法(Chen *et al.*, 2020; Yang *et al.*, 2021; Meng *et al.*, 2022)。依赖于数据的空间自相关性,但这些方法在处理非线性和复杂模式时能力有限。近年来,基于机器学习的方法,尤其是深度学习方法,如CNN和生成对抗网络(generative adversarial network, GAN),已被证明在空间数据重构中更为有效(Amani *et al.*, 2022)。这些方法能够学习数据的复杂非线性关系,生成空间上连续和一致的数据集(Sadaippan *et al.*, 2023)。例如 Mohebzadeh 等(2021)使用支持向量机回归,基于 MODIS 卫星数据以及其他环境参数对叶绿素浓度进行时空插值;Ouala 等(2018)使用基于神经网络的卡尔曼滤波器,结合了卫星衍生的海面温度数据和海面高度数据,对海面温度数据进行时空插值;Zhang 等(2024a)使用最佳插值(optimal interpolation, OI)模型,将来自不同数据源(包括 MERSI-II 和 MWRISST 数据、重建数据和背景场

数据)进行融合,生成了时间分辨率为 12 h、空间分辨率为 5 km 的更高质量的 SST 融合数据产品;Liu 等(2022b)使用生成对抗网络对 WindSat 卫星海面风速数据进行空间降尺度,以重构空间分辨率更高的遥感数据;Cutolo 等(2024)提出了 CLOINet 模型,训练得到最优插值网络,将遥感数据、原位稀疏观测和深度学习相结合,重建包含多个海洋参数(例如海面温度、盐度、叶绿素浓度等)的完整海洋状态图像,此外,Zhang 等(2024b)的工作,展示了如何利用 AI 技术生成长时间序列的高质量全球海洋数据产品。这些研究证明了机器学习方法在处理大规模、多源海洋数据方面的巨大潜力。

1.4.2 时间重构 时间重构关注如何利用历史和实时数据预测未来或填补过去的时间序列数据。传统方法如时间序列分析和插值方法,在处理长期趋势和季节性变化时效果有限。机器学习方法,如长短时记忆网络(long short-term memory, LSTM),能够捕捉时间序列数据的长期依赖关系,提供更准确的时间重构产品。

针对因噪声、云层而处于低质量状态的海洋数据集,研究者们也使用机器学习以进行重构,进一步提高数据集完整性。Hirahara 等(2020)使用了一种 GAN 来学习海面温度图像的分布,并通过将物理模型的约束整合到 GAN 的损失函数中,来提高模型的准确性和物理合理性,从而对海面温度图像进行降噪和修复;Jouini 等(2013)使用神经网络来识别和重建被云层遮挡的区域,从而生成完整的叶绿素图像;Barth 等(2022)使用多变量卷积神经网络 DINCAE2.0 重建了海面温度卫星观测数据和高度计观测数据,用以补全由于云层与轨道间隙遮挡造成的数据缺失。

1.4.3 多源数据融合 多源数据融合是数据重构的高级形式,它结合了来自不同传感器和数据源的信息。传统的融合方法,如主成分分析(principal component analysis, PCA)和贝叶斯方法,可能难以处理大规模和多模态数据。深度学习方法,特别是 DBN 和多模态深度学习,能够有效地整合和利用多源数据,提高数据的质量和分辨率。如 Park 等(2020)使用基于集成学习的随机森林方法,将罗斯海的遥感叶绿素浓度数据与其他环境参数(如海冰、水深、气温等)进行整合,重建了更加完整和准确的叶绿素数据;Ćatipović 等(2023)使用 GAN,利用卫星衍生的叶绿素浓度数据以及其他相关数据,同样重建了更加完整和准确的叶

绿素浓度数据; Archambault 等(2023)训练多模态无监督深度神经网络, 以对卫星海洋高度计进行时空插值, 生成更高分辨率的海洋高度计图像。

1.4.4 噪声去除与数据优化 噪声去除和数据优化是数据重构的另一个重要方面, 旨在提高数据的质量和可用性。传统的滤波方法, 如卡尔曼滤波和中值滤波, 可能无法有效处理复杂的噪声模式。深度学习方法, 如自编码器和变分自编码器, 能够学习数据的内在表示, 去除噪声并优化数据质量。Martin 等(2023)利用编码器-解码器网络的深度学习方法将海面温度数据与卫星高度计观测数据相结合, 提高了格网海面高度异常数据的精度和分辨率, 生成更精细的海面高度图像; You 等(2023)采用基于权重函数与解混方法的时空数据融合算法 (flexible spatial and temporal data fusion algorithm, FSDAF) 模型, 进行覆盖范围更广的高精度影像重建, 并以此为基础进行更精确的红树林数据提取。图像融合不仅可用于生成新的高质量数据集, 也可用于前述的已有数据集劣质数据补全, 如 Estrada 等(2023)开发了一种基于机器学习的多帧影像融合方法, 用以解决由于湍流引起的水下影像退化问题, 从而对已有数据集进行优化。

2 海洋水色遥感机器学习模型的挑战

虽然机器学习在回归拟合方面表现出色, 但它们并不能生成训练数据分布之外的“新”信息。由于海洋的复杂性和动态性, 机器学习模型在有限或偏差的数据集上训练时可能会遇到泛化能力不足的问题。此外, 评估模型在不同时间和空间上的鲁棒性是具有挑战性的, 设计合理的数据分割和评估实验对于模拟预期用例至关重要。其中数据分布的变化在海洋遥感中非常普遍, 机器学习模型对此非常敏感。空间和时间自相关性也会影响模型性能, 如果不考虑这种自相关性, 可能会导致测试数据与训练数据之间的信息泄露, 从而高估模型性能。采样策略的选择对于确保测试集能够代表目标至关重要, 而常用的随机采样可能会引起偏差, 影响模型的准确性。数据驱动的科学探索并不意味着可以忽视对系统的了解。在模型复杂性与泛化能力之间的权衡也是关键, 需要考虑不确定性的量化和异常值的检测。

2.1 机器学习模型提取信息并进行插值, 但并不生成“新”信息

无论复杂程度如何, 机器学习模型无法从输入数

据中提取不包含的信息。虽然训练数据实际上可能为模型提供了一个强烈的先验知识, 结合输入数据可以做出预测, 但用户应该质疑这种预测是否足够明智, 以及模型可能忽略了系统的哪些重要方面。例如, 一个使用不包含厄尔尼诺现象的数据集训练的模型, 可能不会学习到厄尔尼诺相关的模式, 这些模式很可能在模型部署时遇到。因此, 在许多情况下, 机器学习模型可以看作是一种插值方式。模型可以被视为一个基于标记的 x - y 示例集估计未知 x 的函数 $f(x)$ 。神经网络特别有效, 因为它们可以将原始输入数据转换到高维空间, 从而更有效地进行插值。这个看法并不总是正确的, 但它可以为机器学习模型表现不佳提供一些直观的理解。

机器学习模型通过从训练数据中学习模式来预测未知数据点, 但它们并不创造原始数据中不存在的信息。例如, 在处理海面温度图像时, 模型可以基于训练集中的相似样本来估计并填补图像中的空白区域 (Agabin *et al*, 2024)。但这种方法的有效性建立在训练数据的代表性上。如果训练数据未能覆盖到某些特定的情况, 模型在这些未知领域的预测可能会不准确。因此, 确保训练数据能够充分捕捉到海洋环境的多样性和复杂性是至关重要的, 这有助于提高模型在面对未见过的数据时的泛化能力。

在使用机器学习预测比原始数据具有更高空间、时间或光谱分辨率的观测时, 必须小心相关情况。一个模型从 10 个多光谱波段生成 50 个高光谱波段并不会生成新的、独立的数据。这些模型都是基于它们所训练过的所有先前数据进行预测, 即它们的先验。应用这种方法意味着上采样得到的数据中的所有变异性都可以通过较低分辨率数据预测。然而, 这种假设在海洋系统中可能存在缺陷, 那里的动态过程和精细尺度变化可能不会被较低分辨率数据完全捕捉。例如, 基于遥感反射率 R_{rs} (520 nm) 和 R_{rs} (580 nm) 预测的 R_{rs} (550 nm) 处很可能失真, 因为海洋中在 550 nm 处的藻红蛋白 (蓝藻和其他浮游植物的一种辅助色素) 的尖锐吸收峰可能与 520 nm 和 580 nm 处的变化不相关。将季节性、温度和位置作为输入可能会帮助模型建立更准确的预测, 但并不是一种直接的联系。

在海洋科学中, 特别是在海洋水色遥感中, 数据本身可能是低维的 (Cael *et al*, 2023)。与自然图像 (即手机照片) 相比, 后者可以拥有大量的空间信息, 而海洋水色光谱只有少数几个维度 (即光谱波段)。这些信息难以在大型神经网络中维持多层次的表示和抽象, 以

生成稳健的关系。虽然目前仍在讨论可以从海洋水色数据中可以提取的参数数量,但我们不应该盲目地使用机器学习从训练数据中提取原本不存在的更多信息。在海洋水色反演模型的情况下,我们不应该仅微调 R_{rs} 或 R_{rs} 组合的遥感模型(如波段比值等)来约束效果较差的输入参数。相反,我们应该探索超越当前单像素以外的方法,利用 R_{rs} 的空间和时间模式(Jönsson *et al.*, 2023),结合如海面温度(Chase *et al.*, 2022)或激光雷达后向散射(Bisson *et al.*, 2023)等信息来约束我们的反演。此外,使用如新发射的浮游生物、气溶胶、云、海洋生态系统卫星任务提供的偏振信息和相关的空间观测,也可能会提供更准确的预测。

2.2 难以理解和评估模型在时空上的鲁棒性

当评估机器学习模型在一组测试样本上的性能时,我们假设测试样本应满足以下条件:(1)与训练样本独立;(2)代表了模型将在部署应用时的数据总体。设计训练/验证/测试数据集的分割和评估实验,以模拟预期的实际应用场景是至关重要的。值得注意的是,这些假设与开发显式的实证模型相同,即通过拟合标记数据来推导输入和输出之间的关系。模型应该基于它可能使用的所有可能条件来评估其鲁棒性。如果一个模型只尝试预测特定河口的叶绿素和有色可溶性有机物浓度,那么它就不需要在河口中部评估鲁棒性,而是可能需要确保在感兴趣的河口的所有季节中评估鲁棒性。在模型评估和数据子集设计方面,有 3 个特别重要的考虑因素:分布变化、时空自相关和采样策略。

分布变化在海洋遥感和遥感科学中普遍存在(Taori *et al.*, 2020)。这些变化可能是极为微妙的,机器学习模型对它们是非常敏感的。协变量变化发生在输入数据的分布发生变化时,例如,在传感器校准更新后或由于温度和生态系统属性之间的关系随着气候变化而变化后都有可能发生。另外,标签变化涉及标签分布的变化,例如,当季节和位置变化时,浮游植物物种的组成会发生变化。模型学习到在特定地区夏季稳健的关系可能会在冬季解体,导致模型性能和可靠性下降。例如,一个训练用于在遥感图像中检测牡蛎礁的模型在春季非常有效,但在秋季当盐沼和光照条件发生变化时,模型的准确性急剧下降(Ridge *et al.*, 2020)。如果一个模型用于预测与训练样本分布不同的数据,模型可能会表现不佳,因为其基本假设已经改变。而理解新的数据分布,尤其是多维数据,是否显著变化是很有挑战性的。

空间和时间自相关表现为空间或时间上彼此接近的观测值比那些相隔更远的观测值更相似。这种自相关有助于学习预测模型和插值数据。然而,如果这种自相关在数据集分割和评估时没有被考虑,就可能在训练和测试集之间产生信息泄露,导致我们高估模型性能。如果这些数据被简单地分成随机的训练/验证/测试子集,评估指标可能因数据中的自相关而显著失真。如果模型用于训练数据中不存在的地区或时间段获取的观测值,那么训练/验证/测试分割应该设计为考虑空间或时间自相关(Rolf *et al.*, 2024),例如空间或时间交叉验证、棋盘格评估和块或缓冲交叉验证。

用于收集将构成测试数据集的标签的采样策略,在理解测试数据集是否在模型部署具有代表性非常重要。许多实测数据集限于观测条件,在空间和时间上是聚集分布的(例如,靠近海岸,在冬季风暴期间很少)。这导致对环境有偏的表示,影响了模型的准确性估计,特别是当评估中没有考虑空间/时间自相关。最近的工作表明,一个基于大量生物地球化学 Argo 浮标数据集估计漫射衰减系数的模型仍然存在偏差,因为它没有代表海洋中值的真实分布(Demeaux *et al.*, 2024)。即使构建了一个概率样本(例如,随机均匀)来收集测试数据,样本的大小也可能对模型的不确定性产生很大影响,因为它可能错过了罕见或集中的模式。例如,如果某种浮游植物很少见,可能在训练数据中从未出现过,但在模型部署时仍然可能遇到(Nardelli *et al.*, 2022)。因此,考虑不同的采样策略并在评估预测产品时估计性能指标的标准误差/置信区间非常重要(Stehman *et al.*, 2019)。机器学习模型没有海洋系统的直接表示,只有它们所看到的有限数据。鉴于影响海洋物理和生物状态的许多因素,确保在所有相关维度和条件下适当地训练数据可能很困难,特别是在更高维度的空间中。评估空间和时间的泛化能力,并包括异常检测测试,可以帮助解决这些问题。

2.3 物理机制在机器学习中的重要性

数据驱动的科学和探索并不意味着忽视对系统的了解。预测应该与推断结合——理解系统的工作原理,并进行预测,无论是对未来状态还是反演感兴趣的参数。例如,在西大西洋,气候态风可能通过与日照和风驱动混合与 chl *a* 浓度相关。然而,这种气候态风和 chl *a* 的相关性并不意味着风速在因果上都是 chl *a* 浓度的可靠预测因子。相关性并不等同于因果关系。虽然通过无监督方法对整个数据集进行探索并通过机器学习模型测试解释能力可能有助于形成假设,但通常

需要对模型输入和输出之间的联系有一些了解。当然,机器可以用来获得对意外物理过程的洞察,并指导创建有效的物理关系。具有 1~2 个专家设计特征的物理知情模型可能比在原始数据上工作的机器学习模型更具有普适性和约束性。有研究表明,结合物理参数的深度学习反演模型(图 3a),双分支两步法要比常规的机器学习模型精度更高,泛化能力也更强(图 5b, 5c)(Zhang *et al.*, 2024c)。此外,在最近关于从卫星海洋水色预测海水漫射衰减系数的工作中,一个从辐射传输理论开发的简单分析模型被证明比经验神经网络在开放海洋环境中的偏差要小。尽管经验模型使用了一个大型的全球训练数据集进行了调整,但在开放海洋数据方面仍然有限,导致在这些地区的偏差更加显著(Demeaux *et al.*, 2024)。

2.4 模型不确定性和异常

机器学习模型擅长对输入到输出数据进行非线性转换,但我们必须考虑模型复杂性和泛化之间的权衡。例如,我们自己对地球系统的认识,是否更适合一个性能更高但更复杂的机器学习模型,还是一个分数略低但更简单的模型,或者可能是一个分数更低但更具有普适性的物理模型。答案将根据每个项目的目标而有所不同,但应该被考虑。在这里,我们讨论了与模型复杂性相关的模型开发和部署中的两个问题:不确定性和异常。

将不确定性纳入模型开发,并将不确定性传播到模型预测中,对于确保可靠的输出以及性能评估至关重要(Elipot *et al.*, 2022)。在模型开发建立中,必须理解每个步骤的不确定性。通常在模型建立过程中,模型是基于准确性[例如,均方根误差(root mean square error, RMSE)]进行比较的,而没有考虑输入数据(如 R_{rs})的不确定性,标签值(如测量的 chl a 浓度)的不确定性,或者对于小数据集来说,在训练/测试数据分割中注入的不确定性。为了客观而全面地评估一个模型,必须考虑所有相关的不确定性。比如,考虑 3 种不同复杂性的模型,用于从 R_{rs} 预测 chl a : 多元线性回归,随机森林和多层感知器。对于给定的训练/测试分割,并假设所有输入和标签测量都是精确的,一个特定的模型可能看起来更准确。然而,如果我们采用蒙特卡洛方法,并随机打乱测试/训练分割,并考虑输入和标签的不确定性,情况就不太一样了。在这种情况下, RMSE 的不确定性主要是由训练/测试分割的随机性驱动的,而不是测量技术,这可能与跨区域或水体类型的泛化能力差有关。如果我们想要生成最佳的全球算

法,这可能会鼓励我们收集或整理更多的数据,而不是在现有数据上开发更复杂的算法。这也可能鼓励采用不同的采样方法,如更多的剖面浮标与基于船舶的采样。海洋科学界也应该使用多个随机种子的平均值和标准差报告结果,并将测试数据按季节和区域分层抽样。

为了提高模型在复杂、不确定环境中的表现,可以考虑采用以下关键技术:(1) MC-Dropout 是一种在模型训练过程中引入随机性的方法,通过在训练阶段激活 Dropout 层,可以使模型在推理时考虑多个不同的网络结构,从而提供不确定性估计(Srivastava *et al.*, 2014; Gal *et al.*, 2016)。这种方法已被证明能有效提高模型在小样本数据上的泛化能力,可适用于海洋遥感数据的不确定性评估。(2) 深度集成通过训练多个深度学习模型并集成它们的预测来提高整体模型的性能和不确定性估计(Lakshminarayanan *et al.*, 2017; Lee *et al.*, 2019)。每个模型在训练过程中看到的数据略有不同,这种方法可以提供关于预测不确定性的更全面视角,特别适用于海洋遥感数据的多变性和复杂性。(3) 逐像素不确定性估计对于生成稳健和可靠的反演产品至关重要。我们采用了先进的统计方法来评估每个预测像素的不确定性,包括引导法和贝叶斯方法。这些方法可以为每个预测提供置信区间(Kendall *et al.*, 2017),从而帮助用户理解模型预测的可信度。通过引入这些技术,我们不仅提高了模型在处理海洋遥感数据时的不确定性评估能力,还增强了模型的泛化能力和反演产品的可靠性。这些方法的应用使得模型在面对复杂和不确定的海洋环境时,能够提供更为准确和可靠的预测结果。

在气候变化的背景下,广泛关注的海洋问题往往涉及一些异常情况和超出训练数据之外的数据点。然而,如果没有适当训练,旨在预测浮游植物类型或有害藻华的机器学习模型可能无法检测到这些新的重要事件。例如,一个用于预测显微镜下观察到的、训练数据集中所有过去的图像中的浮游植物物种模型,但在接下来的一年中,一个新的浮游植物物种出现在该地区,该模型将很难预测出正确的类别。但是,如果恰当设计,选择合适的深度学习模型,如 GAN,可以不识别为已有物种,从而判定为新物种。此外,还可以选用有效的传统统计和机器学习方法用于异常检测(例如,隔离森林、局部异常因子)。许多模型的损失函数也可以修改,以优先考虑罕见的例子。这与生态数据集的长尾分布特别相关,特别是在浮游植物方面。如稀有物种、




图5 耦合物理参数的机器学习模型

Fig.5 Machine learning models with coupled physical parameters

注: a. 双分支两步法深度学习模型框架; b. POC 反演模型对比; c. 颗粒无机碳(particulate inorganic carbon, PIC)反演模型对比, 对应刻度为顺时针处数值; Input β 为激光雷达回波波形信号; Input β_{clim} 为气候态回波信号; Input β_{anom} 为回波信号与气候态的差值; FC 为全连接层 fully connected layer; δT 为水体总退偏比; δT_{clim} 为气候态水体总退偏比; δT_{anom} 为水体总退偏比与气候态差值; β_w 为水体垂直偏振后向散射; $\beta_{w, \text{clim}}$ 为气候态水体垂直偏振后向散射; $\beta_{w, \text{anom}}$ 为水体垂直偏振后向散射与气候态差值; POC_{clim} 为气候态颗粒有机碳浓度; POC_{anom} 为颗粒有机碳浓度与气候态差值; PIC_{clim} 为气候态颗粒无机碳浓度; PIC_{anom} 为颗粒无机碳浓度与气候态差值; R 为相关系数, 无量纲, 对应刻度为右侧数值; MAPD 为 mean absolute percentage difference, 平均绝对百分比偏差, 无量纲, 对应刻度为正下方数值; RMSD 为 root mean square difference, 均方根偏差, 单位为 $\text{mg} \cdot \text{m}^{-3}$, 对应刻度为上方数值; MdSA 为 median symmetric accuracy, 中位对称准确性, 无量纲, 对应刻度为左侧数值; TBTS 为 two-branch-two-step, 二分支两步法; RF 为 random forest, 随机森林; SVR 为 support vector regression, 支持向量回归; TabNet 为 tabular neural network, 表格神经网络; XGBoost 为 extreme gradient boosting, 极限梯度提升方法

稀有光谱、沉积物和矿物质以及浮游植物类型的罕见组合的长尾分布; 所有这些方面都使传统的分类方法具有挑战性。有时问题被称为“开放集”分类问题, 是在海洋科学中尚未充分探索的领域。总之, 如果一个模型没有经过适当的评估、论证, 并且没有理解其局限

性, 将其部署到野外或从模型的预测中得出结论实际上可能并不准确。

2.5 大模型对计算资源的需求

在当前的海洋水色遥感研究中, 随着数据量的不断增加和算法的日益复杂, 对计算资源的需求也越来

越高。机器学习和深度学习模型,尤其是大型模型,需要大量的计算资源来进行训练和预测。这些资源包括高性能的计算设备(如 GPU)、足够的存储空间以及高效的数据处理算法。为了满足这些需求,研究人员需要依赖云计算平台、高性能计算集群或者专门的硬件加速器。此外,优化算法结构、采用分布式计算和模型压缩等技术也是提高计算效率、降低资源消耗的有效途径。在未来的研究中,如何平衡模型的复杂度和计算资源的需求,以及如何利用有限的资源实现高效的海洋水色遥感数据分析,将成为一个重要的研究方向。

3 海洋水色遥感定标与真实性检验 AI 大模型展望

卫星遥感器的精确定标对于获取可靠的海洋水色数据至关重要。目前,国际标准要求水色传感器在大气校正后达到 5% 的绝对不确定度和 1% 的相对不确定度。由于传感器观测的大气层顶辐亮度中大约 90% 是由大气气体和气溶胶散射贡献,而仅有 10% 来自水体信号,因此,水色遥感产品的不确定度对传感器的辐射定标精度极为敏感。为了满足这些严格要求,必须执行精细的辐射定标任务,以监控和保持传感器的性能稳定性。这涉及复杂的定标过程,包括传感器输出信号与输入辐射能之间建立准确的联系,这对于量化地球物理变量如水体成分浓度和气溶胶含量至关重要(Bailey *et al*, 2008)。随着人工智能技术的发展,特别是深度学习模型的应用,为传统定标方法带来了革命性的改进。这些模型不仅提高了定标的精度,而且由于其出色的泛化能力,有望在未来的海洋水色遥感中发挥更加广泛的作用。深度学习模型能够处理和分析大规模的复杂数据,提供更加精确和自动化的定标服务,从而增强了遥感数据在海洋科学研究和环境监测中的应用价值。

海洋卫星水色遥感器的在轨辐射定标对于确保数据的量化应用至关重要。在缺乏专用星上定标系统时,通常采用海上场地定标和交叉定标方法(Clark *et al*, 2003)。绝对辐射定标通过反射率波段平均和归一化处理,消除传感器带宽带来的误差,并根据叶绿素含量、风速和观测几何角度等因素调整定标系数(Hagolle *et al*, 2004; Datla *et al*, 2011)。替代定标依靠海洋物理参数在特定海域的稳定性,通过同步现场观测和大气修正,比较海面归一化离水辐亮度与卫星测量信号,调整定标系数以匹配现场实测值(Mopper *et al*, 1993; Fougnie *et al*, 1999)。交叉定标则利用高精度参

考传感器对目标传感器进行定标,通过光谱匹配和重构方法,分析不同条件下的光谱辐亮度,确保定标精度(Evans *et al*, 1994; Dubuisson *et al*, 2003)。

海洋水色遥感数据的真实性检验是确保这些数据能够准确反映海洋水体的光学特性和相关参数的重要步骤之一。以下是一些常见的方法和技术,用于检验海洋水色遥感数据的真实性:(1) 地面真实观测数据对比:将卫星遥感数据与地面真实观测数据进行对比。地面真实观测数据通常由浮标、水下仪器等设备获取,可以提供准确的海洋水体光学参数。通过将遥感数据与地面真实观测数据进行对比分析,可以验证遥感数据的准确性和真实性。(2) 同步地面验证实验:在卫星遥感数据获取的同时,进行同步的地面验证实验。通过在海洋水域放置水质监测设备或传感器,实时记录水体的光学参数,并与卫星遥感数据进行对比分析,验证遥感数据的真实性。(3) 相对一致性检验:利用不同时间、不同地点或不同遥感传感器获取的海洋水色遥感数据进行相对一致性检验。通过比较不同数据源获取的数据,在一定条件下的一致性,来评估数据的真实性和稳定性。(4) 时间序列分析:对连续时间段内的海洋水色遥感数据进行时间序列分析,观察数据的变化趋势和周期性。如果数据能够准确反映海洋水体的季节性、年际变化等特征,可以进一步验证数据的真实性。(5) 模型验证:利用建立的海洋水色遥感大模型对实际遥感数据进行验证。将模型预测的数据与实际观测数据进行比较,评估模型的准确性和可靠性,从而间接验证遥感数据的真实性。实现海洋光学定量遥感反演产品的真实性检验,提高遥感数据的质量。

当前,基于人工智能方法对遥感数据进行定标和校正的研究开始引起领域关注。整体来看该研究领域仍处于起步阶段,在人工智能快速发展的背景下仍有很大探索空间。海洋卫星遥感定标 AI 模型要处理的是海量三维时空数据,尚需针对性研究与之相适应的大模型。针对三维时空数据的 Transformer 大模型架构已经取得了显著的研究进展,并且已有多项研究工作在这一领域展开。例如,Zhou 等(2023b)提出了创新的模型架构,能够有效处理时空数据的复杂性。该研究展示了 Transformer 模型在处理海洋水色遥感等三维时空数据中的潜力和应用价值。其基于 Encoder-Decoder 思想构建三维 Transformer 网络,利用 Transformer 模型的 Attention 多头注意力机制以及多层感知机(multi-layer perceptron, MLP)的强大非线性特征提取能力,以端到端方式建模地表遥感反射率 A_B

到大气层顶遥感反射率 A_T 复杂映射关系,以支撑定标验证。可采用 4 层 Encoder-Decoder 架构,将 A_B 、大气参量数据作为 Encoder 编码器的输入,通过多层 Encoder 不断提取融合后的多源特征到高特征维度。将 Encoder 输出的高维信息作为 Decoder 输入,用于多个 Decoder 处理,最后一个 Decoder 输出 A_T 数据。

卫星遥感辐射定标和大气校正两个任务之间有很紧密的联系,可将两个任务视为互逆运算,前者实现海表遥感反射率 A_B 到大气层顶遥感反射率 A_T 计算,后者实现 A_T 到 A_B 计算,具有明显的对偶性。考虑到目前 A_B 与 A_T 对应数据不足,可引入对偶学习(图 6),并采用有监督和无监督相结合的训练方法。可构建 2 个 3D-Transformer 基础模型,一个定标大模型,用于实现 A_B 到 A_T 计算,另一个校正大模型,用于实现 A_T 到 A_B 计算。训练可分为 2 个阶段:一是采用有监督训练方法,基于 A_B 与 A_T 对应数据,分别训练定标大模型和校正大模型;二是采用对偶学习对定标大模型和校正大模型进行双模型联合训练,进一步优化 2 个模型。这 2 个大模型将通过对偶学习的方式相互协作,整个过

程通过强化学习来相互学习,基于该过程生成的反馈信号,迭代更新两个基础模型直到收敛。2 个模型联合训练的步骤如下:

1. 模型构建:构建了两个基于深度学习的模型,分别为定标模型(M1)和真实性检验模型(M2)。

2. 有监督训练:首先,使用标记的数据对两个模型进行有监督训练。这一步骤确保了每个模型能够独立地学习其任务。

3. 对偶学习训练:在有监督训练完成后,采用对偶学习策略,通过设计一个联合损失函数,同时优化两个模型。在这个过程中,M1 的输出作为 M2 的输入,反之亦然。通过这种方式,两个模型能够相互学习和优化。

4. 反馈信号机制:我们设计了一个反馈机制,使得 M2 的性能反馈到 M1,从而调整 M1 的参数。同样,M1 的性能也反馈到 M2。这种双向反馈机制确保了两个模型能够相互协调和优化。

5. 模型优化:通过迭代训练和反馈,两个模型的性能逐渐提升,直到达到收敛。




图 6 基于对偶学习的定标检验大模型训练方法

Fig.6 The large model training method based on dual learning

注: MLP 为 multi-layer perceptron,多层感知机;Attention 为注意力机制模块;Mask-Attention 为掩膜注意力机制模块

为了训练遥感定标大模型,需要充足的算力和数据作为保障。数据方面,当使用深度学习的方法训练遥感定标大模型时,面临数据量不足、数据时空不连续等问题,可从全球获取可用数据并辅以仿真模拟。数据来源包括:(1) 定标实验室数据,如海洋光学浮标(marine optical buoy, MOBY)等遥感定标数据集、自有定标实验数据;(2) 仿真模拟数据,基于辐射传递方程

模拟生成;(3) 原位观测数据,来自浮标、台站、船基等原位观测、调查数据;(4) 大气再分析数据,如来自欧洲中期天气预报中心(European centre for medium-range weather forecasts, ECMWF)的哥白尼大气监测服务(copernicus atmosphere monitoring service, CAMS)数据。全球水平分辨率 $0.75^{\circ} \times 0.75^{\circ}$,时间间隔 3 h 的大气再分析数据集,如 CAMS 全球温室气体再分析数

据和 CAMS 全球辐射强迫数据, 包含 TOA 上行辐亮度、地表上行辐亮度、10 m 风速、水蒸气、可见度、云量、气溶胶、二氧化碳、甲烷、臭氧等变量。CAMS 全球温室气体再分析数据是 ECMWF 大气成分再分析数据集的一部分, 使用 4D-var 同化方法同化 12 h 窗口内的数据, 该同化方法考虑了同化窗口内观测和模式演变的精确时间, 有效提高再分析数据集的质量。CAMS 全球辐射强迫数据集提供了主要大气成分的辐射强迫的地理分布, 分别提供了二氧化碳、甲烷、臭氧和气溶胶的估计值。两个再分析数据集均具有全球高分辨率覆盖、时空连续性高等特点, 适合作为遥感定标大模型的训练数据集。

遥感数据和原位观测数据等多源多模态数据在相同的时空范围内具有显著的相关性和差异性。例如, 通过卫星和浮标可以同时获取同一地点的海表温度、叶绿素等数据要素, 这些要素之间具有很强的关联性。同时, 不同卫星搭载不同类型的传感器和仪器, 以获取多样化、差异化信息。通过数据整合可以提供更全面的数据视角, 相互验证和校准, 从而提高数据的可靠性。针对多源多模态数据存在的时空差异性、尺度差异性问题。可将卫星遥感数据、浮标观测数据以及再分析等多源数据相结合, 构建多源多模态样本集, 充分融合遥感数据空间连续以及原位观测数据精度高的各自优势, 为 Transformer 大模型从多源数据中学习复杂的非线性关系打下坚实数据基础。

基于人工智能的替代定标方法是一种新的探索, 一方面其定标效果需要持续检验, 另一方面也需基于检验结果对其进行持续改进。包括: (1) 点检验: 利用检验大模型反演出物理量后, 与浮标原位观测数据进行综合误差分析, 评估效果; (2) 面检验: 融合浮标原位观测数据, 利用检验大模型反演出海表物理量, 与浮标原位观测数据进行综合误差分析, 评估效果; (3) 体检验: 融合浮标海表原位、水体剖面观测数据, 利用检验大模型反演出三维海洋立方体物理量, 与浮标原位观测数据进行综合误差分析, 评估效果。检验大模型一方面基于大模型强大的理解能力挖掘端到端之间的多变量复杂关联, 基于大模型生成能力实现高分辨率、高频率或多要素反演; 另一方面, 能够减少整个应用流程的复杂性, 以提高模型的性能和应用价值。

为解决卫星遥感像元尺度海水“真值”获取的难题, 除了硬件层面传感器及浮标平台测量精度和稳定性的提升, 软件算法层面的设计同样至关重要。包括: (1) 数据收集与整合: 整合分布式观测网络多个海上定

标浮标的多源异构观测数据到一个统一的数据库中, 对其进行初步的清洗和分类。(2) 数据预处理与标准化: 应用数据清洗方法进行处理, 包括去除明显的异常值、填充缺失值等。使用 PCA 或 t-SNE 等降维技术来观察数据分布, 为后续的深度神经网络模型训练提供依据。(3) 模型开发与训练: 利用地理空间分析方法和图像处理手段构建和提取多源异构输入变量。将所有变量转换为栅格格式, 在特定的时空尺度上匹配多个变量的网格。然后得到每个标记网格的多元向量, 即模型输入样本的形式。最后, 可以使用一个时空均匀的多源特征集进行深度信念网络的建模。为了消除维数, 加快该模型的收敛速度, 在训练前采用了 Min-Max 归一化方法。输出层包含了每个神经元的学习权重值。使用交叉验证方法进行模型训练, 以避免过拟合或欠拟合。(4) 模型验证与测试: 选用独立的观测数据集进行模型验证。使用混淆矩阵、精确度、召回率和 F1 分数等指标来评估模型的性能。利用局部可解释模型无关解释方法(local interpretable model-agnostic explanations, LIME)或沙普利加性解释方法(Shapley additive explanations, SHAP)等方法来解释模型的决策过程。并通过敏感性分析来评估模型在不同环境条件下的稳健性。

地面(海表)“真值”一方面可以通过改善地面获取方式进行获取, 另一方面, 如何高效利用现有浮标观测站点及其观测数据同样是定标真实性检验中获取地面“真值”的一个重要手段。需要分析遥感和实测数据的匹配不确定性, 主要包括: (1) 时间-空间-角度匹配不确定性分析: 时间匹配不确定性分析解决地面(海表)观测对于卫星遥感观测的绝对同步问题。空间匹配不确定性分析卫星导航误差和地面(海表)浮标观测点单点定位误差及漂移情况。角度匹配考虑修正观测角度和光照角度对定标检验测量的影响。通过借助中高空间分辨率数据, 结合经典统计方法和空间分析方法, 通过逐渐递推、标定的思路或空间降尺度的反过程, 可构建浮标观测数据的尺度上推方法, 对站点像元的空间异质性和时间尺度变化规律进行评价。根据观测点异质性质量化其空间代表性。在不同空间代表性的情况下, 分析其定标真实性检验中的影响程度。(2) 大模型定标不确定性量化分析: 在地面或海表观测误差方面, 采用监督学习算法, 通过训练地面真值与卫星观测之间的映射模型, 以量化并校正观测误差。这一步可利用高质量的地面观测数据作为训练集。在尺度扩展问题上, 利用深度学习的 CNN 来自适应地融合不同

尺度和分辨率的数据,可以有效减少由于尺度扩展导致的模型偏差。在时间-空间-角度多维配准不准确性方面,使用 GAN 或增强学习,进行时空多维变换参数的自动学习,以达到更精确的数据配准。为了全面评估不确定性的传播效应,应用贝叶斯网络或概率图模型进行多源不确定性的综合建模,系统分析不同类型和尺度不确定性之间的相互作用和传播机制。

4 结论

海洋水色遥感作为一个多学科交汇的研究领域,未来仍有广阔的探索空间和应用潜力。随着 AI 技术的不断进步和跨学科研究的深入,预计将为海洋生态环境的保护、管理和可持续发展提供更加精准和有效的科学支撑。尽管基于机器学习的海洋水色遥感研究取得了一定进展,但仍面临着数据质量、模型泛化能力和计算资源需求等方面的挑战。包括:(1) 数据量巨大:随着遥感技术的进步,每天都会产生大量的海洋数据,如何有效地存储、管理和处理这些大型数据集是一个重大挑战。(2) 数据多样性:遥感大模型需要处理各种格式和分辨率的数据,比如卫星图像、传感器数据和模型输出等,这些海量且异构的数据需要统一的处理、融合和分析框架。(3) 数据质量和准确性:数据存在噪音和缺失值,影响数据的质量。确保数据的准确性、一致性和完整性对模型的性能至关重要。(4) 实时数据处理需求:某些应用场景需要即时分析遥感数据,但巨量的数据使得实时处理变得很有挑战性。(5) 复杂的海洋现象建模:海洋环境复杂多变,需要复杂的算法来理解和预测其行为,例如:海流、温度及其对气候的影响。(6) 算法的可扩展性和灵活性:随着新数据的不断涌现,模型需要不断更新和适应新的数据源和分析方法。(7) 模型验证和评估:对遥感数据处理和模型输出的验证和评估是确认模型可靠性的关键步骤,但往往缺乏足够的地面真值数据。(8) 数据安全和隐私:存储和处理敏感数据时需要确保合规性和数据隐私,特别是当运用公共云服务时。(9) 云计算和分布式计算资源的依赖:高效的数据处理需要强大的计算资源,如何优化资源使用,减少计算成本,是另一个主要挑战。(10) 科学家和技术人员之间的沟通:数据科学家、海洋学家和 IT 专家之间需要有良好的交流与合作,以建立有效的数据处理流程和准确的模型。了解并克服这些挑战对于发展有效的海洋遥感大模型以及提高其在实际应用中的应用价值是至关重要的。

未来的研究方向可能包括:

1. 高质量水色数据集的建设:加强高精度、高时空分辨率的海洋遥感数据集建设,提供更有用的模型训练和验证资源。

2. 模型泛化和解释能力的提升:探索更具泛化性和解释性的模型结构和学习策略,以适应复杂多变的海洋环境。

3. 跨学科融合:加强海洋科学、遥感技术和人工智能等多学科交叉合作,推动海洋水色遥感技术的创新和应用。

(作者声明本文符合出版伦理要求)

参 考 文 献

- 赵海阳, 沈芳, 孙雪融, 等, 2022. 中国东部海域浮游植物类群遥感反演研究[J]. 海洋学报, 44(4): 153-168.
- AGABIN A, PROCHASKA J X, CORNILLON P C, *et al*, 2024. Mitigating Masked Pixels in a Climate-Critical Ocean Dataset [J]. Remote Sensing, 16 (13): 2439.
- ALAM M S, TIWARI S P, RAHMAN S M, 2024. Optimized ensemble machine learning models for predicting phytoplankton absorption coefficients [J]. IEEE Access, 12: 5760-5769.
- ALLAM M, MENG Q Y, ELHAG M, *et al*, 2024. Atmospheric correction algorithms assessment for Sentinel-2A imagery over inland waters of China: Case study, Qiandao Lake [J]. Earth Systems and Environment, 8(1): 105-119.
- AMANI M, MOGHIMI A, MIRMAZLOUMI S M, *et al*, 2022. Ocean remote sensing techniques and applications: A review (Part I) [J]. Water, 14(21): 3400.
- ARCHAMBAULT T, FILOCHE A, CHARANTONIS A, *et al*, 2023. Multimodal unsupervised spatio-temporal interpolation of satellite ocean altimetry maps [C] // Proceedings of the 18th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications (VISIGRAPP 2023)-Volume 4. Lisbonne: VISAPP: 159-167.
- BAILEY S W, HOOKER S B, ANTOINE D, *et al*, 2008. Sources and assumptions for the vicarious calibration of ocean color satellite observations [J]. Applied Optics, 47(12): 2035-2045.
- BARTH A, ALVERA-AZCÁRATE A, TROUPIN C, *et al*, 2022. DINCAE 2.0: Multivariate convolutional neural network with error estimates to reconstruct sea surface temperature satellite and altimetry observations [J]. Geoscientific Model Development, 15(5): 2183-2196.
- BI S, LI Y M, XU J, *et al*, 2019. Optical classification of inland waters based on an improved Fuzzy C-Means method [J]. Optics Express, 27(24): 34838-34856.
- BISSON K M, WERDELL P J, CHASE A P, *et al*, 2023. Informing ocean color inversion products by seeding with ancillary observations [J]. Optics Express, 31(24): 40557-

- 40572.
- BLIX K, ELTOFT T, 2018. Machine learning automatic model selection algorithm for oceanic Chlorophyll-a content retrieval [J]. *Remote Sensing*, 10(5): 775.
- BROCKMANN C, DOERFFER R, PETERS M, *et al*, 2016. Evolution of the C2RCC neural network for sentinel 2 and 3 for the retrieval of ocean colour products in normal and extreme optically complex waters [C]// *Living Planet Symposium*. 740: 54.
- CAEL B B, BISSON K, BOSS E, *et al*, 2023. How many independent quantities can be extracted from ocean color? [J]. *Limnology and Oceanography Letters*, 8(4): 603-610.
- ĆATIPOVIĆ L, MATIĆ F, KALINIĆ H, *et al*, 2023. CCGAN as a tool for satellite-derived chlorophyll a concentration gap reconstruction [J]. *Journal of Marine Science and Engineering*, 11(9): 1814.
- CHASE A P, BOSS E S, HAËNTJENS N, *et al*, 2022. Plankton imagery data inform satellite-based estimates of diatom carbon [J]. *Geophysical Research Letters*, 49(13): e2022GL098076.
- CHAU T T T, GEHLEN M, CHEVALLIER F, 2022. A seamless ensemble-based reconstruction of surface ocean $p\text{CO}_2$ and air-sea CO_2 fluxes over the global coastal and open oceans [J]. *Biogeosciences*, 19(4): 1087-1109.
- CHEN S L, HU C M, BARNES B B, *et al*, 2019. A machine learning approach to estimate surface ocean $p\text{CO}_2$ from satellite measurements [J]. *Remote Sensing of Environment*, 228: 203-226.
- CHEN Z Q, WANG X D, LIU L, 2020. Reconstruction of three-dimensional ocean structure from sea surface data: An application of is QG method in the Southwest Indian Ocean [J]. *Journal of Geophysical Research: Oceans*, 125(6): e2020JC016351.
- CHUNG S, PARK H, YOO J, 2018. Variability of $p\text{CO}_2$ in surface waters and development of prediction model [J]. *Science of the Total Environment*, 622/623: 1109-1117.
- CLARK D K, YARBROUGH M A, FEINHOLZ M, *et al*, 2003. MOBY, a radiometric buoy for performance monitoring and vicarious calibration of satellite ocean color sensors: Measurement and data analysis protocols [M]// MUELLER J L, FARGION G S, MCCLAIN C R. *Ocean Optics Protocols for Satellite Ocean Color Sensor Validation*. Volume 6: Special Topics in Ocean Optics Protocols and Appendices. Greenbelt: Goddard Space Flight Space Center.
- CORCORAN F, PARRISH C E, 2021. Diffuse attenuation coefficient (K_d) from *ICESat-2* ATLAS spaceborne lidar using random-forest regression [J]. *Photogrammetric Engineering & Remote Sensing*, 87(11): 831-840.
- CUARTERO A, CÁCERES-MERINO J, TORRECILLA-PINERO J A, 2023. An application of C2-Net atmospheric corrections for chlorophyll-a estimation in small reservoirs [J]. *Remote Sensing Applications: Society and Environment*, 32: 101021.
- CUI Z D, DU D P, ZHANG X L, *et al*, 2022. Modeling and prediction of environmental factors and chlorophyll a abundance by machine learning based on *Tara* Oceans data [J]. *Journal of Marine Science and Engineering*, 10(11): 1749.
- CUTOLO E, PASCUAL A, RUIZ S, *et al*, 2024. CLOINet: Ocean state reconstructions through remote-sensing, *in-situ* sparse observations and deep learning [J]. *Frontiers in Marine Science*, 11: 1151868.
- DALL'OLMO G, GITELSON A A, RUNDQUIST D C, *et al*, 2005. Assessing the potential of SeaWiFS and MODIS for estimating chlorophyll concentration in turbid productive waters using red and near-infrared bands [J]. *Remote Sensing of Environment*, 96(2): 176-187.
- DATLA R U, RICE J P, LYKKE K R, *et al*, 2011. Best practice guidelines for pre-launch characterization and calibration of instruments for passive optical remote sensing [J]. *Journal of Research of the National Institute of Standards and Technology*, 116(2): 621-646.
- DEKKER A G, 1993. Detection of optical water quality parameters for eutrophic waters by high resolution remote sensing [D]. Amsterdam: Vrije Universiteit Amsterdam.
- DEMEAUX C B, BOSS E, TAN J, *et al*, 2024. Algorithms to retrieve the spectral diffuse attenuation coefficient of light in the ocean from remote sensing [J]. *Optics Express*, 32(2): 2507-2526.
- DENVIL-SOMMER A, GEHLEN M, VRAC M, *et al*, 2019. LSCE-FFNN-v1: A two-step neural network model for the reconstruction of surface ocean $p\text{CO}_2$ over the global ocean, *Geosci* [J]. *Geoscientific Model Development*. 12: 2091-2105.
- DEVLIN J, CHANG M W, LEE K, *et al*, 2018. BERT: Pre-training of deep bidirectional transformers for language understanding [C]. *Proceedings of naacL-HLT*, 1: 2.
- DUBUISSON P, BORDE R, DESSAILLY D, *et al*, 2003. In-flight spectral calibration of the oxygen A-band channel of MERIS [J]. *International Journal of Remote Sensing*, 24(5): 1177-1182.
- ELIPOT S, DRUSHKA K, SUBRAMANIAN A, *et al*, 2022. Overcoming the challenges of ocean data uncertainty [J]. *Eos Transactions American Geophysical Union*, 104(4): 20-22.
- ESTRADA D, HOU W L, MATT S C, *et al*, 2023. Multi-frame image fusion using a machine learning-based weight mask predictor for turbulence-induced image degradation [J]. *Journal of Applied Remote Sensing*, 17(1): 016514.
- EVANS R H, GORDON H R, 1994. Coastal zone color scanner "system calibration": A retrospective examination [J]. *Journal of Geophysical Research: Oceans*, 99(C4): 7293-7307.
- FAN Y Z, LI W, CHEN N, *et al*, 2021. OC-SMART: A machine learning based data analysis platform for satellite ocean color sensors [J]. *Remote Sensing of Environment*, 253:

- 112236.
- FAN Y Z, LI W, GATEBE C K, *et al*, 2017. Atmospheric correction over coastal waters using multilayer neural networks [J]. *Remote Sensing of Environment*, 199: 218-240.
- FOUGNIE B, DESCHAMPS P Y, FROUIN R, 1999. Vicarious calibration of the POLDER ocean color spectral bands using in situ measurements [J]. *IEEE Transactions on Geoscience and Remote Sensing*, 37(3): 1567-1574.
- FRIEDRICH T, OSCHLIES A, 2009. Neural network - based estimates of North Atlantic surface $p\text{CO}_2$ from satellite data: A methodological study [J]. *Journal of Geophysical Research: Oceans*, 114(C3).
- GAL Y, GHARAMANI Z, 2016. Dropout as a Bayesian approximation: Representing model uncertainty in deep learning [C] // *Proceedings of the 33rd International Conference on International Conference on Machine Learning*. New York: JMLR.org: 1050-1059.
- GONS H J, RIJKEBOER M, RUDDICK K G, 2002. A chlorophyll-retrieval algorithm for satellite imagery (Medium Resolution Imaging Spectrometer) of inland and coastal waters [J]. *Journal of Plankton Research*, 24(9): 947-951.
- GOWER J, KING S, BORSTAD G, *et al*, 2005. Detection of intense plankton blooms using the 709 nm band of the MERIS imaging spectrometer [J]. *International Journal of Remote Sensing*, 26(9): 2005-2012.
- HAGOLLE O, NICOLAS J M, FOUGNIE B, *et al*, 2004. Absolute calibration of VEGETATION derived from an interband method based on the sun glint over ocean [J]. *IEEE Transactions on Geoscience and Remote Sensing*, 42 (7): 1472-1481.
- HALES B, STRUTTON P G, SARACENO M, *et al*, 2012. Satellite-based prediction of $p\text{CO}_2$ in coastal waters of the eastern North Pacific [J]. *Progress in Oceanography*, 103: 1-15.
- HE X Q, PAN T F, BAI Y, *et al*, 2024. Intelligent atmospheric correction algorithm for polarization ocean color satellite measurements over the open ocean [J]. *IEEE Transactions on Geoscience and Remote Sensing*, 62: 1-22.
- HIRAHARA N, SONOGASHIRA M, KASAHARA H, *et al*, 2020. Denoising and inpainting of sea surface temperature image with adversarial physical model loss [C] // *5th Asian Conference on Pattern Recognition*. Auckland: Springer: 339-352.
- IOANNOU I, GILERSON A, GROSS B, *et al*, 2013. Deriving ocean color products using neural networks [J]. *Remote Sensing of Environment*, 134: 78-91.
- JAMET C, LOISEL H, DESSAILLY D, 2012. Retrieval of the spectral diffuse attenuation coefficient $K_d(\lambda)$ in open and coastal ocean waters using a neural network inversion [J]. *Journal of Geophysical Research: Oceans*, 117(C10): C10023.
- JAMET C, MOULIN C, LEFÈVRE N, 2007. Estimation of the oceanic $p\text{CO}_2$ in the North Atlantic from VOS lines *in-situ* measurements: Parameters needed to generate seasonally mean maps [J]. *Annales Geophysicae*, 25(11): 2247-2257.
- JO Y H, DAI M H, ZHAI W D, *et al*, 2012. On the variations of sea surface $p\text{CO}_2$ in the northern South China Sea: A remote sensing based neural network approach [J]. *Journal of Geophysical Research: Oceans*, 117(C8): C08022.
- JÖNSSON B F, SALISBURY J, ATWOOD E C, *et al*, 2023. Dominant timescales of variability in global satellite chlorophyll and SST revealed with a MOving Standard deviation Saturation (MOSS) approach [J]. *Remote Sensing of Environment*, 286: 113404.
- JOUINI M, LÉVY M, CRÉPON M, *et al*, 2013. Reconstruction of satellite chlorophyll images under heavy cloud coverage using a neural classification method [J]. *Remote Sensing of Environment*, 131: 232-246.
- KENDALL A, GAL Y, 2017. What uncertainties do we need in bayesian deep learning for computer vision? [C] // *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Long Beach: Curran Associates Inc.: 5580-5590.
- KIRK J T O, 1983. *Light and Photosynthesis in Aquatic Ecosystems* [M]. New York, USA: Cambridge University Press.
- KOLLURU S, GEDAM S S, INAMDAR A B, 2021. A machine learning approach for deriving spectral absorption coefficients of optically active oceanic constituents [J]. *Computers & Geosciences*, 155: 104879.
- KOLLURU S, TIWARI S P, 2022. Modeling ocean surface chlorophyll-a concentration from ocean color remote sensing reflectance in global waters using machine learning [J]. *Science of the Total Environment*, 844: 157191.
- LAKSHMINARAYANAN B, PRITZEL A, BLUNDELL C, 2017. Simple and scalable predictive uncertainty estimation using deep ensembles [C] // *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Long Beach: Curran Associates Inc.: 6405-6416.
- LANDSCHÜTZER P, GRUBER N, BAKKER D C E, *et al*, 2013. A neural network-based estimate of the seasonal to inter-annual variability of the Atlantic Ocean carbon sink [J]. *Biogeosciences*, 10(11): 7793-7815.
- LANDSCHÜTZER P, GRUBER N, BAKKER D C E, *et al*, 2014. Recent variability of the global ocean carbon sink [J]. *Global Biogeochemical Cycles*, 28(9): 927-949.
- LARUELLE G G, LANDSCHÜTZER P, GRUBER N, *et al*, 2017. Global high-resolution monthly $p\text{CO}_2$ climatology for the coastal ocean derived from neural network interpolation [J]. *Biogeosciences*, 14(19): 4545-4561.
- LE C F, LI Y M, ZHA Y, *et al*, 2009. A four-band semi-analytical model for estimating chlorophyll a in highly turbid lakes: The case of Taihu Lake, China [J]. *Remote Sensing of Environment*, 113(6): 1175-1182.

- LEE Z, CARDER K L, ARNONE R A, 2002. Deriving inherent optical properties from water color: A multiband quasi-analytical algorithm for optically deep waters [J]. *Applied Optics*, 41(27): 5755-5772.
- LEE H Y, KIM N W, LEE J G, *et al*, 2019. Uncertainty-aware deep learning forecast using dropout-based ensemble method [C] // 2019 International Conference on Information and Communication Technology Convergence (ICTC). Jeju: IEEE: 1120-1125.
- LEFÉVRE N, WATSON A J, WATSON A R, 2005. A comparison of multiple regression and neural network techniques for mapping in situ $p\text{CO}_2$ data [J]. *Tellus B: Chemical and Physical Meteorology*, 57(5): 375-384.
- LI H, HE X Q, BAI Y, *et al*, 2020a. Atmospheric correction of geostationary satellite ocean color data under high solar zenith angles in open oceans [J]. *Remote Sensing of Environment*, 249: 112022.
- LI X F, LIU B, ZHENG G, *et al*, 2020b. Deep-learning-based information mining from ocean remote-sensing imagery [J]. *National Science Review*, 7(10): 1584-1605.
- LI X L, YANG Y, ISHIZAKA J, *et al*, 2023. Global estimation of phytoplankton pigment concentrations from satellite data using a deep-learning-based model [J]. *Remote Sensing of Environment*, 294: 113628.
- LINGHU L X, WU J J, HUANG B R M, *et al*, 2018. GPU-accelerated massively parallel computation of electromagnetic scattering of a time-evolving oceanic surface model I: Time-evolving oceanic surface generation [J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 11(8): 2752-2762.
- LIU G, LI L, SONG K S, *et al*, 2020. An OLCI-based algorithm for semi-empirically partitioning absorption coefficient and estimating chlorophyll a concentration in various turbid case-2 waters [J]. *Remote Sensing of Environment*, 239: 111648.
- LIU H, LIN L, WANG Y J, *et al*, 2022a. Reconstruction of monthly surface nutrient concentrations in the Yellow and Bohai Seas from 2003-2019 using machine learning [J]. *Remote Sensing*, 14(19): 5021.
- LIU X H, STEELE C, SIMIS S, *et al*, 2021. Retrieval of chlorophyll-a concentration and associated product uncertainty in optically diverse lakes and reservoirs [J]. *Remote Sensing of Environment*, 267: 112710.
- LIU J, SUN Y J, REN K J, *et al*, 2022b. A spatial downscaling approach for windsat satellite sea surface wind based on generative adversarial networks and dual learning scheme [J]. *Remote Sensing*, 14(3): 769.
- LIU Z C, ZHOU W, YUAN Y, 2023. 3D DBSCAN detection and parameter sensitivity of the 2022 Yangtze river summertime heatwave and drought [J]. *Atmospheric and Oceanic Science Letters*, 16(4): 100324.
- MARTIN S A, MANUCHARYAN G E, KLEIN P, 2023. Synthesizing sea surface temperature and satellite altimetry observations using deep learning improves the accuracy and resolution of gridded sea surface height anomalies [J]. *Journal of Advances in Modeling Earth Systems*, 15(5): e2022MS003589.
- MEN J L, FENG L, CHEN X, *et al*, 2023. Atmospheric correction under cloud edge effects for Geostationary Ocean Color Imager through deep learning [J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 201: 38-53.
- MENG L S, YAN X H, 2022. Remote sensing for subsurface and deeper oceans: An overview and a future outlook [J]. *IEEE Geoscience and Remote Sensing Magazine*, 10(3): 72-92.
- MOBLEY C D, 1994. *Light and Water: Radiative Transfer in Natural Waters* [M]. San Diego: Academic Press.
- MOHEBZADEH H, MOKARI E, DAGGUPATI P, *et al*, 2021. A machine learning approach for spatiotemporal imputation of MODIS chlorophyll-a [J]. *International Journal of Remote Sensing*, 42(19): 7381-7404.
- MOPPER K, SCHULTZ C A, 1993. Fluorescence as a possible tool for studying the nature and water column distribution of DOC components [J]. *Marine Chemistry*, 41(1/2/3): 229-238.
- NAKAOKA S, TELSZEWSKI M, NOJIRI Y, *et al*, 2013. Estimating temporal and spatial variation of ocean surface $p\text{CO}_2$ in the North Pacific using a self-organizing map neural network technique [J]. *Biogeosciences*, 10(9): 6093-6106.
- NARDELLI S C, GRAY P C, SCHOFIELD O, 2022. A convolutional neural network to classify phytoplankton images along the West Antarctic Peninsula [J]. *Marine Technology Society Journal*, 56(5): 45-57.
- NEIL C, SPYRAKOS E, HUNTER P D, *et al*, 2019. A global approach for chlorophyll-a retrieval across optically complex inland waters based on optical water types [J]. *Remote Sensing of Environment*, 229: 159-178.
- NIU J, FENG Z Y, HE M X, *et al*, 2023. Incorporating marine particulate carbon into machine learning for accurate estimation of coastal chlorophyll-a [J]. *Marine Pollution Bulletin*, 192: 115089.
- ONO T, SAINO T, KURITA N, *et al*, 2004. Basin-scale extrapolation of shipboard $p\text{CO}_2$ data by using satellite SST and Chl a [J]. *International Journal of Remote Sensing*, 25 (19): 3803-3815.
- OUALA S, FABLET R, HERZET C, *et al*, 2018. Neural network based kalman filters for the spatio-temporal interpolation of satellite-derived sea surface temperature [J]. *Remote Sensing*, 10(12): 1864.
- OUYANG L, LING F H, LI Y, *et al*, 2023. Wave forecast in the Atlantic Ocean using a double-stage ConvLSTM network [J]. *Atmospheric and Oceanic Science Letters*, 16(4): 100347.
- PARK J, KIM H C, BAE D, *et al*, 2020. Data reconstruction for remotely sensed chlorophyll-a concentration in the Ross Sea

- using ensemble-based machine learning [J]. *Remote Sensing*, 12(11): 1898.
- RAFFEL C, SHAZEER N, ROBERTS A, *et al*, 2020. Exploring the limits of transfer learning with a unified text-to-text transformer [J]. *The Journal of Machine Learning Research*, 21(1): 5485-5551.
- REICHSTEIN M, CAMPS-VALLS G, STEVENS B, *et al*, 2019. Deep learning and process understanding for data-driven Earth system science [J]. *Nature*, 566(7743): 195-204.
- RIDGE J T, GRAY P C, WINDLE A E, *et al*, 2020. Deep learning for coastal resource conservation: Automating detection of shellfish reefs [J]. *Remote Sensing in Ecology and Conservation*, 6(4): 431-440.
- RÖDENBECK C, BAKKER D C E, GRUBER N, *et al*, 2015. Data-based estimates of the ocean carbon sink variability—first results of the Surface Ocean $p\text{CO}_2$ Mapping intercomparison (SOCOM) [J]. *Biogeosciences*, 12(23): 7251-7278.
- RÖDENBECK C, BAKKER D C E, METZL N, *et al*, 2014. Interannual sea-air CO_2 flux variability from an observation-driven ocean mixed-layer scheme [J]. *Biogeosciences*, 11(17): 4599-4613.
- ROLF E, KLEMMER K, ROBINSON C, *et al*, 2024. Position: Mission Critical—Satellite Data is a Distinct Modality in Machine Learning[C]//Forty-first International Conference on Machine Learning. Vienna.
- RUSIA P, BHATEJA Y, MISRA I, *et al*, 2021. An efficient machine learning approach for atmospheric correction [J]. *Journal of the Indian Society of Remote Sensing*, 49(10): 2539-2548.
- SADAIAPPAN B, BALAKRISHNAN P, C R V, *et al*, 2023. Applications of machine learning in chemical and biological oceanography [J]. *ACS Omega*, 8(18): 15831-15853.
- SARMA V V S S, 2003. Monthly variability in surface $p\text{CO}_2$ and net air-sea CO_2 flux in the Arabian Sea [J]. *Journal of Geophysical Research: Oceans*, 108(C8): 3255.
- SCHILLER H, DOERFFER R, 1999. Neural network for emulation of an inverse model operational derivation of Case II water properties from MERIS data [J]. *International Journal of Remote Sensing*, 20(9): 1735-1746.
- SCHROEDER T, SCHAALE M, LOVELL J, *et al*, 2022. An ensemble neural network atmospheric correction for Sentinel-3 OLCI over coastal waters providing inherent model uncertainty estimation and sensor noise propagation [J]. *Remote Sensing of Environment*, 270: 112848.
- SHEN M, LUO J H, CAO Z G, *et al*, 2022. Random forest: An optimal chlorophyll-a algorithm for optically complex inland water suffering atmospheric correction uncertainties [J]. *Journal of Hydrology*, 615: 128685.
- SIMIS S G H, PETERS S W M, GONS H J, 2005. Remote sensing of the cyanobacterial pigment phycocyanin in turbid inland water [J]. *Limnology and Oceanography*, 50(1): 237-245.
- SONG Z G, HE X Q, BAI Y, *et al*, 2023. Atmospheric correction of absorbing aerosols for satellite ocean color remote sensing over coastal waters [J]. *Remote Sensing of Environment*, 290: 113552.
- SRIVASTAVA N, HINTON G, KRIZHEVSKY A, *et al*, 2014. Dropout: A simple way to prevent neural networks from overfitting [J]. *The Journal of Machine Learning Research*, 15(1): 1929-1958.
- STEHMAN S V, FOODY G M, 2019. Key issues in rigorous accuracy assessment of land cover products [J]. *Remote Sensing of Environment*, 231: 111199.
- STEPHENS M P, SAMUELS G, OLSON D B, *et al*, 1995. Sea-air flux of CO_2 in the North Pacific using shipboard and satellite data [J]. *Journal of Geophysical Research: Oceans*, 100(C7): 13571-13583.
- SUN J, XU F C, CERVONE G, *et al*, 2021. Automatic atmospheric correction for shortwave hyperspectral remote sensing data using a time-dependent deep neural network [J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 174: 117-131.
- TAORI R, DAVE A, SHANKAR V, *et al*, 2020. Measuring robustness to natural distribution shifts in image classification [C]//Proceedings of the 34th International Conference on Neural Information Processing Systems. Vancouver: Curran Associates Inc.: 18583-18599.
- TELSZEWSKI M, CHAZOTTES A, SCHUSTER U, *et al*, 2009. Estimating the monthly $p\text{CO}_2$ distribution in the North Atlantic using a self-organizing neural network [J]. *Biogeosciences*, 6(8): 1405-1421.
- WANG H Y, LI X F, 2024. DeepBlue: Advanced convolutional neural network applications for ocean remote sensing [J]. *IEEE Geoscience and Remote Sensing Magazine*, 12(1): 138-161.
- WANG J W, WANG Y C, LEE Z P, *et al*, 2022. A revision of NASA SeaDAS atmospheric correction algorithm over turbid waters with artificial Neural Networks estimated remote-sensing reflectance in the near-infrared [J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 194: 235-249.
- WANG M Q, WANG D N, XIANG Y F, *et al*, 2023. Fusion of ocean data from multiple sources using deep learning: Utilizing sea temperature as an example [J]. *Frontiers in Marine Science*, 10: 1112065.
- XUE K, MA R H, DUAN H T, *et al*, 2019. Inversion of inherent optical properties in optically complex waters using sentinel-3A/OLCI images: A case study using China's three largest freshwater lakes [J]. *Remote Sensing of Environment*, 225: 328-346.
- YANG Z L, DAI Z H, YANG Y M, *et al*, 2019. XLNet:

- Generalized autoregressive pretraining for language understanding [C] // Proceedings of the 33rd International Conference on Neural Information Processing Systems. Vancouver: Curran Associates Inc.: 5753-5763.
- YANG M M, KHAN F A, TIAN H Z, *et al*, 2021. Analysis of the monthly and spring-neap tidal variability of satellite chlorophyll-a and total suspended matter in a turbid coastal ocean using the DINEOF method [J]. *Remote Sensing*, 13 (4): 632.
- YENDURI G, RAMALINGAM M, SELVI G C, *et al*, 2024. Gpt (generative pre-trained transformer) -a comprehensive review on enabling technologies, potential applications, emerging challenges, and future directions [J]. *IEEE Access*, 12: 54608-54649.
- YOU Q X, DENG W X, LIU Y, *et al*, 2023. Extraction the spatial distribution of mangroves in the same month based on images reconstructed with the FSDAF model [J]. *Forests*, 14(12): 2399.
- ZENG J Y, MATSUNAGA T, SAIGUSA N, *et al*, 2017. Technical note: Evaluation of three machine learning models for surface ocean CO₂ mapping [J]. *Ocean Science*, 13(2): 303-313.
- ZENG J, NOJIRI Y, LANDSCHÜTZER P, *et al*, 2014. A global surface ocean fCO₂ climatology based on a feed-forward neural network [J]. *Journal of Atmospheric and Oceanic Technology*, 31(8): 1838-1849.
- ZENG J Y, NOJIRI Y, NAKAOKA S I, *et al*, 2015. Surface ocean CO₂ in 1990-2011 modelled using a feed-forward neural network [J]. *Geoscience Data Journal*, 2(1): 47-51.
- ZHANG S Q, BAI Y, HE X Q, *et al*, 2023a. Spatial and temporal variations in sea surface pCO₂ and air-sea flux of CO₂ in the Bering Sea revealed by satellite-based data during 2003-2019 [J]. *Frontiers in Marine Science*, 10: 1099916.
- ZHANG S Q, BAI Y, HE X Q, *et al*, 2023b. The carbon sink of the Coral Sea, the world's second largest marginal sea, weakened during 2006-2018 [J]. *Science of the Total Environment*, 872: 162219.
- ZHANG S Q, CHEN P, HU Y X, *et al*, 2023c. Research report diurnal global ocean surface pCO₂ and air-sea CO₂ flux reconstructed from spaceborne LiDAR data [J]. *PNAS Nexus*, 3(1): pgad432.
- ZHANG Z H, CHEN P, JAMET C, *et al*, 2023e. Retrieving bbp and POC from CALIOP: A deep neural network approach [J]. *Remote Sensing of Environment*, 287: 113482.
- ZHANG S Q, CHEN P, ZHANG Z H, *et al*, 2022. Carbon air-sea flux in the arctic ocean from CALIPSO from 2007 to 2020 [J]. *Remote Sensing*, 14(24): 6196.
- ZHANG Z H, CHEN P, ZHONG C Y, *et al*, 2023f. Chlorophyll and POC in polar regions derived from spaceborne lidar [J]. *Frontiers in Marine Science*, 10: 1050087.
- ZHANG Y, SHEN F, LI R H, *et al*, 2024b. AIGD-PFT: The first AI-driven global daily gap-free 4 km phytoplankton functional type products from 1998 to 2023 [J]. *Earth System Science Data*, 16(10): 4793-4816.
- ZHANG Y, SHEN F, SUN X R, *et al*, 2023d. Marine big data-driven ensemble learning for estimating global phytoplankton group composition over two decades (1997-2020) [J]. *Remote Sensing of Environment*, 294: 113596.
- ZHANG M, XU N, CHEN L, 2024a. Fusion SST from infrared and microwave measurement of FY-3D meteorological satellite [J]. *Journal of Tropical Meteorology*, 30(1): 89-96.
- ZHANG Z H, ZHANG S Q, BEHRENFELD M J, *et al*, 2024c. Combining deep learning with physical parameters in POC and PIC inversion from spaceborne lidar CALIOP [J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 212: 193-211.
- ZHAO N, HUANG B X, ZHANG X M, *et al*, 2023a. Intelligent identification of oceanic eddies in remote sensing data via Dual-Pyramid UNet [J]. *Atmospheric and Oceanic Science Letters*, 16(4): 100335.
- ZHAO X, MA Y, XIAO Y F, *et al*, 2023b. Atmospheric correction algorithm based on deep learning with spatial-spectral feature constraints for broadband optical satellites: Examples from the HY-1C Coastal Zone Imager [J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 205: 147-162.
- ZHENG G M, STRAMSKI D, DIGIACOMO P M, 2015. A model for partitioning the light absorption coefficient of natural waters into phytoplankton, nonalgal particulate, and colored dissolved organic components: A case study for the Chesapeake Bay [J]. *Journal of Geophysical Research: Oceans*, 120(4): 2601-2621.
- ZHOU L, GAO C, ZHANG R H, 2023a. A spatiotemporal 3D convolutional neural network model for ENSO predictions: A test case for the 2020/21 La Niña conditions [J]. *Atmospheric and Oceanic Science Letters*, 16(4): 100330.
- ZHOU Q, WANG S, LIU N F, *et al*, 2023c. Towards operational atmospheric correction of airborne hyperspectral imaging spectroscopy: Algorithm evaluation, key parameter analysis, and machine learning emulators [J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 196: 386-401.
- ZHOU L, ZHANG R H, 2023b. A self-attention-based neural network for three-dimensional multivariate modeling and its skillful ENSO predictions [J]. *Science Advances*, 9(10): eadf2827.
- ZHU Q, SHEN F, SHANG P, *et al*, 2019. Hyperspectral remote sensing of phytoplankton species composition based on transfer learning [J]. *Remote Sensing*, 11(17): 2001.

CURRENT APPLICATIONS OF OCEAN COLOR REMOTE SENSING MACHINE LEARNING MODELS AND PROSPECTS FOR CALIBRATION AND VALIDATION

CHEN Peng^{1,3}, LI Yun-Zhou^{1,2}, ZHAO Zhi-Gang¹, ZHANG Si-Qi^{1,3},
ZHANG Zhen-Hua^{1,3}, WANG Jun-Cheng^{1,2}, PAN De-Lu^{1,3}

(1. *Qilu University of Technology (Shandong Academy of Sciences), Qingdao 266061, China*; 2. *Laoshan Laboratory, Qingdao 266237, China*; 3. *Second Institute of Oceanography, Ministry of Natural Resources, Hangzhou 310012, China*)

Abstract As an effective means for rapid, large-scale, and continuous observation of ocean color conditions, ocean color remote sensing technology has provided a global view of ocean optical properties, water color, and biogeochemical parameter distributions for several decades. In recent years, with the advancement of artificial intelligence technologies, research on ocean color remote sensing based on machine learning models has become a burgeoning field. This paper aims to review the current applications and challenges of machine learning models in ocean color remote sensing. It analyzes the performance of various algorithms in atmospheric correction, water color inversion, carbon cycle studies, and data reconstruction. Additionally, it discusses the considerations for using machine learning models in ocean color remote sensing, focusing particularly on their application progress in this domain. Given that satellite sensors are subject to degradation over long-term operations, continuous calibration and validation are essential to ensure the quality of observational data. Calibration and validation are fundamental to the application of satellite remote sensing. Therefore, this article also explores the future prospects of large-scale artificial intelligence models in the calibration and validation of ocean color remote sensing.

Key words ocean color remote sensing; large models; machine learning; radiometric calibration; validation; atmospheric correction