

湖泊悬浮物质量浓度遥感反演及变化分析

——以岱海为例

位俊燕, 赵轶鸣, 郝艳玲*, 贾晓雪, 马欣妍
(内蒙古大学 生态与环境学院, 呼和浩特 010021)

摘要:【目的】对比分析传统经验模型和 5 种机器学习算法精度和性能, 分析 2017—2023 年岱海悬浮物质量浓度的时空分布特征, 并探讨岱海悬浮物质量浓度变化的影响因素。【方法】通过现场实验获取岱海水体实测光谱和悬浮物质量浓度, 对比分析 5 种机器学习模型(BP 神经网络模型、卷积神经网络模型、随机森林模型、支持向量机模型、径向基函数神经网络模型)和传统经验模型的遥感反演精度, 选取精度最高的反演模型基于 Sentinel-2 MSI 卫星数据反演岱海悬浮物质量浓度。【结果】①机器学习模型较传统经验模型的反演精度高, 经三折交叉和地面同步数据验证 BP 模型反演效果优于其他模型, 模型 R^2 为 0.76, RMSE 为 4.66 mg/L, MAPE 为 26.57%; ②BP 模型的 9 个输入特征变量均对模型有正贡献作用, 特征变量 $B4 \cdot B5$ 对模型的重要性最为显著, 其次 $B4$ 、 $B4+B5$ 和 $B5 \cdot (B4+B5)$ 对模型精度影响较大; ③2017—2023 年岱海年平均悬浮物质量浓度介于 8.43~11.68 mg/L, 且呈小幅波动下降趋势, 5—10 月岱海月平均悬浮物质量浓度介于 7.77~10.84 mg/L, 5 月悬浮物质量浓度显著高于其他月份且变化较大, 6 月后开始下降并趋于稳定。空间上, 岱海悬浮物质量浓度主要呈“近岸高、离岸低”的特点, 高值区主要分布在岱海西南和东部近岸水域; ④岱海悬浮物质量浓度与风速表现出显著的正线性关系($r=0.61$, $p<0.001$), 与气温和降水量的相关性不大。【结论】遥感技术结合机器学习模型能够大幅度提升水质监测的效率和精度。在众多模型中, BP 模型和 CNN 模型精度优势更为明显, 其中 BP 模型精度更高且更为稳定。

关键词: 岱海; 悬浮物质量浓度; Sentinel-2 MSI; 机器学习; 遥感反演

中图分类号: TP79

文献标志码: A

doi: 10.13522/j.cnki.ggps.2024342

位俊燕, 赵轶鸣, 郝艳玲, 等. 湖泊悬浮物质量浓度遥感反演及变化分析: 以岱海为例[J]. 灌溉排水学报, 2025, 44(6): 99-110.

WEI Junyan, ZHAO Yiming, HAO Yanling, et al. Analyzing spatiotemporal variation in suspended particulate matter in lakes using remote sensing[J]. Journal of Irrigation and Drainage, 2025, 44(6): 99-110.

0 引言

【研究意义】悬浮颗粒物(Suspended Particulate Matter, SPM)是水体中漂浮的固态颗粒, 它的存在会改变水体的透明度、颜色和光学特性, 从而对水体生态系统和生物多样性产生影响^[1-2]。水体悬浮物质量浓度遥感反演在水体环境监测、水质评估、湖泊生态研究等领域具有广泛的应用, 通过监测和分析湖泊水体悬浮物的时空分布, 可以有效评估水体质量和生

态环境状态, 为相关决策和管理提供科学依据^[3-4]。遥感技术能够监测水体中具有光学活性的水质参数, 与常规的水质监测方法相比, 具有宏观、实时、成本低等优势, 能够满足大规模水质监测的需求^[5-6]。

【研究进展】悬浮物可以直接影响卫星某些波段的光谱反射, 早在 1973 年 Williamson^[7]发现悬浮物浓度与 Landsat 某些波段反射率具有较高的相关性, 这为后续学者研究遥感反演水质提供了新方向。目前, MODIS、Landsat、Sentinel、MERIS、SPOT 和 ZY1-02D 等卫星数据常被用于悬浮物质量浓度的反演^[8-13]。其中 Sentinel-2 MSI 的高时空分辨率使其可被用于内陆小型湖泊及沿海水域的高频次动态水质监测^[14-15]。目前反演悬浮物质量浓度最常用的模型有经验模型、半经验模型、半分析模型、准解析模型^[16-18], 这些模型虽然取得了较好的精度但仍然存在一定的局限性。近

收稿日期: 2024-09-02

修回日期: 2024-11-25

基金项目: 内蒙古自治区自然科学基金项目(2024MS04016); 内蒙古自治区水利科技项目(NSK202408)

作者简介: 位俊燕(1999—), 女, 山东烟台人。硕士研究生, 主要从事遥感应用研究。E-mail: 1398385804@qq.com

通信作者: 郝艳玲(1982—), 男, 内蒙古凉城人。副教授, 博士, 主要从事环境遥感方向研究。E-mail: haoyl@imu.edu.cn

©《灌溉排水学报》编辑部, 开放获取 CC BY-NC-ND 协议

年来,随着机器学习的发展,越来越多的学者尝试用机器学习模型进行悬浮物质量浓度的反演,并证明机器学习模型精度优于传统的经验模型。例如孙德勇等^[19]对太湖总悬浮物 and 无机悬浮物分别建立了神经网络模型,并证明神经网络模型的建模精度高于单波段经验模型。Deluca 等^[20]基于 MODIS 传感器建立了随机森林模型,模型精度优于经验模型。Wen 等^[21]利用简单线性回归和随机森林模型对中国湖泊进行总悬浮物质量浓度的反演,同时证明机器学习 RF 模型精度高于线性回归模型。【切入点】许多国内外学者利用机器学习算法反演悬浮物质量浓度,但是对于常见的几种机器学习算法并没有进行反演精度比较和稳定性分析,难以确定最佳反演模型。【拟解决的关键问题】岱海位于北方半干旱区,是典型高原湖泊,本文通过现场实验获取水体实测光谱和悬浮物质量浓度,通过对比传统经验模型和 BP 神经网络模型、卷积神经网络模型、随机森林模型、支持向量机模型、径向基函数神经网络模型的反演悬浮物质量浓度精度,选出最佳反演模型,分析 2017—2023 年岱海悬浮物质量浓度的时空分布特征,探讨悬浮物质量浓度变化的主要影响因素。

1 材料与方法

1.1 研究区概况

岱海 (40°29′07″—40°37′06″N, 112°33′31″—113°46′40″E)位于内蒙古自治区乌兰察布市凉城县境

内,是内蒙古第三大内陆湖,属于典型的内陆咸水湖,平均水深约为 7 m,呈椭圆形,其水源由周围 20 多条河流和 中层地下水汇聚而成^[22-25]。流域气候属中温带半干旱大陆性季风气候,春季干旱多风,夏季短促温热且雨水集中,秋季早寒易冻,冬季漫长寒冷。近年来,在自然和人为因素的驱动下,岱海主要面临着水位持续下降,咸化程度加剧,水污染日趋严重,湿地生态功能退化等问题^[22]。2020 年,内蒙古政府开启了“引黄济岱”等建设工程,以期增加岱海入湖水资源量,改善水质,遏制生态环境退化趋势,保障岱海生态系统健康。

1.2 实测数据

2020 年 7 月—2023 年 8 月,共开展了 9 次野外实验,获得实测数据 221 组,采样点分布见图 1。根据《内陆湖水取样手册》(EANET, 2010)中规定的方法采集水样,从水面以下 0.3~0.5 m 处采集样品。悬浮物质量浓度参考国家标准 GB 11901—89 采用重量法测定,即将水样通过孔径为 0.45 μm 的滤膜,计算截留在滤膜上并于 103~105 °C 烘干至恒质量的固体物质^[26],计算式为:

$$C = \frac{(A-B) \times 10^6}{V}, \quad (1)$$

式中: C 表示水中悬浮物质量浓度 (mg/L); A 表示悬浮物+滤膜+称量瓶质量 (mg); B 表示滤膜+称量瓶质量 (g); V 表示试样体积 (L)。




图 1 岱海研究区概况及采样点分布

Fig.1 Overview of Lake Daihai research area and the distribution map of sampling points

表 1 为岱海实测悬浮物质量浓度统计分析。由表 1 可知,悬浮物质量浓度均值介于 7.60~14.50 mg/L,最大值出现在 2021 年 7 月,为 44.00 mg/L,最小值出现在 2020 年 10 月、2021 年 7 月和 2023 年 8 月,

均为 2.00 mg/L; 7 月悬浮物质量浓度均值整体偏高,最高为 14.54 mg/L; 2021 年 6、7 月各采样点悬浮物质量浓度相差较大,较为离散。

表 1 岱海悬浮物质量浓度统计分析

Tab.1 Statistical analysis of suspended particulate matter in Lake Daihai							
日期	采样数 n	最大值/(mg·L ⁻¹)	最小值/(mg·L ⁻¹)	平均值/(mg·L ⁻¹)	标准差/(mg·L ⁻¹)	中位数/(mg·L ⁻¹)	变异系数
20200721	27	33.50	3.50	12.59	7.30	13.00	0.58
20200824	24	28.00	3.50	12.06	7.49	9.00	0.62
20200917	27	24.00	3.00	9.87	5.52	8.50	0.56
20201012	26	26.50	2.00	9.11	6.58	7.75	0.72
20100630	25	38.75	2.25	10.63	10.69	5.75	0.99
20210731	24	44.00	2.00	14.54	11.62	10.50	0.80
20210926	22	21.00	4.50	11.78	5.33	10.75	0.45
20211017	25	26.00	3.50	13.34	6.75	12.00	0.51
20230821	20	22.50	2.00	7.66	6.31	3.50	0.87

实测光谱数据利用美国 Analytical Spectral Devices 公司的 ASD Field Spec 4 进行测量,光谱波段介于 350~2 500 nm,光谱分辨率为 3 nm,本文采用的光谱波段介于 400~900 nm。剔除异常光谱数据,共 207 组数据用于后续模型建立,利用式(2)将实测遥感反射率转化为 Sentinel-2 卫星的等效遥感反射率^[27-29]。

$$R_{rs}(band_i)=\frac{\int_{\lambda_1}^{\lambda_2} R_{rs}(\lambda)SRF(\lambda)d(\lambda)}{\int_{\lambda_1}^{\lambda_2} SRF(\lambda)d(\lambda)}, \tag{2}$$

式中： $R_{rs}(band_i)$ 为卫星 i 波段等效反射率； λ_1 、 λ_2 为该波段的波段范围； $R_{rs}(\lambda)$ 为实测高光谱遥感反射率； $SRF(\lambda)$ 为 λ 波长处的光谱响应率。

1.3 遥感数据及预处理

Sentinel-2 是高分辨率多光谱成像卫星,携带

1 枚多光谱成像仪 (MultiSpectral Instrument, MSI),用于陆地监测,可提供植被、土壤和水覆盖、内陆水路及海岸区域等图像,分为 2A、2B 共 2 颗卫星^[12]。GEE 具有强大的数据处理能力也是非常便捷的数据获取方式,因此本文通过 GEE 平台,剔除部分受云雾、太阳光等影响强烈的影像,获取了岱海 2017—2023 年经过 Sen2cor 大气校正后共计 42 幅 Sentinel-2MSI 影像。选取 2020 年 9 月 17 日、10 月 12 日、2021 年 9 月 26 日、2023 年 8 月 21 日共计 89 组星地匹配数据,进行大气校正结果验证。由表 2 可知,所有波段整体上具有较高的相关性 ($R^2=0.88$, $RMSE=0.002$, $MAPE=32.57\%$), B4 波段的验证精度最高 ($R^2=0.79$, $RMSE=0.001\ 9$, $MAPE=15.89\%$), B2、B3、B5、B6 波段的 R^2 均在 0.6 以上,相关性较高。

表 2 Sentinel-2 各波段大气校正结果验证

Tab.2 Sentinel-2 verification of the atmospheric correction results in each band							
Sentinel-2 波段	R^2	$RMSE$	$MAPE/\%$	Sentinel-2 波段	R^2	$RMSE$	$MAPE/\%$
B1	0.57	0.002	24.99	B6	0.62	0.001 9	46.39
B2	0.66	0.002 4	19.52	B7	0.54	0.001 9	58.57
B3	0.78	0.002 22	11.79	B8	0.34	0.001 9	64.24
B4	0.79	0.001 9	15.89	B8a	0.46	0.002 1	62.31
B5	0.70	0.002 1	27.13	B1-B8a	0.88	0.002	32.57

1.4 气象数据

气象数据下载自国家气象信息中心 (<https://data.cma.cn/>),根据岱海流域的主要分布区—乌兰察布市凉城县,获得对应时间的平均气温 (°C)、平均风速 (m/s)、累积降水量 (mm) 等气象数据。

1.5 研究方法

1.5.1 波段相关性分析方法

为了选取适合于悬浮物质量浓度遥感反演的敏感波段及波段组合,利用皮尔逊 (Pearson) 相关系数法对实测悬浮物质量浓度与遥感反射率进行相关性分析,计算式为:

$$r=\frac{\sum_{i=1}^n(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum_{i=1}^n(X_i-\bar{X})^2}\sqrt{\sum_{i=1}^n(Y_i-\bar{Y})^2}}, \tag{3}$$

式中： r 代表 2 组变量相关系数； X_i 为实测悬浮物质量浓度 (mg/L)； Y_i 为实测遥感反射率； $\bar{X}$ 为实测悬

浮物质量浓度的平均值 (mg/L)； $\bar{Y}$ 为实测遥感反射率的平均值； n 为样本数量。

1.5.2 经验统计模型

在波段敏感性分析的基础上,选取最佳波段及波段组合,利用统计回归分析法,构建多种算法形式的单波段、多波段组合线性和非线性悬浮物质量浓度遥感反演模型。

1.5.3 机器学习模型

本文采用 5 种水质反演常用的机器学习算法:BP 神经网络模型 (BP 模型)、卷积神经网络模型 (CNN 模型)、随机森林模型 (RF 模型)、支持向量机模型 (SVM 模型) 和径向基函数神经网络模型 (RBF 模型) 构建悬浮物质量浓度遥感反演模型。

BP 模型是一种基于误差反向传播算法的人工神经网络,它的计算过程包括正向计算和反向计算。前向传播是将输入数据传递到第 1 层,每个输入变量对

应 1 个输入神经元, 然后通过输入层的加权和非线性变换传递到下一层直到传递到网络的最后 1 层输出结果。反向传播根据误差值和链式法则从输出层向输入层逐层计算每个神经元的梯度, 通过计算得到的梯度信息, 调整每个神经元的权重和偏置以降低误差值并提高网络的精度^[30-32], 本文迭代学习 1 000 次, 输入层节点数为 10, 输出层为 1, 学习率为 0.01。CNN 模型主要通过卷积层、池化层和全连接层来处理图像^[33-34]。卷积操作是通过滤波器或者卷积核与图像不同位置进行卷积操作来实现的, 池化操作在卷积层之后, 通常使用池化层来减小特征图的尺寸同时保留最重要的特征, 本文训练次数为 1 000 次, 初始学习率为 0.001, 学习率下降因子为 0.1。RF 模型是集成多个决策树的结果, 是在构建 Bagging 集成的基础上, 进一步在决策树的训练过程中引入随机特征选择, 这种方法有助于减小方差, 提高模型的泛化性能^[35], 本文决策树数目为 100, 最小叶子数为 5。SVM 模型利用决策函数 $f(x)=\text{sign}(w \cdot x+b)$ 将输入特征向量映射到超平面进行分类, 它的目标是最大化间隔, 可以通过对于所有训练样本在约束条件下 $y_i(w \cdot x_i+b) \geq 1$ 找到最优权重向量 w 和偏置 b 以得到最大化间隔 $\frac{2}{\|w\|}$, 本文惩罚因子 c 为 0.4, 核函数参数 g 为 0.8。RBF 模型学习过程与 BP 模型类似, 不同的是 RBF 模型的作用函数是高斯基函数, 其值在输入空间有限范围内为非 0 值, 因而它是局部逼近的神经网络, 本文径向基函数扩展速度为 100。具体算法流程可见参考文献[30-35]。

1.5.4 精度评价

模型精度评价指标选用**决定系数** (Correlation of Determination, R^2)、**均方根误差** (Root Mean Square Error, RMSE) 和**平均绝对百分比误差** (Mean Absolute

Percentage Error, MAPE), 计算式分别为:

$$R^2 = \frac{[\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})]^2}{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}, \quad (4)$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}, \quad (5)$$

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right|, \quad (6)$$

式中: y_i 表示第 i 个悬浮物质量浓度实测值 (mg/L); $\hat{y}_i$ 表示第 i 个悬浮物质量浓度估算值 (mg/L); $\bar{y}$ 表示悬浮物质量浓度平均值 (mg/L); x_i 表示自变量实测值; $\bar{x}$ 表示自变量平均值; n 表示样本数量。

2 结果与分析

2.1 相关性分析

利用 207 组实测遥感反射率与悬浮物质量浓度数据进行 Pearson 相关性分析, 从而选取相关性好的特征波段及波段组合用于反演模型构建。图 2 为悬浮物质量浓度与 52 种波段及波段组合的相关性热图。悬浮物质量浓度与单波段的皮尔逊相关系数 (r) 均大于 0.5, B4、B5 波段与悬浮物质量浓度相关系数最高, 对应 r 分别为 0.78、0.79; B6、B7 波段次之, r 均大于 0.65。以 B4、B5 波段为基础构建的 35 种波段组合与悬浮物质量浓度的相关性分析表明, 24 个波段组合与悬浮物质量浓度的 r 大于 0.7, 其中 B4+B5、B5·(B4+B5)、(B5·B4)/(B5+B4) 波段组合与悬浮物质量浓度的相关性最高, r 分别为 0.79、0.79、0.79。因此, 本文选取 B4、B5、B4+B5 作为特征变量建立经验统计模型, 选取相关性较高的 9 个变量 B4、B5、B4+B5、B4·B5、B5·(B4+B5)、B4·(B4+B5)、(B5·B4)/(B5+B4)、B4+(B4/B3) 和 B5+(B4/B3) 作为机器学习模型的输入变量。




图 2 实测悬浮物质量浓度与不同波段及波段组合的相关性热图

Fig.2 Heat map of measured SPM mass concentration and different bands and band combinations

2.2 反演模型构建

2.2.1 传统经验模型构建

将 207 组匹配样本数据的 70% ($N=145$) 用于模型建立，剩余 30% ($N=62$) 用于模型精度检验。以上文选取的相关性较高的 $B4$ 、 $B5$ 、 $B4+B5$ 作为模型特征变量，采用最小二乘法确定未知模型参数，建立

了包括单波段、多波段组合线性和非线性悬浮物质量浓度反演模型，详见表 3。由表 3 可知，多波段模型反演悬浮物质量浓度的精度优于单波段模型，非线性模型精度优于线性模型，其中以红绿波段比和近红外波段作为特征变量的模型 13 精度最高， $R^2=0.69$ ， $RMSE=4.46$ mg/L， $MAPE=34.37\%$ 。

表 3 悬浮物质量浓度传统经验反演模型

Tab.3 Traditional empirical inverse modelling of SPM mass concentration					
波段	模型序号	模型表达式	R^2	$RMSE/(mg \cdot L^{-1})$	$MAPE/\%$
$x=B5$	1	$y=1\ 103.089x+0.303$	0.64	5.01	40.47
	2	$y=2\ 727.083x^2+1\ 023.781x+0.729$	0.64	4.96	40.35
	3	$y=-665\ 351\ 064x^3+3\ 645\ 847x^2+547.231x+2.508$	0.64	4.90	39.73
	4	$y=806.3x^{0.954}$	0.45	5.05	34.47
$x=B4+B5$	5	$y=541.002x-0.601$	0.65	4.87	39.31
	6	$y=1\ 347.496x^2+455.752x+0.428$	0.65	4.76	39.15
	7	$y=-99\ 520.133x^3+12\ 547.411x^2+103.502x+3.405$	0.65	4.67	38.41
	8	$y=481.409x^{1.019}$	0.44	4.87	33.59
$x=B5 \cdot (B4+B5)$	9	$y=364.765x-0.362$	0.65	4.90	39.58
	10	$y=542.874x^2+314.719x+0.51$	0.65	4.81	39.40
	11	$y=-28\ 311.268x^3+5\ 165.457x^2+103.714x+3.087$	0.65	4.72	38.65
$x=(B5 \cdot B4)/(B5+B4)$	12	$y=-6\ 418\ 546.3x^3+198\ 442.1x^2+470.19x+3.359$	0.65	4.68	38.44
$x_1=B3, x_2=B4, x_3=B5$	13	$y=16.571(x_3+(x_2/x_1))+1\ 254.172 \times ((x_2 \times x_3)/(x_2+x_3))-5.656$	0.69	4.46	34.37

注 y 为悬浮物质量浓度。

2.2.2 机器学习模型

将 207 组匹配样本数据的 70% ($N=145$) 作为训练集，剩余 30% ($N=62$) 作为测试集。以相关性最高的 9 个光谱特征作为机器学习的输入变量训练模型，图 3 为 5 种不同机器学习模型悬浮物质量浓度反演值与实测值对比散点图。由图 3 可知，与传统经验

模型相比，机器学习模型均取得了相近甚至更高的反演精度，其中 BP、CNN 模型精度优势更为显著，在测试集中 BP 模型 R^2 为 0.76， $RMSE$ 为 4.66 mg/L， $MAPE$ 为 26.57%，CNN 模型 R^2 为 0.75， $RMSE$ 为 4.15 mg/L， $MAPE$ 为 33.59%。




图 3 不同模型悬浮物质量浓度反演值与实测值对比散点图

Fig.3 Scatter plot of inversion and measured values of SPM mass concentration for different models

2.3 模型三折交叉验证

利用三折交叉验证法将原始数据随机划分为 3 个相等大小的互斥子集,每次选择 2 份作为训练集,剩下 1 份作为测试集,采用旋转划分方式使得每个子集都有机会成为验证集,取 3 次平均结果对 BP、CNN

模型的性能进行评估。图 4 为 BP 模型、CNN 模型三折交叉验证结果,表 4 为三折交叉验证精度。由表 4 可知,2 种模型三折交叉验证精度均表现较好,但从 3 项精度指标均值和离散度来看,BP 模型在训练集和测试集中精度均更高,且模型更稳定。




图 4 BP、CNN 三折交叉验证结果

Fig.4 BP and CNN 3-fold cross-validation results

表 4 BP-SPM 和 CNN-SPM 三折交叉验证精度

Tab.4 BP-SPM and CNN-SPM 3-fold cross-validation accuracy

模型		R^2		$RMSE/(mg \cdot L^{-1})$		$MAPE/\%$	
		训练集	测试集	训练集	测试集	训练集	测试集
BP	1	0.80	0.72	4.26	3.63	28.62	27.05
	2	0.78	0.79	4.26	3.81	28.29	30.77
	3	0.75	0.83	3.77	4.21	29.99	29.89
	Mean	0.78	0.78	4.09	3.89	28.97	29.24
CNN	1	0.76	0.76	3.89	3.93	30.94	29.84
	2	0.83	0.78	3.37	3.72	29.30	28.11
	3	0.76	0.71	4.00	4.42	31.12	35.16
	Mean	0.78	0.75	3.75	4.02	30.45	31.04

2.4 基于 Sentinel-2 影像的悬浮物质量浓度反演验证

现场试验于 2020 年 9 月 17 日、10 月 12 日、2021 年 9 月 26 日和 2023 年 8 月 21 日进行了 4 期 Sentinel-2 影像的同步观测,共获取 89 组星地同步数据用于模型验证。图 5 为基于 CNN 模型和 BP 模型

的 Sentinel-2 影像悬浮物质量浓度反演值与实测值散点图。由图 5 可知,2 种机器学习模型悬浮物质量浓度反演值与实测值均具有较高的相关性,BP 模型较 CNN 模型反演效果更优, R^2 为 0.80, $RMSE$ 为 2.60 mg/L, $MAPE$ 为 29.81%。





图 5 基于 CNN、BP 模型的 Sentinel-2 影像悬浮物质量浓度反演值与实测值

Fig.5 Scatter plot of SPM mass concentration inversion and measured values of Sentinel-2 images based on CNN and BP models

2.5 BP 模型特征变量重要性分析

本文通过特征置零试验对 BP 模型特征变量进行了重要性分析。特征置零试验是采用控制变量法，对单个输入特征赋值为 0，其余输入特征保持不变，对比其与原输入下模型精度的变化。图 6 为 BP 模型输入特征置零试验测试精度结果。由图 6 可知，去除单

个变量后 BP 模型 R^2 和 $MAPE$ 精度均有不同程度降低，而 $RMSE$ 也有 6 个特征变量对应模型精度下降，说明所选特征变量均对模型有正贡献作用。特征变量 $B4 \cdot B5$ 对模型的重要性最为显著，其次是 $B4$ 、 $B4+B5$ 和 $B5 \cdot (B4+B5)$ 对模型精度影响也较大。



注 变量：1: $B4$, 2: $B5$, 3: $B4+B5$, 4: $B4 \cdot B5$, 5: $B5 \cdot (B4+B5)$, 6: $(B5-B4)/(B5+B4)$, 7: $B4 \cdot (B4+B5)$, 8: $B4+(B4/B3)$, 9: $B5+(B4/B3)$ 。


图 6 BP 模型输入特征置零试验测试精度结果（红色直线为原模型精度）

Fig.6 BP model input feature zero test accuracy results (the red line is the original model accuracy)

2.6 岱海悬浮物质量浓度时空变化分析

岱海部分浅水区生长有水生植物，以沉水植物为主，且主要分布于西南部^[36-37]。这导致部分水体光谱混入大量水生植物信息，造成混合像元问题，悬浮物

质量浓度反演会产生不确定性，因而本文首先将水生植物生长区提取并掩膜。图 7 为 2023 年 8 月 20 日 Planet 影像（空间分辨率为 3 m）及现场照片，可以看出岱海西南部生长有大范围沉水植被及漂浮藻类。



(a) 2023 年 8 月 20 日 Planet 影像 (b) 2023 年 8 月 20 日现场照片

图 7 2023 年 8 月 20 日 Planet 影像及现场照片

Fig.7 August 20, 2023 Planet images and live photos


利用沉水植物在近红外的反射峰和红光波段的吸收谷，可以通过 $NDVI$ 指数对水生植被进行提取^[38]。以 2023 年 8 月 18 日 Sentinel-2 影像为例，由图 8 可知，岱海西南部出现大范围的高悬浮物质量浓度分布

区,对比遥感影像和 *NDVI* 图后确定该区域为水生植被生长区,为提高悬浮物质量浓度反演的精度,要将


该区域掩膜。




(a) 2023 年 8 月 18 日 Sentinel-2 影像



(b) 悬浮物质量浓度反演结果



(c) 基于 *NDVI* 提取植被



(d) 悬浮物质量浓度反演结果

图 8 2023 年 8 月 18 日 Sentinel-2 影像的悬浮物质量浓度反演、水生植物提取和掩膜

Fig.8 Retrieval of SPM mass concentration, extraction of aquatic plants and masking of Sentinel-2 images on August 18, 2023

受冰封期影响,本文利用 BP 模型对 2017—2023 年的 5—10 月共 42 期 Sentinel-2 影像进行悬浮物质量浓度反演,图 9 为 2017—2023 年岱海 5—10 月平均悬浮物质量浓度空间分布,图 11 (a) 为岱海悬浮物质量浓度年际变化。从年际变化来看,岱海年平均

悬浮物质量浓度呈一定的年际差异,2017—2023 年 5—10 月平均悬浮物质量浓度介于 8.43~11.68 mg/L,2017、2019 年明显偏高,而 2022、2023 年较低。从空间分布来看,主要呈“近岸高、离岸低”的特点,高值区主要分布在岱海西南和东部近岸水域。




图 9 2017—2023 年 5—10 月平均悬浮物质量浓度空间分布

Fig.9 Spatial distribution of average SPM concentration from May to October, 2017—2023

图 10 为 2017—2023 年岱海月平均悬浮物质量浓度空间分布,图 11 (b) 为岱海悬浮物质量浓度月际变化。由图 11 可知,5—10 月岱海悬浮物质量浓度介于 7.77~10.84 mg/L,主要月际差异出现在 5 月,其悬浮物质量浓度显著高于其他月份且变化较大,6 月后开始下降并趋于稳定。空间分布上来看,5 月岱海湖悬浮物质量浓度均较高,湖中心可达 11.00 mg/L 以上;而其他月份差异主要体现在近岸,尤其是西南水域,离岸水域差异不明显,较为均一。

2.7 影响因素分析

气温、降水和风速等气象条件是湖泊水体悬浮物质量浓度变化的主要影响因素^[39],温度可以影响悬浮物输运和沉降速度,降水通过影响径流变化从而使悬浮物输入增加,风速则通过扰动作用影响湖泊悬浮物质量浓度^[40]。图 12 为悬浮物质量浓度与气温、降水量和风速的变化趋势及关系。由图 12 可知,悬浮物质量浓度与风速表现出显著的正线性关系 ($R^2=0.61$),

而与气温和降水量的关系不大。通常风会加速水面的气体和水体运动,较强的风可以引起水体底部泥沙再悬浮,这些泥沙颗粒甚至会到达水面并持续一段时间,从而增加了水体悬浮物质量浓度^[41-42]。此外,受风速影响的悬浮物质量浓度与浅水水深密切相关,水深越浅风引起的悬浮泥沙更容易到达水体表层,从而被卫星观测到。结合图 1 岱海等水深线可知,近岸水域悬浮物质量浓度变化与等水深线分布格局非常相似,西南和东南近岸水深较浅且变化缓慢,而悬浮物质量浓度则较高;而北部近岸水域水深变化较大,悬浮物质量浓度则由岸边向湖心迅速降低。

另外,强风可以将岱海周边的植物碎片、泥沙和有机物吹到水体中,也可能会增加水体中的悬浮物质量浓度^[43]。岱海冬春二季常受西伯利亚及蒙古高原冷空气侵袭,多风且大,这可能是导致 5 月悬浮物质量浓度较其他月份高的主要原因。





图 10 2017—2023 年月平均悬浮物质量浓度空间分布

Fig.10 Distribution map of monthly average SPM mass concentration from 2017 to 2023




(a) 年际悬浮物质量浓度

(b) 5—10 月悬浮物质量浓度

图 11 岱海悬浮物质量浓度变化


Fig.11 Annual and monthly variation box plot of Daihai Lake SPM mass concentration



(a) 悬浮物质量浓度-气温

(b) 悬浮物质量浓度-降水量

(c) 悬浮物质量浓度-风速



(d) 2017—2023 年悬浮物质量浓度与气温、降水量和风速的变化趋势

图 12 悬浮物质量浓度影响因素分析

Fig.12 Analysis of factors affecting suspended matter mass concentration

3 结 论

1) 与传统经验模型相比,机器学习模型均取得了较高的反演精度,其中 BP、CNN 模型精度优势更为显著,在测试集中 BP 模型 R^2 为 0.76, $RMSE$ 为 4.66 mg/L, $MAPE$ 为 26.57%, CNN 模型 R^2 为 0.75, $RMSE$ 为 4.15 mg/L, $MAPE$ 为 33.59%。

2) 三折交叉验证表明, BP 模型较 CNN 模型在训练集和测试集中精度均相对更高,且模型更稳定;地面同步实测数据验证也表明, BP 模型反演效果更优, R^2 为 0.80, $RMSE$ 为 2.60 mg/L, $MAPE$ 为 29.81%。

3) 时间上,岱海年平均悬浮物质量浓度介于 8.43~11.68 mg/L,整体呈小幅波动下降趋势,2017、2019 年偏高,2022、2023 年较低;5—10 月岱海月平均悬浮物质量浓度介于 7.77~10.84 mg/L,主要月际差异出现在 5 月,其值显著高于其他月份且变化较大,6 月后开始下降并趋于稳定。空间上,岱海悬浮物质量浓度主要呈“近岸高、离岸低”的特点,高值区主要分布在岱海西南和东部近岸水域。

4) 岱海悬浮物质量浓度与风速表现出显著的正线性关系, R^2 为 0.61,而与气温和降水量无明显关系;岱海春季受西伯利亚及蒙古高原冷空气侵袭,多风且大,可能是导致 5 月悬浮物质量浓度较其他月份高的主要原因。

(作者声明本文无实际或潜在利益冲突)

参考文献:

- [1] LI J, HAO Y L, ZHANG Z Z, et al. Analyzing the distribution and variation of suspended particulate matter (SPM) in the Yellow River Estuary (YRE) using landsat 8 OLI[J]. *Regional Studies in Marine Science*, 2021, 48: 102-104.
- [2] BINDING C E, BOWERS D G, MITCHELSON-JACOB E G. Estimating suspended sediment concentrations from ocean colour measurements in moderately turbid waters; the impact of variable particle scattering properties[J]. *Remote Sensing of Environment*, 2005, 94(3): 373-383.
- [3] 冷潇涵. 岱海叶绿素 a 遥感反演模型及藻华监测研究[D]. 呼和浩特: 内蒙古大学, 2023.
LENG Xiaohan. Study on chlorophyll a remote sensing inversion model and algal bloom monitoring in Daihai Lake[D]. Hohhot: Inner Mongolia University, 2023.
- [4] 赵爽, 柳锦宝, 耿蔚, 等. 基于 PIE-Engine Studio 的西藏典型湖泊总悬浮物反演[J]. *人民长江*, 2024, 55(9): 85-92, 99.
ZHAO Shuang, LIU Jinbao, GENG Wei, et al. Inversion of total suspended matter in typical lakes in Tibet based on PIE-Engine Studio[J]. *Yangtze River*, 2024, 55(9): 85-92, 99.
- [5] LI J, PEI Y Q, ZHAO S H, et al. A review of remote sensing for environmental monitoring in China[J]. *Remote Sensing*, 2020, 12(7): 1 130.
- [6] 侯毅凯, 张安兵, 吕如兰, 等. 基于多源数据的河道水质遥感反演研究[J]. *灌溉排水学报*, 2023, 42(11): 121-130.
HOU Yikai, ZHANG Anbing, LYU Rulan, et al. Assessing river water quality using different remote sensing technologies[J]. *Journal of Irrigation and Drainage*, 2023, 42(11): 121-130.
- [7] WILLIAMSON A N, GRABAU W E. Sediment concentration mapping in tidal estuaries[J]. *NASA Special Publication*, 1974, 351: 1 347.
- [8] DOXARAN D, FROIDEFOND J M, LAVENDER S, et al. Spectral signature of highly turbid waters Application with SPOT data to quantify suspended particulate matter concentrations[J]. *Remote Sensing of Environment*, 2002, 81(1): 149-161.
- [9] MOHAMMADPOUR G, PIRASTEH S. Interference of CDOM in remote sensing of suspended particulate matter (SPM) based on MODIS in the Persian Gulf and Oman Sea[J]. *Marine Pollution Bulletin*, 2021, 173: 113 104.
- [10] GERNEZ P, BARILLÉ L, LEROUXEL A, et al. Remote sensing of suspended particulate matter in turbid oyster-farming ecosystems[J]. *Journal of Geophysical Research: Oceans*, 2014, 119(10): 7 277-7 294.
- [11] 阿如娜, 青松, 包玉海. 基于 Landsat-8 OLI 数据的乌梁素海总溶解性固体质量浓度遥感反演[J]. *灌溉排水学报*, 2018, 37(4): 99-105.
A Runa, QING Song, BAO Yuhai. Estimating the concentration of dissolved solid in the Wuliangsuhai Lake based on the landsat-8 OLI images[J]. *Journal of Irrigation and Drainage*, 2018, 37(4): 99-105.
- [12] PAHLEVAN N, SARKAR S, FRANZ B A, et al. Sentinel-2 MultiSpectral Instrument (MSI) data processing for aquatic science applications: Demonstrations and validations[J]. *Remote Sensing of Environment*, 2017, 201: 47-56.
- [13] 张志军, 王茹, 姚月, 等. 基于资源一号 02D 高光谱卫星影像的青海湖悬浮物浓度反演研究[J]. *遥感技术与应用*, 2023, 38(5): 1 159-1 166.
ZHANG Zhijun, WANG Ru, YAO Yue, et al. Retrieval study of total suspended matter concentration in Qinghai Lake based on ZY1 02D hyperspectral satellite images[J]. *Remote Sensing Technology and Application*, 2023, 38(5): 1 159-1 166.
- [14] LI P, KE Y H, BAI J H, et al. Spatiotemporal dynamics of suspended particulate matter in the Yellow River Estuary, China during the past two decades based on time-series Landsat and Sentinel-2 data[J]. *Marine Pollution Bulletin*, 2019, 149: 110 518.
- [15] YUE Y L, QING S, DIAO R X, et al. Remote sensing of suspended particulate matter in optically complex estuarine and inland waters based on optical classification[J]. *Journal of Coastal Research*, 2020, 102(sp1): 303-317.
- [16] BERNARDO N, DO CARMO A, PARK E, et al. Retrieval of suspended particulate matter in inland waters with widely differing optical properties using a semi-analytical scheme[J]. *Remote Sensing*, 2019, 11(19): 2 283.

- [17] RUDDICK K, VANHELLEMONT Q, YAN J, et al. Variability of suspended particulate matter in the Bohai Sea from the geostationary Ocean Color Imager (GOCI)[J]. *Ocean Science Journal*, 2012, 47(3): 331-345.
- [18] 周艺, 周伟奇, 王世新, 等. 遥感技术在内陆水体水质监测中的应用[J]. *水科学进展*, 2004, 15(3): 312-317.
- ZHOU Yi, ZHOU Weiqi, WANG Shixin, et al. Applications of remote sensing techniques to inland water quality monitoring[J]. *Advances in Water Science*, 2004, 15(3): 312-317.
- [19] 孙德勇, 李云梅, 王桥, 等. 基于实测高光谱的太湖水体悬浮物浓度遥感估算研究[J]. *红外与毫米波学报*, 2009, 28(2): 124-128.
- SUN Deyong, LI Yunmei, WANG Qiao, et al. Study on remote sensing estimation of suspended matter concentrations based on *in situ* hyperspectral data in Lake Tai waters[J]. *Journal of Infrared and Millimeter Waves*, 2009, 28(2): 124-128.
- [20] DELUCA N M, ZAITCHIK B F, CURRIERO F C. Can multispectral information improve remotely sensed estimates of total suspended solids? A statistical study in Chesapeake Bay[J]. *Remote Sensing*, 2018, 10(9): 1 393.
- [21] WEN Z D, WANG Q, LIU G, et al. Remote sensing of total suspended matter concentration in lakes across China using Landsat images and Google Earth Engine[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2022, 187: 61-78.
- [22] 周云凯, 姜加虎, 黄群, 等. 内蒙古岱海水体咸化过程分析[J]. *干旱区资源与环境*, 2008, 22(12): 51-55.
- ZHOU Yunkai, JIANG Jiahu, HUANG Qun, et al. Analysis on water salinization process of Daihai Lake in Inner Mongolia[J]. *Journal of Arid Land Resources and Environment*, 2008, 22(12): 51-55.
- [23] 刁瑞翔, 青松, 越亚娜, 等. 基于 BP 神经网络算法的内蒙古岱海水体透明度遥感估算[J]. *灌溉排水学报*, 2022, 41(8): 114-121.
- DIAO Ruixiang, QING Song, YUE Yalei, et al. Using back propagation neural network algorithm and remote sensing to estimate lake water transparency[J]. *Journal of Irrigation and Drainage*, 2022, 41(8): 114-121.
- [24] 赵丽, 陈俊伊, 姜霞, 等. 岱海水体氮、磷时空分布特征及其差异性分析[J]. *环境科学*, 2020, 41(4): 1 676-1 683.
- ZHAO Li, CHEN Junyi, JIANG Xia, et al. Temporal and spatial distribution characteristics and difference analysis of nitrogen and phosphorus in Daihai Lake[J]. *Environmental Science*, 2020, 41(4): 1 676-1 683.
- [25] 王芳, 张勇智. 基于投影寻踪模型的岱海湖泊富营养化评价[J]. *内蒙古水利*, 2021(12): 10-12.
- [26] 周虹丽, 朱建华, 韩冰, 等. 重量法测量悬浮物浓度关键技术研究[J]. *海洋技术*, 2004, 23(3): 15-20.
- ZHOU Hongli, ZHU Jianhua, HAN Bing, et al. Research on the key technique of the analysis of suspended matter by weighting method[J]. *Ocean Technology*, 2004, 23(3): 15-20.
- [27] 唐军武, 田国良, 汪小勇, 等. 水体光谱测量与分析 I: 水面上测
- 量法[J]. *遥感学报*, 2004, 8(1): 37-44.
- TANG Junwu, TIAN Guoliang, WANG Xiaoyong, et al. The methods of water spectra measurement and analysis I: Above-water method[J]. *Journal of Remote Sensing*, 2004, 8(1): 37-44.
- [28] MOBLEY C D. Estimation of the remote-sensing reflectance from above-surface measurements[J]. *Applied Optics*, 1999, 38(36): 7 442-7 455.
- [29] KLOIBER S M, BREZONIK P L, OLMANSON L G, et al. A procedure for regional lake water clarity assessment using Landsat multispectral data[J]. *Remote Sensing of Environment*, 2002, 82(1): 38-47.
- [30] SHARAF EL DIN E, ZHANG Y, SULIMAN A. Mapping concentrations of surface water quality parameters using a novel remote sensing and artificial intelligence framework[J]. *International Journal of Remote Sensing*, 2017, 38(4): 1 023-1 042.
- [31] 时蕾. 内陆富营养化湖泊藻类碳遥感估算研究: 以太湖为例[D]. 南京: 南京师范大学, 2018.
- SHI Lei. Remote sensing estimation of algal carbon in inland eutrophic lakes: A case study of Taihu Lake[D]. Nanjing: Nanjing Normal University, 2018.
- [32] 刘文耀. 基于 BP 神经网络和哨兵二号遥感影像的乌梁素海叶绿素 a 浓度反演[D]. 呼和浩特: 内蒙古农业大学, 2022.
- LIU Wenyao. Inversion of chlorophyll a concentration in Wuliangsuhai Lake based on BP neural network and Sentinel-2 remote sensing image[D]. Hohhot: Inner Mongolia Agricultural University, 2022.
- [33] 吕俊霄, 陈金浩, 张怡卓, 等. 应用二维相关近红外光谱特征建立蒙古栎弹性模量卷积神经网络预测模型[J]. *东北林业大学学报*, 2022, 50(9): 109-113, 134.
- LYU Junxiao, CHEN Jinhao, ZHANG Yizhuo, et al. Establishment of convolutional neural network prediction model for elastic modulus of quercus mongolica using two-dimensional correlation near infrared spectral features[J]. *Journal of Northeast Forestry University*, 2022, 50(9): 109-113, 134.
- [34] SONG H H, LIU Q S, WANG G J, et al. Spatiotemporal satellite image fusion using deep convolutional neural networks[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2018, 11(3): 821-829.
- [35] 张悦, 陈冰, 李旭文, 等. 基于 Sentinel-2 与随机森林算法的太湖水生植被分布监测[J]. *环境监控与预警*, 2023, 15(6): 42-49.
- ZHANG Yue, CHEN Bing, LI Xuwen, et al. Monitoring aquatic vegetation distribution of Taihu lake from sentinel-2 and random forest algorithm[J]. *Environmental Monitoring and Forewarning*, 2023, 15(6): 42-49.
- [36] 刘凯, 孙丽, 张志成, 等. 基于遥感信息的植被变化对岱海湖面积的影响[J]. *北方农业学报*, 2022, 50(5): 112-118.
- LIU Kai, SUN Li, ZHANG Zhicheng, et al. Influence of vegetation change on the area of Daihai Lake based on remote sensing information[J]. *Journal of Northern Agriculture*, 2022, 50(5): 112-118.
- [37] 刘旭隆. 岱海湖泊面积与水位动态变化及其驱动力分析[D]. 呼和

- 浩特: 内蒙古大学, 2019.
- LIU Xulong. Dynamic change of area and water level of Daihai Lake and its driving force analysis[D]. Hohhot: Inner Mongolia University, 2019.
- [38] LI S S, YANG S N, LIU X F, et al. *NDVI*-based analysis on the influence of climate change and human activities on vegetation restoration in the Shaanxi-Gansu-Ningxia Region, Central China[J]. Remote Sensing, 2015, 7(9): 11 163-11 182.
- [39] TSAPANOU A, OIKONOMOU E, DRAKOPOULOS P, et al. Coupling remote sensing data with *in-situ* optical measurements to estimate suspended particulate matter under the Evros river influence (North-East Aegean sea, Greece)[J]. International Journal of Remote Sensing, 2020, 41(6): 2 062-2 080.
- [40] 陶慧. 中国近 30 年湖泊秋季悬浮物浓度时空演变及其驱动因素[D]. 哈尔滨: 中国科学院大学(中国科学院东北地理与农业生态研究所), 2023.
- TAO Hui. Spatiotemporal dynamics and driving factors of lake total suspended matter of recent 30 years in China[D]. Harbin: Northeast Institute of Geography and Agroecology, Chinese Academy of Sciences, 2023.
- [41] 周童. 浅析巢湖湖区水深与浊度、悬浮物、营养盐影响关系[J]. 科学技术创新, 2022(23): 71-74.
- ZHOU Tong. Analysis on the relationship between water depth and turbidity, suspended solids and nutrients in Chaohu Lake area[J]. Scientific and Technological Innovation, 2022(23): 71-74.
- [42] SALDÍAS G S, SOBARZO M, LARGIER J, et al. Seasonal variability of turbid river plumes off central Chile based on high-resolution MODIS imagery[J]. Remote Sensing of Environment, 2012, 123: 220-233.
- [43] HERBECK L S, UNGER D, KRUMME U, et al. Typhoon-induced precipitation impact on nutrient and suspended matter dynamics of a tropical estuary affected by human activities in Hainan, China[J]. Estuarine, Coastal and Shelf Science, 2011, 93(4): 375-388.

Analyzing spatiotemporal variation in suspended particulate matter in lakes using remote sensing

WEI Junyan, ZHAO Yiming, HAO Yanling^{*}, JIA Xiaoxue, MA Xinyan

(College of Ecology and Environment, Inner Mongolia University, Hohhot 010021, China)

Abstract: 【Objective】Suspended particulate matter (SPM) in lakes not only affects water quality but also influences ecological functions. This paper investigates the feasibility of using remote sensing to analyze the spatiotemporal variation in SPM in lakes, with an application to Daihai Lake. 【Method】Field measurements were conducted to collect spectral and SPM concentration data in Daihai Lake. The accuracy of five machine learning inversion models - backpropagation (BP) neural network, convolutional neural network (CNN), random forest (RF), support vector machine (SVM), and radial basis function (RBF) neural network-was compared with that of traditional empirical models using Sentinel-2 MSI satellite data. The most accurate model was selected to estimate SPM concentrations across the lake. 【Result】① Machine learning models outperformed traditional empirical models. Among them, the BP neural network achieved the highest accuracy, with a three-fold cross-validation test using synchronous ground data yielding $R^2=0.76$, $RMSE=4.66$ mg/L, and $MAPE=26.57\%$. ② All nine input variables in the BP model contributed positively to model performance. The most influential variable was the $B4 \cdot B5$, followed by $B4$, $B4+B5$, and $B5 \cdot (B4+B5)$. ③ From 2017 to 2023, annual average SPM concentrations ranged from 8.43 to 11.68 mg/L, showing a slight downward trend. Monthly averages SPM concentration from May to October ranged from 7.77 to 10.84 mg/L, with May exhibiting the highest concentrations. After June, SPM levels generally declined and stabilized. Spatially, the highest concentrations occurred near the shore, particularly in the southwestern and eastern parts of the lake. ④ SPM concentrations were significantly and positively correlated with wind speed ($r = 0.61, p < 0.001$), while correlations with air temperature and precipitation were not significant. 【Conclusion】Remote sensing combined with machine learning provides an effective and accurate method for monitoring SPM in lakes. This approach can help to improve management and ecological protection of lake environments. Among all models evaluated, the BP neural network is most accurate and stable, followed by the CNN model.

Key words: Lake Daihai; suspended particulate matter; Sentinel-2 MSI; machine learning; remote sensing inversion

责任编辑: 白芳芳