

高分一号多光谱影像的内陆水体大气校正方法

赵文睿, 李大成

(太原理工大学 地球科学与测绘工程学院, 太原 030024)

摘要:米级高分辨率卫星影像的大气校正技术仍处于发展阶段,针对目前缺乏统一的构建高质量训练样本集方法,模型构建中对参数优选不够重视等问题,提出了一种基于机器学习的大气校正方法。该方法基于XGBoost算法,通过先进的水体提取技术,辅助数据匹配,构建了高质量水体训练样本集;通过特征选择以及超参数优化,减弱了噪声和冗余信息的影响,提升了模型性能。在不同水体的反演中取得了较低的绝对百分比误差(MAPE),其中蓝色波段为22.11%,绿色波段为19.23%,红色波段为24.46%,近红外波段为32.45%。结果证实了该方法在不同水域的适应性,并展现了其在多种对地观测卫星数据大气校正中的潜在应用价值。

关键词:GF1-PMS; XGBoost; 内陆水体; 大气校正; 水体反射率

DOI:10.20091/j.cnki.1000-3177.2025.05.017

中图分类号:TP751 **文献标志码:**A **文章编号:**1000-3177(2025)05-0138-10

Atmospheric Correction Method for Inland Water Body Using Gaofen-1 Multispectral Images

ZHAO Wenrui, LI Dacheng

(College of Geological and Surveying Engineering, Taiyuan University of Technology, Taiyuan 030024, China)

Abstract: The atmospheric correction technology for meter-scale high-resolution satellite imagery is still in its development stage. In response to the current lack of a unified method for constructing high-quality training sample sets and insufficient attention to parameter optimization in model construction, a machine learning-based atmospheric correction method is proposed. This method, based on the XGBoost algorithm, constructs a high-quality water body training sample set through advanced water body extraction technology and auxiliary data matching. Through feature selection and hyperparameter optimization, the impact of noise and redundant information is reduced, enhancing model performance. The method has achieved a low mean absolute percentage error (MAPE) in the inversion of different water bodies, with 22.11% in the blue band, 19.23% in the green band, 24.46% in the red band, and 32.45% in the near-infrared band. The results confirm the adaptability of this method across different water areas and demonstrate its potential application value in atmospheric correction of various Earth observation satellite data.

Keywords: GF1-PMS; XGBoost; inland water body; atmospheric correction; water reflectance

0 引言

在海洋学、水生物学研究以及水质监测领域,水体反射率是一个关键指标^[1-2],在反演叶绿素浓

度、悬浮物浓度以及有害藻类监测中具有广泛应用。卫星在接收地表水体反射信息时,受到大气吸收和散射的影响,包括瑞利散射、气溶胶散射等,因此需要进行大气校正^[3],以获取真实的内陆

收稿日期:2024-12-31 修订日期:2025-02-20

基金项目:国家重点研发计划(2022YFB3903000、2022YFB3903004)。

作者简介:赵文睿(2000—),男,硕士研究生,主要研究方向为遥感影像处理。

E-mail: zhaowr1226@163.com

通信作者:李大成(1983—),男,副教授,主要研究方向为遥感反演与数智融生。

E-mail: lidacheng@tyut.edu.cn

水体的信息。

Morel^[4]根据水体的光学特性,将水体分为了两类:一类水体和二类水体。由于传统的暗黑像元法难以满足二类水体的大气校正要求,目前对于二类水体的研究仍在发展中。

研究者们发展了多种针对二类水体的大气校正方法。Ruddick 等^[5]基于近红外波段和红色波段比值的空间均匀性提出了改进方法;Hu 等^[6]定义了非浑浊区域水体,分块使用非浑浊区域的水体估计气溶胶类型。辐射传输模型如 6S、Flaash、Modtran 等,构建了大气顶部(TOA)与地表之间的光学传输模型。De Keukelaere 等^[7]开发的 ICOR 方法通过各种辅助数据以及多端元反演气溶胶光学厚度,然后使用 Modtran 进行大气校正;Harmel 等^[8]开发的 GRS 算法借助短波红外波段进行邻接效应校正,结合 OSOAA 模型进行大气校正。这些方法能够在不同的大气条件下运行,在内陆水域中具有很高的应用价值,但预先设定的参数十分有限,在云杂光、太阳耀斑和水质变异性强等复杂情况下反演存在不稳定性,且存在负反射率问题。

深度学习和机器学习技术的发展,提供了一种用于构建大气顶部反射率(TOA)与水体反射率之间的映射关系的方法,可以解决内陆水体大气校正存在的问题^[9]。算法最初用于水质较简单的海域,其中神经网络能有效提高大气校正的效率^[10]。随着算力的增强和辐射传输(RT)模型的进步,这些算法已逐渐拓展到气溶胶和水质较复杂的区域,发展出了许多优秀的算法,如 OC-Smart^[11]和 CR2CC^[12]。通过优选样本和质量控制,可以有效避免负反射率的出现,而模型训练可以有效减弱斑点噪声、云杂光和太阳耀斑的影响^[13]。相比于传统方法,深度学习和机器学习方法更具有稳定性。然而,目前这类方

法还存在一些问题亟待解决:对于内陆复杂水域,卫星接收到的信号包括水体和大气成分影响,为了分离这两部分信息,通常会额外输入一些大气以及水质参数。辅助数据是构建高质量数据集的重要部分,目前方法直接选定用于辐射传输模拟和一些潜在影响大气条件因子的参数,缺乏可解释的选择过程。


随着对地物观测要求的日益提高,米级分辨率的观测平台成为研究的迫切需求。特别是在水体大气校正领域,已有的阴影投射方法^[14]和暗光谱拟合法(DSF)为米级高分卫星研究提供了新的技术路径。目前针对米级高分卫星的大气校正方法相对较少,且方法适应性研究也较为匮乏,尤其是在低信噪比卫星的应用上。

针对目前方法对特征选择和超参数优化重视不足、缺乏对米级高分卫星和非水色卫星的研究应用等问题,本文提出了一种新的水体大气校正方法,以多光谱分辨率 8 m、全色分辨率 2 m 的高分一号 PMS 卫星为例,通过构建高质量训练数据集、特征选择和超参数优化等步骤,结合机器学习构建模型,对卫星影像进行大气校正。通过实测数据验证本文方法在内陆水体大气校正中的潜力。

1 研究区与数据

1.1 研究区

本文的研究区为兴凯湖、太湖和月亮泡水库包括周边的附属水域。兴凯湖位于黑龙江省鸡西市东部,水域面积为 4 380 km²,太湖位于长江三角洲的南边,水域面积为 2 338.1 km²,月亮泡水库原称日月池,位于吉林省大安市月亮泡镇,嫩江洮儿河上,流域面积 2 480 km²。研究区概况如图 1 所示。



(a) 月亮泡水库

(b) 太湖

(c) 兴凯湖

图 1 研究区概况

1.2 数据源

数据选取是建立高质量数据集和模型构建的基础。为了选取的影像平均分布于不同季节,确保覆盖不同地理区域和季节变化,选取了 2021—2023 年间非结冰期的 GF1-PMS 卫星数据,共收集了 92 景影像,其中包括兴凯湖 16 景、太湖 16 景、月亮泡水库 10 景、研究区周边以及其他水域的 50 景影像。采用来自陆地观测卫星共性应用支撑平台的同步地面实测数据,共收集了 24 个采样点的数据,分别为太湖在 2023 年 11 月 14 日的 13 个采样点、兴凯湖在 2021 年 10 月 23 日的 9 个采样点、月亮泡水库在 2022 年 9 月 26 日的 2 个采样点。这些采样点的选择基于其在不同水体的代表性,确保了验证数据的广泛性和可靠性。

在水色遥感大气校正研究中,辅助参数的选择十分重要,鉴于目前水质产品不够成熟,部分大气产品稳定性不强,最终预选了 13 种辅助数据用于后续筛选,辅助参数数据情况见表 1。

表 1 辅助参数介绍

辅助参数类型	数据来源	英文简称	时间分辨率	空间分辨率
风速	ERA5	FG10	1 h	0.10°
地表温度	ERA5	T2M	1 h	0.10°
臭氧浓度	ERA5	TCO3	1 h	0.25°
水汽含量	ERA5	TCWV	1 h	0.25°
云覆盖	ERA5	TCC	1 h	0.25°
太阳辐射量	ERA5	CDIR	1 h	0.25°
总柱水量	ERA5	TCW	1 h	0.25°
相对方位角	元数据	RAA	—	—
卫星天顶角	元数据	VZA	—	—
太阳天顶角	元数据	SZA	—	—
大气压强	—	P	—	—
海拔高程	Copernicus	DEM	—	30 m
气溶胶光学厚度	MCD19A2	AOD	每天	1 000 m

其中,相对方位角、卫星天顶角、太阳天顶角由高分一号 PMS 影像中元数据中获得,相对方位角通过卫星方位角与太阳方位角计算得到。风速、地表温度、臭氧浓度、水汽含量、云覆盖、太阳辐射量、总柱水量来源于 ERA5 数据,DEM 使用的是哥白尼 DEM (Copernicus DEM),气溶胶光学厚度数据

使用 MODIS 卫星数据产品 MCD19A2,大气压强通过计算得出^[15]。

2 方法

目前利用机器学习进行大气校正研究缺乏统一的构建高质量训练样本集方法,本文因此提出了一种结合瑞利校正、水体提取、辅助数据匹配和大气校正的高质量数据集构建方法。该方法构建瑞利查找表,预先减弱了大气环境对模型的影响;基于最大类间方差法 OTSU 的水体分布提取,确定了影像中水体的范围,进而通过随机点提取瑞利校正后的影像值作为输入特征集的一部分,保证样本的代表性,并与 6S 大气校正反演的反射率数据集和辅助数据匹配,生成高质量水体训练样本集,为构建模型奠定了坚实的基础。

针对于模型构建中存在的问题,本文提出了一种结合特征选择和超参数优化方法进行建模,通过特征选择排序,筛选不重要的特征,减弱了噪声和冗余信息的影响,超参数优化获取了相对最优参数,极大地提升了模型的性能。具体流程如图 2 所示,阴影标注部分为本文主要工作内容。




图 2 技术流程

2.1 高质量水体训练样本集构建

在利用机器学习进行水体大气校正的研究中,训练样本集的代表性和精准度直接决定了模型的性能。基于此,提出了一种构建高质量水体训练样本集的方法。该方法主要通过对影像进行预处理、瑞利校正、提取水体、生成随机样本点、大气校正和辅助数据匹配等步骤获取训练样本集,力求最小化输入输出之间的不确定性,提高模型构建的精度。具体流程介绍如下。

1)影像预处理。对原始高分一号影像进行预处理,其中包括正射校正和辐射定标,并进一步转换为大气顶部(TOA)反射率。

2)瑞利校正。参考 Vanhellemont 等^[16]构建瑞利查找表的方法,增加了波长模拟的步长,减少了太阳天顶角和卫星天顶角的模拟,具体瑞利查找表参数情况如表 2 所示,波长参数括号中步长为 0.01。在瑞利校正中,使用线性插值计算单个像元的瑞利反射率。

表 2 瑞利查找表参数模拟范围

参数	模拟值
波长/ μm	[35]0.4,(0.45,0.52),(0.52,0.59),(0.63,0.69),(0.77,0.89),1
气溶胶模式	[2]default 6SV models:Continental,Urban
大气压强/mbar	[3]500,1 013.25,1 100
气溶胶光学厚度(550 nm)	[12]0.001,0.1,0.2,0.3,0.5,0.7,1.0,1.3,1.6,2.0,3.0,5.0
太阳天顶角/(°)	[9]0,4,8,16,24,32,40,48,56
卫星天顶角/(°)	[8]0,1.5,4,8,12,16,24,32
相对方位角/(°)	[12]0,10,20,40,60,80,100,120,140,160,170,180
风速/($\text{m} \cdot \text{s}^{-1}$)	[1]2

3)基于 OTSU 的水体分布提取。使用归一化水指数 NDWI(normalized difference water index)^[17]与城市阴影指数 USI(urban shadow index)^[18]指数结合 OTSU 自动确定阈值提取影像水体。NDWI 通过对近红外波段(NIR)和绿光波段(green)反射率的差异进行计算,能够有效地突出水体在影像中的特征。USI 通过对影像中低反射率区域的识别,来帮助分辨城市中的高大建筑物和地形造成的阴影。阴影区域与水体的光谱特性相似,并且可以很好地区分阴影和水体,在提取水体中具有良好的效果。通过求两种指数提取结果的交集,显著提高了分类的准确性。此外,通过对影像进行简单的平滑处理和碎屑删除,进一步减少了影像噪声的影响,确保了提取的水体范围的精确性。

4)**K-means 聚类生成样本点**。通过聚类分析来区分不同水质的水体,对高分一号 PMS 影像进行 K-means 聚类分析,生成随机点时保证在一定空间范围内每一类水体中都有采样点。通过聚类,计算每个类别的面积,根据水域面积生成随机点,且每张影像最多生成 2 000 个随机点,研究区共生成了

85 620 个样点作为训练样本。

5)辅助数据匹配。为了保证高质量训练样本集构建,需要对辅助数据进行空间插值和时间匹配。为了获取较高分辨率的辅助数据,采用反距离权重插值方法对辅助数据进行空间插值至 2 m。为了优化存储空间并提高处理效率,在生成训练样本时,选择实时调取辅助数据并进行空间插值。对风速、地表温度、臭氧浓度、水汽含量、云覆盖等数据进行逐小时匹配。气溶胶光学厚度进行逐日匹配,数字高程模型直接进行匹配,然后计算每个样本点的大气压强。

6)大气校正。使用 6S 模型对水体样本进行大气校正,考虑的参数包括气溶胶模型、波长、大气模型、太阳天顶角、卫星天顶角、相对方位角、水汽含量、气溶胶光学厚度、臭氧浓度、海拔高度、风速、地表温度^[19-20]。根据随机点提取影像值,通过 6S 模型模拟水体反射率。太阳天顶角、卫星天顶角、相对方位角和成像时间由 GF-1 PMS 影像元数据中获得。在本实验中,参考 FLASSH 方法的大气模式选择表使用了 5 种大气模式,包括 T(热带)、MLS(中

纬度夏季)、MLW(中纬度冬季)、SAS(亚北极夏季)、SAW(亚北极冬季),根据气溶胶光学厚度自动选择气溶胶类型。气溶胶光学厚度来自于 MODIS 产品,水汽含量、臭氧浓度、风速、地表温度来自于 ERA5 数据,海拔高度来自于哥白尼 DEM,其他参数保持默认。

2.2 结合特征选择与超参数优化的模型构建

本文使用 Python 中的 Scikit-learn 库实现 XGBoost 进行模型构建,梯度提升以迭代方式将几个“弱”学习器的预测组合成一个“强”学习器。与传统的神经网络模型相比,XGBoost 可以通过引入正则化模型来防止过拟合。该模型的优越性在水色遥感领域已有充分证明。

设置最大迭代次数为 2 000 次,早停止 20 次,随机种子 42,自定义损失函数 alpha 设置为 0.1。输入参数包括 $\rho_{\text{rc}}(\text{B})$ 、 $\rho_{\text{rc}}(\text{G})$ 、 $\rho_{\text{rc}}(\text{R})$ 、 $\rho_{\text{rc}}(\text{NIR})$ 、T2M、TCO3、TCWV、TCC、CDIR、RAA、VZA、SZA、P、DEM、AOD,输出参数包括 $\text{Rrs}(\text{B})$ 、 $\text{Rrs}(\text{G})$ 、 $\text{Rrs}(\text{R})$ 、 $\text{Rrs}(\text{NIR})$ 。

在模型训练中,辅助数据的精度不足可能会引入额外的误差,从而影响反演结果的可靠性。因此,特征选择成为了提高模型性能的关键步骤。参考 Guo 等^[21]提出的 PRE-PC-IRS 特征选择方法,通过预训练、Pearson 相关性分析、基于重要性分数的特征排序,找出干扰模型参数,综合结果进行特征筛选。

1)进行预训练(PRE),并将训练样本集中的 20%的数据用于验证,从经过瑞利校正后 4 个波段参数开始增加辅助数据训练,直到增加全部的辅助数据,根据验证精度判断参数的优劣。

2)皮尔逊相关性(PC)是指两个变量都是正态连续变量,且二者之间存在线性关系时,可以使用计算皮尔逊相关系数。皮尔逊相关性用于衡量两个变量之间的标准差。

3)特征重要性排名(IRS)。XGBoost 提供“weight”“gain”“cover”3 个特征重要性分数。本文使用“weight”作为特征的重要性分数。

超参数在很大程度上决定了模型的性能,最佳参数试错过程是一个非常复杂和耗时的任务。所以构建稳定的模型必须进行超参数优化,目前有 5 种比较先进的超参数优化方法^[22],包括随机搜索(RS)、高斯过程贝叶斯优化(BO-GP)、树形 Parzen 估计器贝叶斯优化(BO-TPE)、遗传算

法(GA)和超带方法(Hyperband)。本文选取 RS、GA 和 BO-TPE 3 种方法进行超参数优化。

根据水色相关研究^[23-24],为保证最优参数在搜索范围之内,指定超参数优化范围如表 3 所示。

表 3 超参数优化范围

超参数	参数描述	搜索范围
max_depth	最大深度	3,20
learning_rate	学习率	0.01,0.3
subsample	随机抽样抽取的比例	0.5,1
colsample_bytree	生成树随机抽样特征的比例	0.5,1
min_child_weight	子权重	1,20
reg_alpha	L1 正则项的参数 α	0,1
reg_lambda	L2 正则项的参数 λ	0,10

3 实验结果与分析

3.1 水体提取结果与水质分析

水体提取的精确性是构建高质量水体样本训练集的基础,是水体大气校正的准备工作。提取情况如图 3 所示,红色框标识了错误提取的水体范围,绿色框表示正确的水体范围,而黄色框则表示通过求交集而损失的水体范围。其中 NDWI 方法误检率为 5.71%,USI 方法误检率为 4.1%,本文方法误检率为 3.29%。通过两种方法求交集,在许多细节处去除噪声,有效提升了提取的精度。最终,通过人机交互的方式对少量边界进行调整,进一步提高了水体提取的准确性和可靠性。




图 3 水体提取方法对比

大范围的水质信息通常难以获取,为了解实验区水质情况和生成样本点,更好地分析本文方法对不同类型水域的适应性,对训练数据进行 K-means 聚类分析(图 4)。设定最大聚类数量为 30,根据贝叶斯信息准则,结果表明,最优聚类数为 28 类。其中太湖包含 19 类主要集中在 C14~C28 之间,兴凯湖为 24 类,主要集中在 C1~C8 之间,月亮泡水库为 18 类主要集中在 C9~C13 之间。由统计可以得出,在 3 个研究区中,C15~C17、C21 和 C24 都有样点,各研究区水质差别较大,太湖和月亮泡水库的水体样本点类别较为集中,兴凯湖的水体样本点较为分散,水质情况较为复杂。




图 4 K-means 聚类分析结果

3.2 特征选择结果

特征选择对模型训练的稳定性至关重要。筛选被筛选两次以上的特征,预训练结果如图 5 所示。从图 5 可见,随着特征数量的增加,RMSE、MAE 降低, R^2 增加,大多数辅助数据对输出数据正向影响,筛选负向影响特征 TCW。




图 5 特征影响预训练

特征相关性结果如图 6 所示,其中辅助参数采用表 1 中的英文缩写, $\rho_{rc}(-)$ 代表经过预处理和瑞利校正的影像值,分别对应高分一号 PMS 的 4 个波段。筛选低于 0.2 的特征,其中有一些变量相关性较弱,但可能和其他特征结合后具有良好的

相关性。例如相对方位角、太阳天顶角和卫星天顶角 3 个参数是共同影响水体反射率的参数,当影像数较少时,这 3 个参数的相关性较弱,随着影像数的增加,这 3 个参数的相关性逐渐增加。因此,筛选特征 FG10。




图 6 特征相关性

计算重要度如图 7 所示。由于辅助数据的特征重要度远远小于主参数,因此按照影响因素最大的辅助数据设置横坐标轴(标注发光效果为超过横坐标轴参数)。高分一号影像中 4 个波段经过瑞利校正后的 TOA 反射率特征重要度最高,其次是太阳辐射量、太阳高度角等参数。筛选特征重要性最低的 3 个特征,分别为 TCW、FG10 和 TCWV。




图 7 特征重要性

综上所述,筛选 TCW 和 FG10 两个辅助参数。

3.3 超参数优化与测试结果

选择合适的参数组合进行模型训练,能够有效提升反演精度。通过 3 种方法进行超参数优化,各个方法得到的最佳参数结果如表 4 所示。

使用得出的参数组合进行训练,其中 80% 的数据用于训练,20% 的数据用于验证,整体误差情况如表 5(4 波段平均)所示。


表 4 超参数优化结果

超参数	BO	GA	RS
max_depth	6.000 00	9.00	9.00
learning_rate	0.013 91	0.01	0.02
subsample	0.901 30	1.00	0.60
colsample_bytree	0.874 00	0.50	0.89
min_child_weight	14.390 00	1.00	16.00
reg_alpha	0.932 10	1.00	0.01
reg_lambda	4.325 00	0.00	4.30

表 5 超参数优化误差评价

评价指标	BO	GA	RS
MAE	0.000 6	0.000 4	0.000 2
R^2	0.997 7	0.998 2	0.999 6
RMSE	0.001 0	0.000 8	0.000 3

利用 RS 方法训练完成的模型对测试集内的 3 景影像进行模拟分析,并将其结果与 6S 模型的模拟结果进行对比,如图 8 所示。模拟结果显示,模型在太湖和兴凯湖的拟合效果较为显著,优于月亮泡水库。具体而言,太湖的模拟结果中存在少量离群值,经分析,这主要是由于影像中云像素的干扰,导致模拟的水体反射率偏高。相比之下,兴凯湖的模拟结果更为稳定,离群值较少。月亮泡水库附近的模拟效果相对较差,这可能与该地区存在多个独立水域且水质情况复杂有关。在样本数量有限的情况下,模型难以准确识别和区分不同水质的特性。尽管如此,总体来看,模型能够将通过先验获得的水体性质信息有效地泛化到不同的时相数据中,显示出良好的适应性和泛化能力。



注:测试集误差由浅蓝色到深紫色逐渐增加。

图 8 测试集结果

3.4 实测数据验证

对 FLAASH 方法^[25]、DSF 方法与本文方法使用实测数据进行对比验证。DSF 方法中分块设置为 16 km×16 km 的小块,FLAASH 方法能见度根据 MODIS 的 AOD 产品计算。

实测数据来自于陆地观测卫星共性应用支撑平台,实测光谱曲线如图 9 所示。从图 9 可见,整体光谱曲线呈先升高后降低的趋势,在 550~700 nm 处于

高峰,在 800 nm 左右存在第二个峰值。太湖和月亮泡水库的光谱曲线较为集中,太湖在蓝色波段处和红色波段处反射率低于其他两个研究区,月亮泡水库光谱曲线处于整体光谱曲线中间,兴凯湖的光谱曲线差异较大,有两组水体光谱曲线明显低于其他光谱曲线,而在 700 nm 处,兴凯湖的反射率值大于其他两个研究区。总之,3 个研究区水体光谱曲线差异较大。使用水体遥感反射率 R_{rs} (单位: sr^{-1}) 进行评价^[26]。




图9 实测光谱曲线

计算水体反射率等效波长,将 XGBoost 反演结果与实测数据进行对比验证,整体绝对百分比误差(MAPE)蓝色波段为 22.11%、绿色波段为 19.23%、红色波段为 24.46%、近红外波段为 32.45%。RMSE 蓝色波段为 0.005 2、绿色波段为 0.006 6、红色波段为 0.009 6、近红外波段为 0.006。由于近红外波段反射率本身比较低,总体百分比误差近红外波段最差。研究区反演误差整体箱线如图 10 所示,其中箱体的中心线是误差的中位数,箱体底线到最高线涵盖了全部数据,箱体中包含反演 15%误差到 85%误差之间的数据。可以看出,红色波段误差的值域比较大,反演较为不稳定,蓝色波段整体反演值较真实值低,绿色波段、红色波段和近红外波段反演值较真实值高。

研究区反演验证结果如图 11 所示。太湖区域的整体校正效果较为理想,涉及的验证点包括 C24 和 C26 类,在这些点上,模型表现出较高的准确性。

对于月亮泡水库,验证点为 C8 类,在蓝色波段出现了高估现象,而在绿色、红色和近红外波段的校正效果则表现优异。兴凯湖的验证点包括 C16 类,总体误差相较于太湖区域较大。分析认为,这一差异可能源于兴凯湖区域的空间变异性较大,导致水体反射率快速变化,从而影响了模型的校正精度。




图10 反演误差




图11 实测点验证结果

3 种大气校正方法验证结果如表 6 所示。使用 RMSE 指标进行评价,波段平均为所有波段误差指标的平均值,作为总体误差评价,最低误差已用灰底色标出。DSF 方法在兴凯湖和月亮泡水库反演为负值被屏蔽,因此不做参考和对比。在兴凯湖,本文方法和 FLAASH 方法精度接近, RMSE 低于 FLAASH 方法 0.002;在太湖 DSF 方法最好, RMSE 优于本文方法 0.001;在月亮泡水库,本文方法明显优于 FLAASH 方法, RMSE 高于 FLAASH 方法 0.002。

表 6 大气校正方法对比结果(RMSE 值)

方法	波段\指标	兴凯湖	太湖	月亮泡水库
本文方法	Band1	0.005	0.004	0.010
	Band2	0.008	0.006	0.002
	Band3	0.014	0.006	0.004
	Band4	0.009	0.004	0.001
	波段平均	0.009	0.005	0.004
FLAASH	Band1	0.006	0.009	0.007
	Band2	0.007	0.010	0.003
	Band3	0.008	0.008	0.007
	Band4	0.008	0.011	0.008
	波段平均	0.007	0.009	0.006
DSF	Band1	—	0.004	—
	Band2	—	0.005	—
	Band3	—	0.002	—
	Band4	—	0.005	—
	波段平均	—	0.004	—

总体看来,本文方法在兴凯湖与 FLAASH 方法精度相当,在太湖和月亮泡水库明显优于 FLAASH

方法。DSF 方法在太湖略优于本文方法,尤其是在红色波段,但 DSF 方法在兴凯湖和月亮泡水库反演为负值,不稳定性更强。

4 结束语

本文在兴凯湖、太湖和月亮泡水库及其周边附属水域展开实验,提出了一种基于机器学习的水体大气校正方法。通过结合高质量水体训练样本集和特征选择与超参数优化的模型构建,显著提高了大气校正模型的精度和泛化能力,各波段反演不确定性总体均在 35% 以内,可见光波段不确定性在 25% 以内。

水体训练样本集的构建采用了本文提出的水体提取方法,为机器学习模型的训练提供了高质量的数据基础。本文将米级高分辨率影像应用于内陆水体监测,证明了其在水色遥感中的巨大潜力。

与大多数研究仅针对单一小区域不同,本文涵盖了 3 种不同类型水域(湖泊、水库和附属水域),并发现机器学习能够很好地对每一种水体进行模拟,通过对比实验,本文方法在精度上优于 FLAASH 方法,在稳定性上优于 DSF 方法。

未来的研究将对比不同的模拟方法,选择适合特定区域和环境条件的机器学习和深度学习模型。同时,计划增加辐射传输模型中气溶胶类型和大气模式的设定,并对数据集进行二次清洗和筛选,以提高数据质量。随着卫星遥感定量辐射研究的成熟和原位数据精度验证的完善,把相关成果有效集成到大气校正模型中,进一步提升模型的应用潜力和准确性。

致谢:感谢国家民用空间基础设施陆地观测卫星共性应用支撑平台(<http://caplos.aircas.ac.cn/>)提供的水体反射率实测数据。

参考文献

- [1] FROUIN R J, FRANZ B A, IBRAHIM A, et al. Atmospheric correction of satellite ocean-color imagery during the PACE era[J]. *Frontiers in earth science*, 2019, 7: 145.
- [2] MOREL A. In-water and remote measurements of ocean color[J]. *Boundary-layer meteorology*, 1980, 18(2): 177-201.
- [3] GORDON H R, WANG M. Retrieval of water-leaving radiance and aerosol optical thickness over the oceans with SeaWiFS: a preliminary algorithm[J]. *Applied optics*, 1994, 33(3): 443-452.
- [4] MOREL A, PRIEUR L. Analysis of variations in ocean color 1[J]. *Limnology and oceanography*, 1977, 22(4): 709-722.
- [5] RUDDICK K G, OVIDIO F, RIJKEBOER M. Atmospheric correction of SeaWiFS imagery for turbid coastal and inland waters[J]. *Applied optics*, 2000, 39(6): 897-912.
- [6] HU C, CARDER K L, MULLER-KARGER F E. Atmospheric correction of SeaWiFS imagery over turbid coastal waters: a practical method[J]. *Remote sensing of environment*, 2000, 74(2): 195-206.
- [7] DE KEUKELAERE L, STERCKX S, ADRIAENSEN S, et al. Atmospheric correction of Landsat-8/OLI and Sentinel-2/MSI data using iCOR algorithm: validation for coastal and inland waters[J]. *European journal of remote sensing*, 2018, 51

- (1):525-542.
- [8] HARMEL T, CHAMI M, TORMOS T, et al. Sun glint correction of the multi-spectral instrument (MSI)-SENTINEL-2 imagery over inland and sea waters from SWIR bands[J]. *Remote sensing of environment*, 2018, 204:308-321.
- [9] SAULQUIN B, FABLET R, BOURG L, et al. MEETC2: ocean color atmospheric corrections in coastal complex waters using a Bayesian latent class model and potential for the incoming sentinel 3-OLCI mission[J]. *Remote sensing of environment*, 2016, 172:39-49.
- [10] JAMET C, THIRIA S, MOULIN C, et al. Use of a neurovariational inversion for retrieving oceanic and atmospheric constituents from ocean color imagery: a feasibility study[J]. *Journal of atmospheric and oceanic technology*, 2005, 22(4): 460-475.
- [11] FAN Y, LI W, CHEN N, et al. OC-SMART: a machine learning based data analysis platform for satellite ocean color sensors[J]. *Remote sensing of environment*, 2021, 253:112236.
- [12] BROCKMANN C, DOERFFER R, PETERS M, et al. Evolution of the C2RCC neural network for Sentinel 2 and 3 for the retrieval of ocean colour products in normal and extreme optically complex waters[C]//*Proceedings of Living Planet Symposium*. [S. l.]:[s. n.], 2016, 740:54.
- [13] MEN J, TIAN L, ZHAO D, et al. Development of a deep learning-based atmospheric correction algorithm for oligotrophic oceans[J]. *IEEE transactions on geoscience and remote sensing*, 2022, 60:1-19.
- [14] SCHLÄPFER D, HUENI A, RICHTER R. Cast shadow detection to quantify the aerosol optical thickness for atmospheric correction of high spatial resolution optical imagery[J]. *Remote sensing*, 2018, 10(2):200.
- [15] MINZNER R A. The 1976 standard atmosphere and its relationship to earlier standards[J]. *Reviews of geophysics*, 1977, 15(3):375-384.
- [16] VANHELLEMONT Q, RUDDICK K. Atmospheric correction of metre-scale optical satellite data for inland and coastal water applications[J]. *Remote sensing of environment*, 2018, 216:586-597.
- [17] GAO B C. NDWI-a normalized difference water index for remote sensing of vegetation liquid water from space[J]. *Remote sensing of environment*, 1996, 58(3):257-266.
- [18] WU W, LI Q, ZHANG Y, et al. Two-step urban water index (TSUWI): a new technique for high-resolution mapping of urban surface water[J]. *Remote sensing*, 2018, 10(11):1704.
- [19] WILSON R T. Py6S: a Python interface to the 6S radiative transfer model[J]. *Computers and geosciences*, 2013, 51: 166-171.
- [20] 王雪丹, 王玉峰, 刘凯, 等. 结合 NCEP 再分析资料优化的 6S 模式大气校正方法[J]. *光学学报*, 2024, 44(6):87-99.
- [21] GUO J, YANG L, BIE R, et al. An XGBoost-based physical fitness evaluation model using advanced feature selection and Bayesian hyper-parameter optimization for wearable running monitoring[J]. *Computer networks*, 2019, 151:166-180.
- [22] KAVZOGLU T, TEKE A. Advanced hyperparameter optimization for improved spatial prediction of shallow landslides using extreme gradient boosting (XGBoost)[J]. *Bulletin of engineering geology and the environment*, 2022, 81(5):201.
- [23] SONG Z, HE X, BAI Y, et al. Atmospheric correction of absorbing aerosols for satellite ocean color remote sensing over coastal waters[J]. *Remote sensing of environment*, 2023, 290:113552.
- [24] WANG Y, LIU H, ZHANG Z, et al. Ocean colour atmospheric correction for optically complex waters under high solar zenith angles: facilitating frequent diurnal monitoring and management[J]. *Remote sensing*, 2023, 16(1):183.
- [25] FELDE G W, ANDERSON G P, COOLEY T W, et al. Analysis of hyperion data with the FLAASH atmospheric correction algorithm[C]//*Proceedings of 2003 IEEE International Geoscience and Remote Sensing Symposium*. [S. l.]: IEEE, 2003:90-92.
- [26] 唐军武, 田国良, 汪小勇, 等. 水体光谱测量与分析 I: 水面以上测量法[J]. *遥感学报*, 2004, 8(1):37-44.